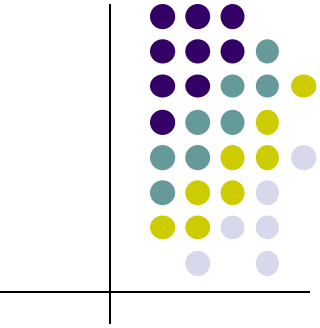
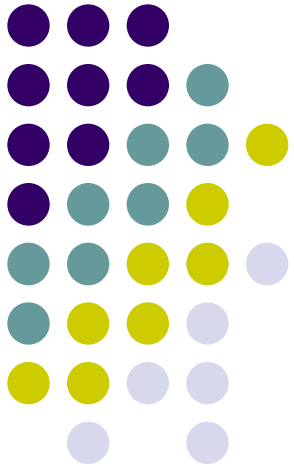
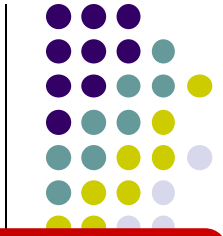


机器学习概述

哈尔滨工业大学计算学部 刘远超



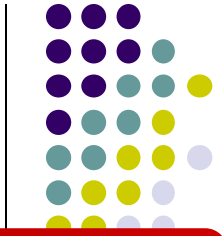
机器学习概述



本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

机器学习概述

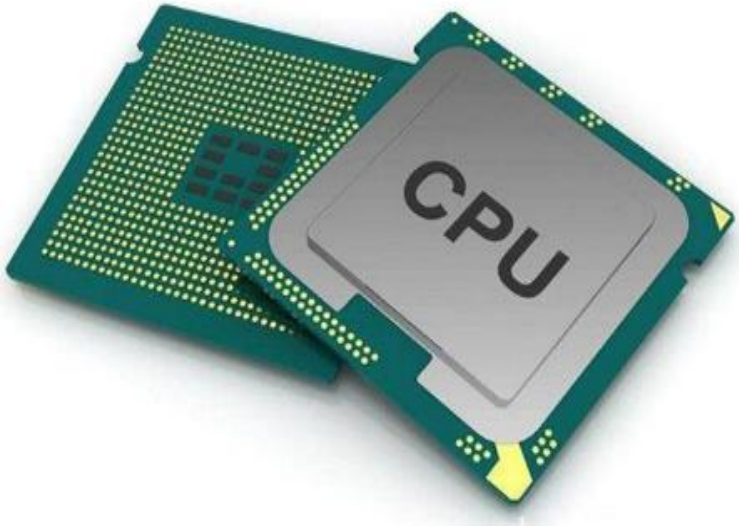


本章内容简介

- **深度学习的硬件计算环境**
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

深度学习的硬件计算环境

深度学习中的重要芯片：GPU





GPU（Graphics Processing Unit）即图形处理单元，又称显示核心、视觉处理器、显示芯片，是显卡上的一块芯片，与显卡集成在一起。

深度学习的硬件计算环境

GPU和CPU进行对比，来进一步理解什么是GPU

1）**从分工和擅长来看。**GPU则为专用处理器，其适合数据之间关联性不高、可分块处理、高度线程化的大规模并行计算。

2）**从CPU和GPU的协作关系来看。**CPU是主芯片而GPU是从芯片，GPU是在替CPU分担部分工作，而不是尝试完全取代CPU。

3）**从内部构成上看。**与CPU相比，GPU有数量众多的逻辑运算单元（ALU）和超长的流水线，可以并行处理大量但较为简单的任务，特别适合处理类型统一的数据。

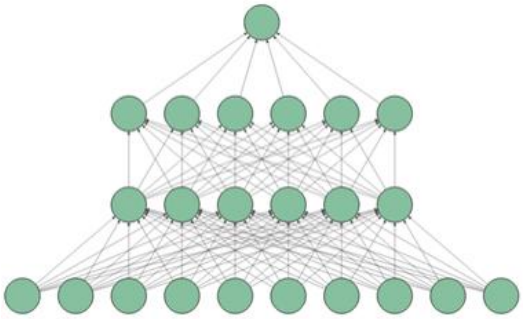
4）**从所在位置上看。**GPU位于独立显卡上，与显卡集成在一起。而CPU则通常是单独的芯片，插在PC机的主板插槽上。

5）**从制造厂商来看。**比较知名的 GPU 制造商有AMD、NVIDIA等公司，其对应的产品分别为人们通常所说的A卡和N卡。

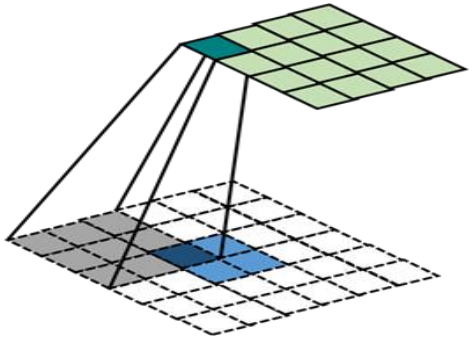
深度学习的硬件计算环境

深度学习为什么需要GPU芯片

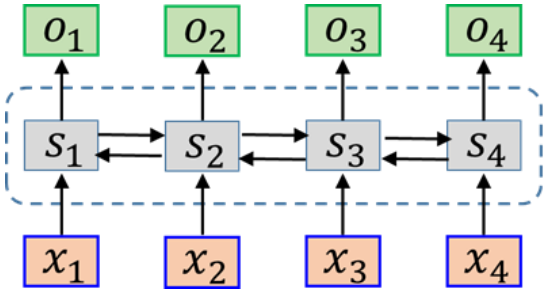
神经网络中有很多计算实际上是可以并行进行的。理论上，对于不依赖于其他计算结果的计算，就可以采用并行的方式。



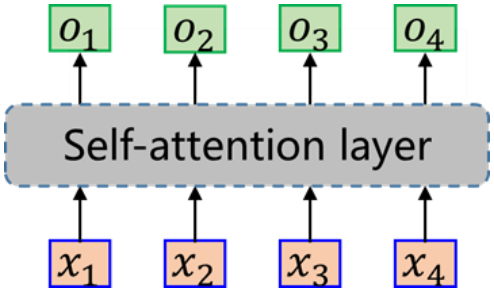
(a) MLP



(b) CNN



(c) RNN

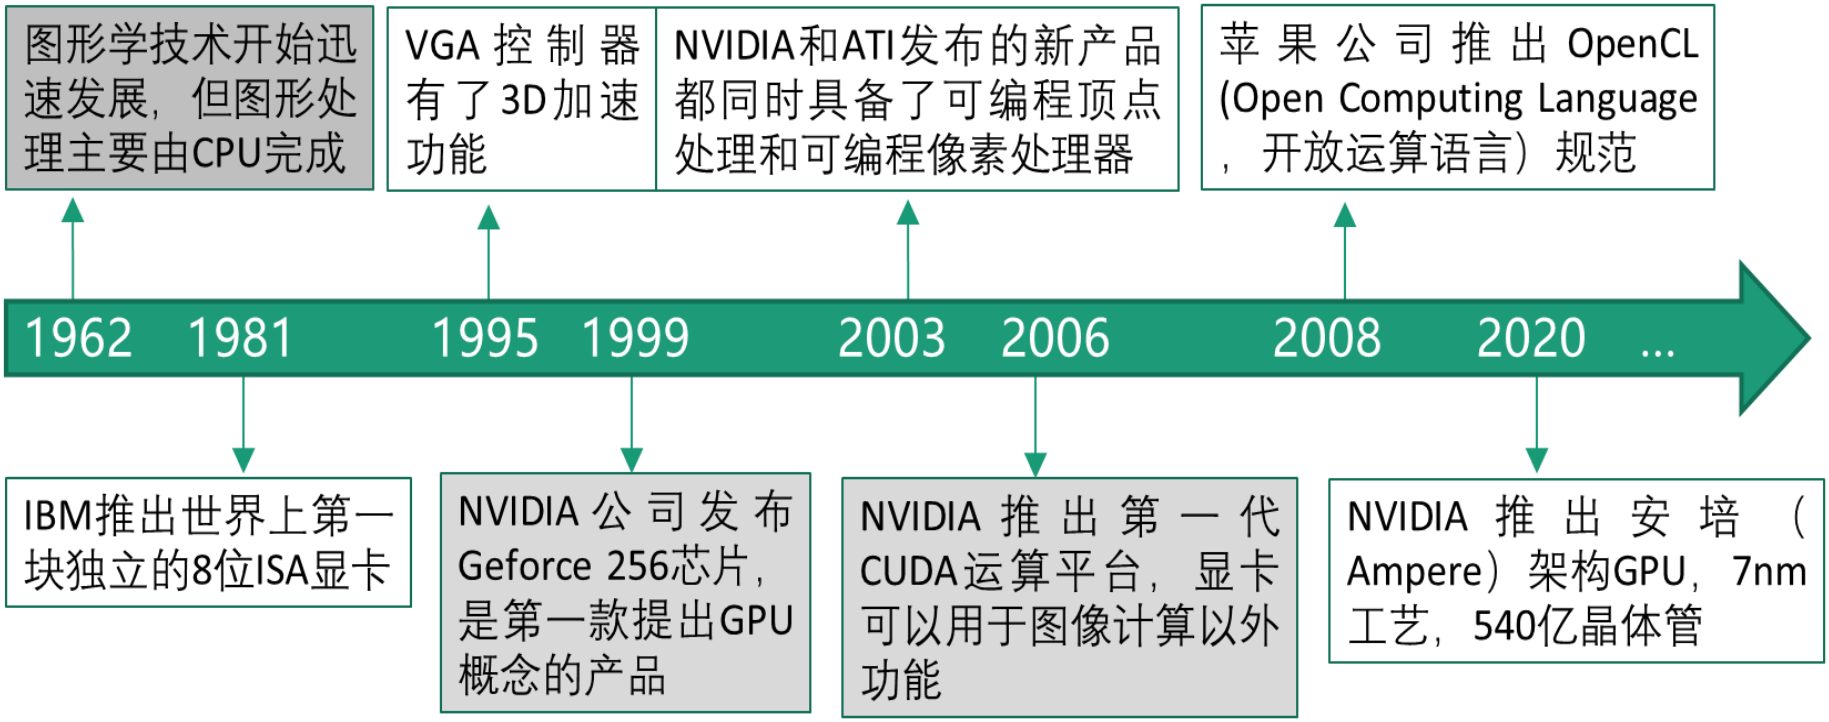


(d) Transformer

几种典型的神经网络

深度学习的硬件计算环境

GPU芯片发展历程



深度学习的硬件计算环境

深度学习GPU环境的搭建

如果使用GPU，以**NVIDIA**产品为例，则通常需要进行如下预先步骤：

1) 根据需要，购置相应的**GPU显卡**（例如NVIDIA 4090），并安装相应的驱动程序。

2) **安装CUDA**。CUDA是NVIDIA公司推出的一种通用并行计算平台和编程模型，从而使其可以高效地解决大规模计算问题。

3) **安装cuDNN**（The NVIDIA CUDA Deep Neural Network library）。cuDNN是专用于深度神经网络的GPU加速库，可加速很多流行的深度学习框架，如Caffe2、Keras、PyTorch 和 TensorFlow等。cuDNN 可大幅优化标准神经网络标准功能（例如用于前向传播和反向传播的卷积层、池化层、归一化层和激活层）的实施，使研究人员和开发者专注于训练神经网络及开发软件应用，不必花时间进行低层级的 GPU 性能调整。

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- **深度学习的软件计算环境**
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

深度学习的软件计算环境

基于Python的重要软件计算平台：Anaconda

Anaconda提供和集成了若干科学计算的常用编程语言和工具，如python、安装包的管理、科学计算常用函数库和典型的机器学习算法库等。安装完毕Anaconda，则可以一次性的设置好上述环境。其包含如下常用模块：

- **Conda**：具有安装、更新、删除、解决包依赖关系的包管理功能。
- **Numpy**（Numerical Python）：重点在于数组和矩阵运算；
- **Scipy**：包括用于最优化、线性代数、积分、插值、拟合、特殊函数等常用科学计算软件包。其依赖于Numpy；
- **Matplotlib**：是 Python 中类似 MATLAB 的重要的绘图工具和数据可视化工具（用图表的形式对数据进行展示）；
- **Scikit-learn**：是一款重要的开源机器学习工具包，涵盖分类，回归和聚类等的常用算法。例如包括**支持向量机、 逻辑回归、朴素贝叶斯、随机森林，k-means等算法**等；
- ……

深度学习的软件计算环境

深度学习框架及其安装

- **什么是深度学习框架。** 深度学习框架是一种便于深度学习和研究人员而开发的开源平台和工具，其中包含了深度学习模型常用的开发包、预训练模型等资源。

- **为什么需要深度学习的框架。**
  - 深度学习框架为模型的实现提供了清晰而简洁的方法，使复杂神秘的深度学习模型开发被大大简化，是AI开发的利器。
  - 借助深度学习框架，深度学习和研究人员可以利用预先构建和优化好的组件集合定义模型，避免了写大量重复代码的工作（即**避免“重复造轮子”**）。

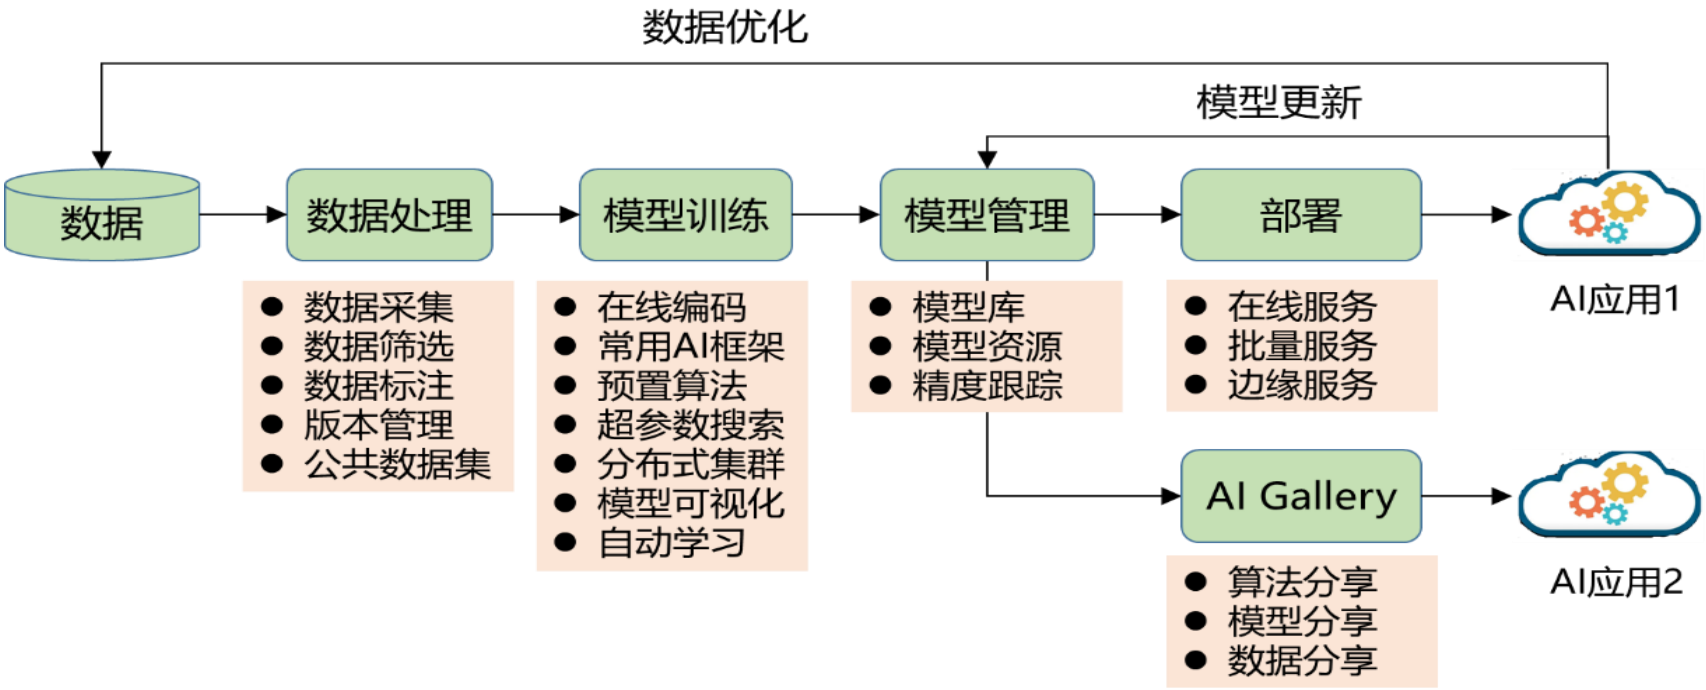
深度学习的软件计算环境

深度学习框架及其安装

- **典型的深度学习框架**
  - TensorFlow
  - PyTorch
  - MindSpore等。
- **使用虚拟环境进行深度学习框架安装的必要性**
  - 其优点在于，不同虚拟环境下的安装结果互不影响，可以很容易的切换不同环境。
  - 反之，如果不创建虚拟环境，而直接在同一个物理环境下安装，则只能使用同一种配置或者版本，无法自由切换（只能采取卸载旧版本、重新安装新版本的办法更换计算环境）。

深度学习的软件计算环境

深度学习的云服务计算环境



华为昇腾人工智能平台ModelArts

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- **数据集**
- 机器学习方法的分类
- 半监督学习
- 主动学习

数据集

数据集的数学表示：以鸢尾花(Iris)数据集为例



山鸢尾(*Iris setosa*)



变色鸢尾(*Iris versicolor*)



维吉尼亚鸢尾(*iris virginica*)

如何进行分类？关键在于特征

数据集

鸢尾花数据集的数据样例

Samples(instances，observations)

	花萼长度	花萼宽度	花瓣长度	花瓣宽度	分类标签
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
…	…	…	…	…	…
50	6.4	3.5	4.5	1.2	Versicolor
…	…	…	…	…	…
150	5.9	3.0	5.0	1.8	Virginia

Features(attributes，measurements，dimensions)

Class labels（targets）

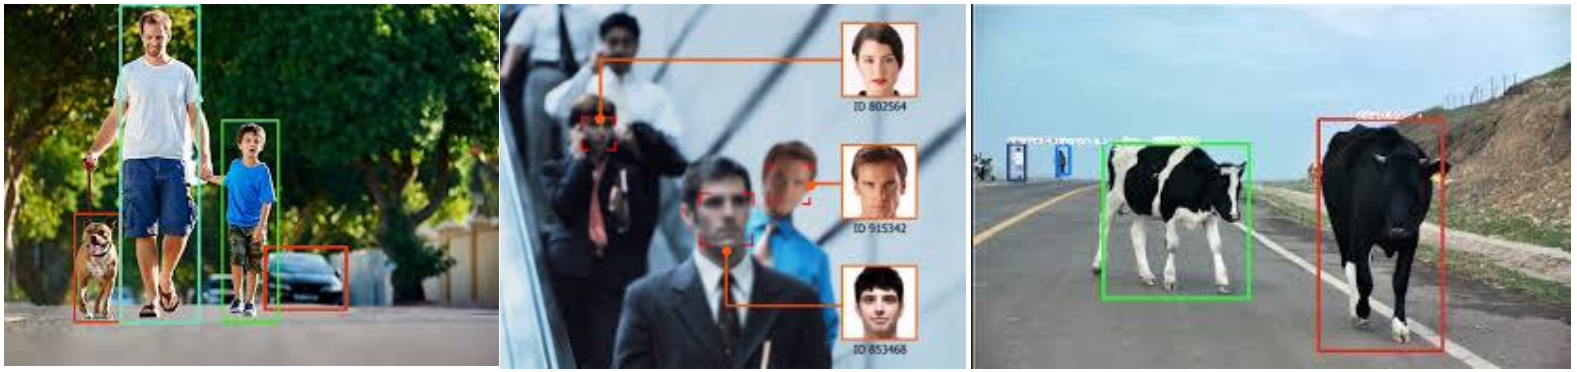


数据集

数据集的数学表示

- 数据集由若干样本（或称实例）组成，其中每个样本 i 通常由特征（Features）x_i（或称属性）和类别标签y_i（或称目标值）组成。因此数据集在数学上通常表示为$\{(x_1, y_1), \ldots, (x_i, y_i), \ldots, (x_m, y_m)\}$的形式。
- 由于样本一般有多个特征，例如鸢尾花数据集有4个特征，因而x_i通常进一步表示为向量，即$x_i = \{x_i^1, x_i^2, \ldots, x_i^n\}^T$。而$y_i$则为样本 i 的类别标签，或称目标值（target value）。
- 数据集中样本的类别标签一般被称之为**真实值**（Ground Truth Value），而通过机器学习算法预测的标签则称之为**预测值**（Prediction Value）。

类别标签的ground truth与gold standard



- **ground truth：** 可翻译为地面实况等。在机器学习领域一般用于表示真实值、**标准答案**等，表示通过直接观察收集到的真实结果。

- **gold standard：** 可翻译为金标准。医学上一般指诊断疾病公认的最可靠的方法。

- 在机器学习领域，更倾向于使用“**ground truth**”。而如果用**gold standard**这个词，则表示其可以很好地代表**ground truth**。

数据集

人工标注的一致性分析

- **皮尔森相关系数 (Pearson correlation coefficient)**
  - **问题举例：** 如何评价两个评委的一致性？

    rater1 = [0.5, 1.6, 2.5, 2.5, 2.4]

    rater2 = [1.5, 2.6, 3.5, 3.5, 3.4]

  - 皮尔森相关系数(Pearson coefficient)的应用背景：
    - 用来衡量两个用户之间兴趣的一致性
    - 用来衡量预测值与真实值之间的相关性
    - 既适用于离散的、也适用于连续变量的相关分析
  - X和Y之间的皮尔森相关系数计算公式：

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} = \frac{E[(X-\mu_X)(Y-\mu_Y)]}{\sigma_X \sigma_Y}$$

    其中，$cov(X,Y)$表示X 和Y 之间的协方差（Covariance），σ_X是X的均方差，μ_X是X的均值，E表示数学期望

  - 取值区间为[-1，1]。 **-1**: 完全的负相关，**+1**: 表示完全的正相关，**0**:没有线性相关

数据集

人工标注的一致性分析

科恩·卡帕相关系数（Cohen's kappa correlation coefficient）

- Cohen's kappa相关系数也可用于衡量两个评价者之间的一致性。其特点在于：
  - 与pearson相关系数的区别：Cohen's kappa 相关系数通常用于离散的分类的一致性评价。
  - 其通常被认为比两人之间的简单一致百分比更强壮，因为Cohen's kappa考虑到了二人之间的随机一致的可能性。

- 如果评价者多于2人时，可以考虑使用Fleiss' kappa.

数据集

人工标注的一致性分析

Cohen's kappa计算方法

●假设有50个人申请奖学金。有两个评委A 和 B。每个评委对每个申请者说"Yes" or "No"。假设AB一致性情况如下矩阵所示。

		B	
		Yes	No
A	Yes	a	b
	No	c	d

		B	
		Yes	No
A	Yes	20	5
	No	10	15

●先计算AB一致性比例为 $p_o = \frac{(a+d)}{(a+b+c+d)} = \frac{20+15}{20+5+10+15} = 0.7$

●再计算AB之间的随机一致性概率 p_e (the probability of random agreement)，注意到:

1. A对25个申请者说yes，因此 比例为25/50=50%
2. B对30个申请者说yes，因此比例为30/50=60%
3. 因此，AB两人随机都说YES的概率 $p_{yes} = \frac{(a+b)}{(a+b+c+d)} \cdot \frac{(a+c)}{(a+b+c+d)} = 0.5 * 0.6 = 0.3$
4. 同样， $p_{no} = \frac{(c+d)}{(a+b+c+d)} \cdot \frac{(b+d)}{(a+b+c+d)} = 0.5 * 0.4 = 0.2$
5. AB的整体随机一致性(Overall random agreement)概率 $p_e = p_{yes} + p_{no}$=0.3+0.2=0.5

● 最后应用Cohen's kappa公式，得到 $k = \frac{p_o - p_e}{1 - p_e} = \frac{0.7-0.5}{1-0.5} = 0.4$

数据集

人工标注的一致性分析

- kappa score是一个介于-1到+1之间的数.

Interpretation of Kappa

	Poor	Slight	Fair	Moderate	Substantial	Almost perfect
Kappa	0.0	.20	.40	.60	.80	1.0

Kappa	Agreement
< 0	Less than chance agreement
0.01–0.20	Slight agreement
0.21– 0.40	Fair agreement
0.41–0.60	Moderate agreement
0.61–0.80	Substantial agreement
0.81–0.99	Almost perfect agreement

Fleiss' kappa

n_{ij}	1	2	3	4	5
1	0	0	0	0	14
2	0	2	6	4	2
3	0	0	3	5	6
4	0	3	9	2	0
5	2	2	8	1	1
6	7	7	0	0	0
7	3	2	6	3	0
8	2	5	3	2	2
9	6	5	2	1	0
10	0	2	2	3	7
Total	20	28	39	21	32
p_j	**0.143**	**0.200**	**0.279**	**0.150**	**0.229**

以上是14个评价者对10个item进行5级评价的结果（N = 10， n = 14， k = 5）。

则计算Fleiss Kappa相关系数的过程为：

step 1. 对每一列计算$\boldsymbol{p_j}$，即同列数据相加除以任务总数 (14*10=140)。 $\boldsymbol{p_j}$可以理解为每个分类的随机一致概率。

以第一列为例，则 $p_1 = \frac{0+0+0+0+2+7+3+2+6+0}{14*10} = 0.143$

Fleiss' kappa(续)

n_{ij}	1	2	3	4	5	P_i
1	0	0	0	0	14	1.000
2	0	2	6	4	2	0.253
3	0	0	3	5	6	0.308
4	0	3	9	2	0	0.440
5	2	2	8	1	1	0.330
6	7	7	0	0	0	0.462
7	3	2	6	3	0	0.242
8	2	5	3	2	2	0.176
9	6	5	2	1	0	0.286
10	0	2	2	3	7	0.286
Total	20	28	39	21	32	
p_j	0.143	0.200	0.279	0.150	0.229	

Step 2. 计算$\boldsymbol{P_i} = \frac{1}{n(n-1)}\left(\sum_{j=1}^{k} n_{ij}^2 - n\right)$，即对每一个标注任务进行实际一致性的计算，

以第2个item为例：$P_2 = \frac{1}{14(14-1)}(0^2 + 2^2 + 6^2 + 4^2 + 2^2 - 14) = 0.253$

Fleiss' kappa (续)

n_{ij}	1	2	3	4	5	P_i
1	0	0	0	0	14	1.000
2	0	2	6	4	2	0.253
3	0	0	3	5	6	0.308
4	0	3	9	2	0	0.440
5	2	2	8	1	1	0.330
6	7	7	0	0	0	0.462
7	3	2	6	3	0	0.242
8	2	5	3	2	2	0.176
9	6	5	2	1	0	0.286
10	0	2	2	3	7	0.286
Total	20	28	39	21	32	
$\boldsymbol{p_j}$	0.143	0.200	0.279	0.150	0.229	

Step 3. 计算p_o和p_e:

$$p_o = \frac{1}{N}\sum_{i=1}^{N} P_i = \frac{1}{10}(1.000 + 0.253 + \cdots + 0.286 + 0.286) = \frac{1}{10} \cdot 3.780 = 0.378$$

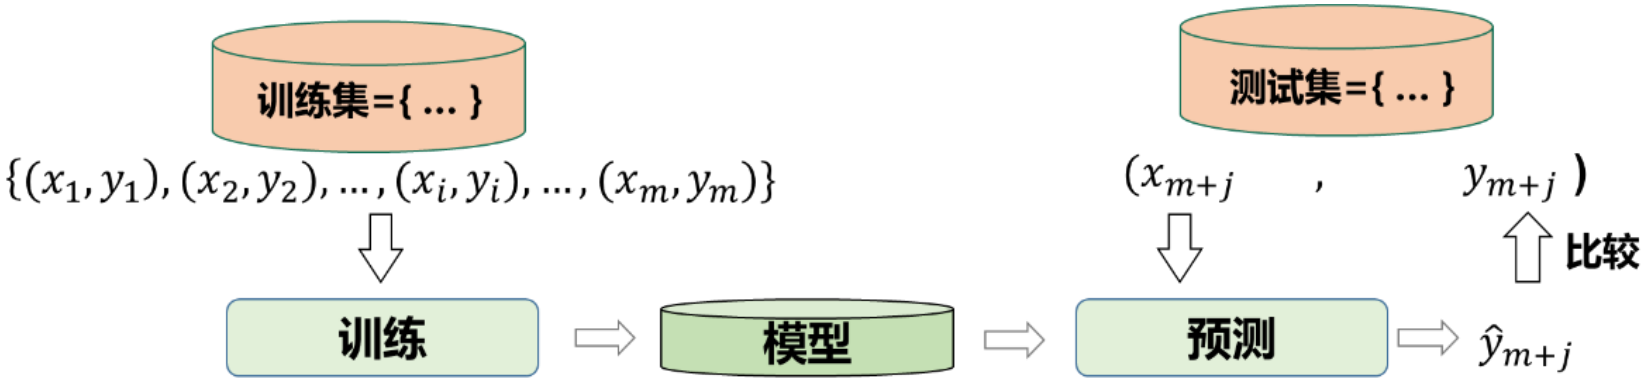
$$p_e = \sum_{j=1}^{k} p_j^2 = 0.143^2 + 0.200^2 + 0.279^2 + 0.150^2 + 0.229^2 = 0.213$$

Step 4. 最后计算Fleiss Kappa系数

$$\boldsymbol{k = \frac{p_o - p_e}{1 - p_e}} = \frac{0.378 - 0.213}{1 - 0.213} = 0.210$$

数据集

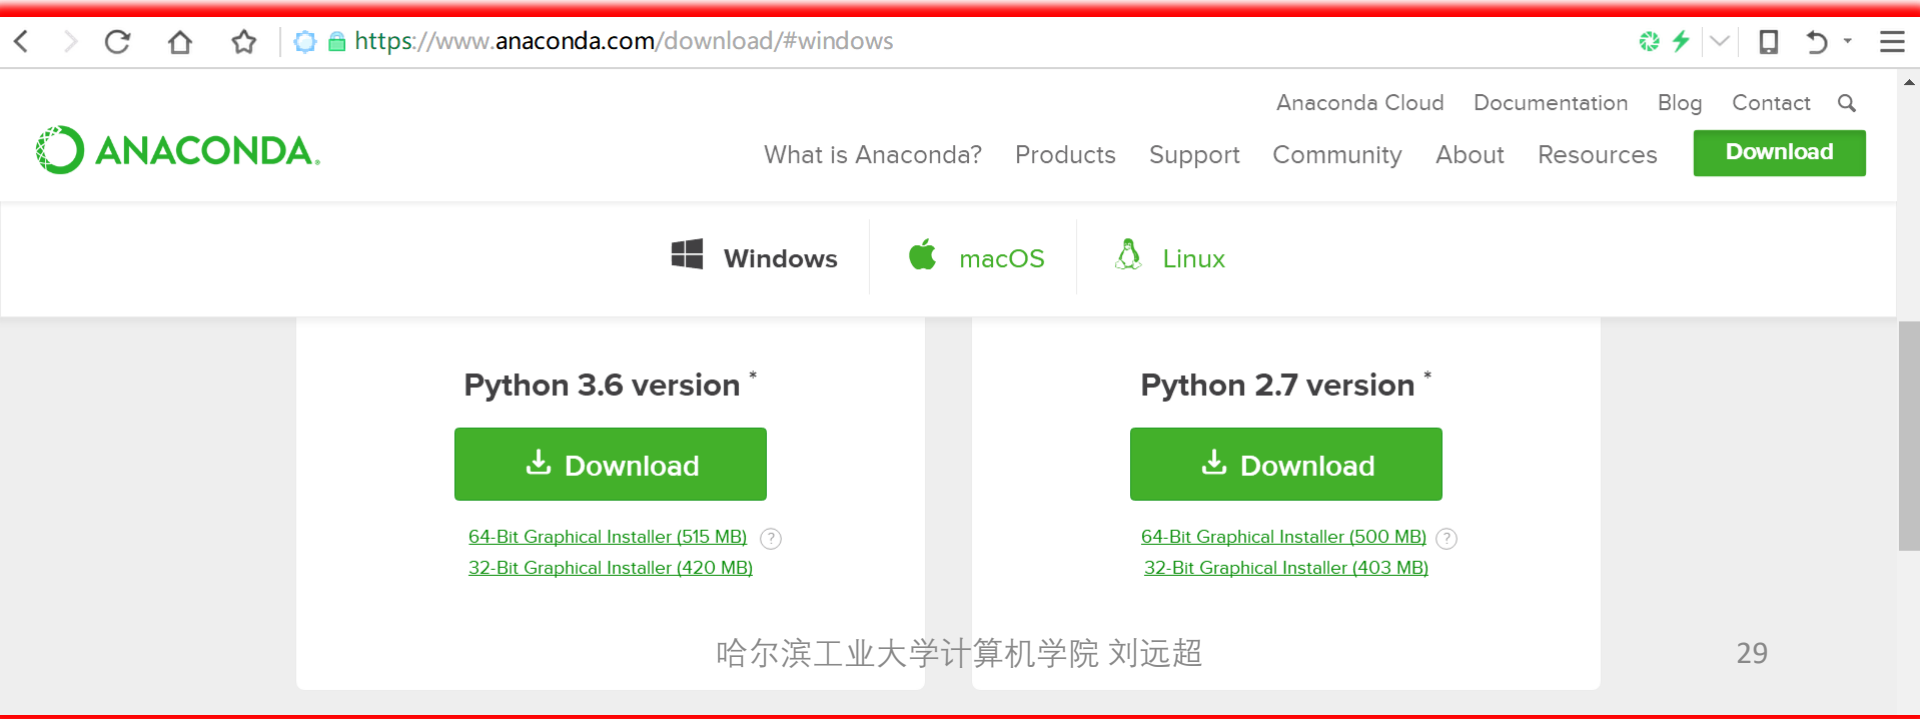
数据集的拆分问题



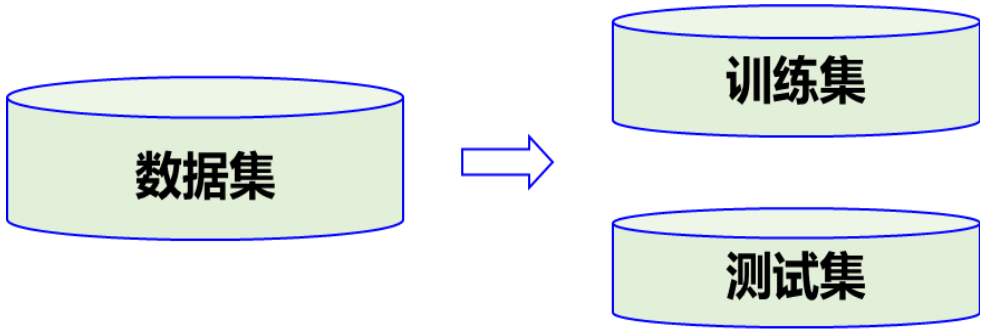
- 有监督学习中数据通常分成训练集、测试集两部分。
  - **训练集(training set)**用来训练模型，即被用来学习得到系统的参数取值。
  - **测试集(testing set)**用于最终报告模型的评价结果，因此在训练阶段测试集中的样本应该是unseen的。
- *有时对训练集做进一步划分为训练集和验证集(validation set)。验证集与测试集类似，也是用于评估模型的性能。区别是验证集主要用于模型选择和调整超参数，因而一般不用于报告最终结果。*

训练集、测试集的拆分

- 可以使用sklearn (即scikit-learn) 进行训练集、测试集的拆分。
- 如何安装sklearn：anaconda是一个开源的Python发行版本，其包含了很多科学包及其依赖项，也包含sklearn。
  - 网址：https://www.anaconda.com/download/#windows

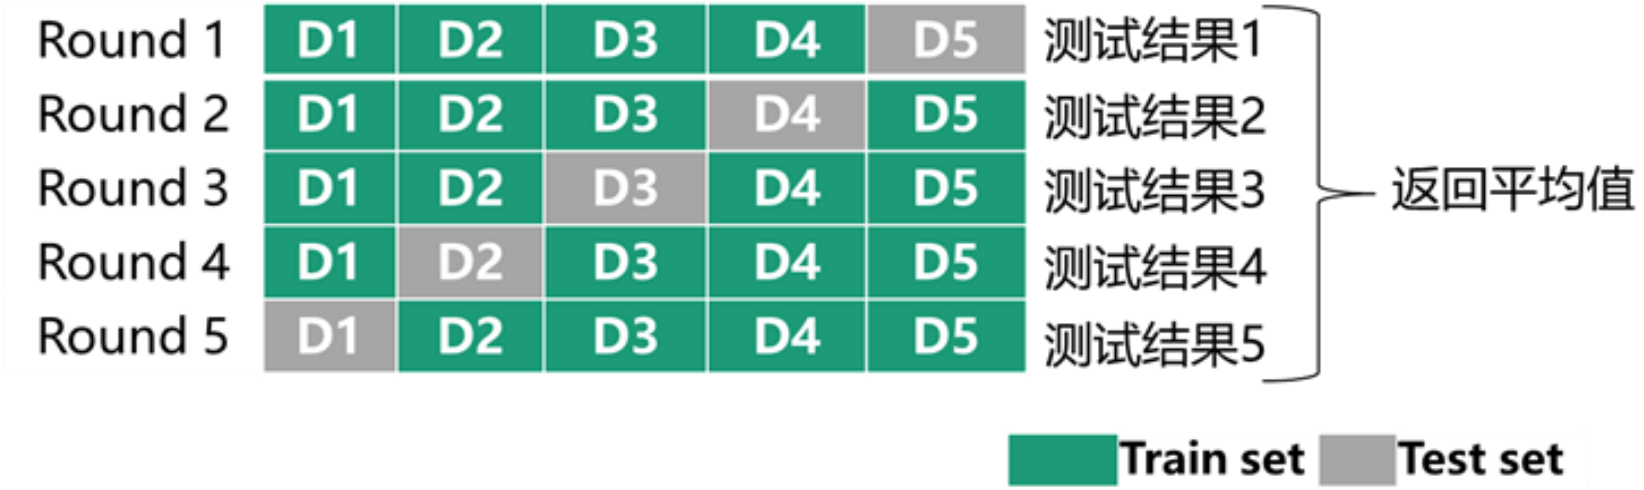


训练集测试集拆分—留出法



- 留出法（**Hold-Out Method**）数据拆分步骤：
  1. 将数据随机分为两组，一组做为训练集，一组做为测试集
  2. 利用训练集训练分类器，然后利用测试集评估模型，记录最后的分类准确率为此分类器的性能指标
- **留出法的优点是**处理简单。而**不足之处是**在测试集上的预测性能的高低与数据集拆分情况有很大的关系，所以基于这种数据集拆分基础上的性能评价结果不够稳定。

K折交叉验证



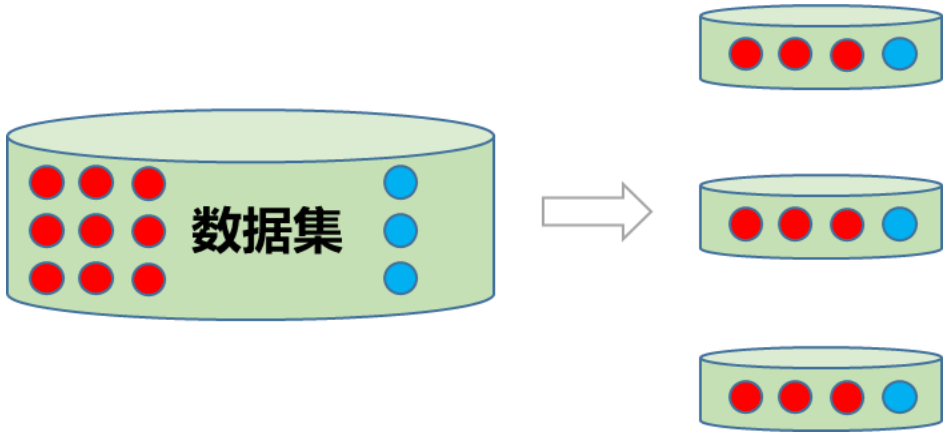
●过程：

1. 数据集被分成K份（K通常取5或者10）
2. 不重复地每次取其中一份做测试集，用其他K-1份做训练集训练，这样会得到K个评价模型
3. 将上述步骤2中的K次评价的性能均值作为最后评价结果

● K折交叉验证的上述做法有助于提高评估结果的稳定性

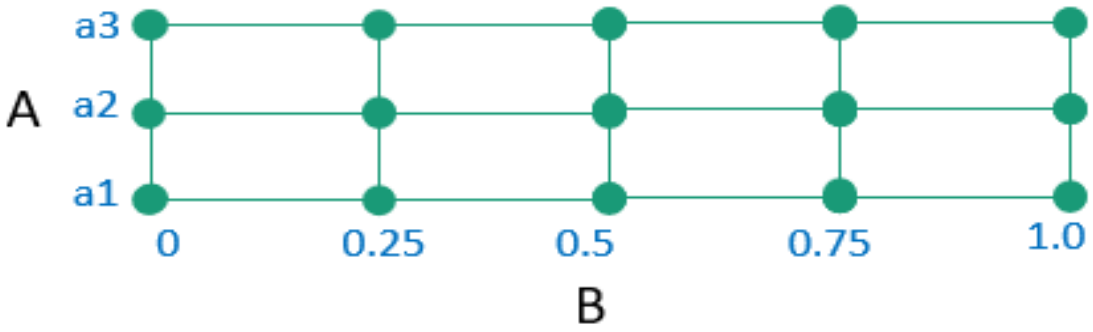
分层抽样策略（Stratified k-fold）

- 将数据集划分成k份，特点在于，划分的k份中，每一份内各个类别数据的比例和原始数据集中各个类别的比例相同。

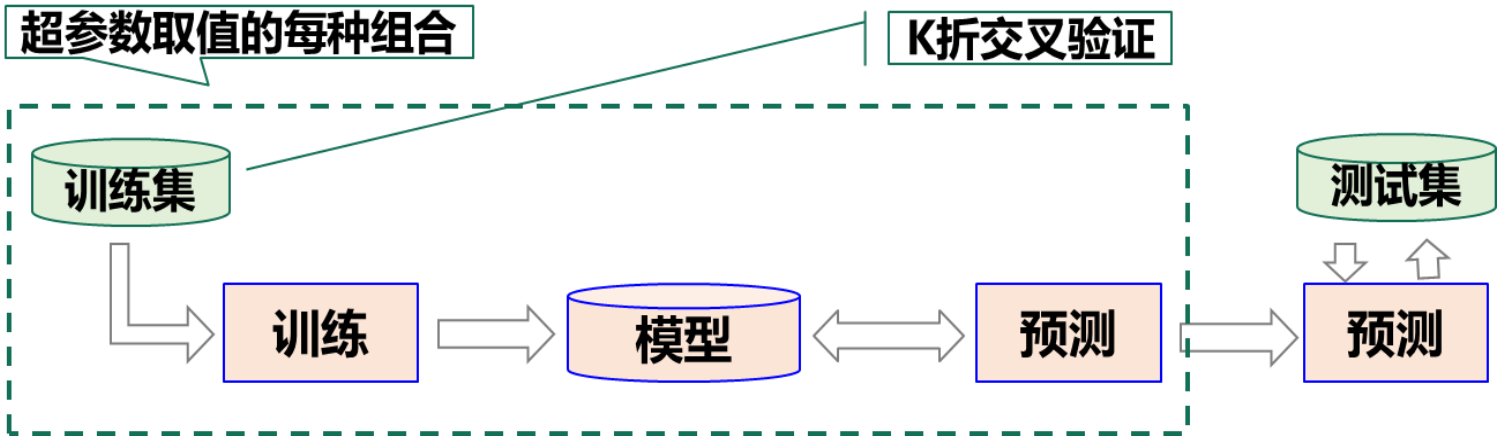


用网格搜索来调超参数（一）

- **什么是超参数？** 指在学习过程之前需要设置其值的一些变量，而不是通过训练得到的参数数据。如深度学习中的学习速率等就是超参数。
- **什么是网格搜索？**
  - 假设模型中有2个超参数：A和B。 A的可能取值为{a1, a2, a3}，B的可能取值为连续的，如在区间[0-1]。由于B值为连续，通常进行离散化，如变为{0， 0.25， 0.5, 0.75, 1.0}
  - 如果使用网格搜索，就是尝试各种可能的(A, B)对值，找到能使的模型取得最高性能的(A, B)值对。



用网格搜索来调超参数（二）



网格搜索与K折交叉验证结合调整超参数的具体步骤：

1. 确定评价指标;
2. 对于超参数取值的每种组合，在训练集上使用交叉验证的方法求得其K次评价的性能均值;
3. 最后，比较哪种超参数取值组合的性能最好，从而得到最优超参数的取值组合。

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- **机器学习方法的分类**
- 半监督学习
- 主动学习

机器学习方法的分类

按样本标签的情况分类

分类名称	样本标签的特点	学习任务特点
有监督学习	训练集中的样本有标签	学习输入到输出的映射
无监督学习	训练集中的样本无标签	学习、揭示数据的内在性质及规律
纯的半监督学习	训练集中部分样本有标签，其余无标签	不依赖人工干预,将无标签样本集中分类（或回归）置信度高的样本自动加入到训练集中，以提升模型的泛化性能
特殊的半监督学习，即直推式学习	训练集样本有标签，测试集样本特征信息可见	训练时利用了测试集除了标签以外的有用信息（例如基于特征的样本相似度或者连接关系等）
主动学习	训练集中部分样本有标签，其余无标签	依赖人工干预。将无标签样本集中分类（或回归）置信度低的样本交由人工专家标注并加入到训练集中，以提升模型的泛化性能
强化学习	数据标签未知，但知道与输出目标相关的反馈	适用决策类问题

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习
- 元学习

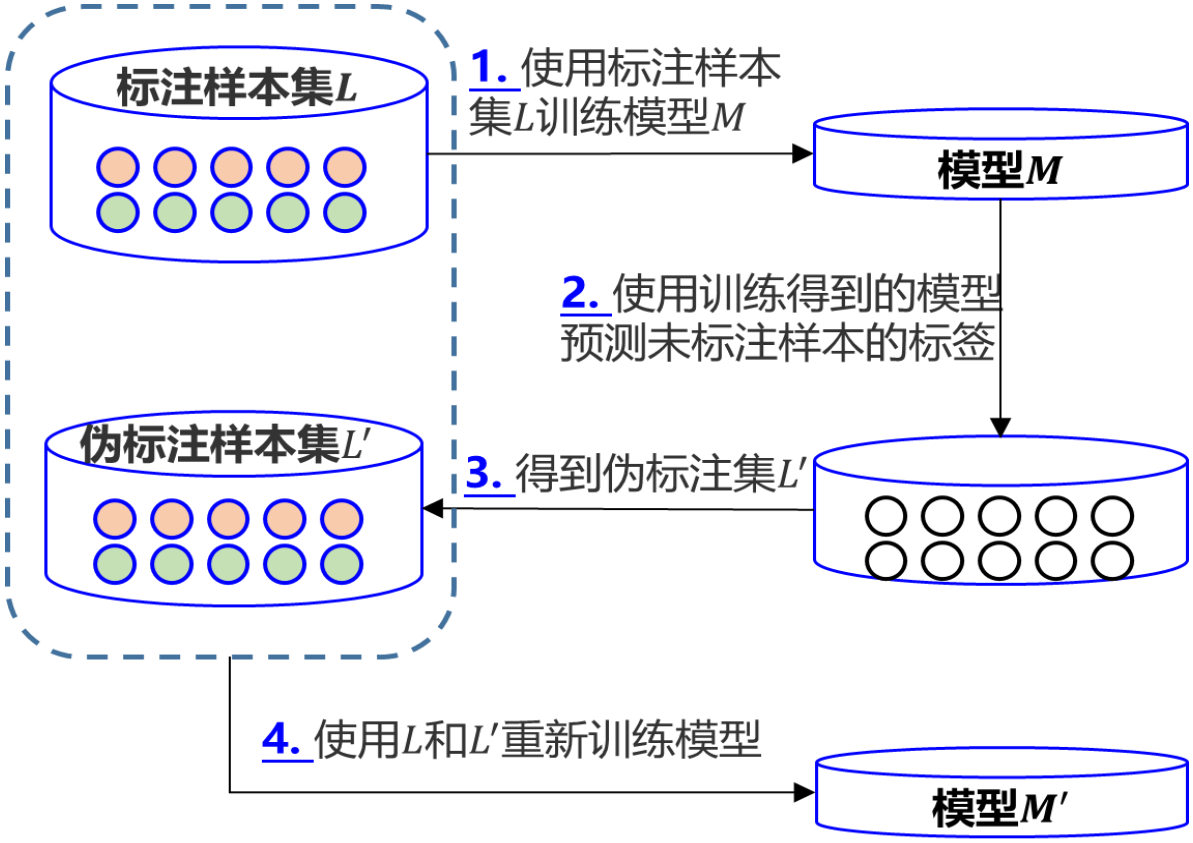
机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- **半监督学习**
- 主动学习

半监督学习举例

简单自训练学习



半监督学习

简单自训练学习

算法 2. 1: 半监督学习中的简单自训练算法（Self-training）

Input: 有标签的样本集 (X_l, y_l)，没有标签的样本集 X_u

Output: 扩充后的训练集 (X_{train}, y_{train})

给定 $(X_{train}, y_{train}) = (X_l, y_l)$

while 没有满足停止准则 **do**

  从 (X_{train}, y_{train}) 训练分类器 C_{int}

  使用 C_{int} 预测 X_u 的类别标签 y_u

  从 (X_u, y_u) 中选择置信度较高的样本 (X_{conf}, y_{conf})

  从 (X_u, y_u) 中移除未能加上标签的样本: $X_u \leftarrow X_u - X_{conf}$

  //将新打上标签的样本加入到训练集中：

  $(X_{train}, y_{train}) \leftarrow (X_l, y_l) \cup (X_{conf}, y_{conf})$

end

机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习

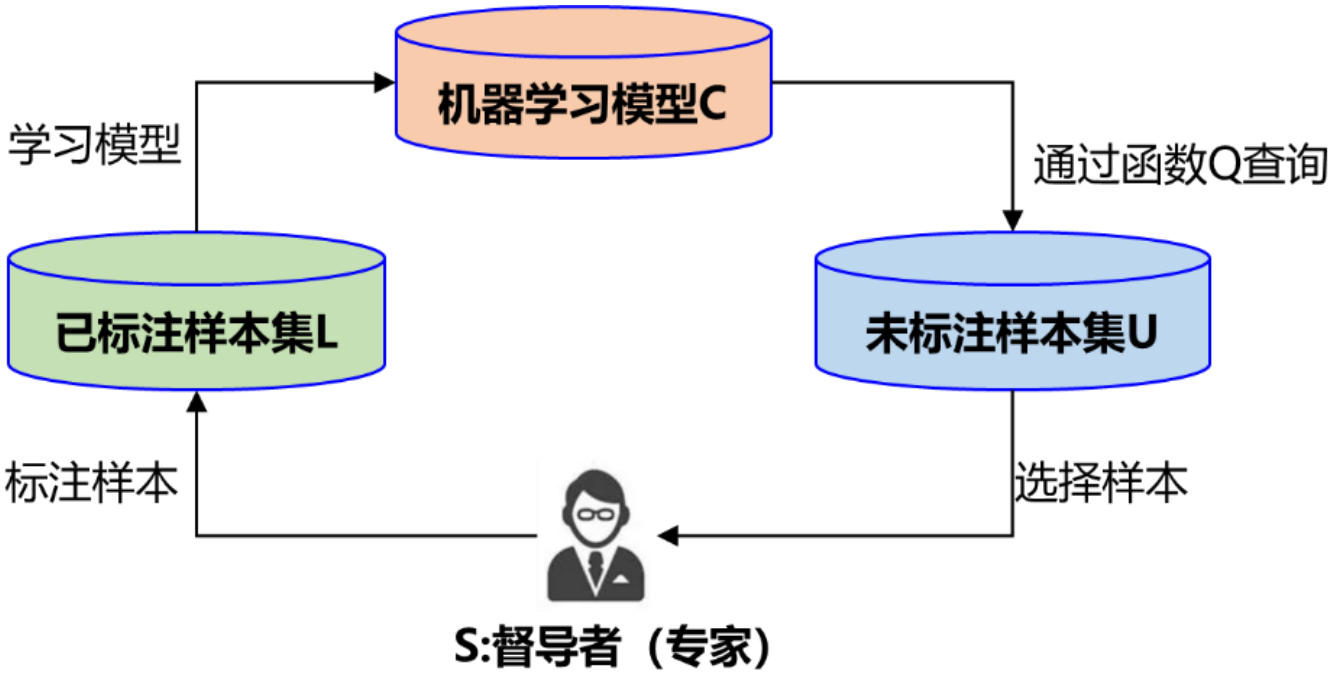
机器学习概述

本章内容简介

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- **主动学习**

主动学习

主动学习的原理示意图



核心思想：让模型能够主动选择对自己最有价值的训练数据，然后向一个“专家”（或称Oracle，通常是人类标注者）询问这些数据的标签，以期用尽可能少的标注成本，达到尽可能高的模型性能。

主动学习

主动学习的查询策略Q(1)--基于不确定性采样的查询策略

主动学习的关键在于如何选择出合适的样本交由人类专家标注，选择的方法即查询策略Q是主动学习的关键之处。典型的策略包括基于不确定性采样的查询策略（Uncertainty Sampling）、基于委员会的查询策略（Query-By-Committee）等。

其中不确定性采样策略是指将模型中难以区分的样本数据提取出来，由人类专家进行标注。可以描述样本不确定性的方法有：

1）最低置信度（Least Confident）方法。其认为那些在不同类别的**概率分布中最大概率最小的样本**更难以区分。例如，三分类中假设两个样本的类别概率分布分别为（0.8、0.1、0.1）和（0.4，0.4,0.2）。则第二个样本更难以被区分，因为其最大概率为0.4，小于第一个样本的最大概率值0.8，因此更有必要交由人类专家继续标注；

2）边缘采样（Margin Sampling）方法。选择模型预测的类别概率分布中**最大概率和次大概率的差值最小的样本**。对于上面的例子，则第二个样本同样也将被选中，因为其最大概率和次大概率的差值为0.4-0.4=0；

3）信息熵（Information Entropy）方法。信息论中熵被用来衡量一个系统的不确定性，**熵越大则表示不确定性越大**，熵越小表示不确定性越小。因此可以对某个样本的概率分布的熵进行计算，并选择熵比较大的样本交由人类专家标注。

主动学习

主动学习的查询策略Q(2)--基于委员会的查询策略

另外一种基于委员会的查询（Query-By-Committee）策略是指采用类似集成学习的方法，通过**多个模型**投票的模式，来选择出那些较难区分的样本。**基于委员会的查询策略**通常也包括两种方法：

1）**投票熵（Vote Entropy）**。对于某一个样本，可以考察其使用多个不同分类器的分类结果。**如果这些结果都一致，则认为该样本容易被区分**；但如果这些结果差距较大，则表示该样本难以区分。不同分类器的分类结果也可以用熵来衡量，称之为投票熵；

2）**平均 KL 散度**。即用 KL 散度找到那些不同分类器下的**分类概率分布 KL 散度较大的样本。**

单选题 1分

设置

47

机器学习（深度学习）系统中通常将数据集划分为训练集和测试集，其中被用来学习得到系统的参数取值的是

A 训练集(training set)

B 测试集(testing set)

C 训练集(training set)和测试集(testing set)

D 以上都不是

提交

单选题 1分

设置

48

测试集(testing set)用于最终报告模型的评价结果，因此在训练阶段测试集中的数据一般是否可以出现在训练集中?

A 可以

B 不可以

提交

多选题 1分

设置

49

超参数和参数的区别。参数一般是模型需要根据数据可以自动学习出的变量。超参数一般就是根据经验确定预设的变量。下面哪些是超参数?

A 深度学习模型的权重，偏差

B 深度学习的学习速率、人工神经网络的层数

C 深度学习的迭代次数

D 深度学习的每层神经元的个数

提交

多选题 1分

设置

50

下面关于使用网格搜索进行超参数的调优的描述正确的是：

A 假设模型中有两个超参数(A, B)。则网格搜索的基本原理就是尝试各种可能的(A, B)对值，并找到其中最好的(A, B)对值

B 为了使用网格搜索进行超参数的调优，通常可以进行交叉验证的方式，并找出使交叉验证性能最高的超参数取值的组合

C 假设模型中某个超参数B的可能取值为连续的，如在区间[0-1]。由于B值为连续，通常进行离散化，如变为{0， 0.5，1.0}

D 假设模型中某个超参数B的取值为离散，则需要连续化处理

提交

单选题 1分

设置

51

下列关于验证集(validation set)的描述错误的是

A 某些情况下，可以对训练集做进一步划分，即分为训练集和验证集

B 验证集与测试集类似，也是用于评估模型的性能。且可以用于报告模型的最终评价结果

C 验证集与测试集之间的区别是，验证集主要用于模型选择和调整超参数，因而一般不用于报告最终结果

D 其它答案都不对

提交

多选题 1分

设置

52

以下关于深度学习硬件计算环境的描述中，哪些是正确的?

A GPU因其大规模并行架构，特别适合处理深度学习中的大量矩阵运算。

B CPU虽然主频高、核心复杂，擅长处理串行复杂逻辑任务，但其核心数量远少于GPU，大规模并行计算能力弱于GPU或TPU。

C 在选择硬件时，除了计算单元，内存(RAM/VRAM)的容量和带宽也是至关重要的考虑因素，它决定了可处理模型和数据的大小。

D 边缘计算设备（如手机、嵌入式芯片）通常使用经过剪枝、量化的轻量级模型，以适应其有限的计算和存储资源。

提交

多选题 1分

设置

53

构建高质量的数据集是机器学习项目成功的关键。以下关于数据集的说法，哪些是正确的?

A 数据清洗和预处理（如处理缺失值、归一化）是准备数据集的重要步骤，可以显著影响模型性能。

B 在监督学习中，数据集可以被划分为训练集、验证集和测试集。

C 数据增强（如对图像进行旋转、裁剪）是一种有效增加训练数据量、提升模型泛化能力的技术。主要是对测试集进行数据增强。

D 公开数据集（如ImageNet, MNIST）的重要性在于为研究者提供了标准基准，用于公平地比较不同算法的性能。

E 数据标注的成本通常很低，且可以完全由机器自动完成，无需人工干预。

提交

多选题 1分

设置

54

机器学习方法可以根据学习范式进行分类。下列哪些划分是公认的机器学习分类?

A 监督学习（Supervised Learning）

B 无监督学习（Unsupervised Learning）

C 强化学习（Reinforcement Learning）

D 半监督学习（Semi-supervised Learning）

E 主动学习（Active Learning）

提交

多选题 1分

设置

55

关于半监督学习和主动学习，以下描述正确的是?

A 半监督学习的核心思想是同时利用大量未标注数据和少量标注数据来进行模型训练

B 主动学习的核心思想是让模型自主选择“最有价值”的数据点交由专家进行标注，以期用更少的标注成本获得更高的模型性能。

C 特殊的半监督学习即直推式学习，训练时利用了测试集除了标签以外的有用信息（例如基于特征的样本相似度或者连接关系等）。

D 在主动学习中，查询策略（如不确定性采样）是决定选择哪些数据进行标注的关键技术。

E 这两种方法的目标都是为了解决“获取大量标注数据成本高昂”这一共同痛点。

提交

多选题 1分

设置

56

关于主动学习（Active Learning），以下描述哪些是准确的?

A 其核心查询策略之一“不确定性采样”，是指选择模型最不确定如何分类的样本进行标注。

B 另一种查询策略“委员会查询（QBC）”，是通过训练多个模型，选择它们分歧最大的样本进行标注。

C 主动学习可以显著减少达到特定模型性能所需的标注数据量，从而降低标注成本。

D 主动学习的过程是完全自动化的，完全不需要人类专家（Oracle）的参与。

E 主动学习特别适用于数据丰富但标注预算有限的应用场景。

提交

多选题 1分

设置

57

在构建深度学习模型时，数据集的处理至关重要。以下哪些做法是合理且常见的?

A 使用One-hot编码来处理分类数据中的类别标签或特征。

B 将数据集随机打乱（Shuffle）后再划分训练集和测试集，以避免数据顺序带来的偏差。

C 对图像数据进行中心化（减去均值）或标准化（缩放到特定范围）等预处理操作，以帮助模型更快更好地收敛。

D 为了获得最可靠的结果，应使用整个数据集反复进行训练和测试，直到模型性能不再提升。

提交

本章小结

- 深度学习的硬件计算环境
- 深度学习的软件计算环境
- 数据集
- 机器学习方法的分类
- 半监督学习
- 主动学习