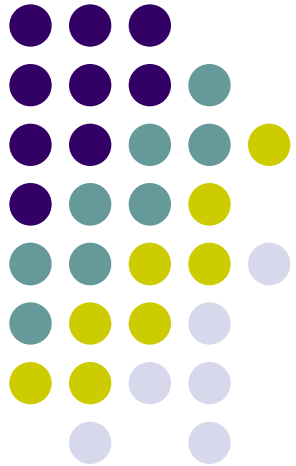
建模序列数据的神经网络

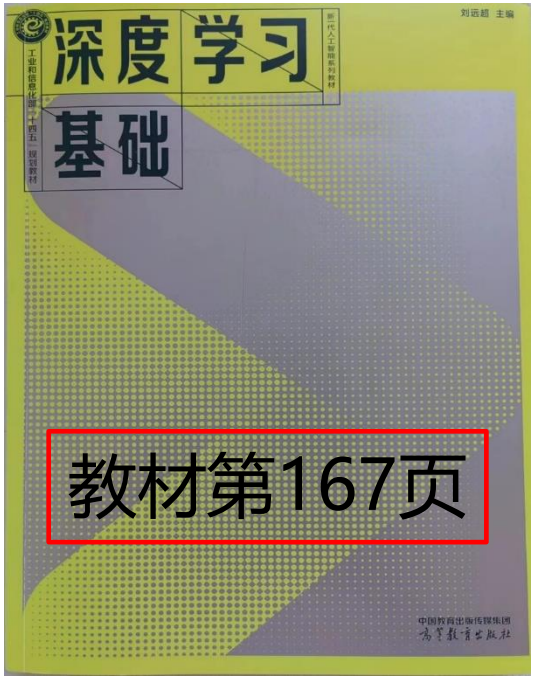
昨日因成今日果，前人栽树后人凉。——清·赵翼

哈尔滨工业大学计算学部 刘远超
E-mail: ycliuharbin@163.com



建模序列数据的神经网络

本章在《深度学习基础》教材中的位置





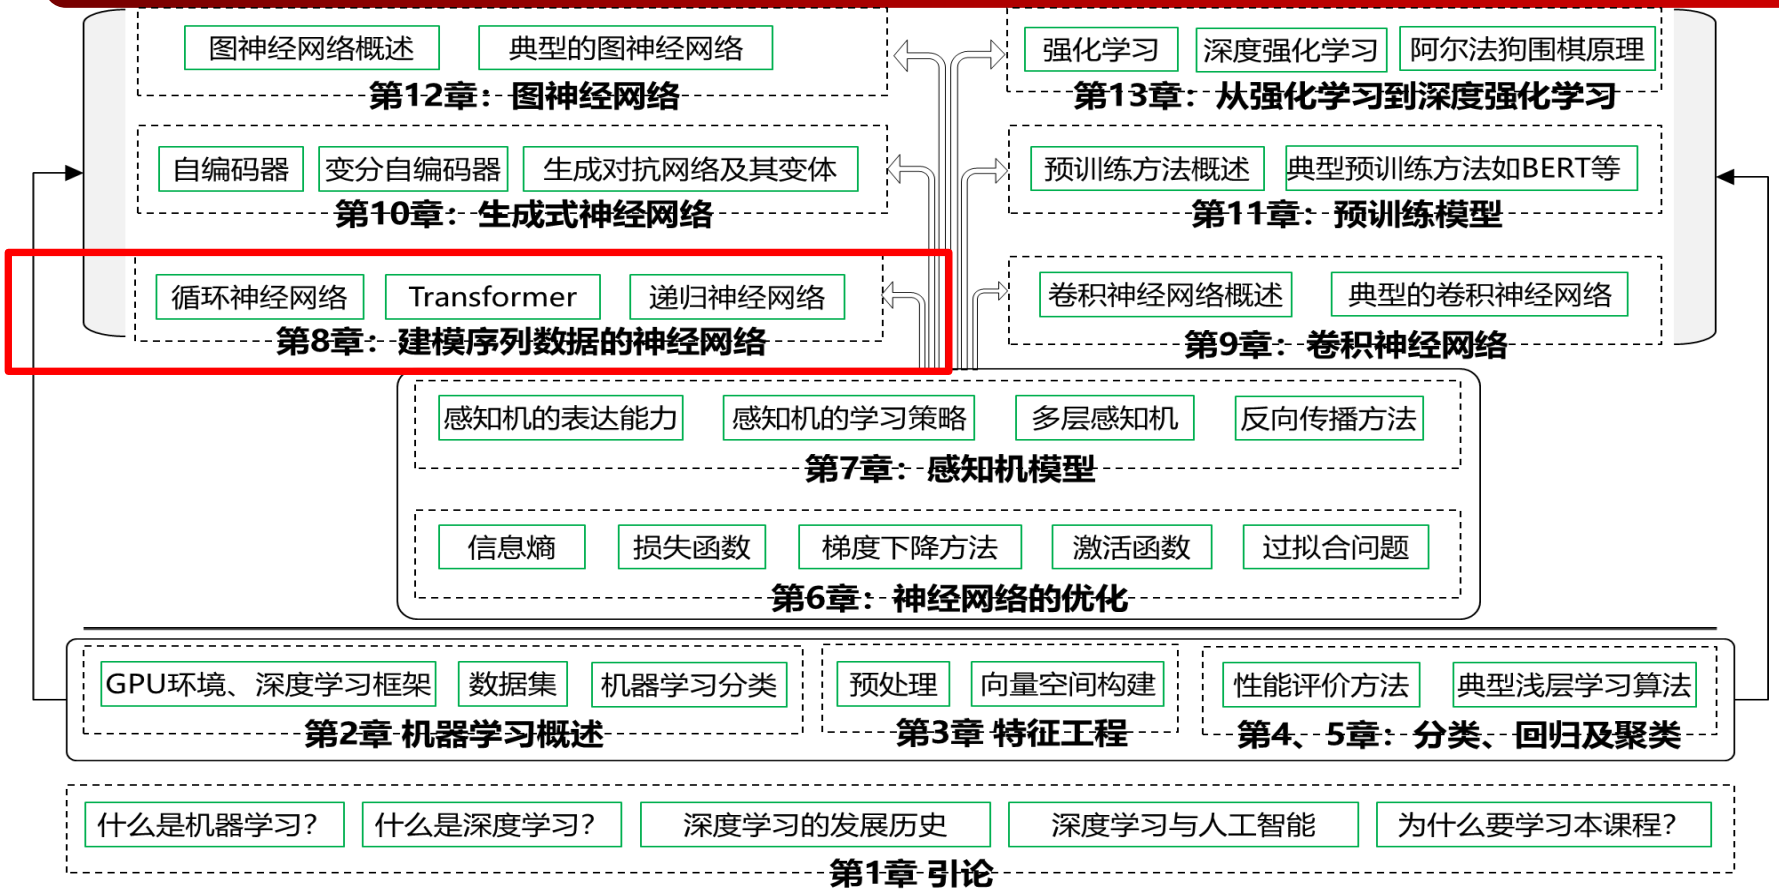


主编：刘远超；出版社：高等教育出版社；出版时间：2023年09月20日。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

建模序列数据的神经网络

本章内容在《深度学习基础》教材知识体系中的位置



主编：刘远超 出版社:高等教育出版社；出版时间:2023年09月。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

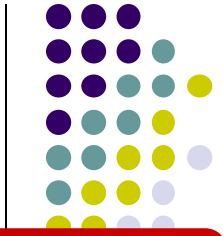
建模序列数据的神经网络

本章内容对应慕课中的配套教学资源位置情况

对应慕课的第5讲：包括讲解视频、在线测验题和配套程序讲解实例。



建模序列数据的神经网络



本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

建模序列数据的神经网络



本章内容简介

- **循环神经网络**
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

时间序列数据

现实世界中有很多序列数据

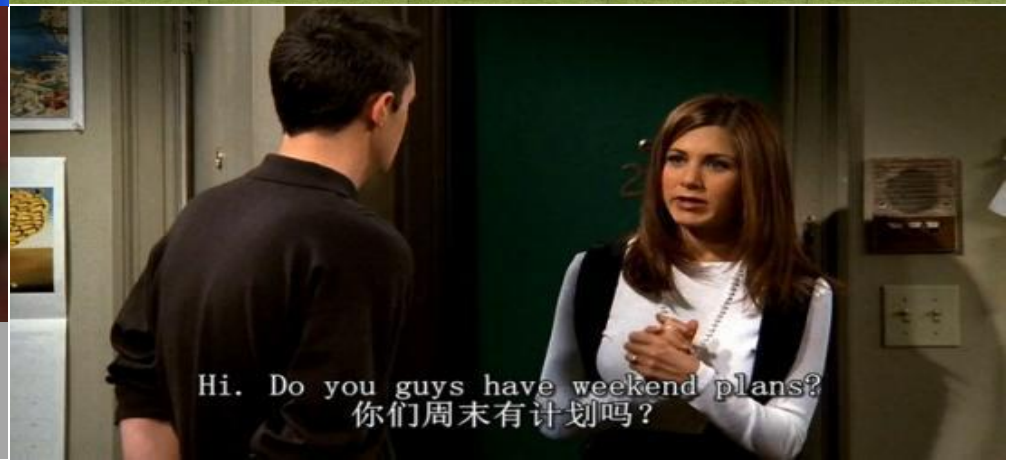
- 所谓时间序列数据，是在不同**时间步**上收集到的数据，用于所描述现象随时间变化的情况。该数据反映了某一事物或现象随时间的变化状态或程度。





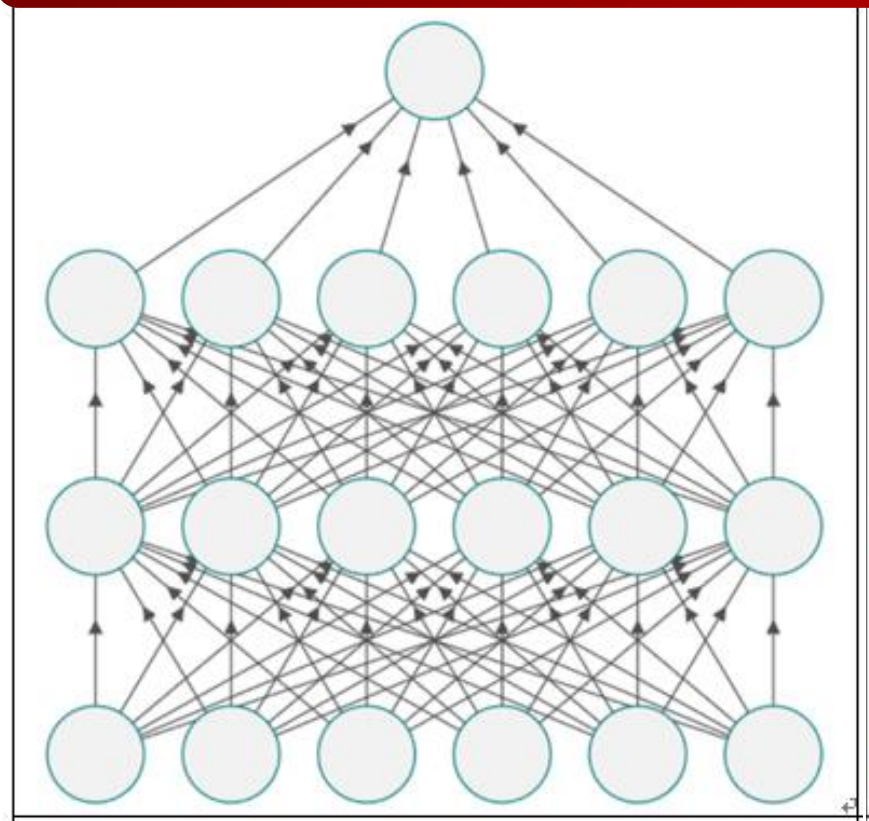


曾经有一份真挚的感情,摆在我面前,
我没有去（　）

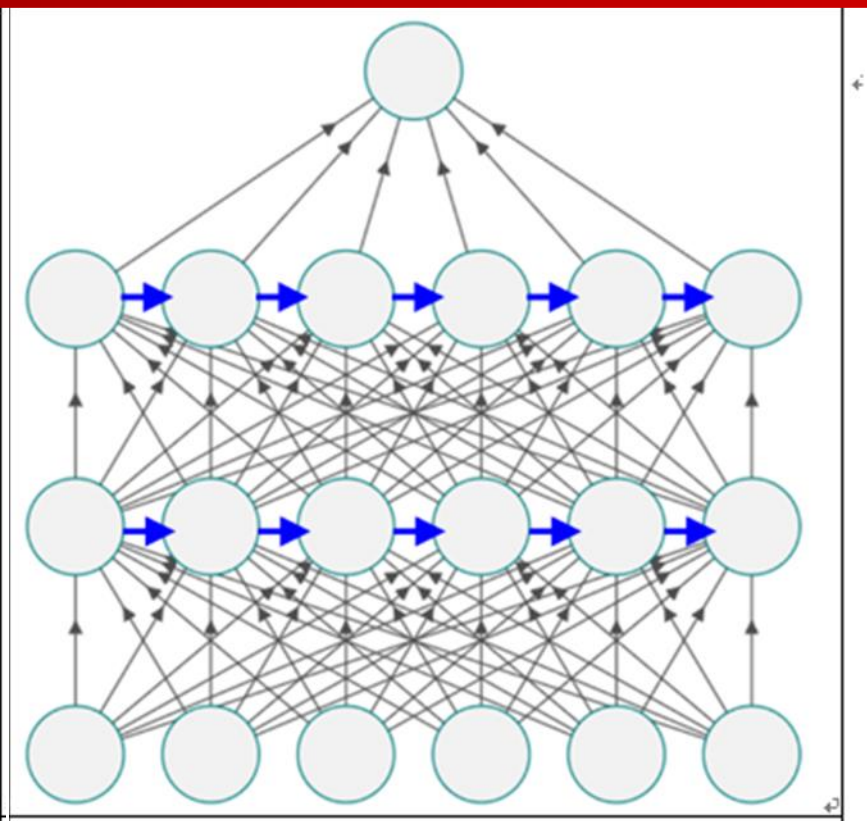


循环神经网络

循环神经网络的特点在于隐藏层的节点之间有连接



(a) **多层感知机**同一隐藏层节点之间无连接

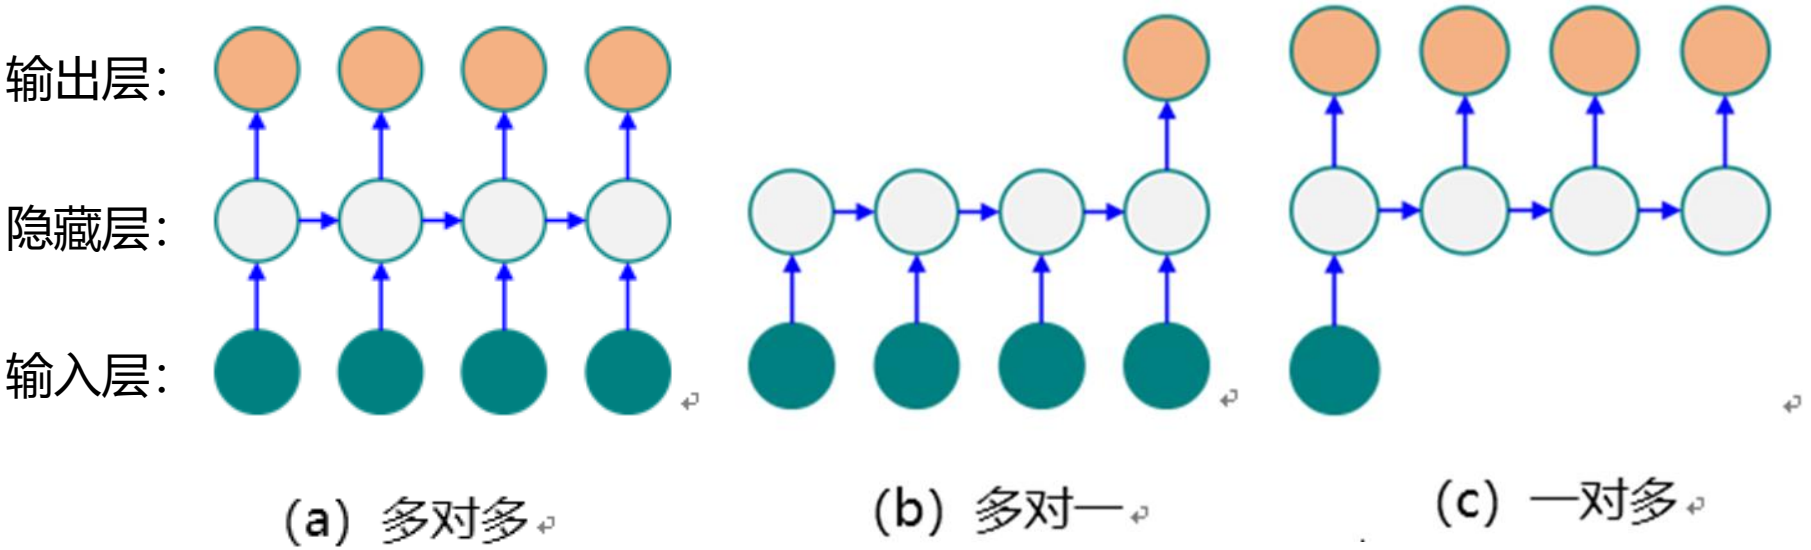


(b) **循环神经网络**同一隐藏层节点之间有连接

问题：有连接意味着什么?

循环神经网络

常见的序列处理任务类型



问题:

1）你能否举出更多的“多对多” 类型的应用场景和实例?

2） “多对一”和“一对多” 呢?

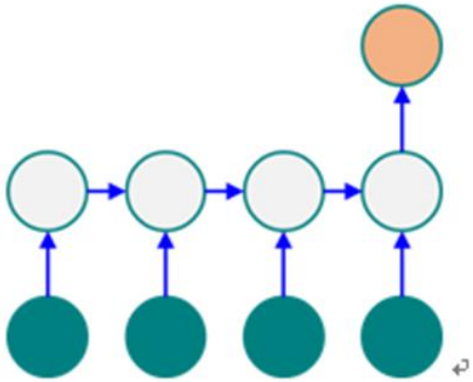
3）图（b）中为什么用隐藏层最后一个节点作为整个输入序列的分类预测计算? —>雨课堂

多选题 1分

设置

10

图（b）中，关于整个输入序列的分类结果的分类预测计算问题，下列说法哪些正确？



A 因为循环神经网络只能对隐藏层最后一个神经元节点做预测

B 根据图中信息传递方向，最后一个隐藏节点可以包含整个序列的信息

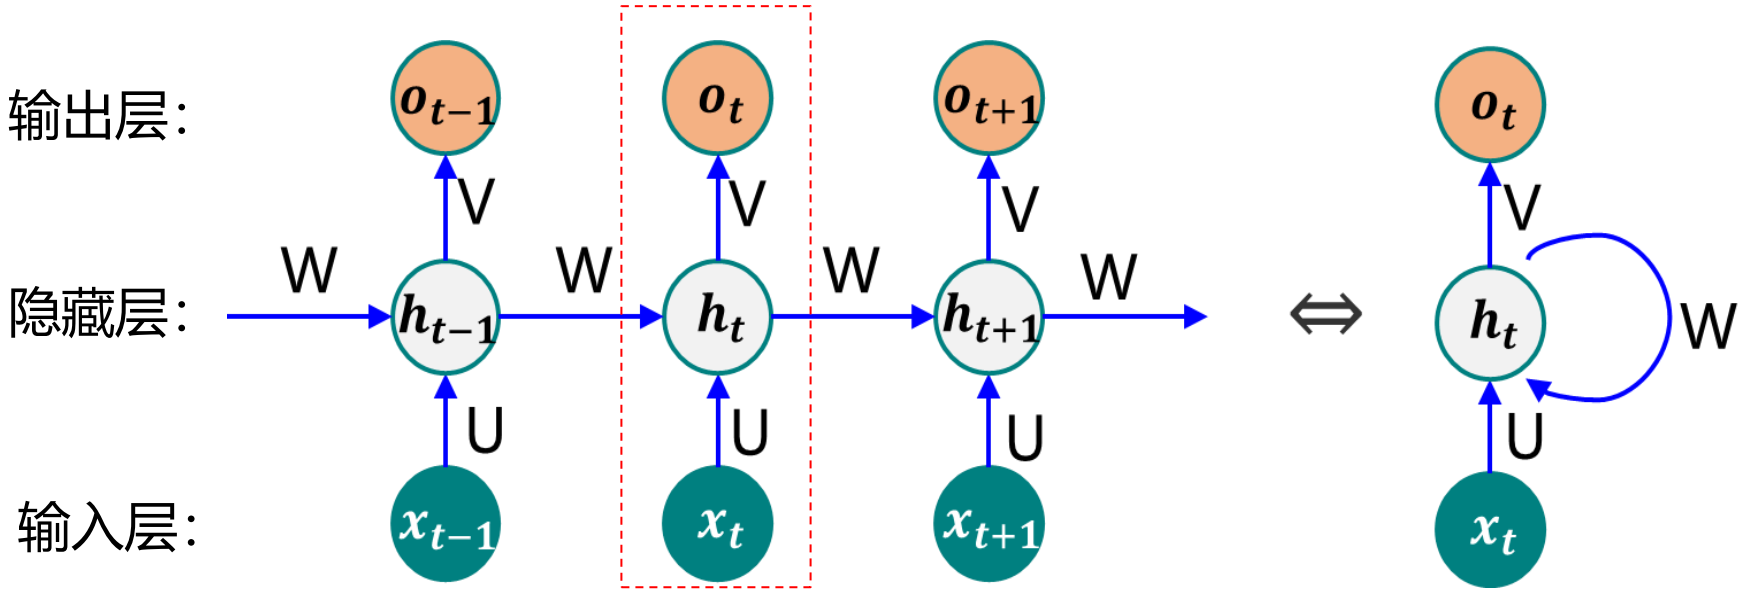
C 因为任何情况下，输入序列中最后一个时间步的信息是最重要的，所以总是要选择最后一个输入时间步对应的隐藏节点对整个输入序列分类

D 如果图中隐藏层的箭头向左，则要用最左边的隐藏节点做整个输入序列的分类预测

提交

循环神经网络

基本循环神经网络结构



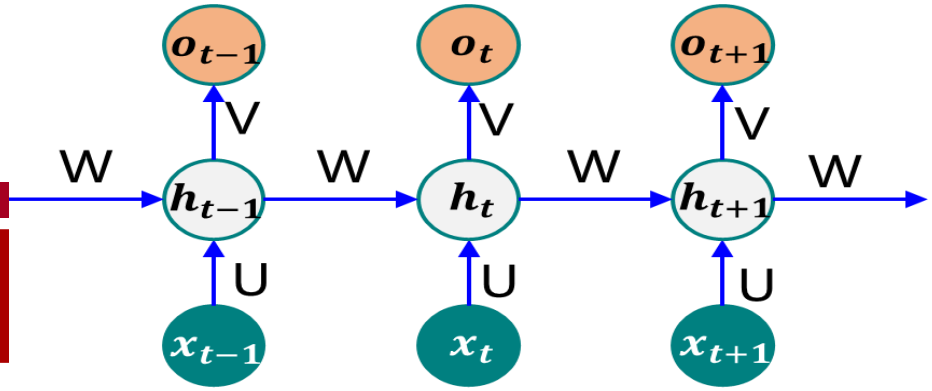
问题:

1）你能否写出隐藏层节点h_t的计算公式?

2）你能否写出输出层节点o_t的计算公式?

循环神经网络

基本循环神经网络的计算过程



- 首先，输入层每个节点x_t表示时刻 t 的输入。在神经网络中，每个节点在数据结构上通常表示为一个向量。
- 然后，隐藏层每个节点h_t表示隐藏层t时刻的状态，是网络的记忆单元。其计算公式为

$$\boldsymbol{h_t = f(U \cdot x_t + W \cdot h_{t-1})}$$

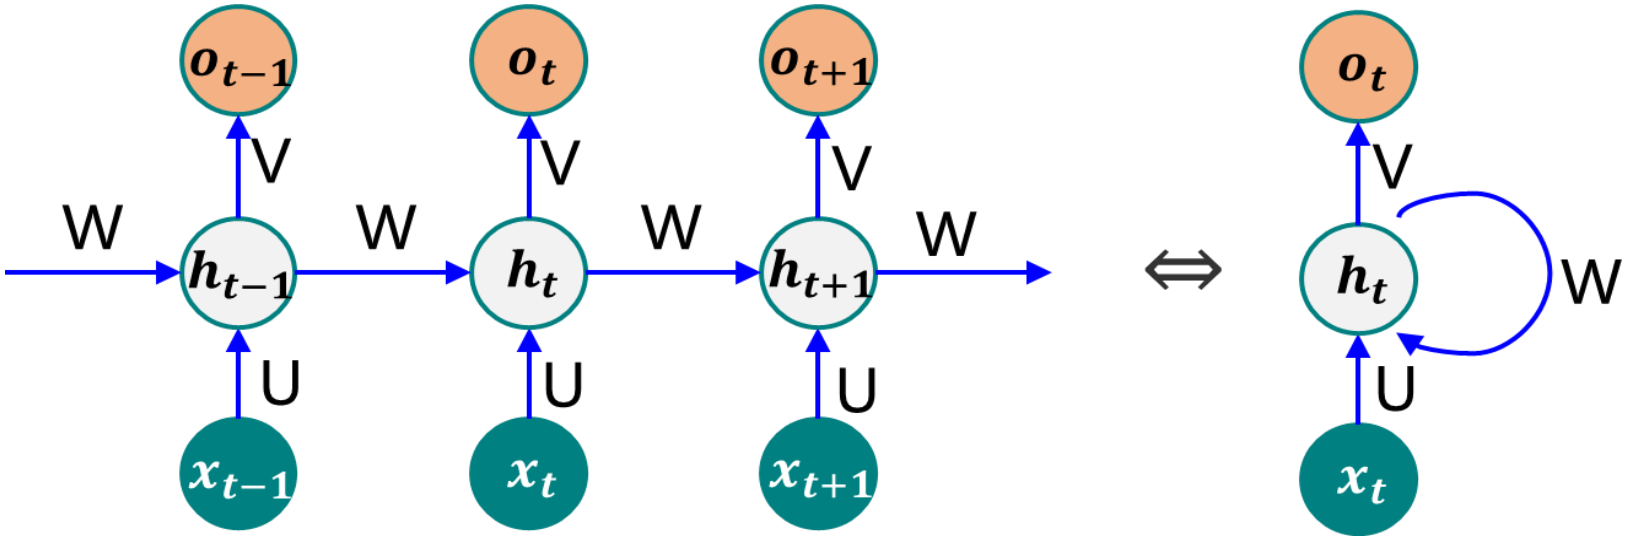
- 最后，输出层每个节点o_t的含义是t时刻的输出：

$$\boldsymbol{o_t = softmax(V \cdot h_t)}$$

其中，softmax函数的形式为：$\boldsymbol{\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^{K} e^{z_k}}}$

循环神经网络

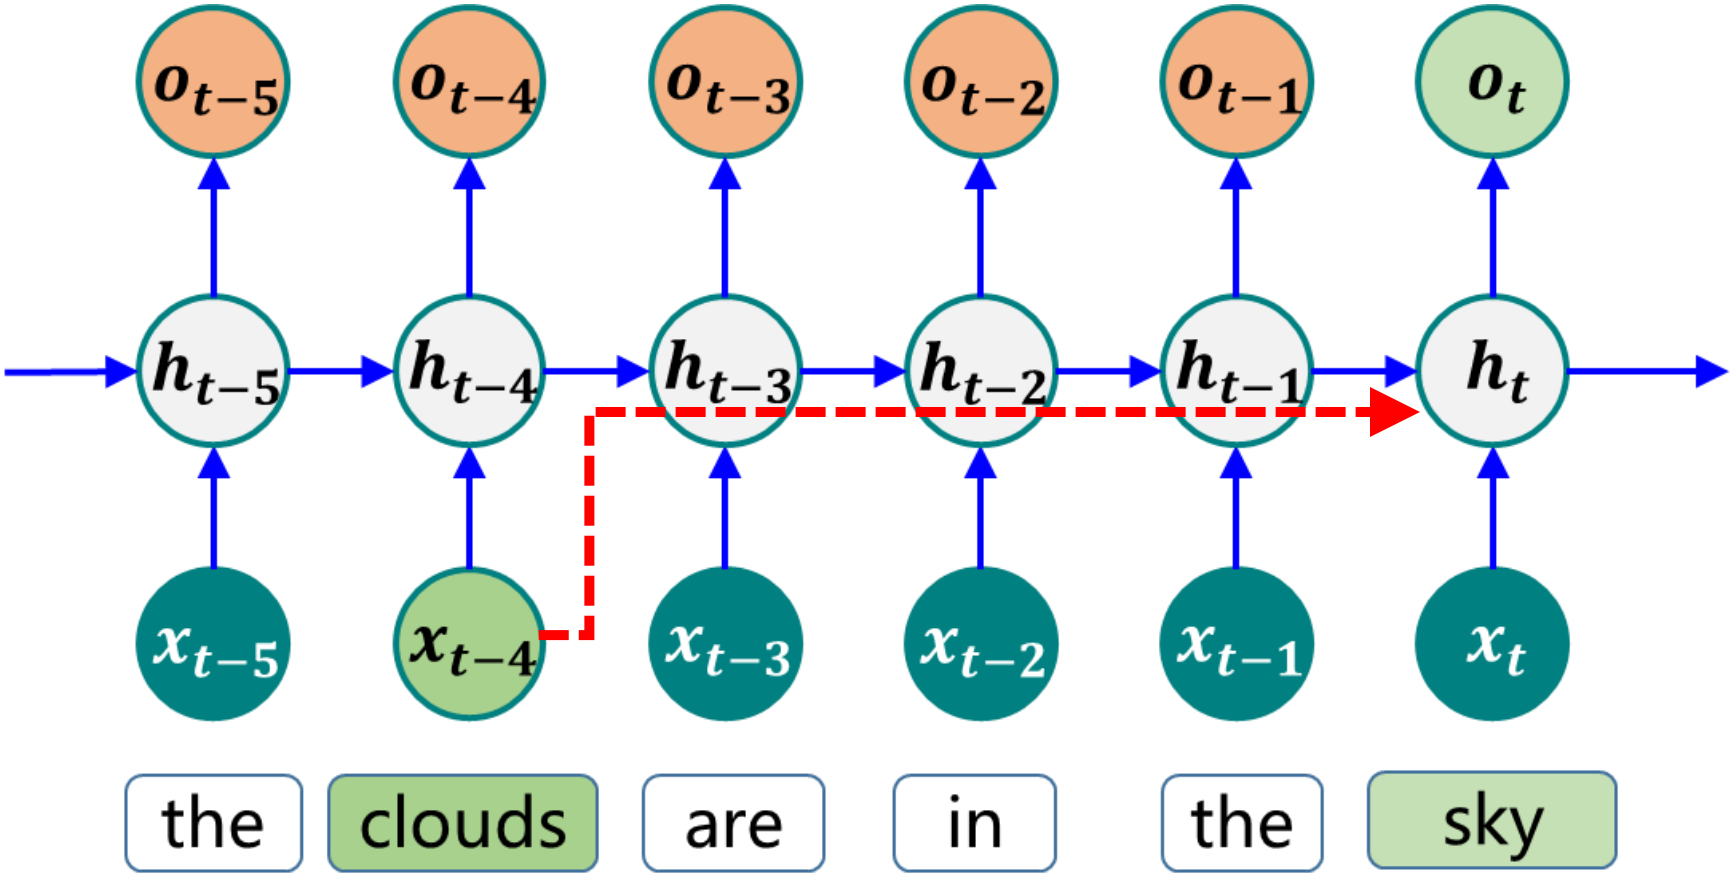
RNN的参数共享



- 图中几个参数U、V、W在运算时通常为以矩阵的数据结构形式存储。
- 多层感知机网络中不同层之间的参数是不共享的。而循环神经网络的一个特点是共享参数，也就是说，当再计算下一个节点的输出o_{t+1}时，也会用到参数U、V、W，且这些参数的取值和计算o_t时的取值相同。
- 共享参数表明循环神经网络中的每一步都在做相同的事，只是输入不同，因此大大地降低了网络中需要学习的参数，从而有利于改善训练效率。

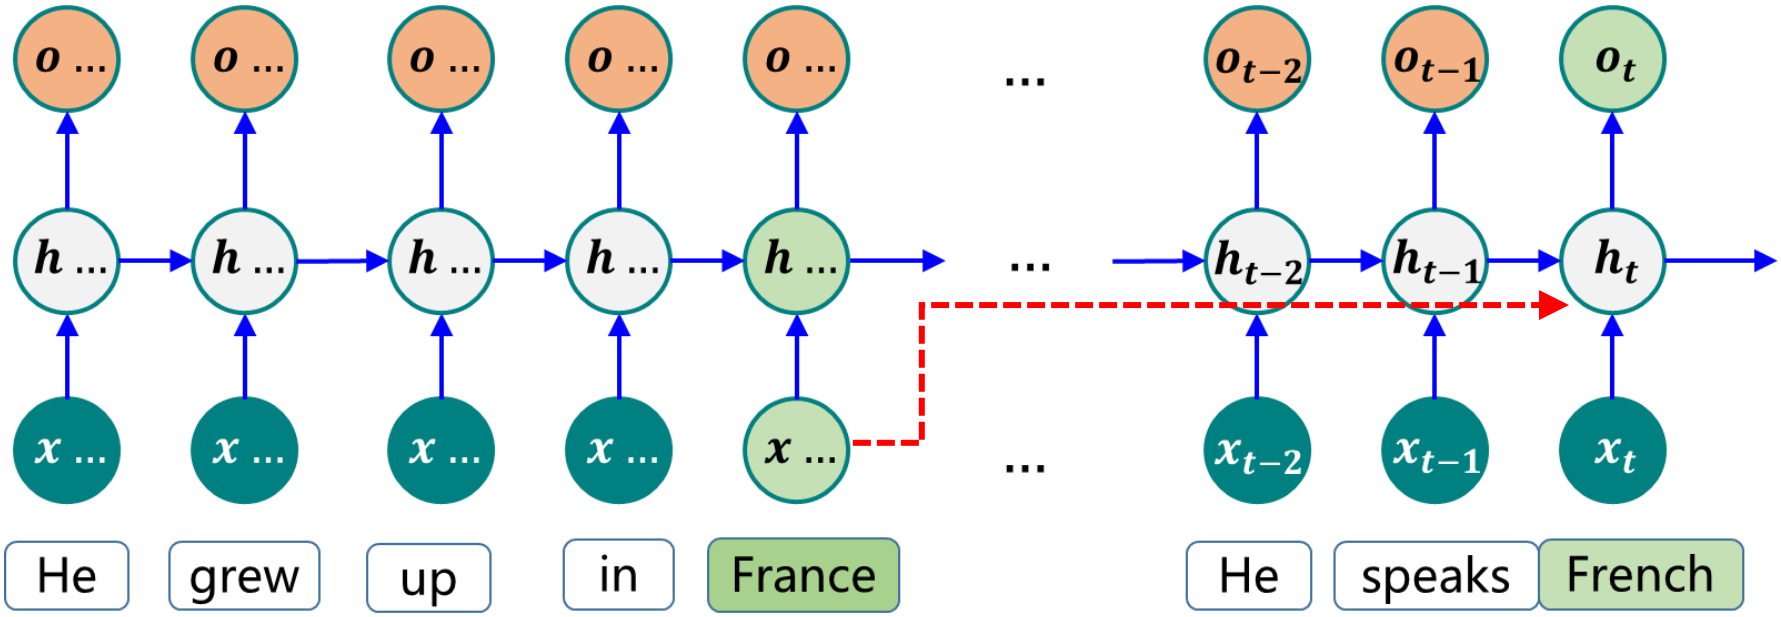
长短期记忆网络

标准循环神经网络一般仅可以处理短期依赖



循环神经网络

标准RNN无法处理更长的上下文间隔，即长期依赖



思考：

1）为什么长期依赖难于处理？

2）你有什么好办法吗？

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

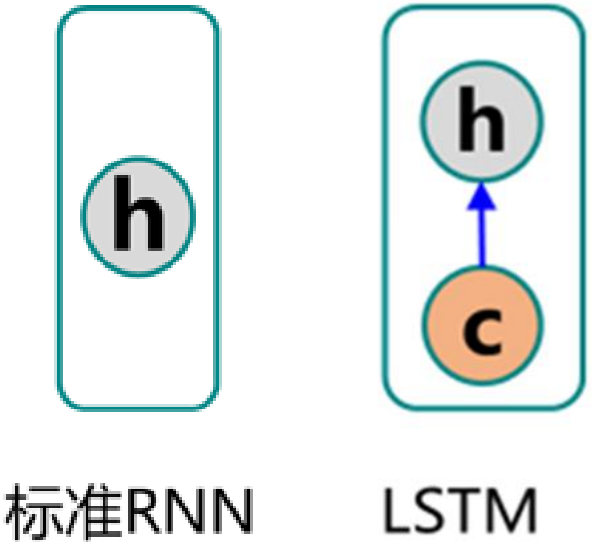
建模序列数据的神经网络

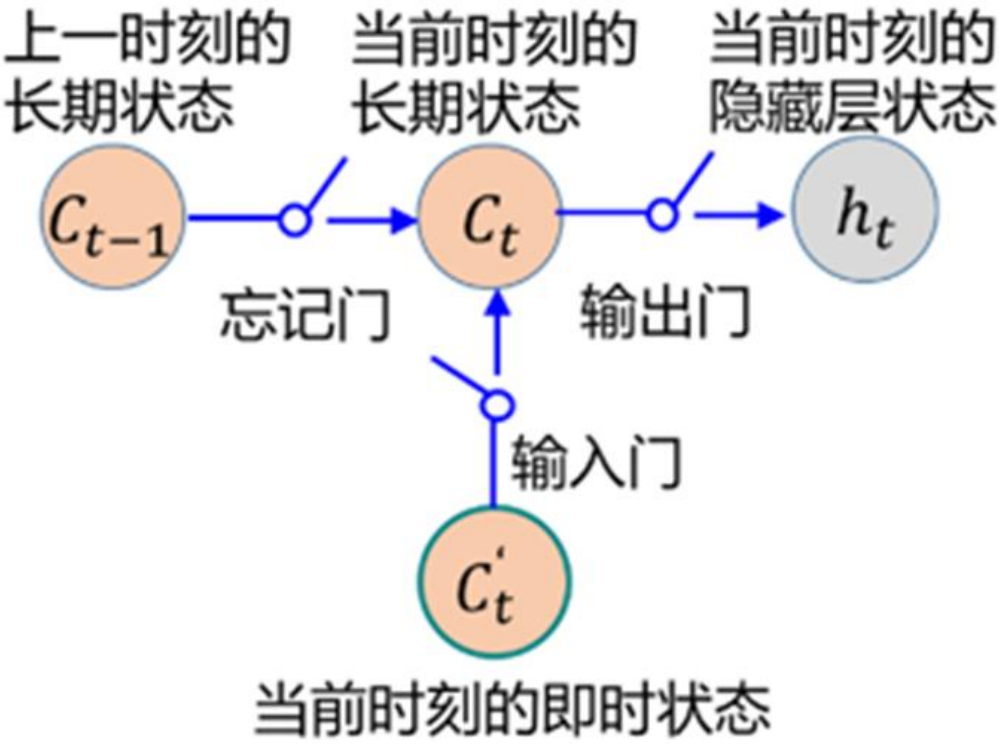
本章内容简介

- 循环神经网络
- **长短期记忆网络**
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

长短期记忆网络的基本原理

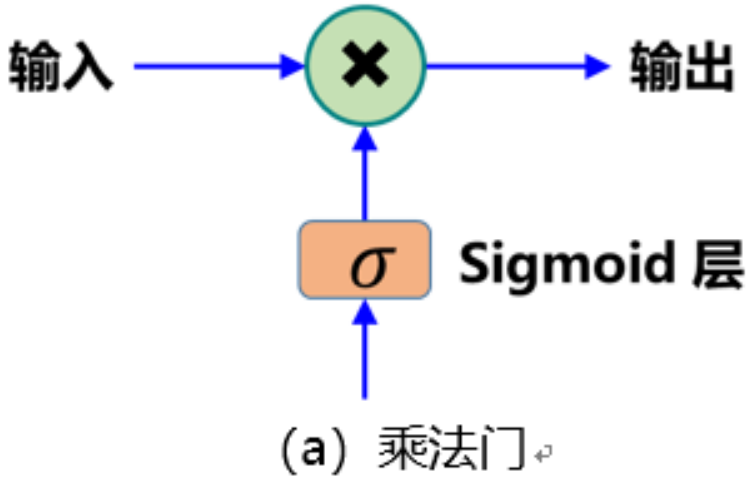
LSTM在隐藏层上额外增加了一个长期状态c（cell state）



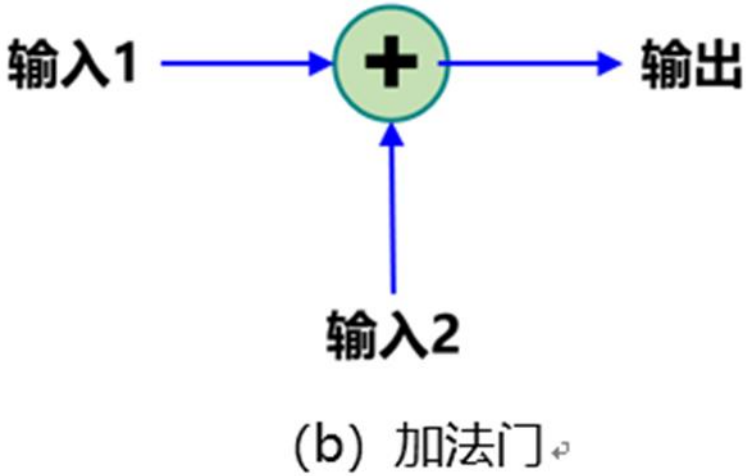


长短期记忆网络的基本原理

神经网络中的门



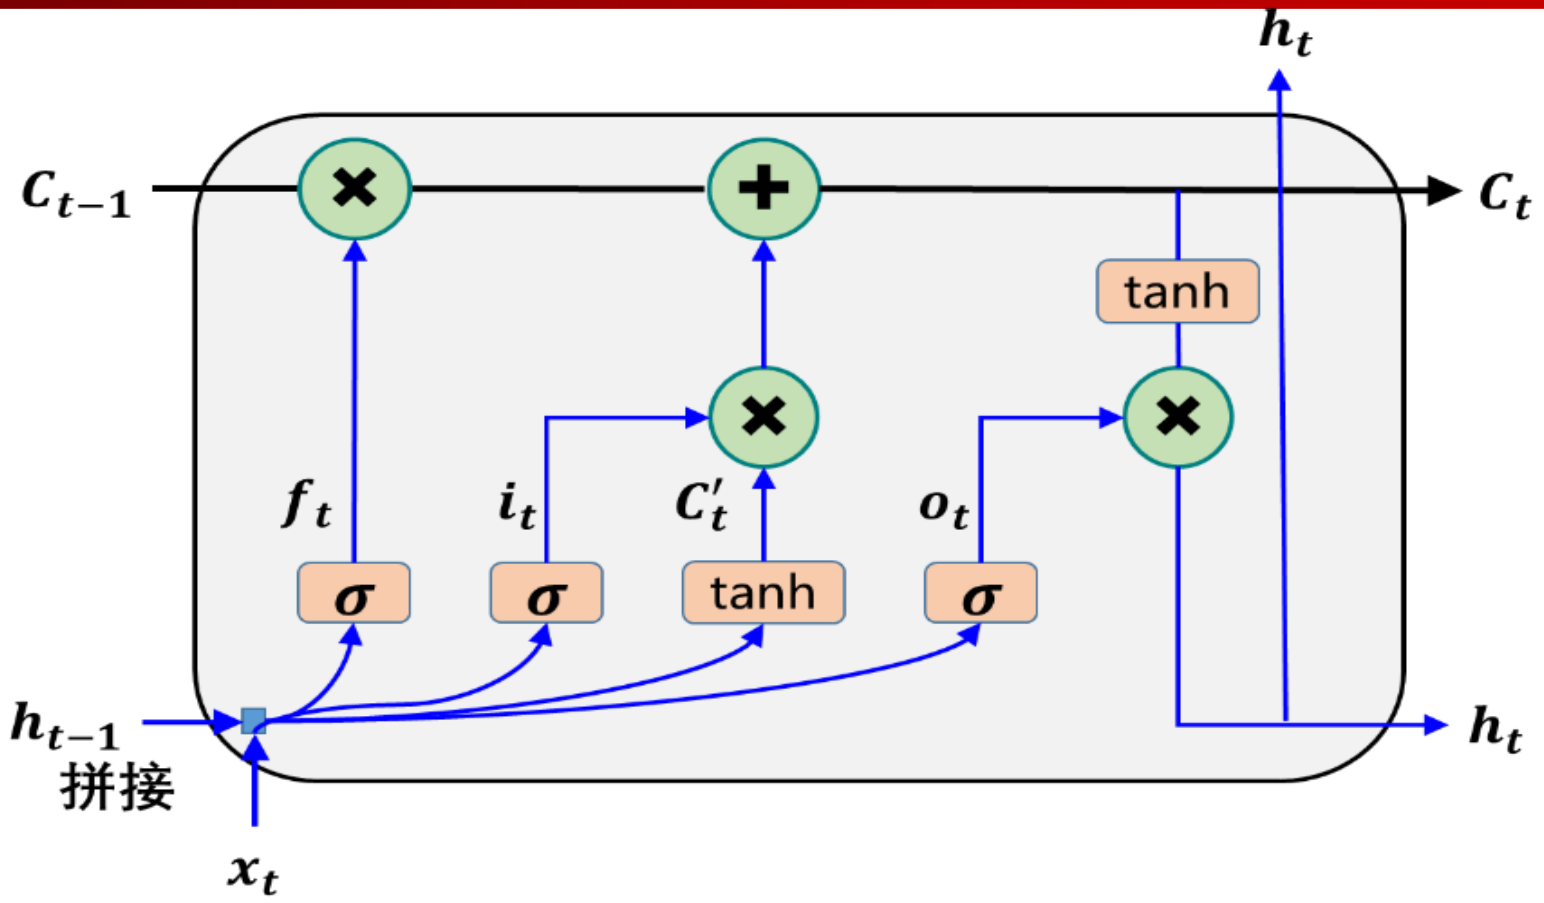
(a) 乘法门



(b) 加法门

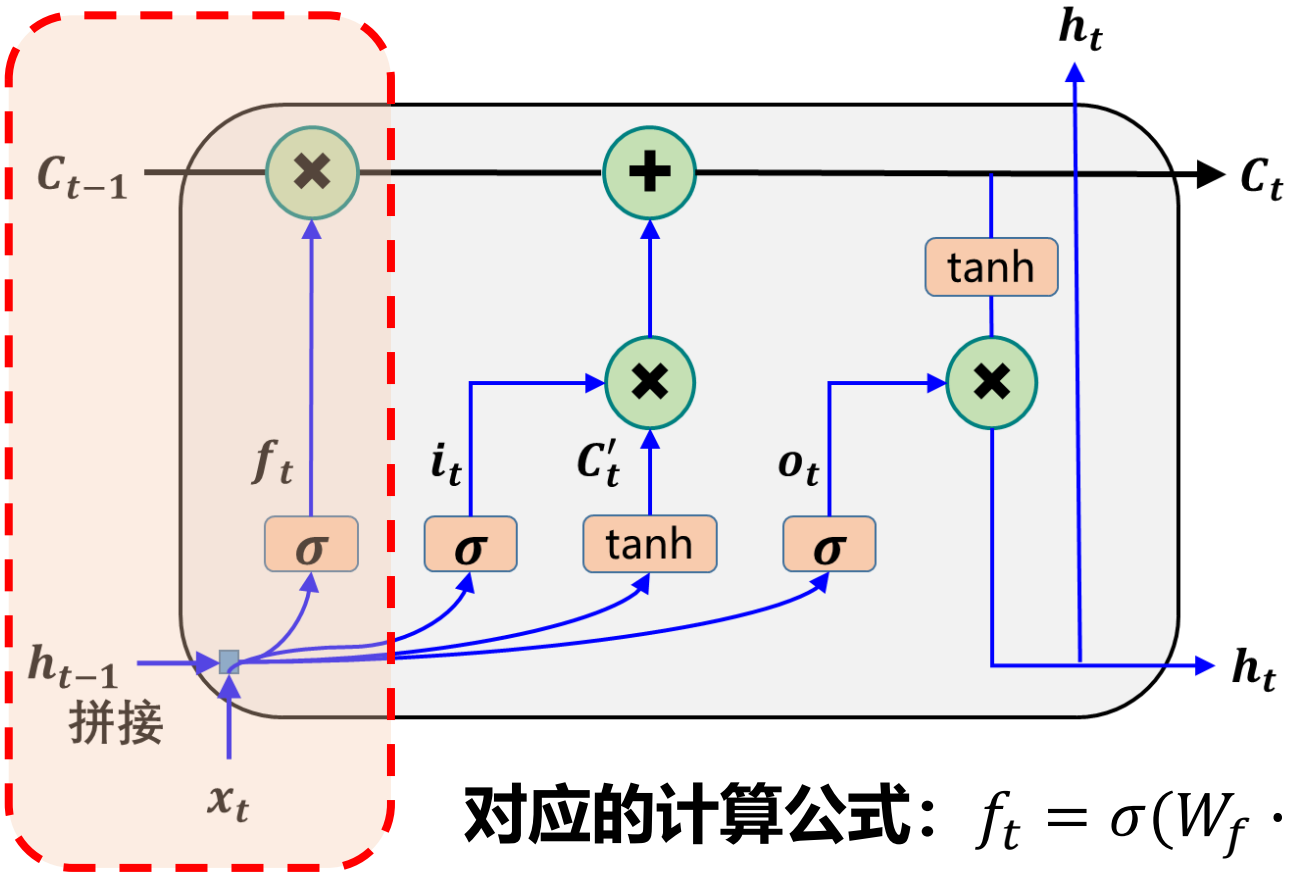
长短期记忆网络的基本原理

LSTM模型的整体框架及计算过程



长短期记忆网络的基本原理

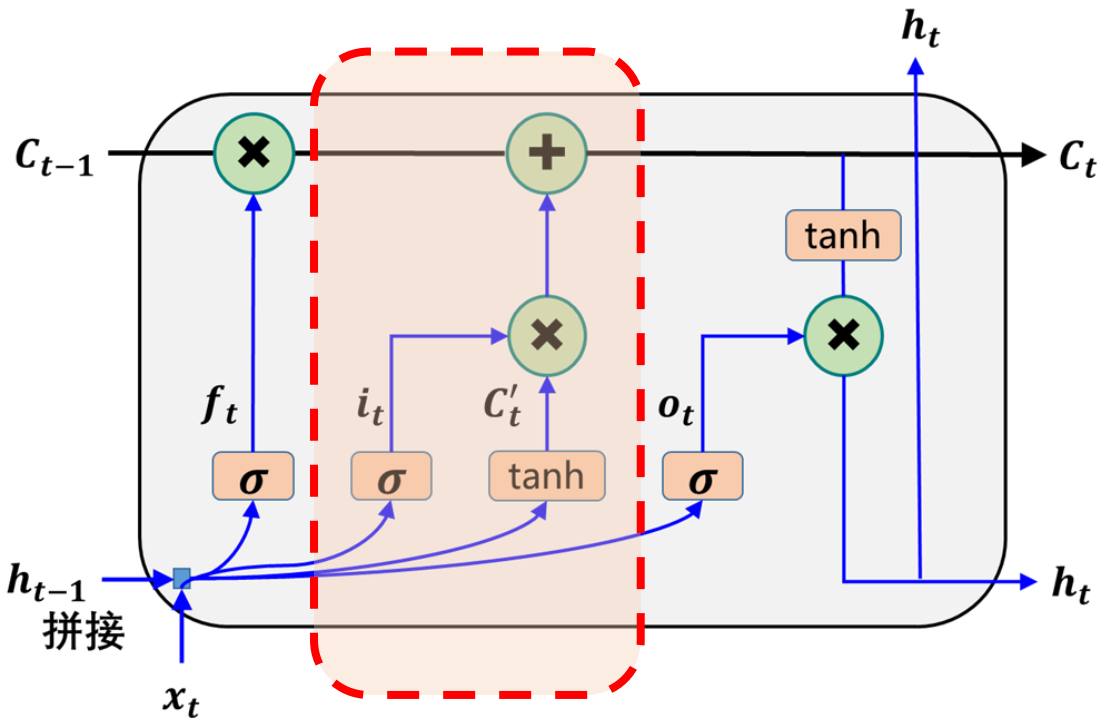
（一）从长期状态中丢弃某些信息



对应的计算公式： $f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$

长短期记忆网络的基本原理

（二）将当前时间步的新信息记忆在长期状态中



对应的计算公式：

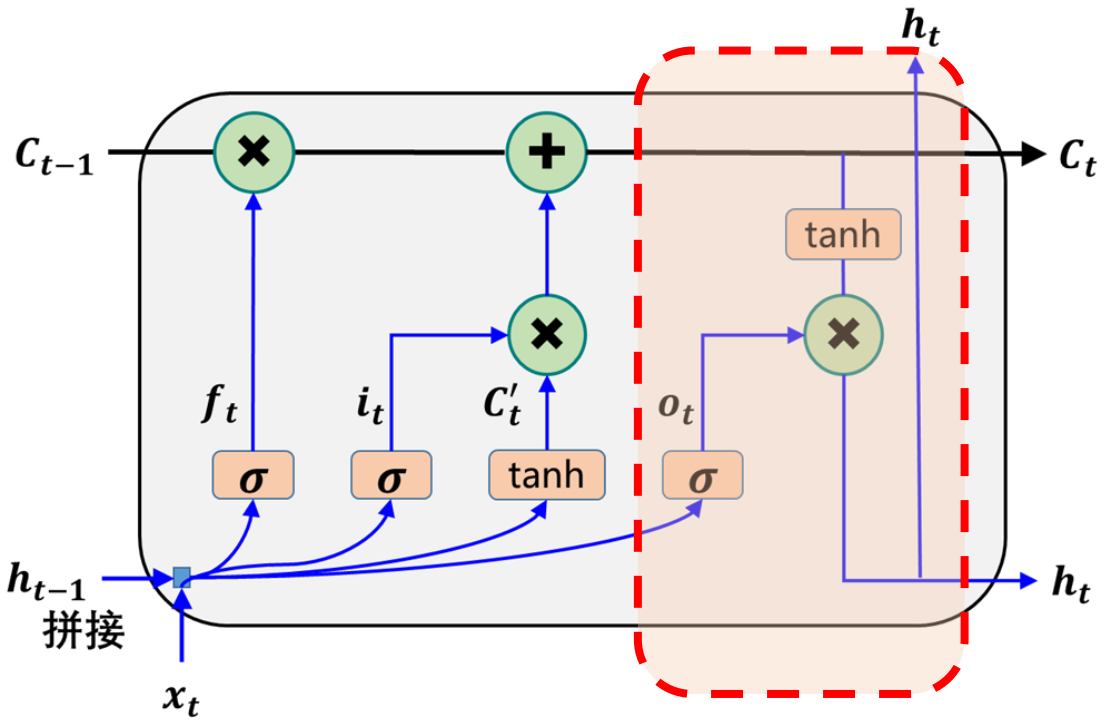
$$C'_t = \tanh\left(W_c \cdot [h_{t-1}, x_t] + b_c\right)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$C_t = f_t \otimes C_{t-1} + i_t \otimes C'_t$$

长短期记忆网络的基本原理

（三）计算得到输出隐藏状态信息



对应的计算公式：

$$o_t = \sigma(W_O \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \otimes \tanh(C_t)$$

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

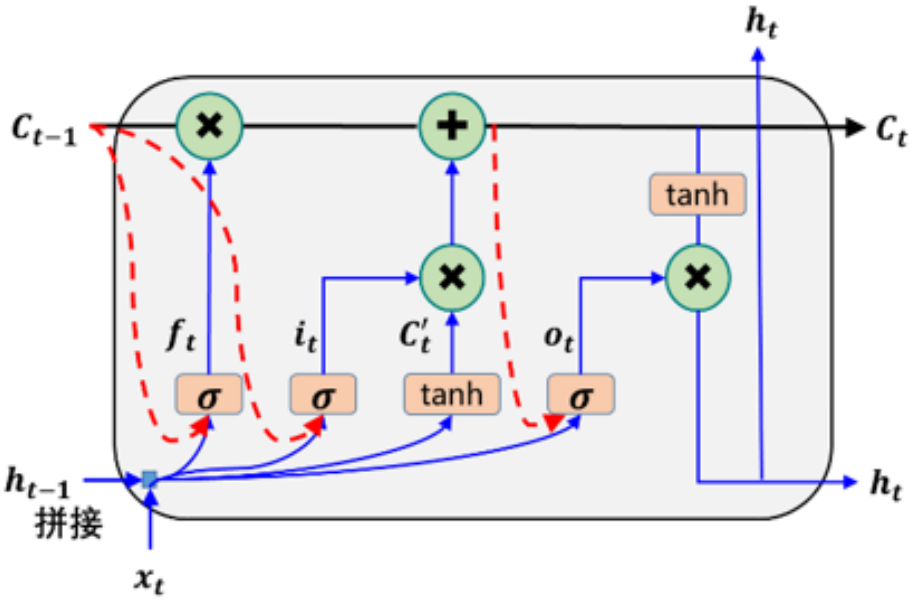
建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- **长短期记忆网络的变体**
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

长短期记忆网络的变体

LSTM 的变体1：猫眼连接



与标准 LSTM 的不同之处：

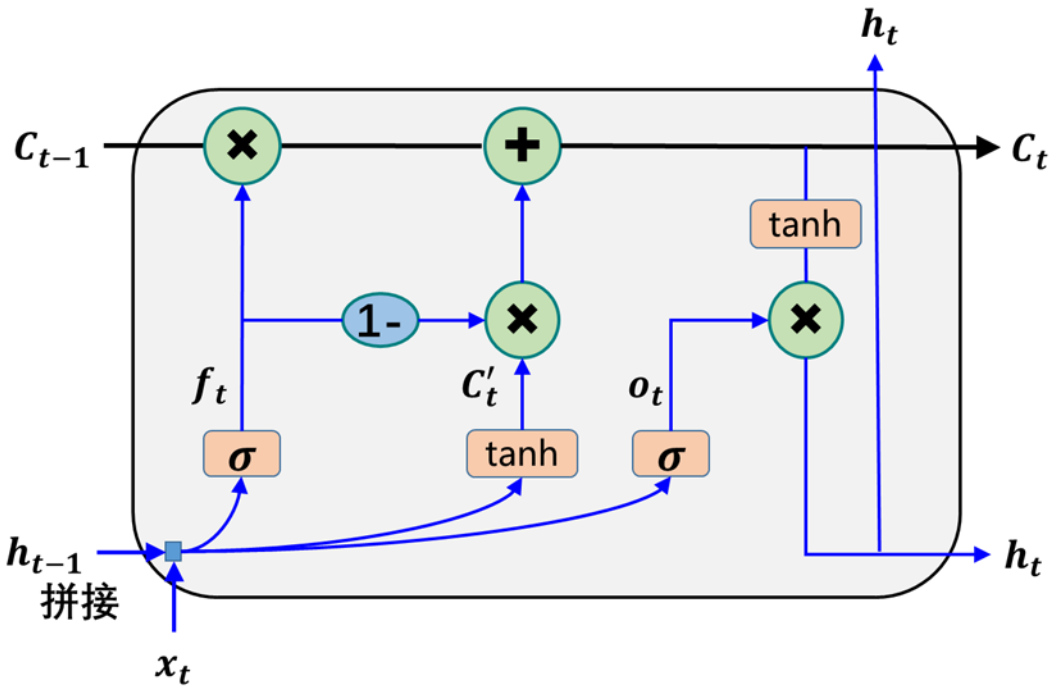
$$f_t = \sigma(W_f \cdot [C_{t-1}, h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [C_{t-1}, h_{t-1}, x_t] + b_i)$$

$$o_t = \sigma(W_o \cdot [C_{t-1}, h_{t-1}, x_t] + b_o)$$

长短期记忆网络的变体

LSTM 的变体2：耦合遗忘和输入单元



C_t从标准LSTM的

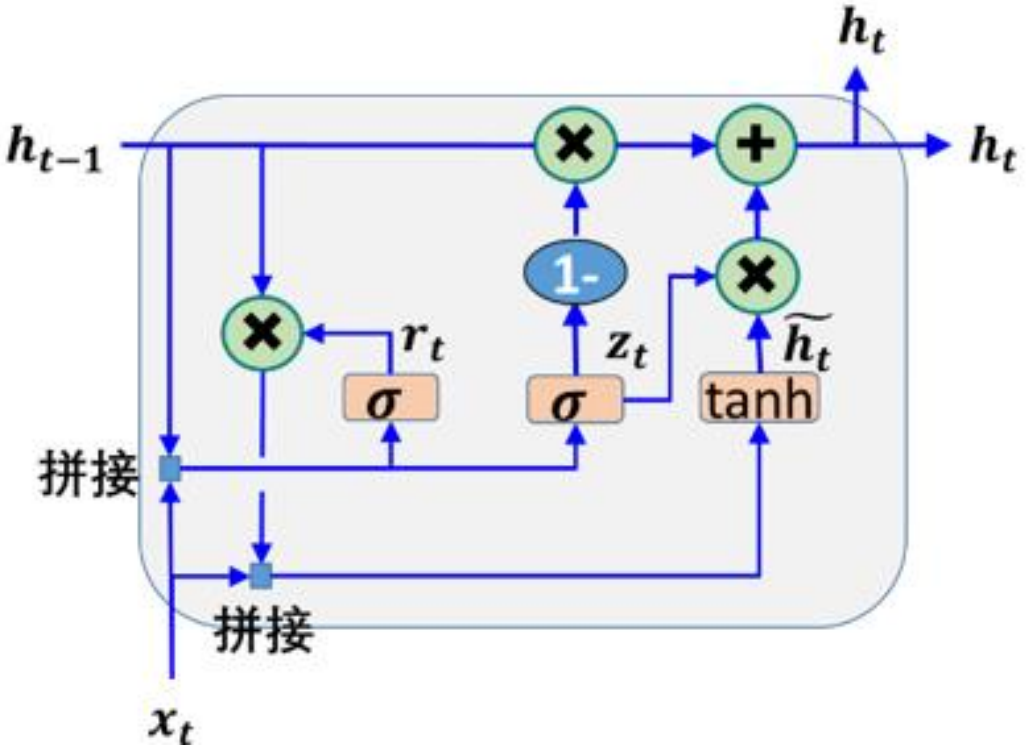
$$C_t = f_t \otimes C_{t-1} + i_t \otimes C'_t \quad \textbf{(8-13)}$$

变为：

$$C_t = f_t \otimes C_{t-1} + (1 - f_t) \otimes C'_t \quad \textbf{(8-14)}$$

长短期记忆网络的变体

LSTM 的变体3: 门控循环单元GRU



对应的计算公式：

$$\tilde{h}_t = \tanh(W \cdot [r_t \otimes h_{t-1}, x_t])$$

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$h_t = z_t \otimes \tilde{h}_t + (1 - z_t) \otimes h_{t-1}$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

建模序列数据的神经网络

本章内容简介

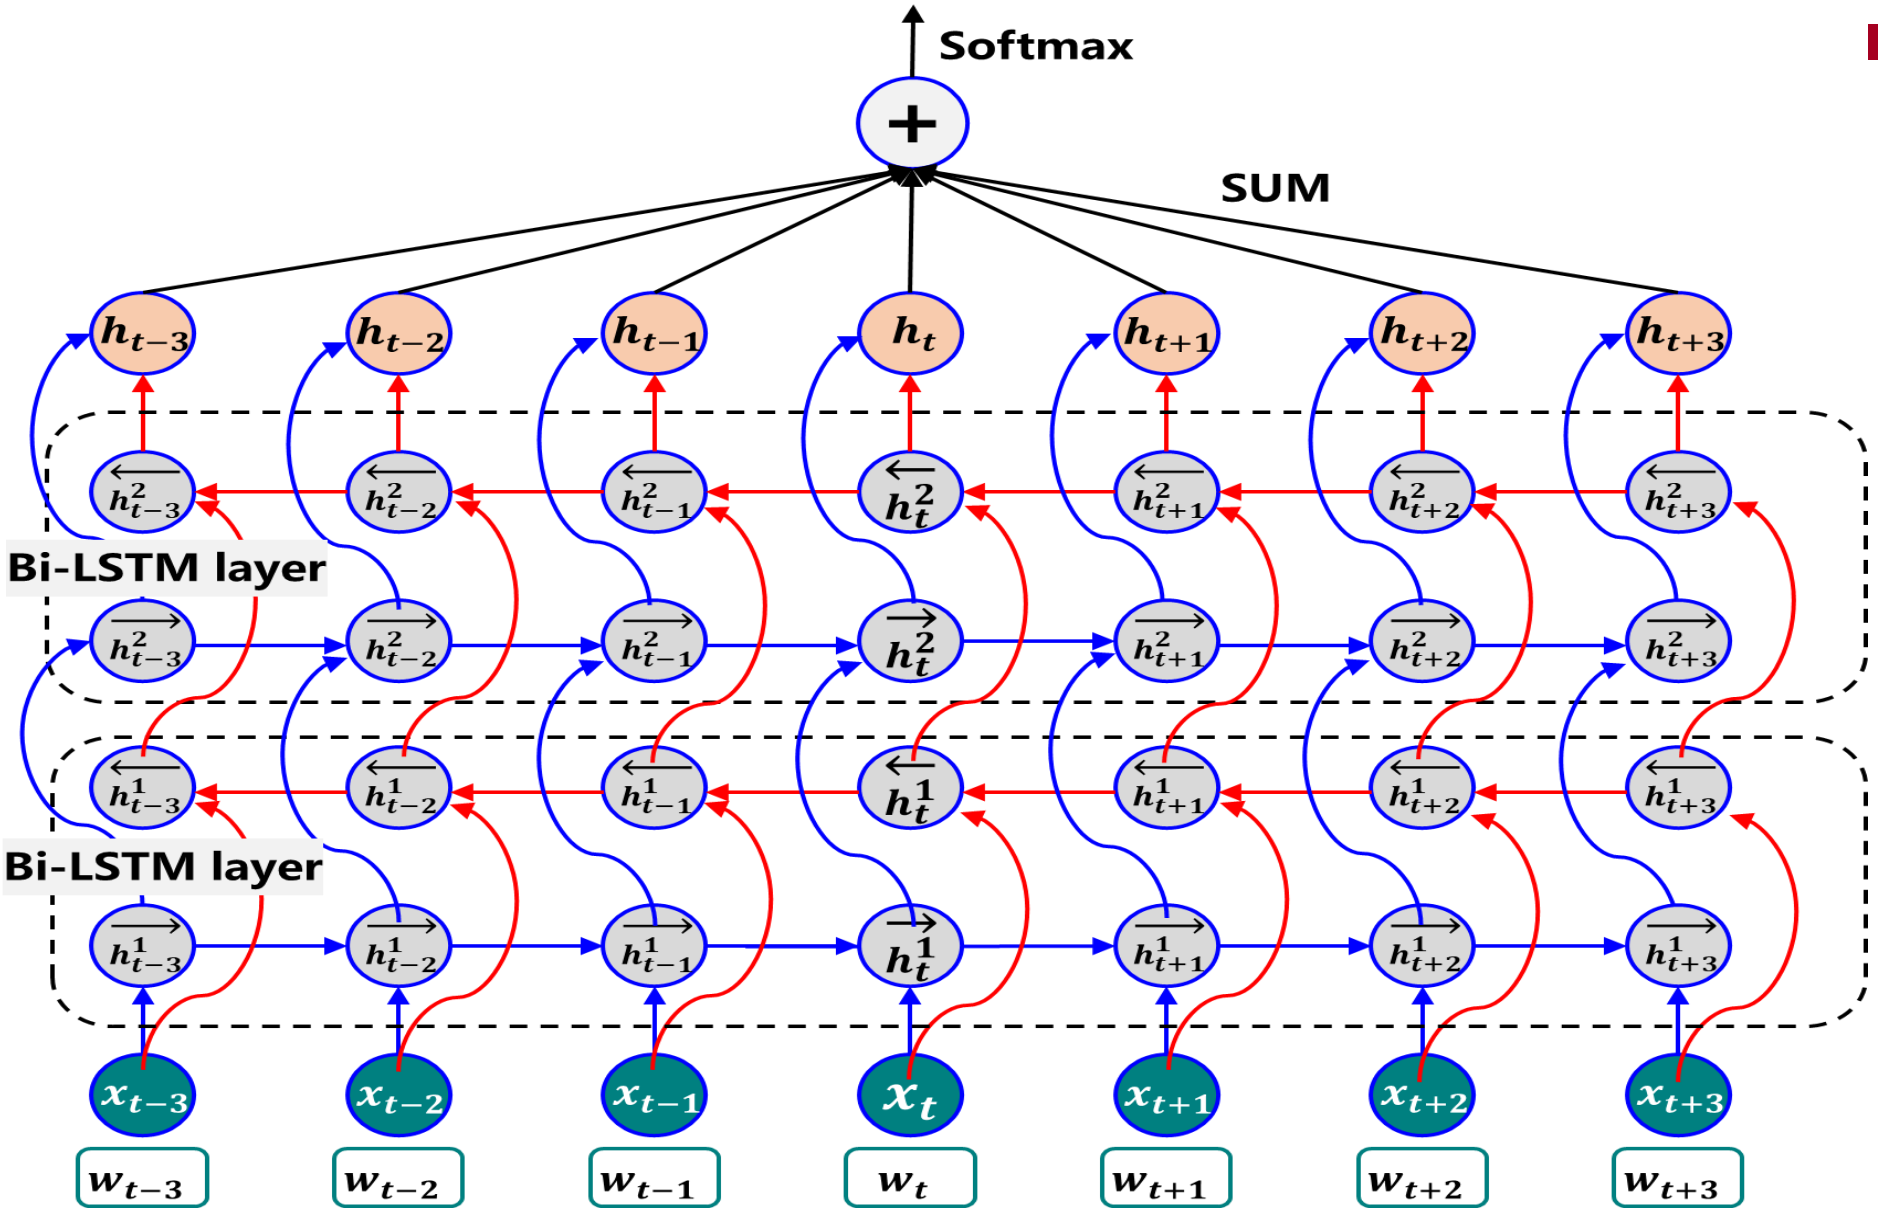
- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- **双向循环神经网络**
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

双向循环神经网络


Softmax
SUM
Bi-LSTM layer
Bi-LSTM layer
h_{t-3} h_{t-2} h_{t-1} h_t h_{t+1} h_{t+2} h_{t+3}
$\overleftarrow{h}^2_{t-3}$ $\overleftarrow{h}^2_{t-2}$ $\overleftarrow{h}^2_{t-1}$ $\overleftarrow{h}^2_t$ $\overleftarrow{h}^2_{t+1}$ $\overleftarrow{h}^2_{t+2}$ $\overleftarrow{h}^2_{t+3}$
$\overrightarrow{h}^2_{t-3}$ $\overrightarrow{h}^2_{t-2}$ $\overrightarrow{h}^2_{t-1}$ $\overrightarrow{h}^2_t$ $\overrightarrow{h}^2_{t+1}$ $\overrightarrow{h}^2_{t+2}$ $\overrightarrow{h}^2_{t+3}$
$\overleftarrow{h}^1_{t-3}$ $\overleftarrow{h}^1_{t-2}$ $\overleftarrow{h}^1_{t-1}$ $\overleftarrow{h}^1_t$ $\overleftarrow{h}^1_{t+1}$ $\overleftarrow{h}^1_{t+2}$ $\overleftarrow{h}^1_{t+3}$
$\overrightarrow{h}^1_{t-3}$ $\overrightarrow{h}^1_{t-2}$ $\overrightarrow{h}^1_{t-1}$ $\overrightarrow{h}^1_t$ $\overrightarrow{h}^1_{t+1}$ $\overrightarrow{h}^1_{t+2}$ $\overrightarrow{h}^1_{t+3}$
x_{t-3} x_{t-2} x_{t-1} x_t x_{t+1} x_{t+2} x_{t+3}
w_{t-3} w_{t-2} w_{t-1} w_t w_{t+1} w_{t+2} w_{t+3}

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- **注意力机制**
- 机器翻译模型Transformer
- 递归神经网络及其变体

注意力机制

注意力机制（Attention Mechanism）概述



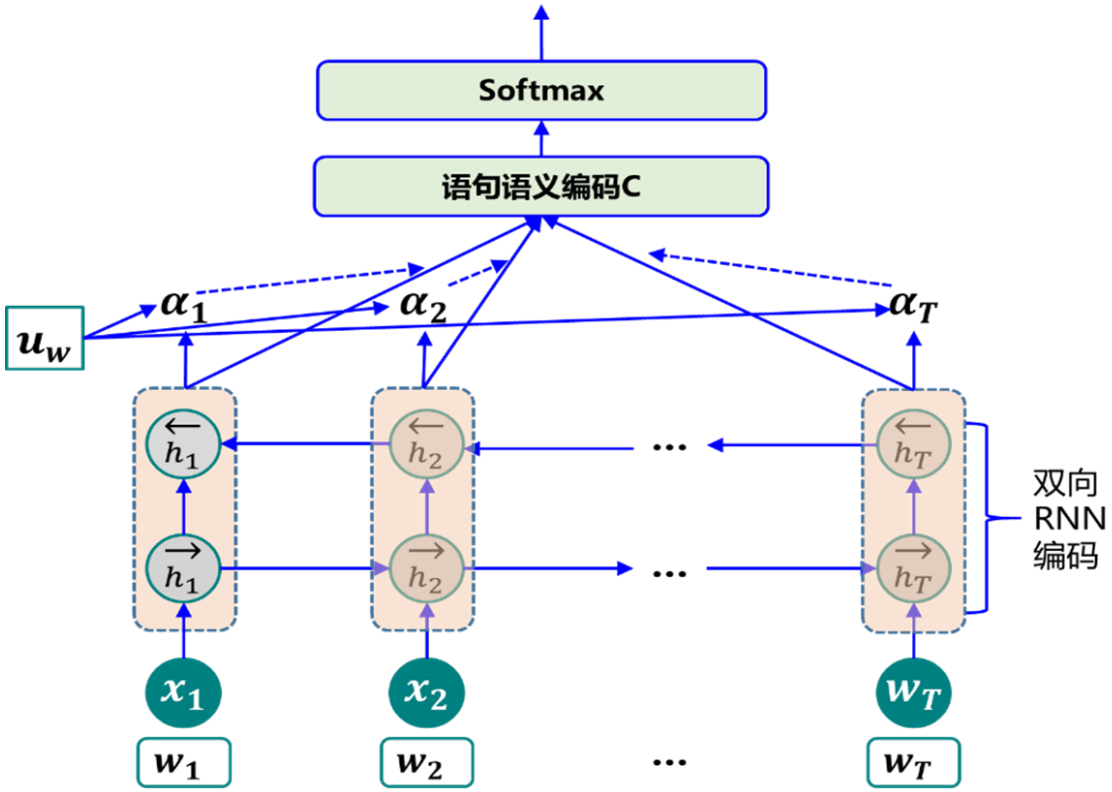
- 注意力机制模型首先应用在图像处理领域，如Google mind团队在循环神经网络模型上使用了注意力机制进行图像分类，使注意力机制得到研究人员的重视。
- 后来Bahdanau等人将注意力机制引入到机器翻译中。此外近年来这种机制也逐渐引入到自然语言处理领域的各种任务中，如问答系统、自动文摘、文本分类等。

Mnih, V., Heess, N., Graves, A., et al. Recurrent models of visual attention. NIPS 2014

Bahdanau, D., Cho, K., & Bengio, Y. Neural machine translation by jointly learning to align and translate. NIPS 2014

注意力机制

注意力机制计算原理



1) 首先，将拼接形式的隐含层节点h_t使用tanh层**进行变换**：

$$\theta_t = tanh(W_w h_t + b_w)$$

2) **其次，计算每个词的权重：**

$$\alpha_t = \frac{exp(\theta_t{}^T u_w)}{\sum_{t=1}^{T} exp(\theta_t{}^T u_w)}$$

其中，u_w为上下文向量，α_t为不同词的注意力概率分布。

3) **得到整个语句的语义编码C：**

$$C = \sum_{t=1}^{T} \alpha_t h_t$$

多选题 1分

设置

36

下列哪种模型更适合序列建模与预测?

A 循环神经网络RNN

B 卷积神经网络CNN

C 多层感知机

D 长短时记忆网络LSTM

提交

单选题 1分

设置

37

标准RNN (循环神经网络) 无法处理更长的上下文间隔，即长期依赖问题。为此Hochreiter & Schmidhuber (1997) 提出一种特殊的RNN类型，其通过特殊的结构设计来避免长期依赖问题。并被 Alex Graves进行了改良和推广。这种改进的模型是

A 长短期记忆网络LSTM

B 卷积神经网络CNN

C 多层感知机MLP

D 受限玻尔兹曼机

提交

多选题 1分

设置

38

下列关于LSTM说法正确的是

A LSTM用三个控制门记忆长期状态

B 忘记门控制保存之前的长期状态

C 输入门控制更新长期状态

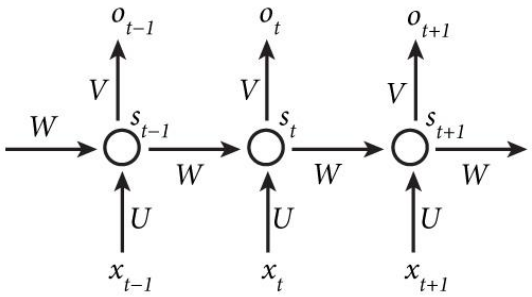
D 输出门控制是否把长期状态作为当前的LSTM的输出

提交

多选题 1分

设置

图中给出了循环神经网络RNN的三个时间步，即x_{t-1}, x_t, x_{t+1}的计算关系图。则下列说法中正确的有



A 在RNNs中，每一步(每一层)都共享参数U，V，W

B 在RNNs中，每一步(每一层)都不共享参数U，V，W

C 在计算当前时间步x_t时，只是利用到了上一时间步的信息，不会利用当前步的输入

D 在计算当前时间步x_t时，既利用到了上一时间步的信息，也用到了当前步的输入

提交

单选题 1分

设置

40

下列说法错误的是

A 标准RNN隐藏层只有一个状态h，对短期输入敏感，但难以捕捉长期上下文

B LSTM在隐藏层上增加了一个长期状态c (cell state)，用于保存长期状态。C也被称为单元状态或细胞状态

C LSTM只有长期状态，没有隐藏状态

D LSTM既有长期状态，也有隐藏状态

提交

单选题 1分

设置

41

下列关于循环神经网络(Recurrent Neural Networks）说法错误的是

A 同一隐藏层之间的节点有连接

B 同一隐藏层之间的节点没有连接

C 隐藏层的输入不仅可能包括输入层的输出，还有可能包括上一时刻隐藏层的输出

D 网络会对之前时刻的信息进行记忆并应用于当前输出的计算中

提交

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

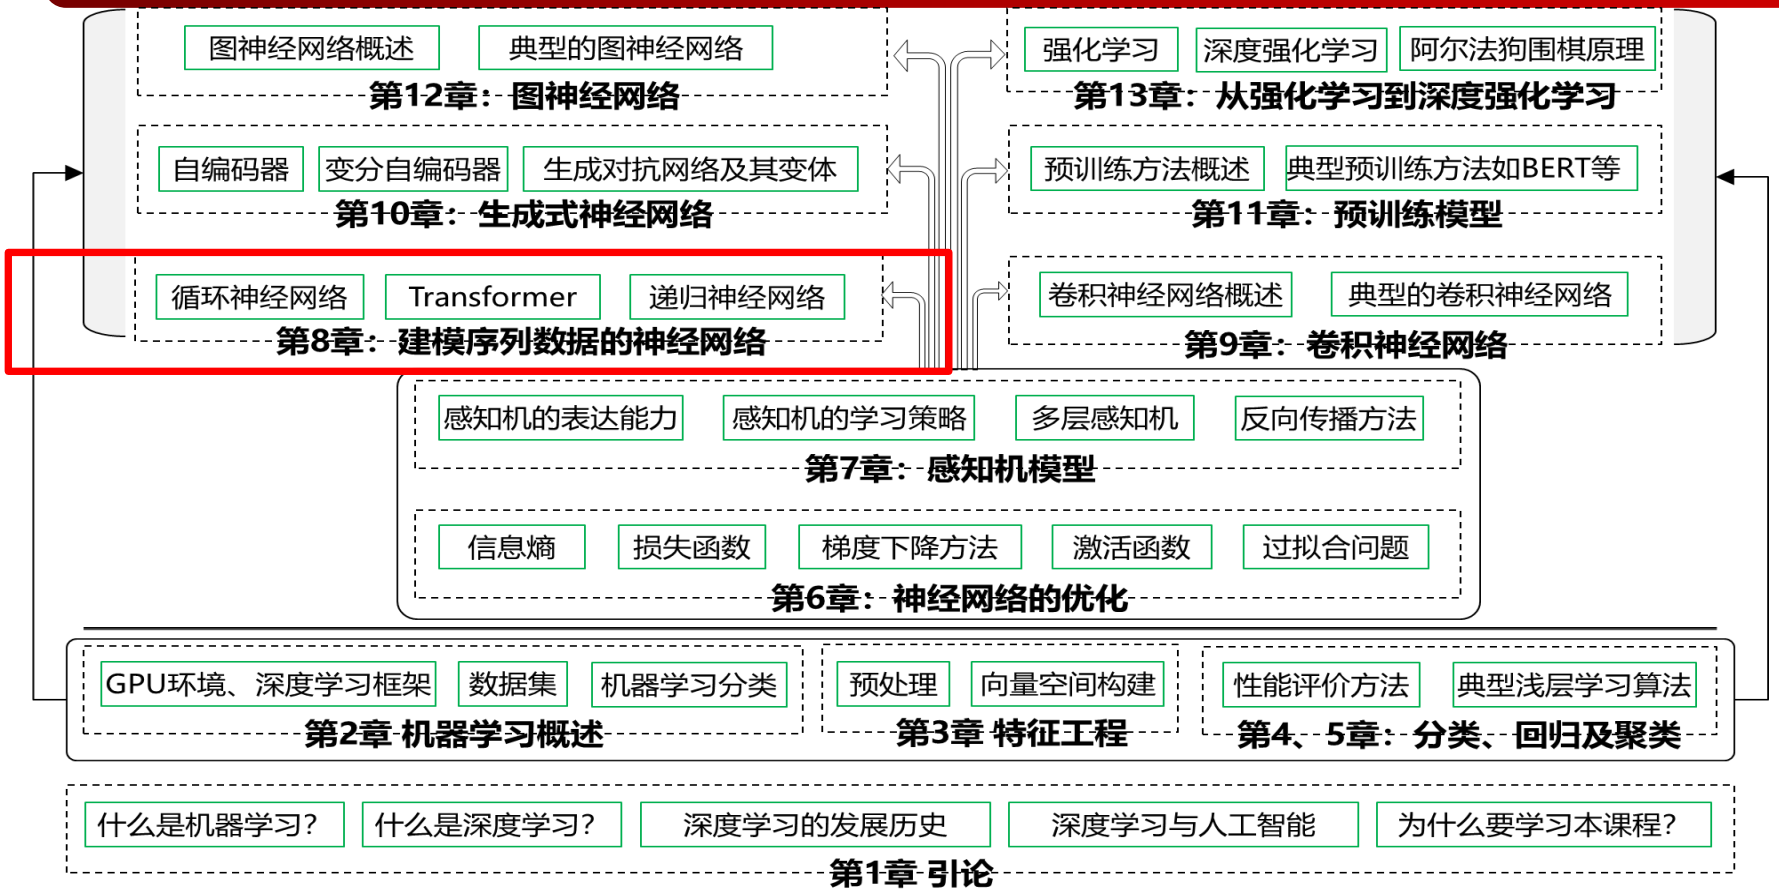
建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- **机器翻译模型Transformer**
- 递归神经网络及其变体

建模序列数据的神经网络

在《深度学习基础》教材知识体系中的位置



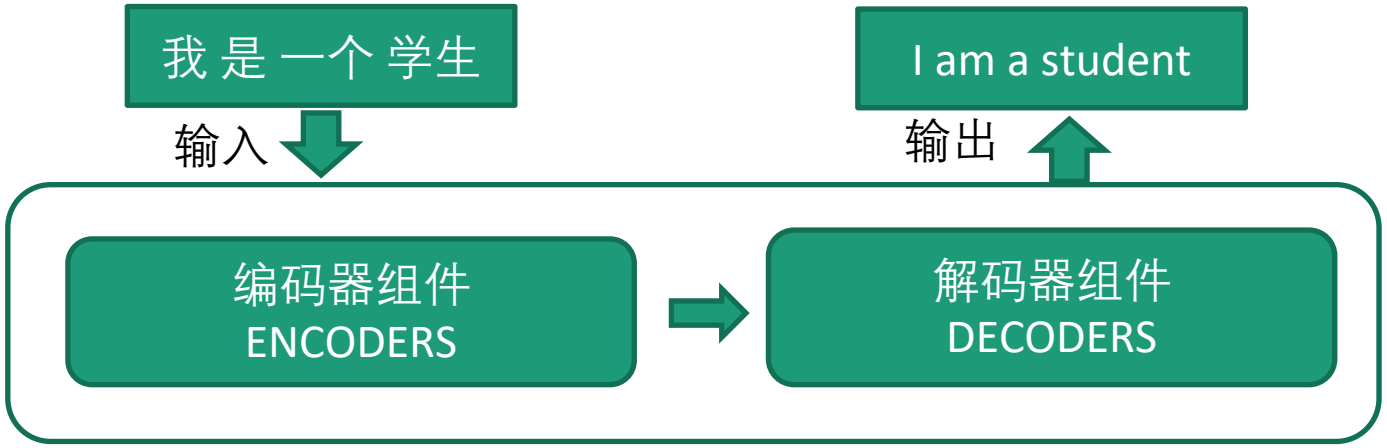
主编：刘远超 出版社:高等教育出版社；出版时间:2023年09月。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

机器翻译模型Transformer

Transformer模型概述

■ Transformer 是谷歌团队于 2017 年在论文《Attention is All You Need》[1]中提出的一种**带有自注意力机制的编码器-解码器（seq2seq）**神经网络。Transformer模型用于机器翻译任务[1]，达到了当时的SOTA效果。



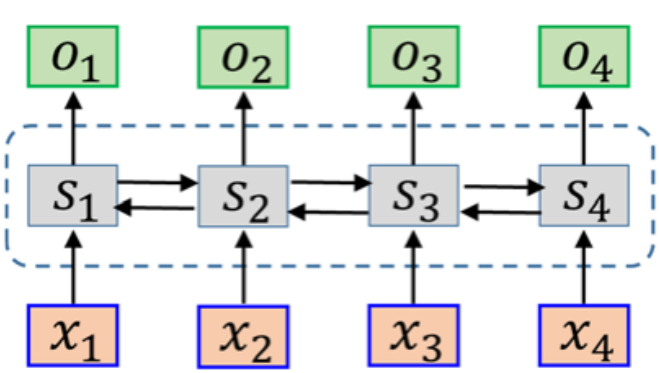
■2018年，谷歌又将Transformer应用在其推出的预训练模型**BERT** [2]上，在11项NLP任务（如自动问答、语言推理等）上取得了SOTA的效果。这里，**BERT取得成功的一个重要因素是Transformer的应用**。

[1] Vaswani A, Shazeer N, Parmar N, et al. ***Attention is all you need*** *[C]//Advances in Neural Information Processing Systems. 2017: 5998-6008*

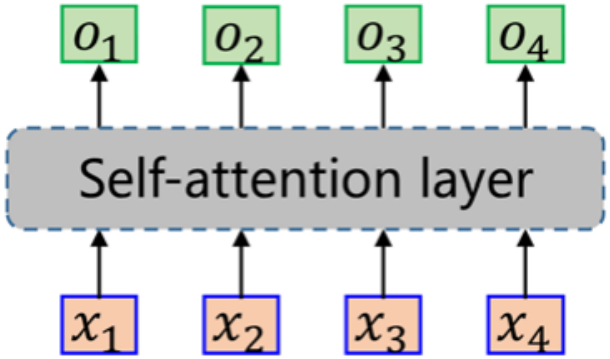
[2] Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova. ***BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding****. 2018. https://arxiv.org/abs/1810.04805*

机器翻译模型Transformer

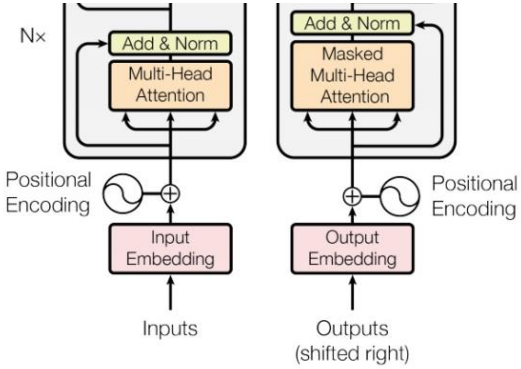
Transformer vs. RNN



(a) 循环神经网络



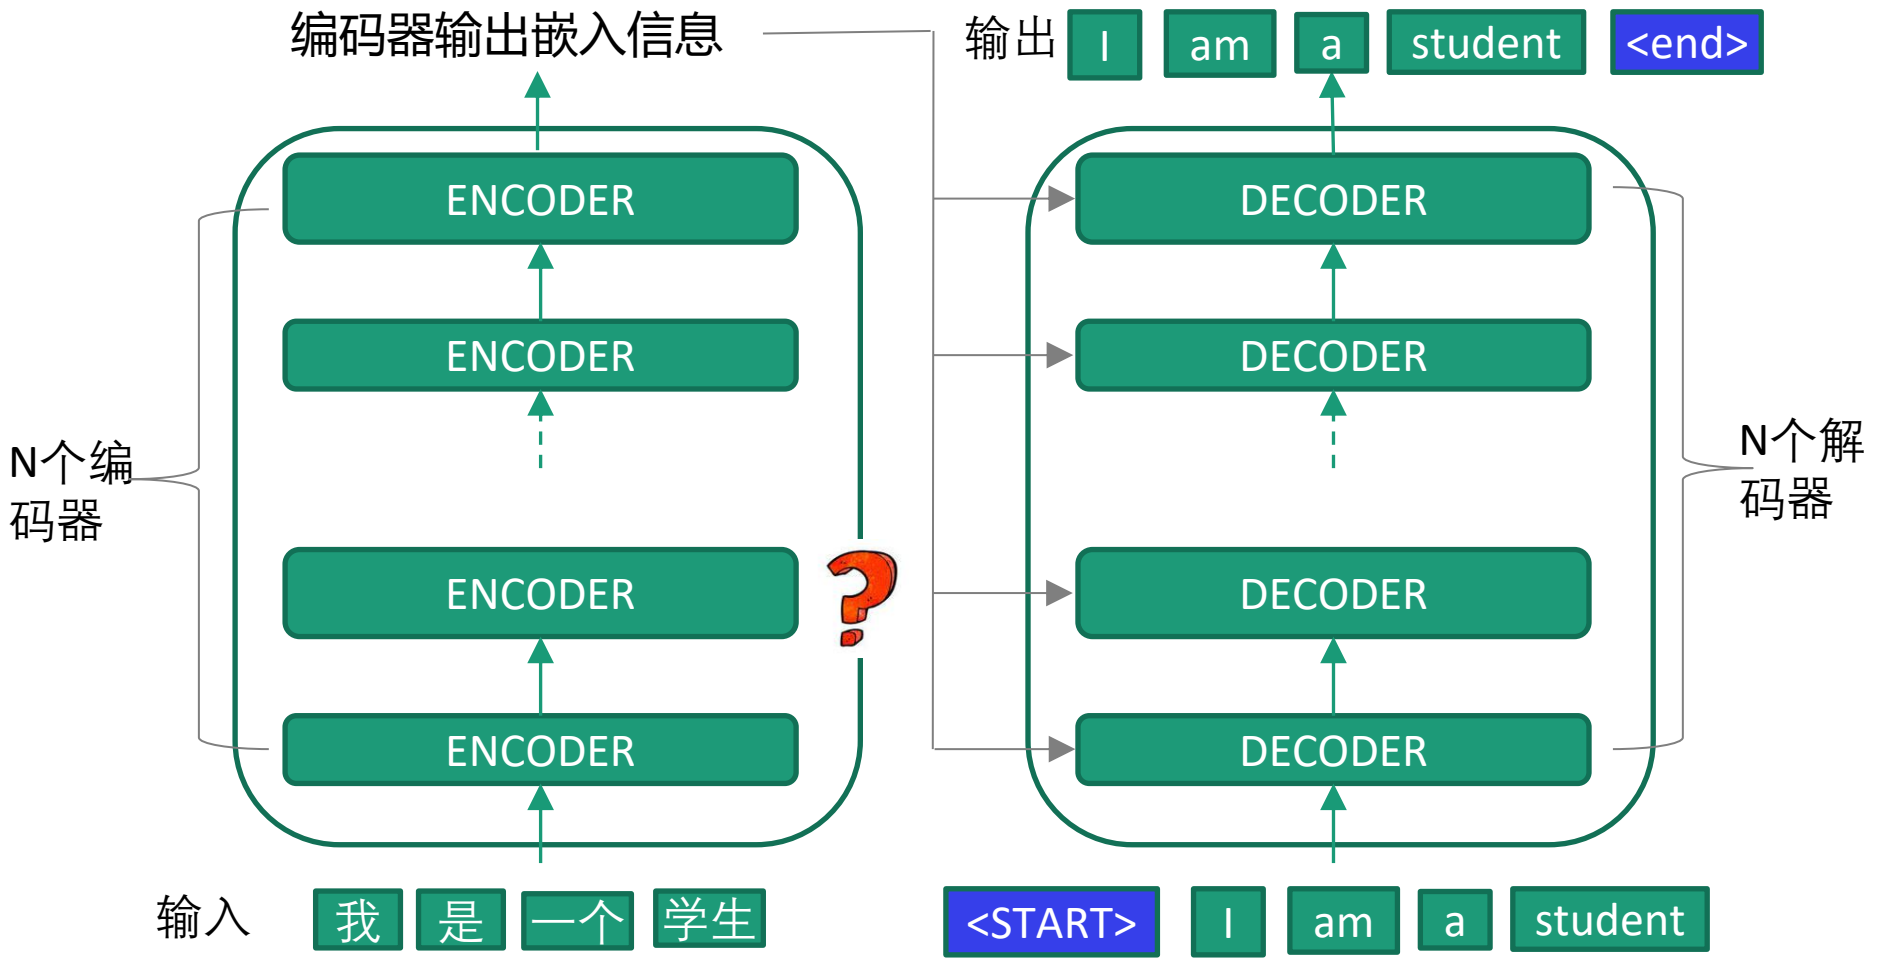
(b) Transformer



- **RNN**(Recurrent Neural Network)存在**时间序列依赖**的问题，即是一种循环网络，其训练上是基于迭代的处理模式。因而上一个时间步（例如输入语句中的词）处理完毕以后，才能处理下一个时间步（例如输入语句中的下一个词）。
- 而**Transformer的训练可以实现并行，即序列中的单词可以同时训练，因而效率较高。其引入位置编码来处理单词的顺序。**

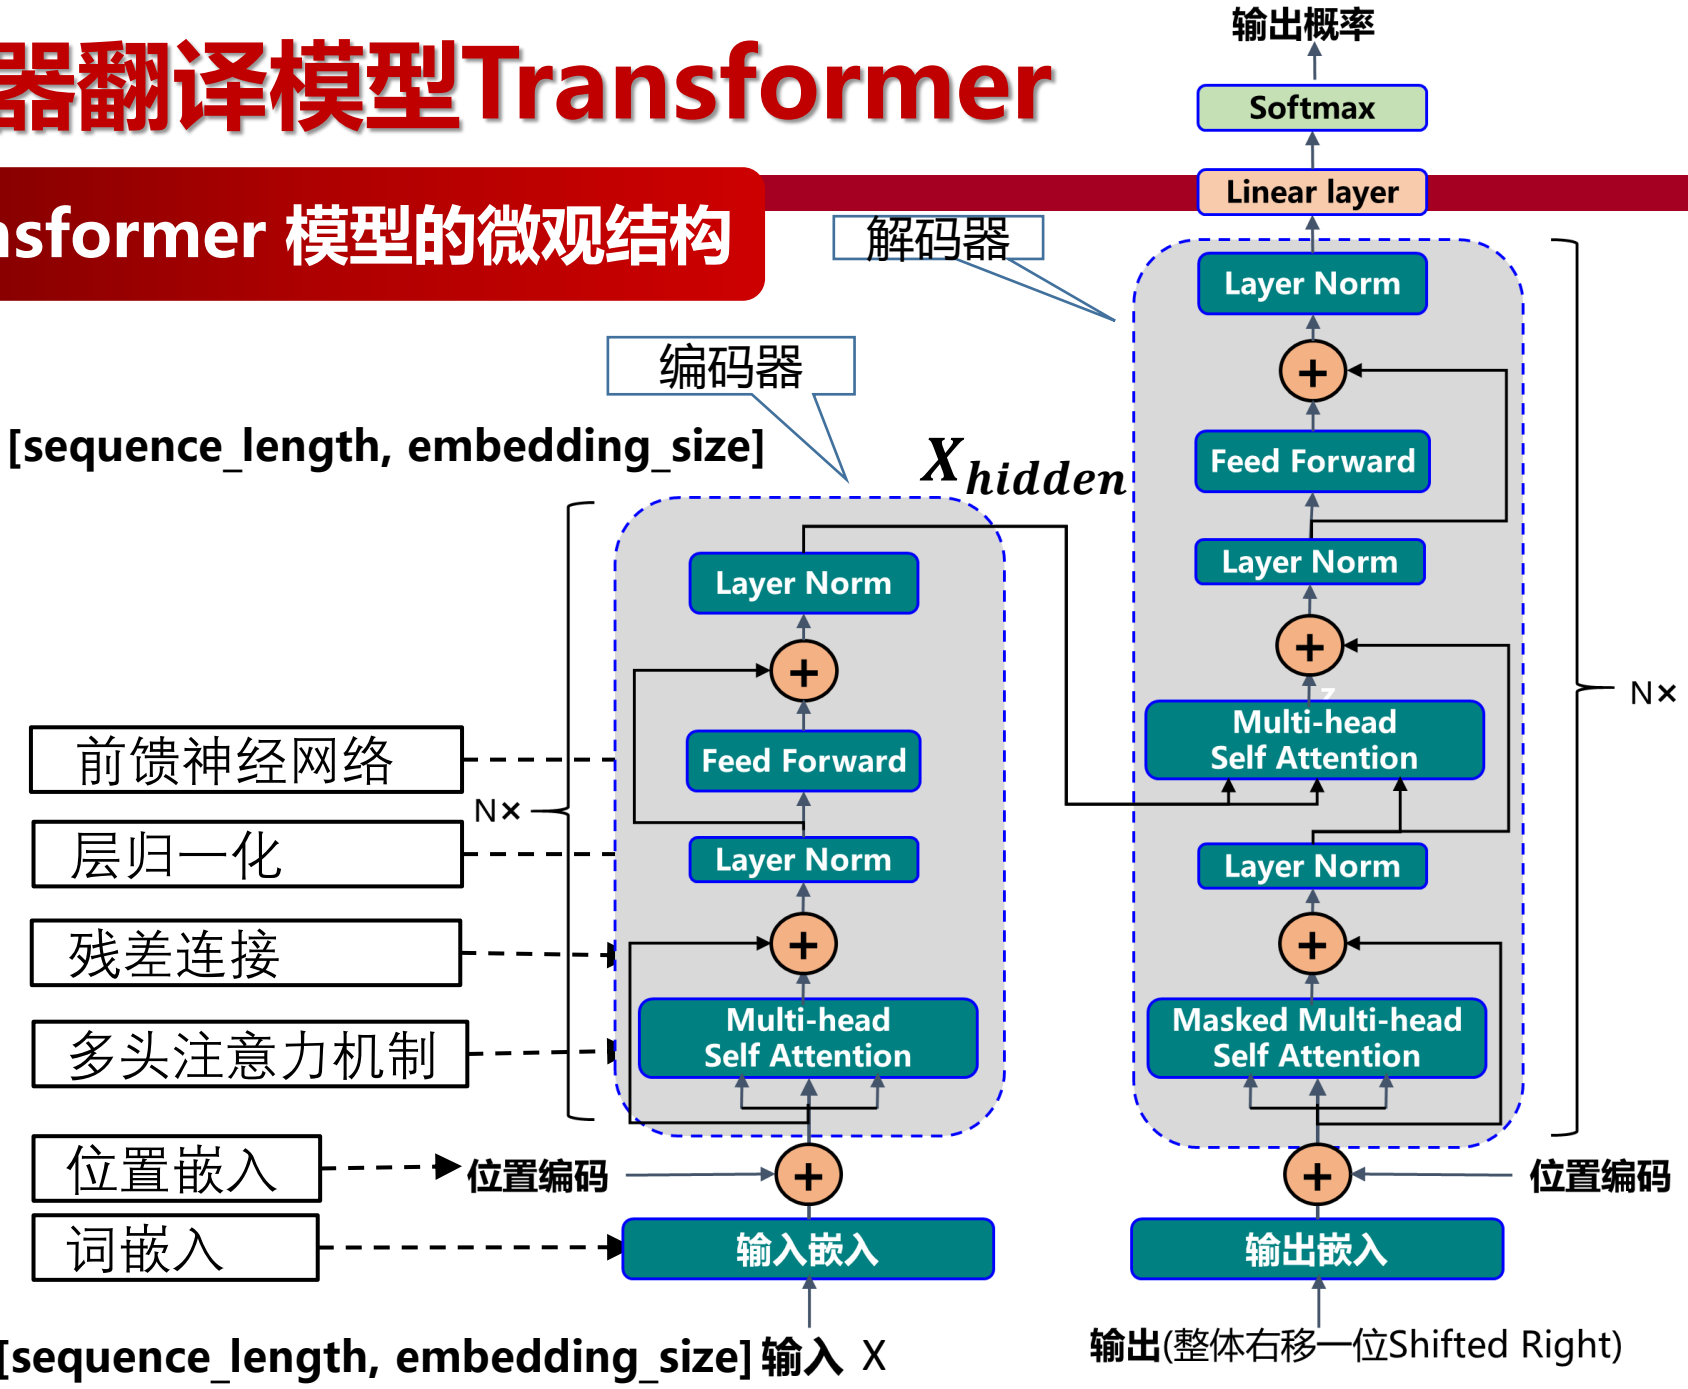
机器翻译模型Transformer

Transformer 模型的宏观结构



机器翻译模型Transformer

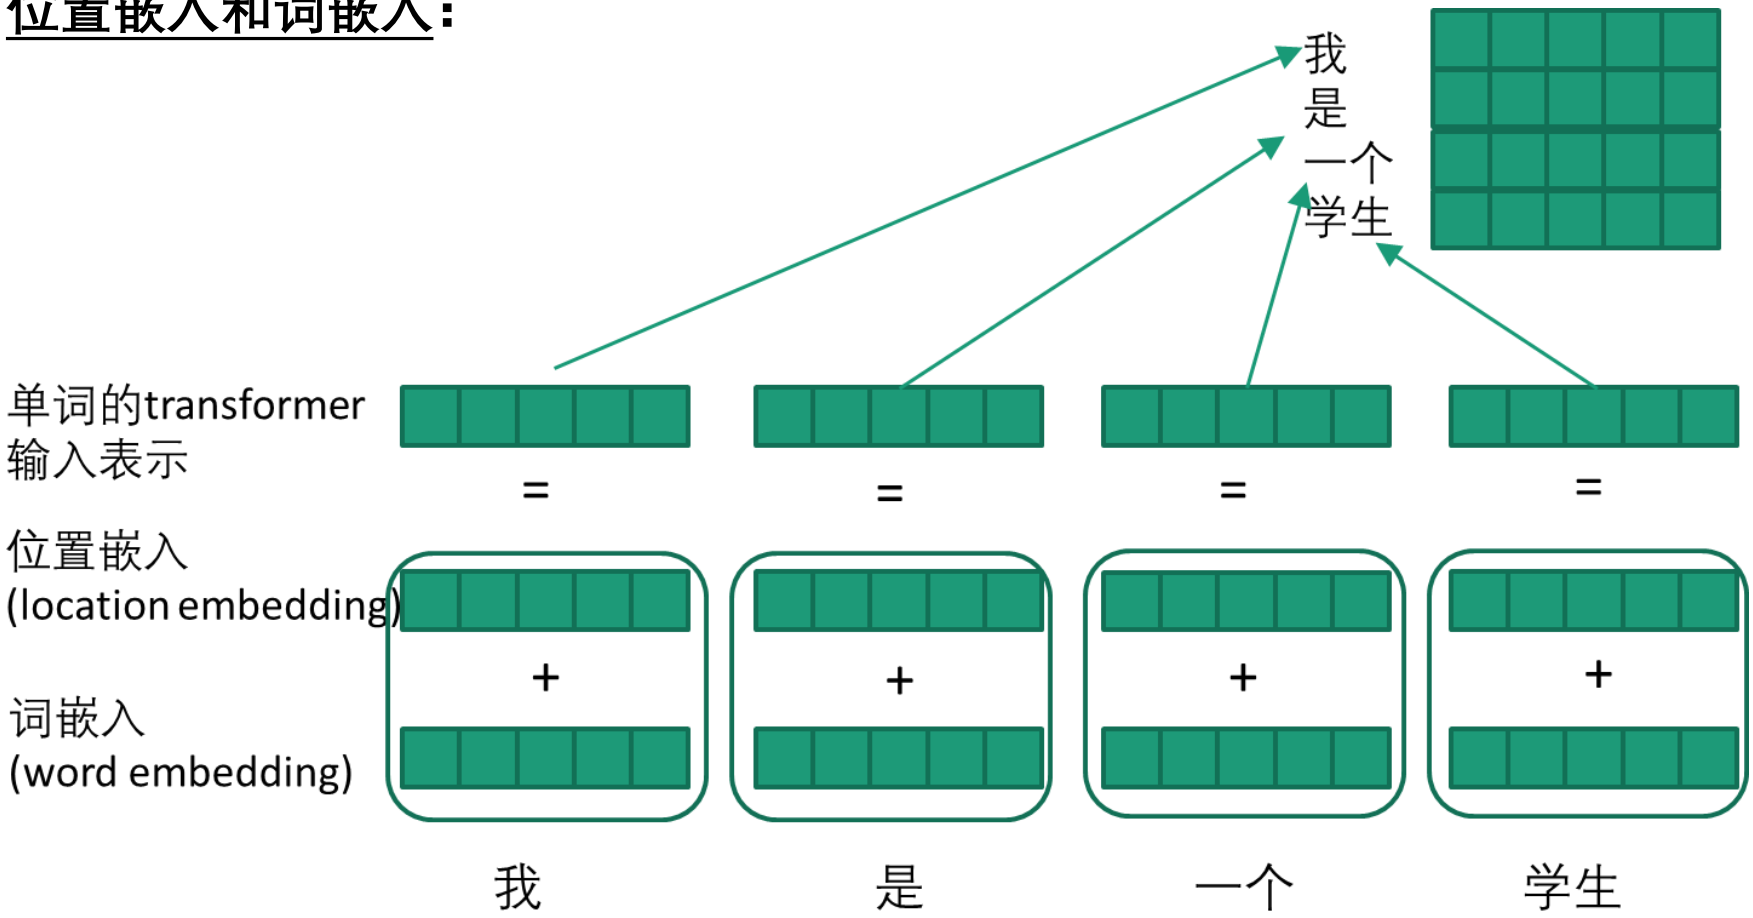
Transformer 模型的微观结构



机器翻译模型Transformer

Transformer编码器工作流程

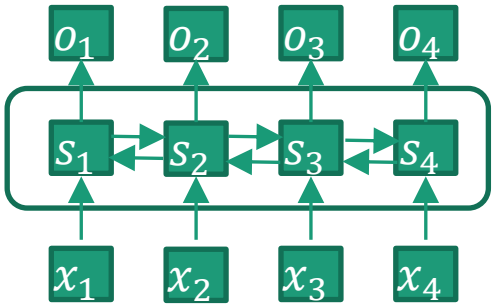
位置嵌入和词嵌入：



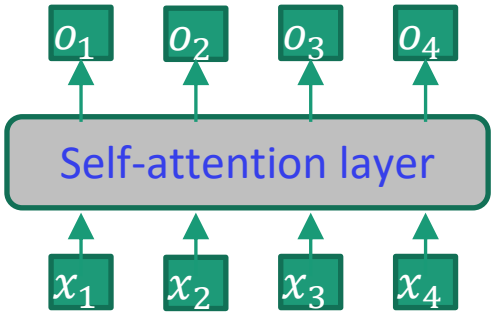
机器翻译模型Transformer

Transformer编码器工作流程

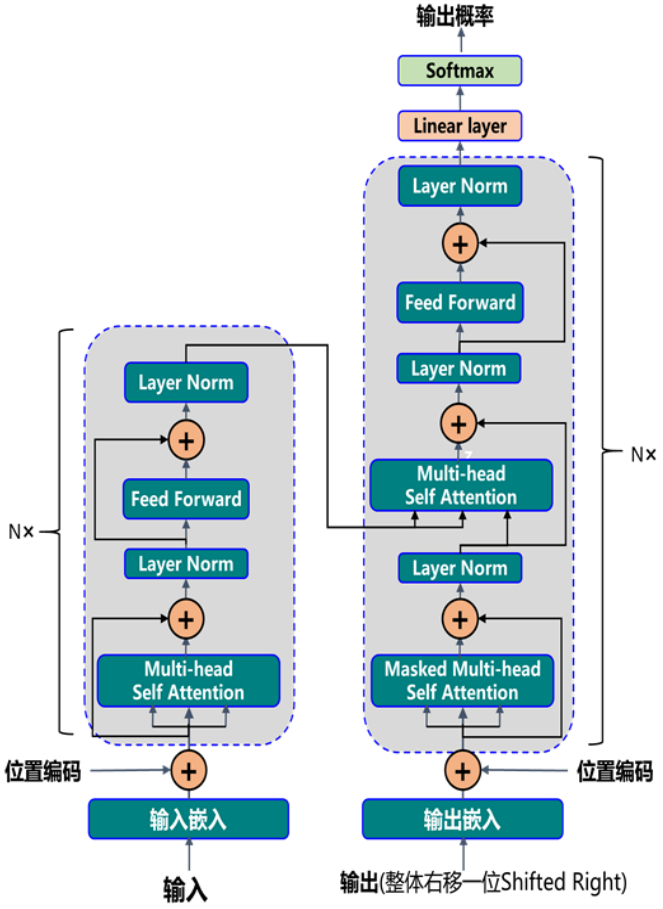
位置嵌入PE(Position Embedding)如何得到？



RNN



Transformer



■ Transformer采用如下公式来计算PE：

$$PE_{(pos,\ 2i)} = \sin(pos/10000^{2i/d_{model}})$$
$$PE_{(pos,\ 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$

其中，pos表示单词在句子中的位置，i 用于表示维度。

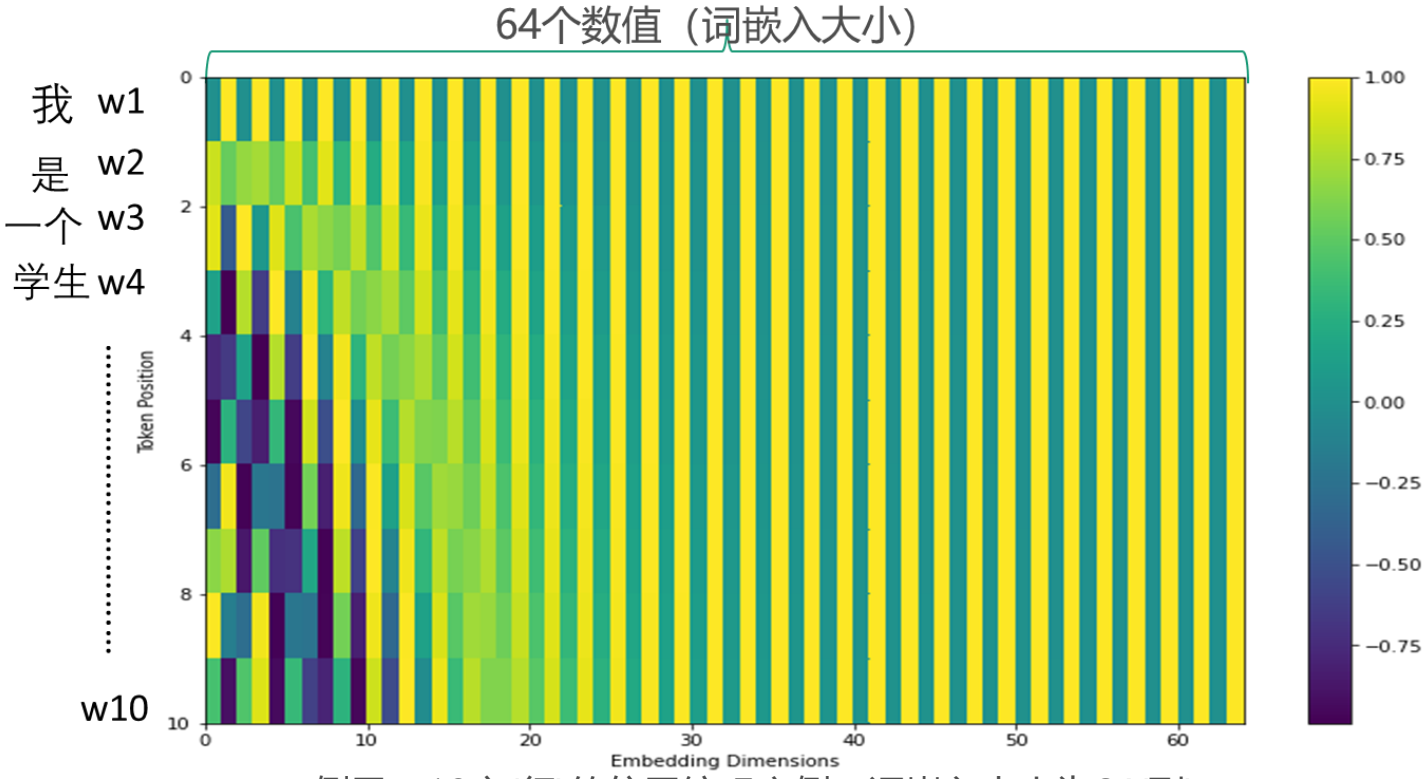
■ 当然也可以有其它选项，如通过训练学习得到PE（注：思维创新）

机器翻译模型Transformer

Transformer编码器工作流程

位置嵌入PE举例：

$$PE_{(pos,\ 2i)} = \sin(pos/10000^{2i/d_{model}})$$
$$PE_{(pos,\ 2i+1)} = \cos(pos/10000^{2i/d_{model}})$$



例子：10字(行)的位置编码实例，词嵌入大小为64(列)。

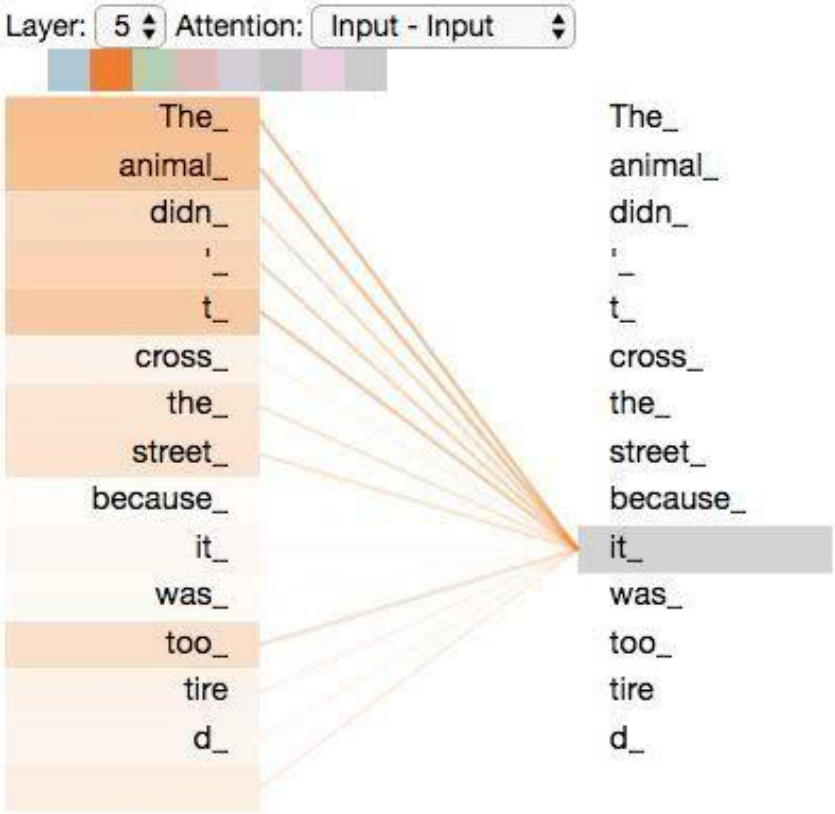
图片来源：https://github.com/jalammar/jalammar.github.io/blob/master/notebookes/transformer/transformer_positional_encoding_graph.ipynb

机器翻译模型Transformer

Transformer编码器工作流程

自注意力机制的作用如何？先看一个例子：

The animal didn't cross the street because it was too tired

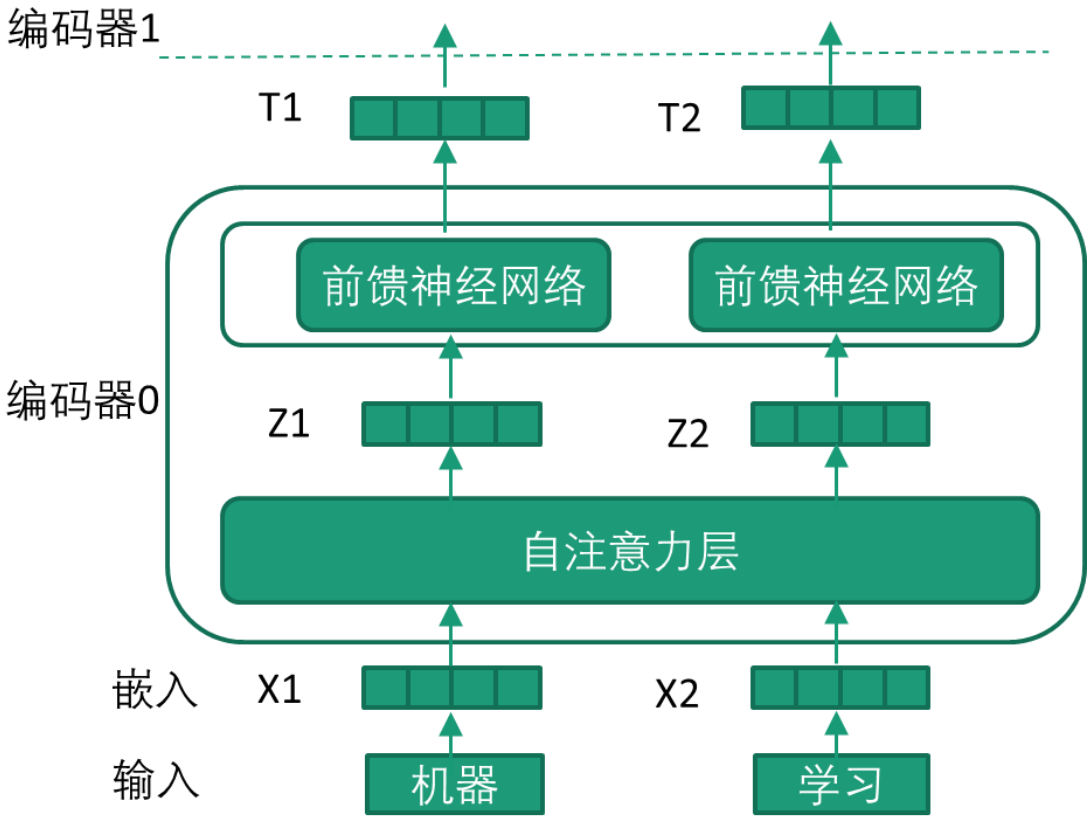


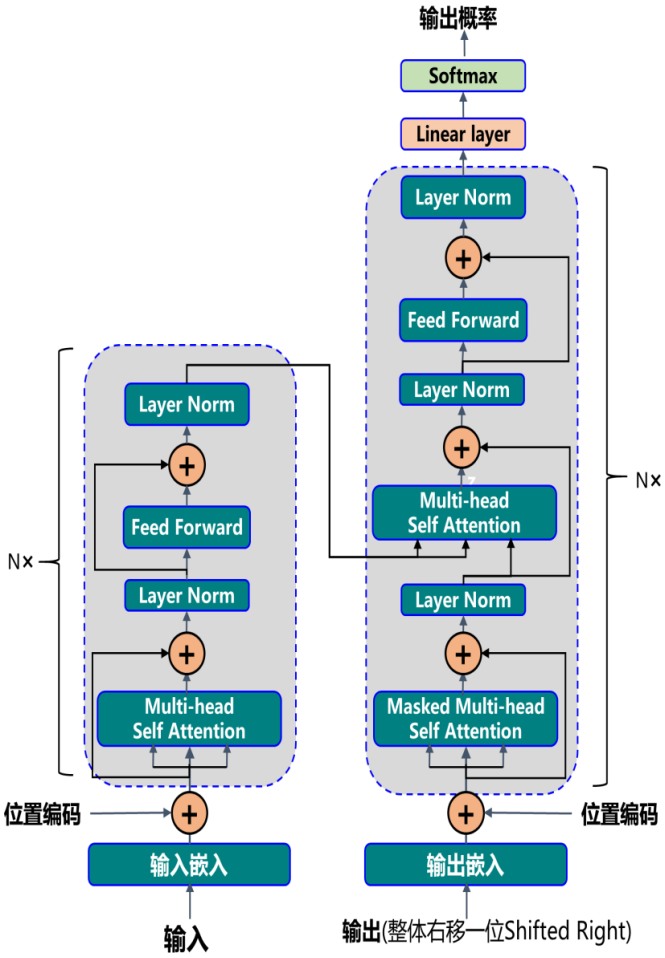
https://jalammar.github.io/illustrated-transformer/

机器翻译模型Transformer

Transformer编码器工作流程

那么自注意力机制是如何实现的？举个简单的例子：



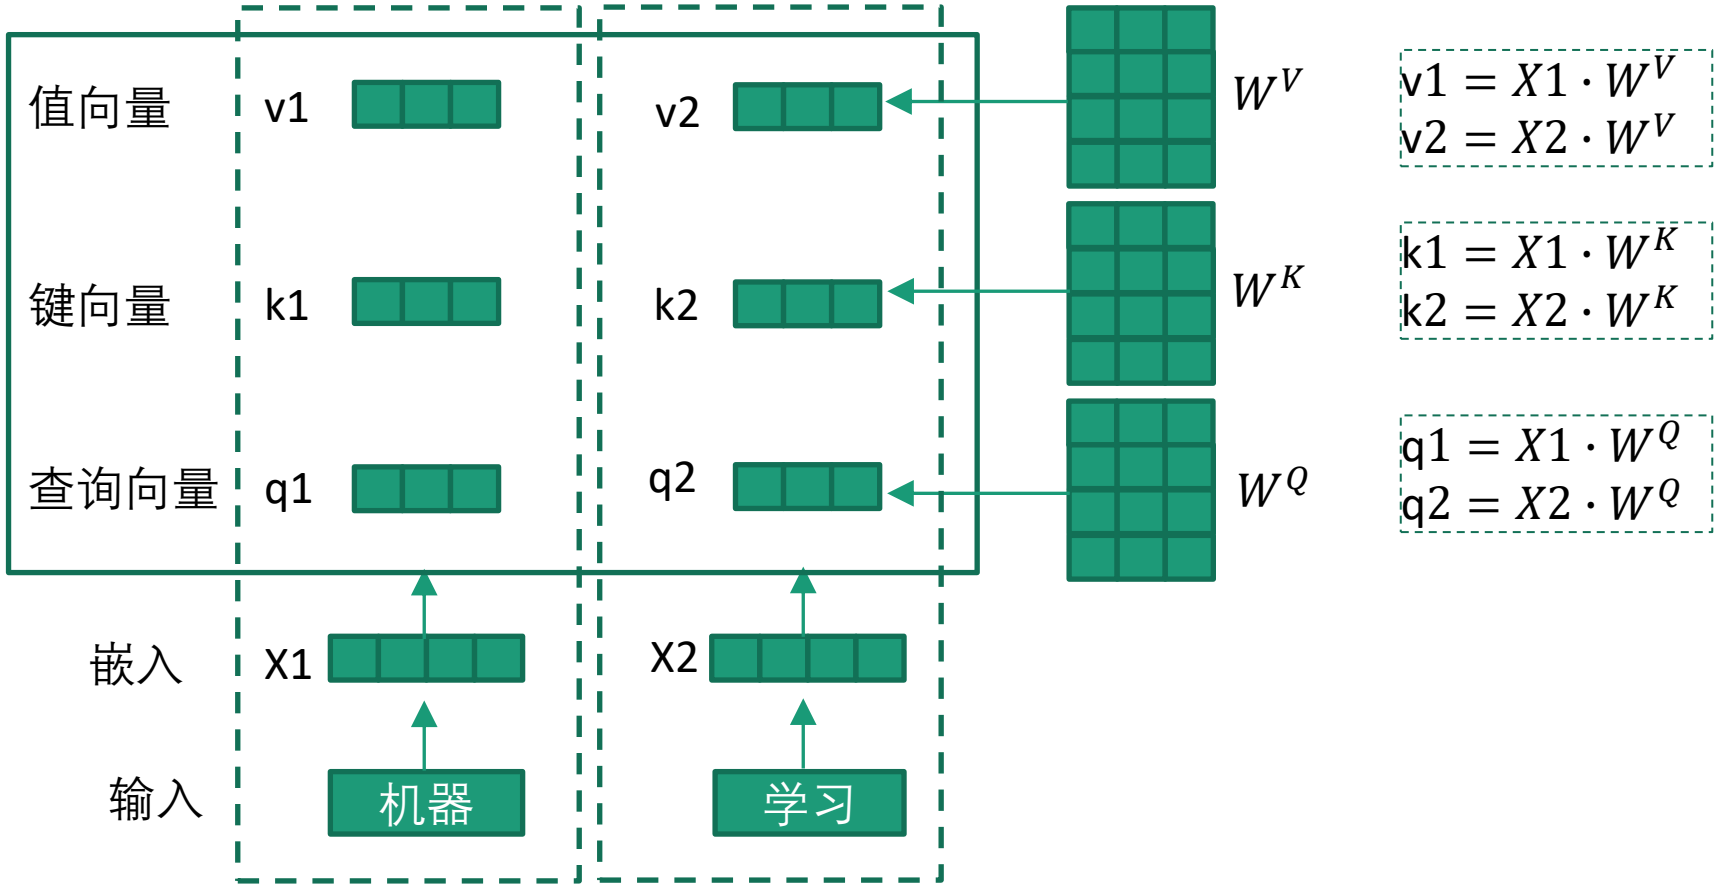


假设输入语句为“机器学习”，如何求得图中的Z?

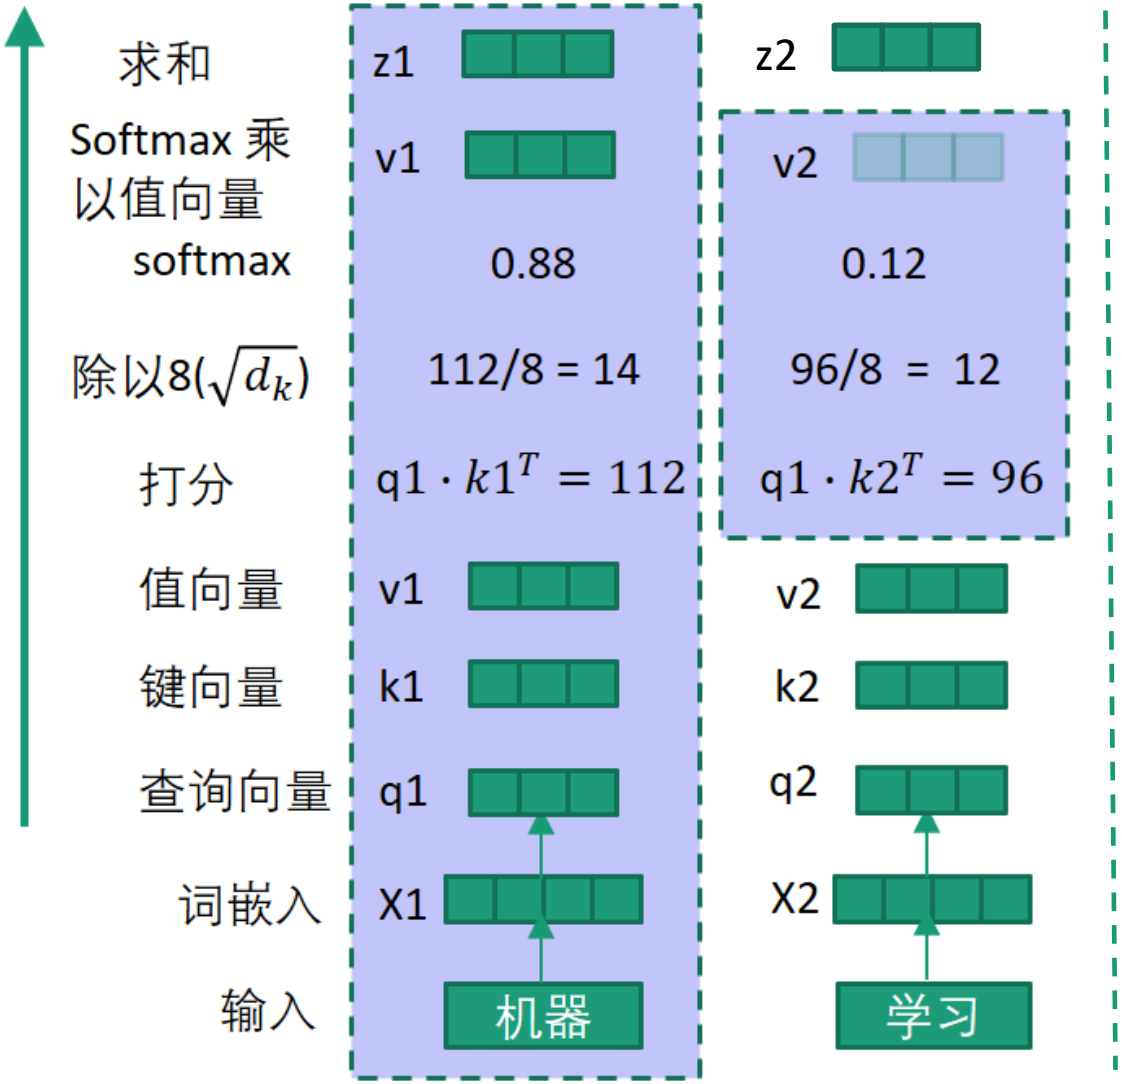
机器翻译模型Transformer

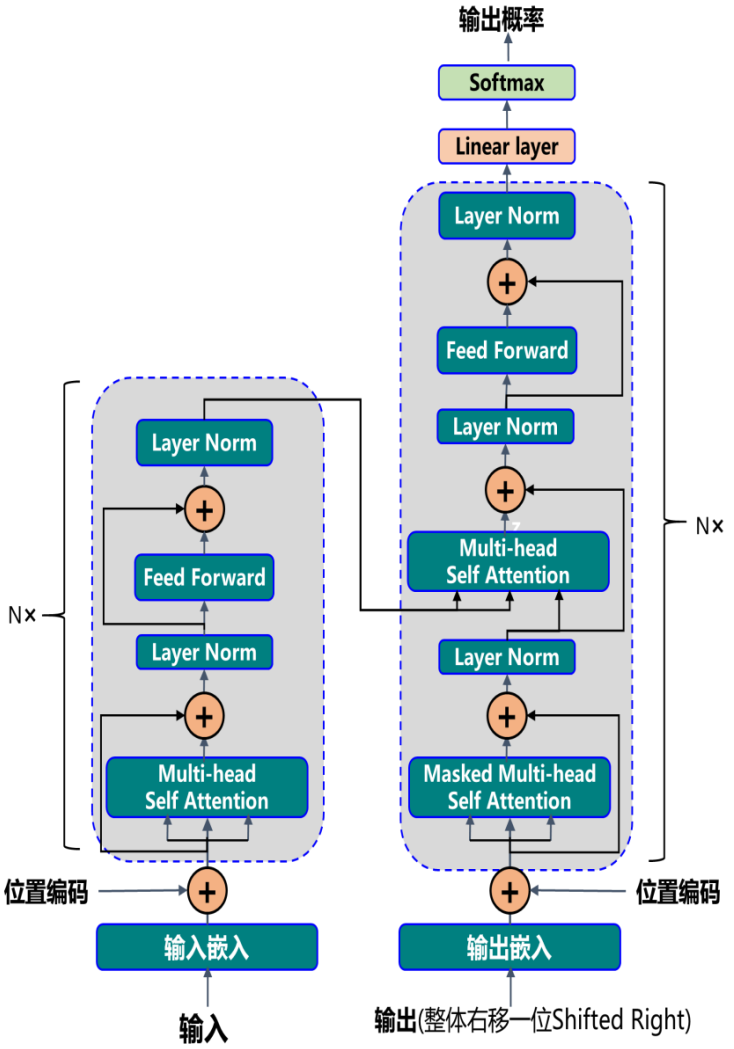
Transformer编码器工作流程

自注意力机制如何实现—如何求得Z?



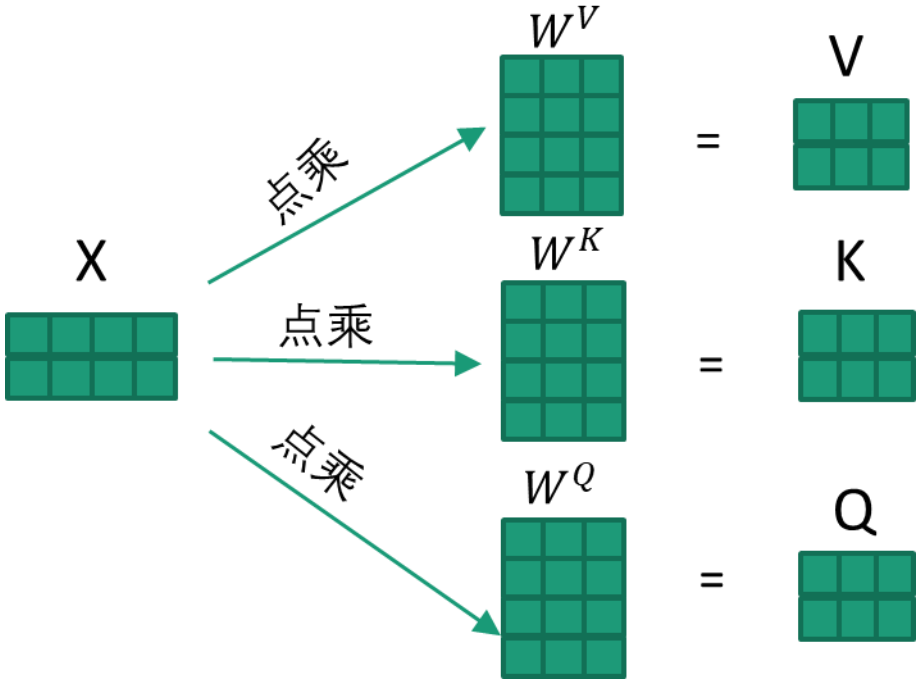
自注意力机制如何实现—如何求得Z?





机器翻译模型Transformer

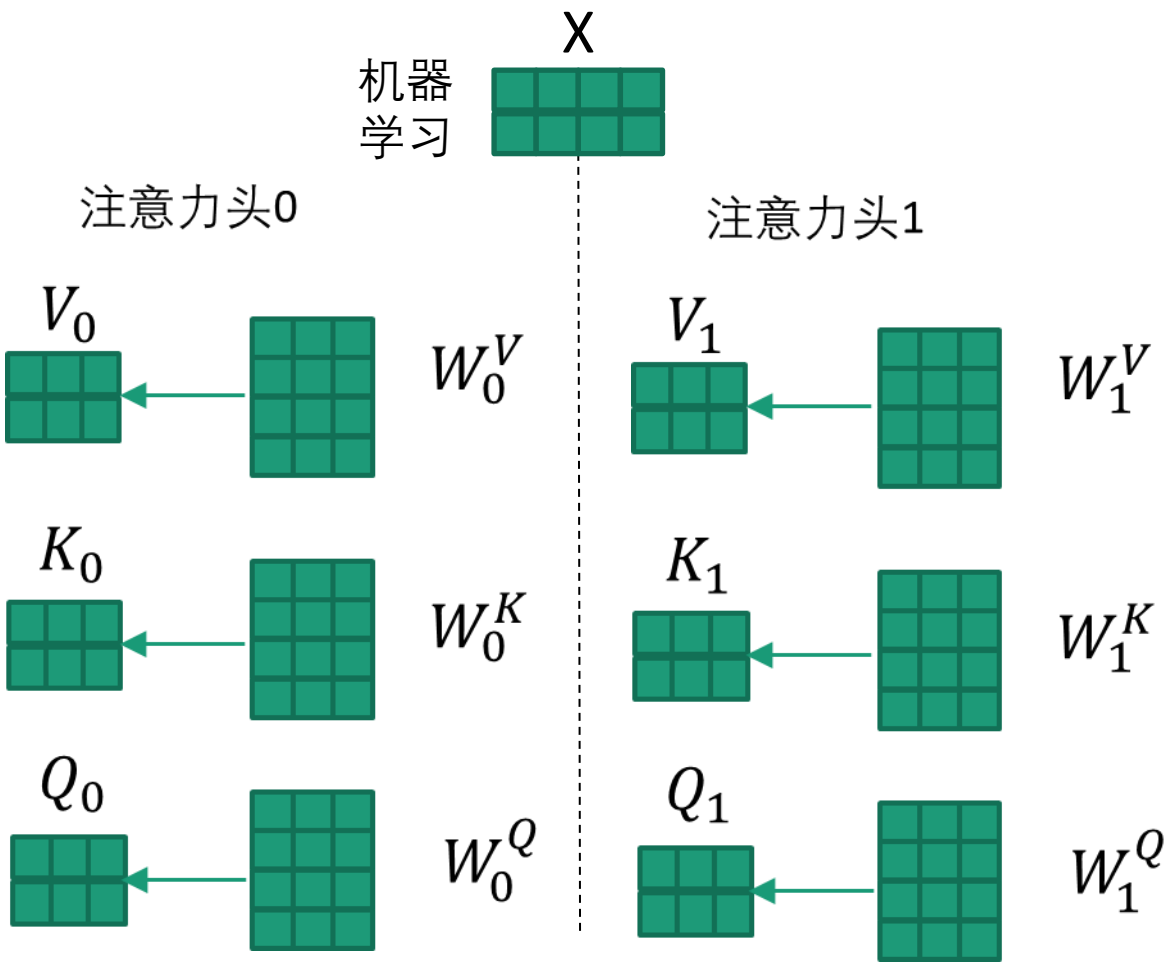
通过矩阵运算实现自注意力机制

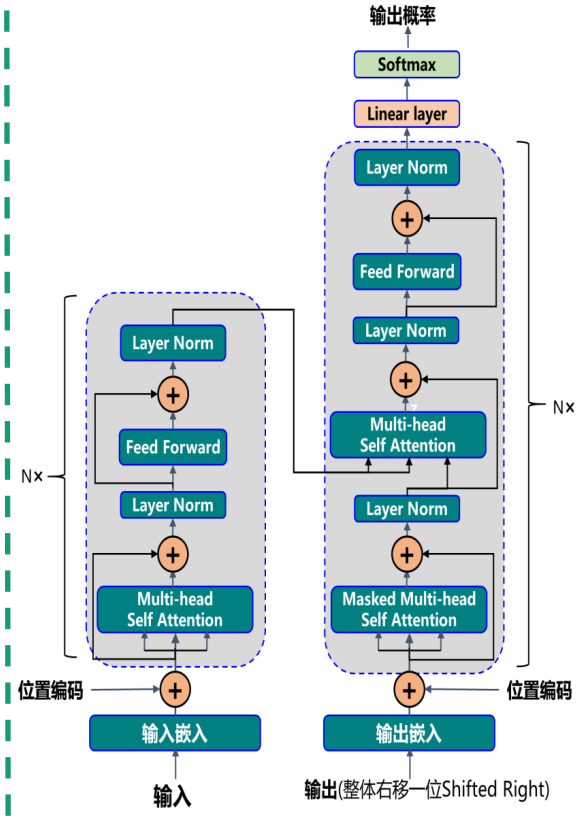


$$\text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_k}}\right) \cdot V = Z$$

机器翻译模型Transformer

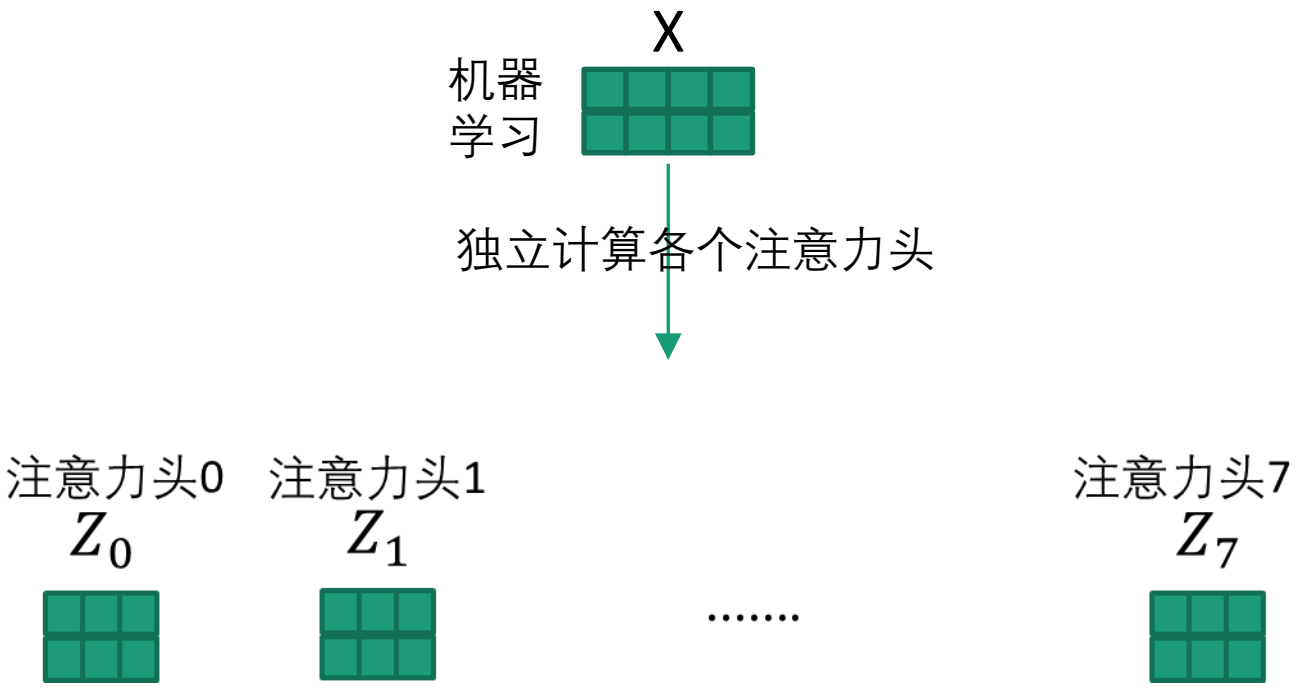
多头注意力机制





机器翻译模型Transformer

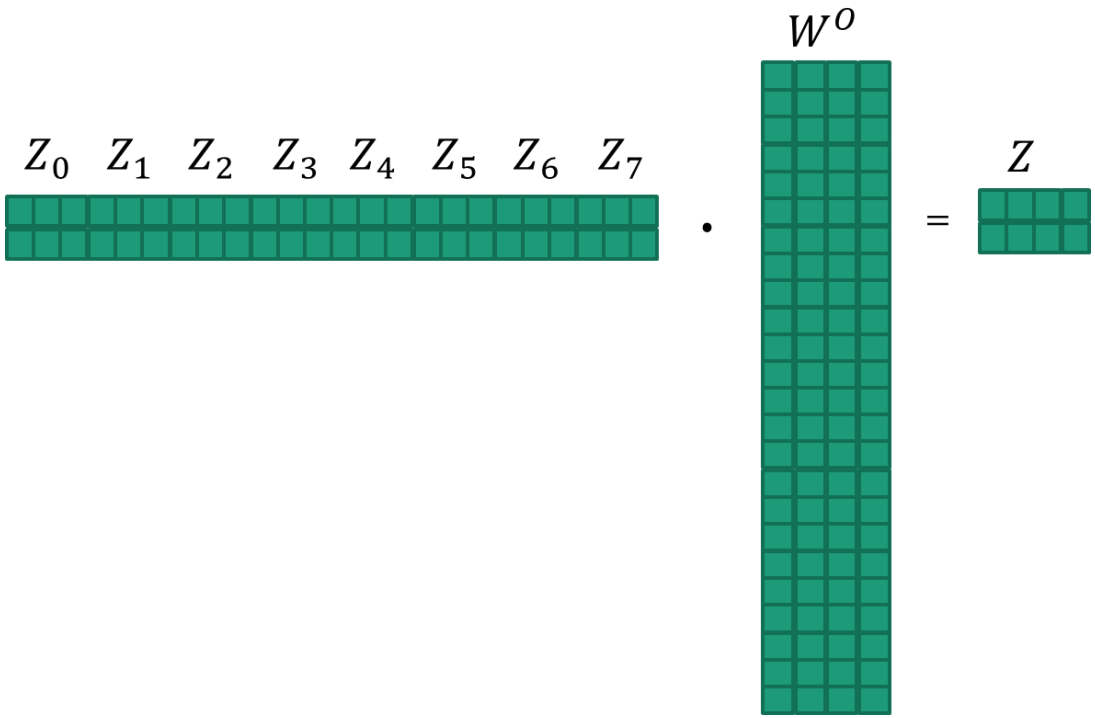
多头注意力机制

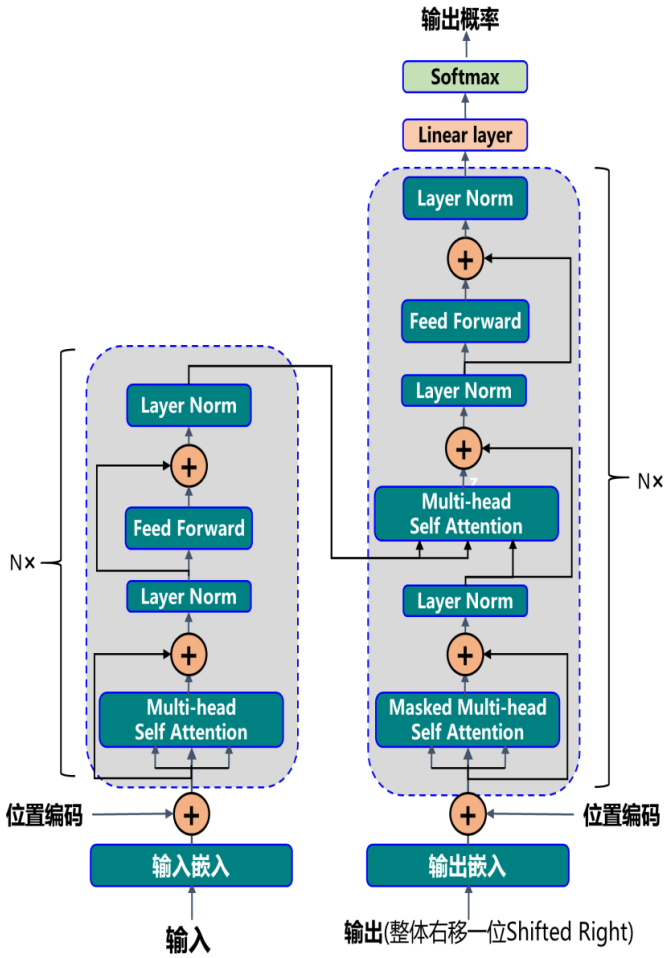


机器翻译模型Transformer

多头注意力机制

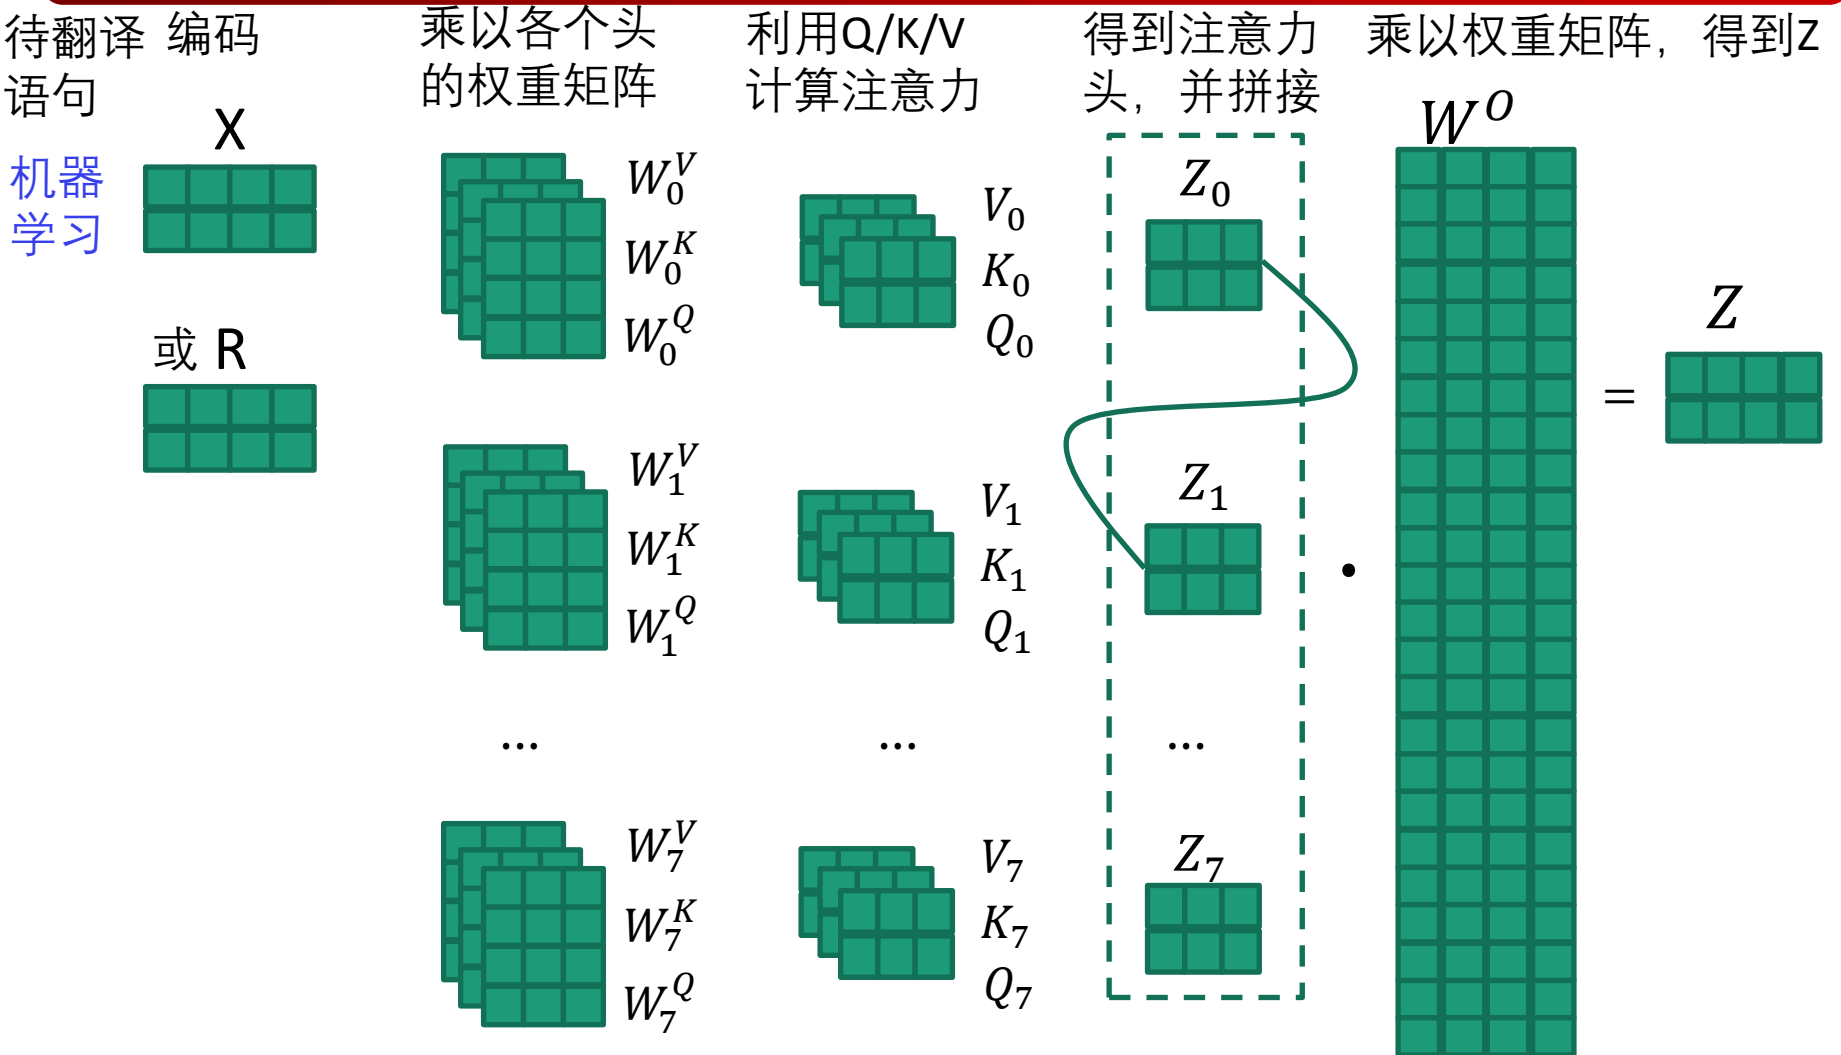
所有注意力头然后再拼接起来：





机器翻译模型Transformer

多头自注意力概览



机器翻译模型Transformer

编码器工作流程

残差连接ADD：

每个子层的输出都用如下方式计算：

$$sub_layer_output = LayerNorm(x + SubLayer(x)))$$

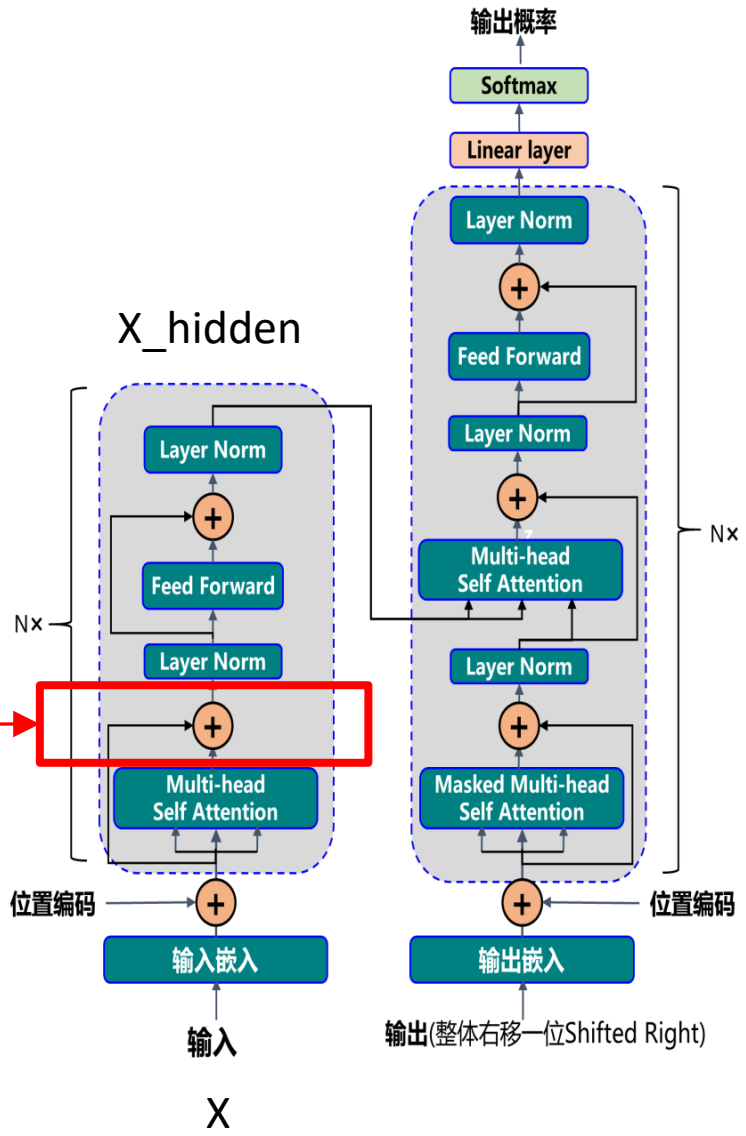
即把计算之前的值和计算之后的值相加，从而得到残差连接。

多头注意力之后的残差连接ADD：

注意力计算的结果加上词嵌入，得到

$X_{embedding} + X_{attention}$

其中$X_{attention} = attenion(Q, K, V)$



机器翻译模型Transformer

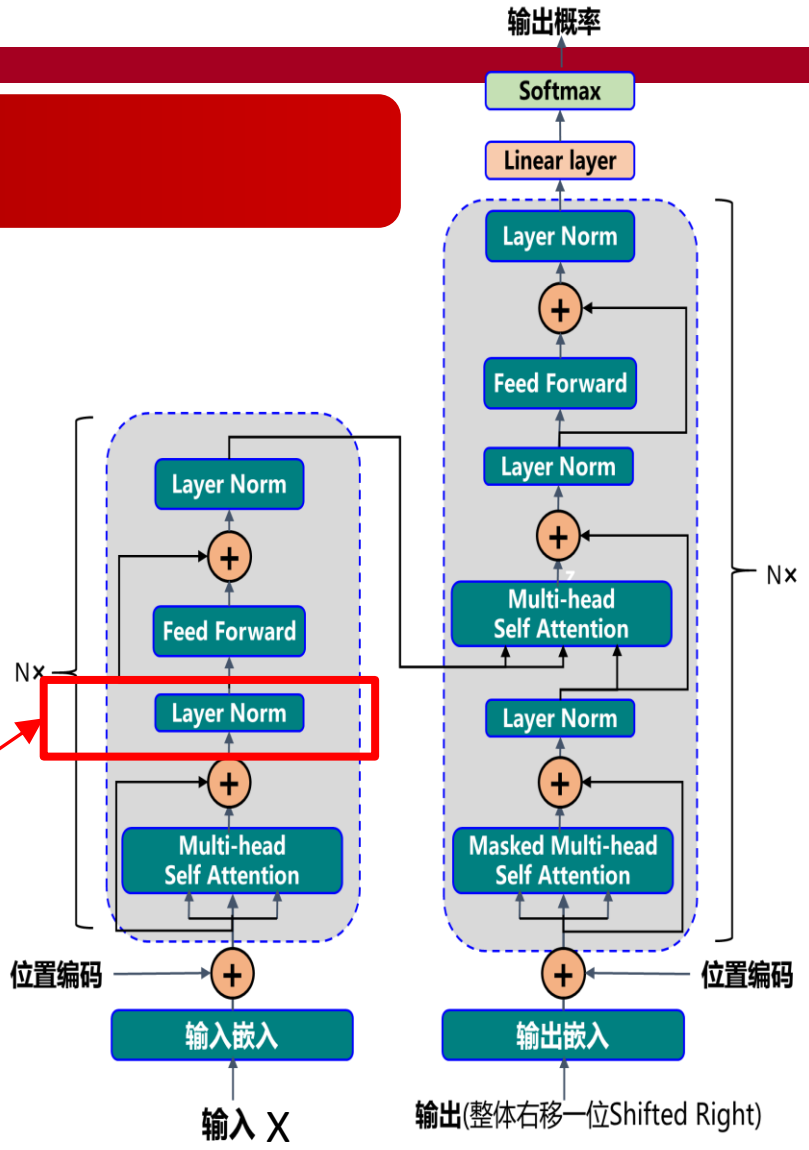
编码器工作流程

层的归一化（LayerNorm）

$$LayerNorm(x) = \alpha \otimes \frac{x_{ij} - \mu_i}{\sqrt{\sigma_i^2 + \epsilon}} + \beta$$

其中：

1. ⊗表示哈达玛乘积，即矩阵对应位置元素的相乘。
2. μ_i是矩阵每行的均值，即$\mu_i = \frac{1}{m}\sum_{i=1}^{m} x_{ij}$。
3. σ_j^2是矩阵每行的方差，$\sigma_j^2 = \frac{1}{m}\sum_{i=1}^{m}(x_{ij} - \mu_j)^2$



机器翻译模型Transformer

Transformer编码器工作流程

Feed Forward(前馈神经网络)层

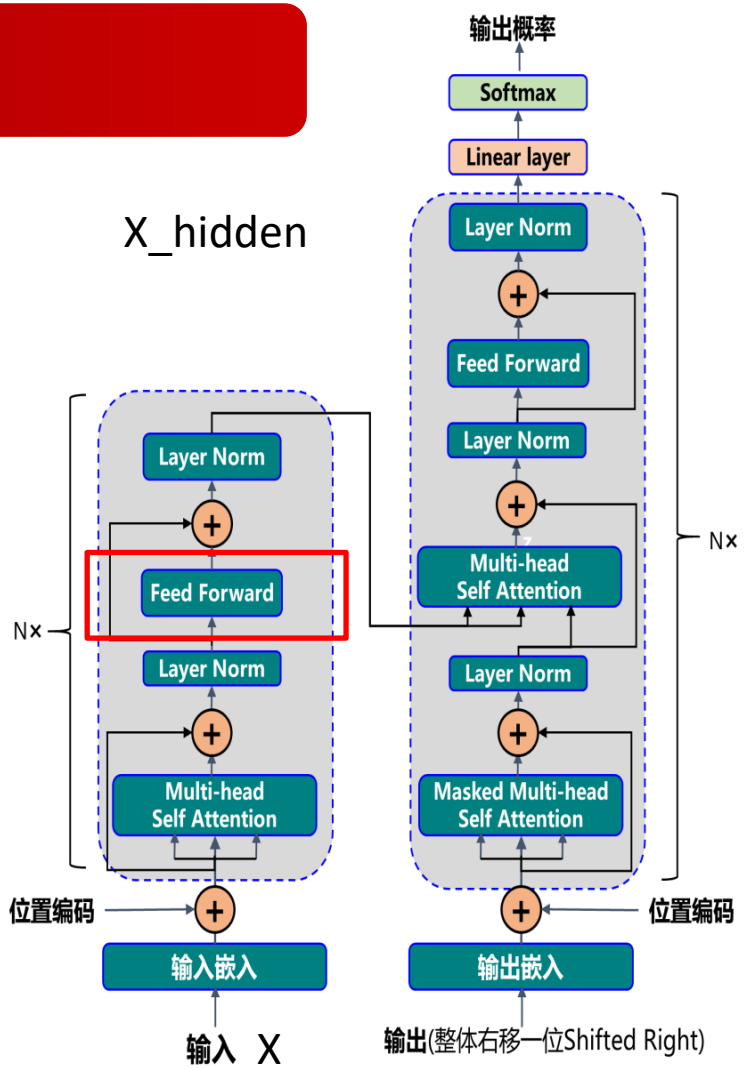
■该层计算公式如下:

$$X_{FeedForward} = Activate\left(Linear\left(Linear\left(X_{Add\&Norm}\right)\right)\right)$$

其中，$X_{Add\&Norm}$表示其输入，即为图中Add & Norm 层的输出。

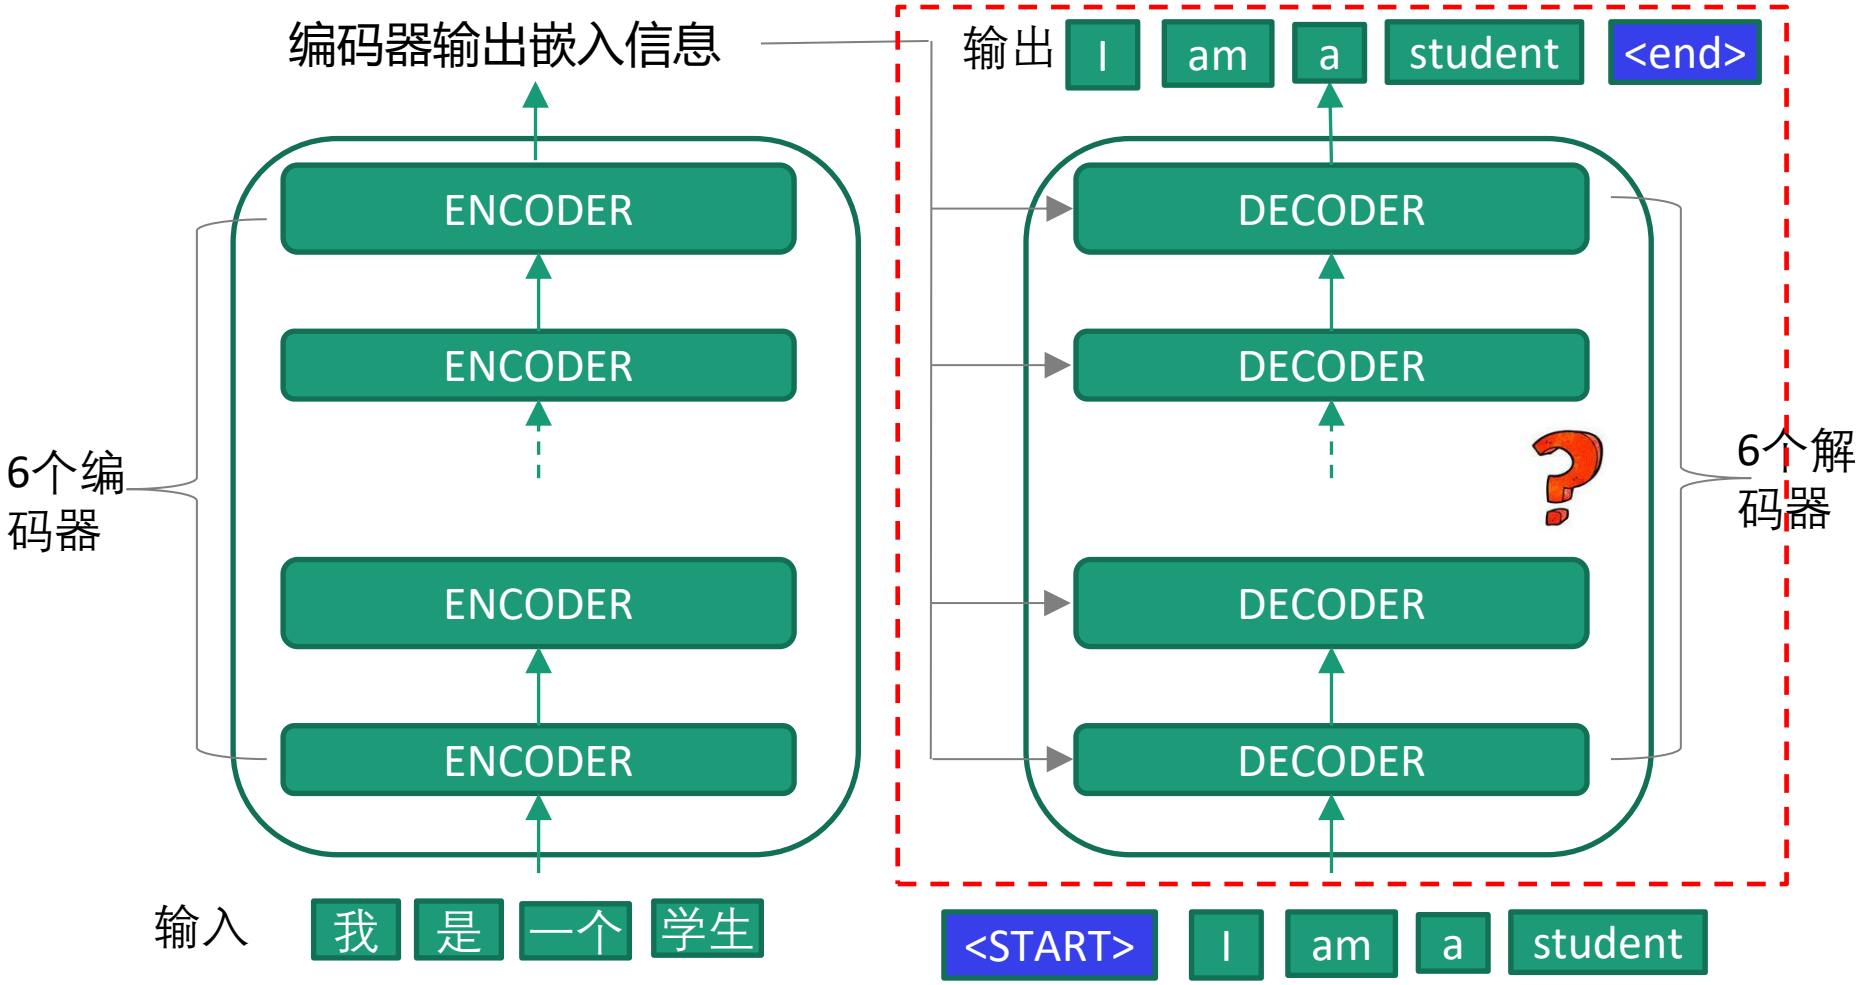
■ 该层的激活函数可以用Relu，即:

$$\max(0, X_{Add\&Norm}W_1 + b_1)\,W_2 + b_2$$



机器翻译模型Transformer

Transformer解码器工作流程



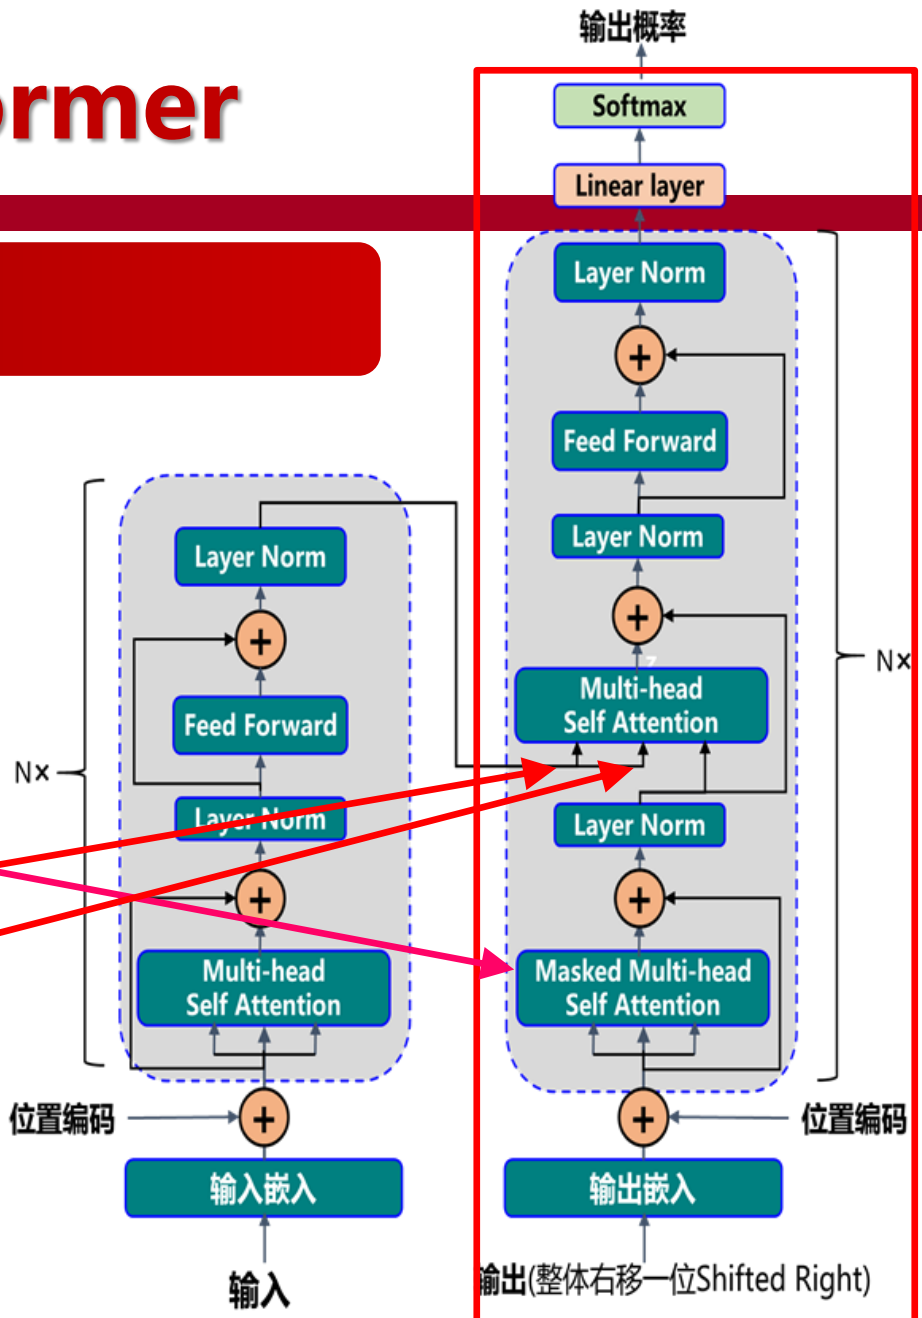
机器翻译模型Transformer

Transformer解码器工作流程

解码器实现的特别之处：

有两个多头注意力层(Multi-Head Attention)：

- 第一个 Multi-Head Attention 层采用了 Masked 操作。
- 第二个 Multi-Head Attention 层的 K, V 矩阵使用编码器encoder输出的编码信息矩阵计算，而 Q 则来自前一位置解码器decoder的输出。

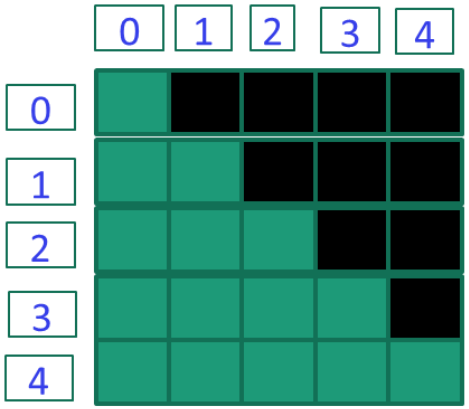


机器翻译模型Transfo

Transformer解码器工作流程

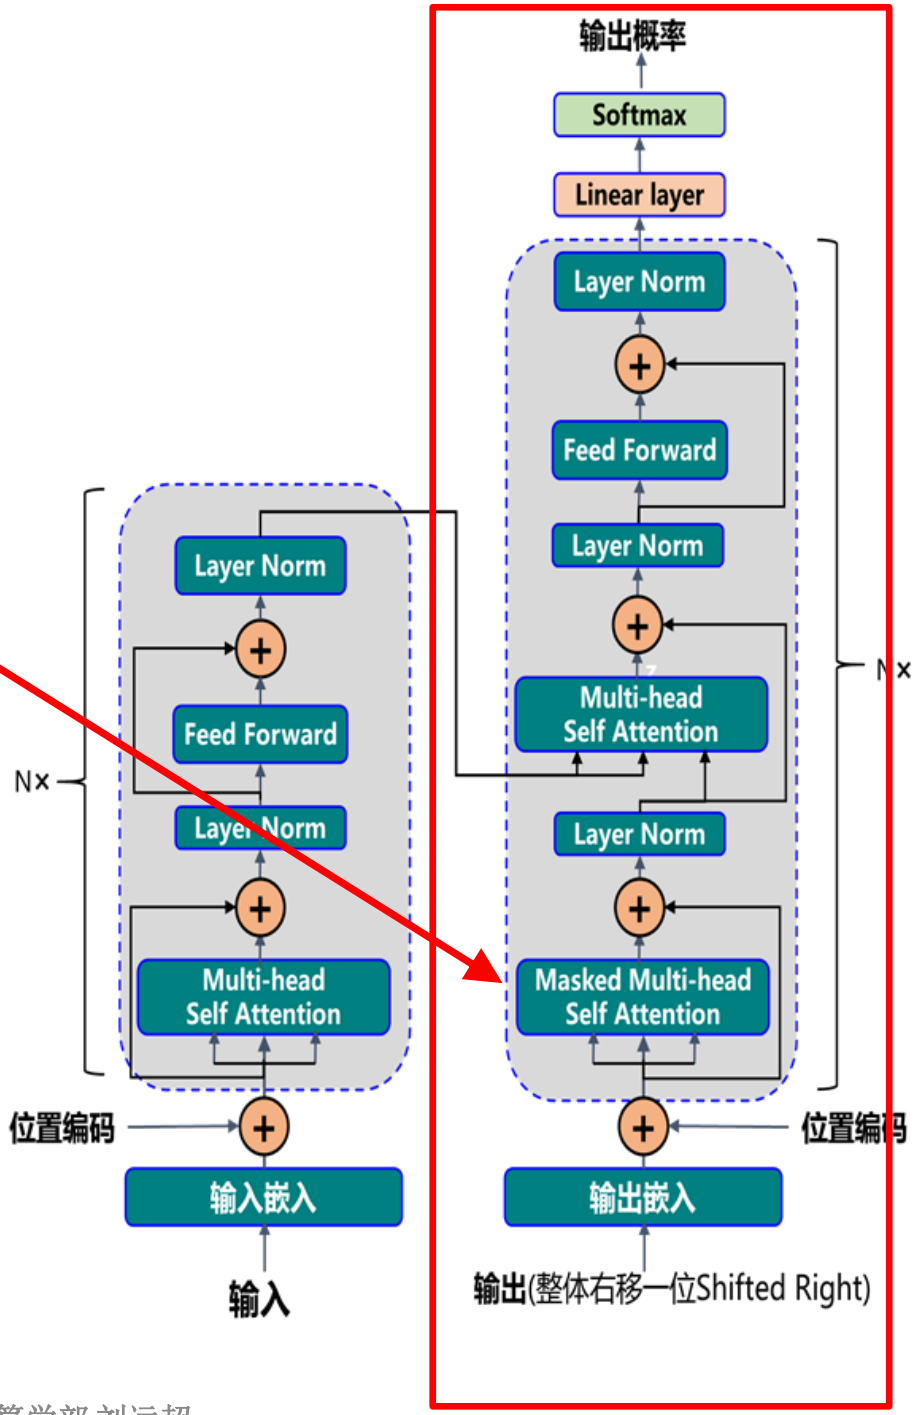
解码中的Masked 操作

Masked 操作的目的是防止在翻译第 i 个单词的时候，利用到 i+1 个单词及其以后的信息，有助于防止过拟合。



0: <START>; **1:** 我; **2:** 是; **3:**一个; **4:**学生

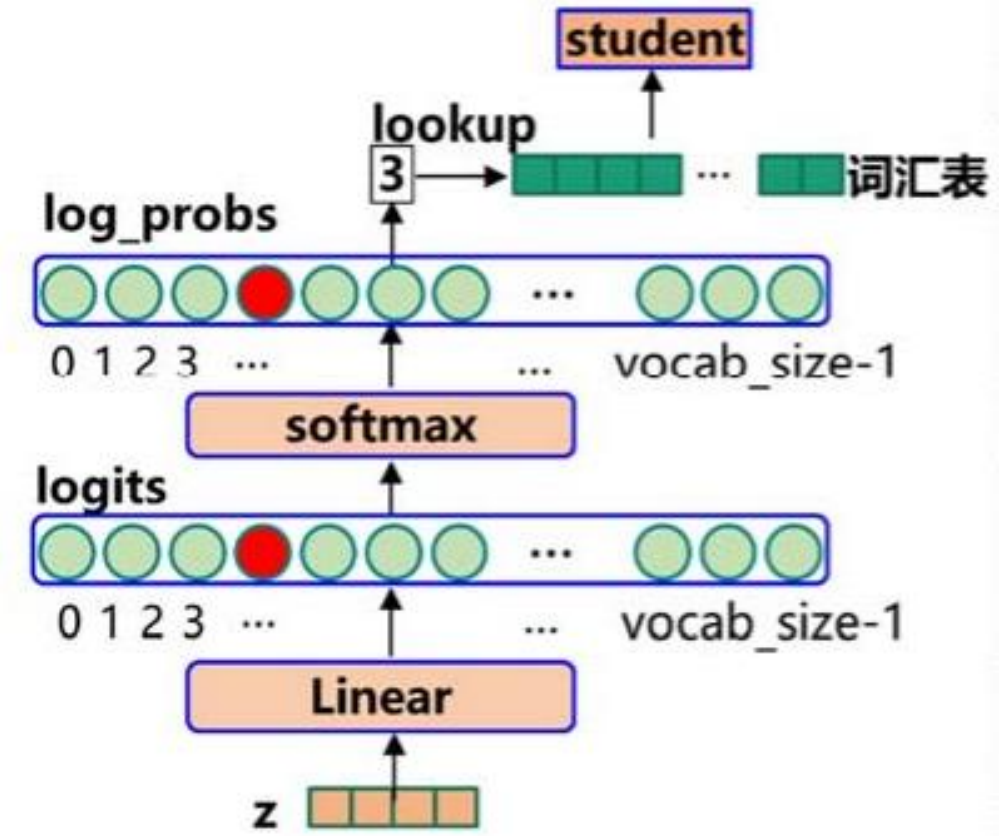
不遮挡　遮挡

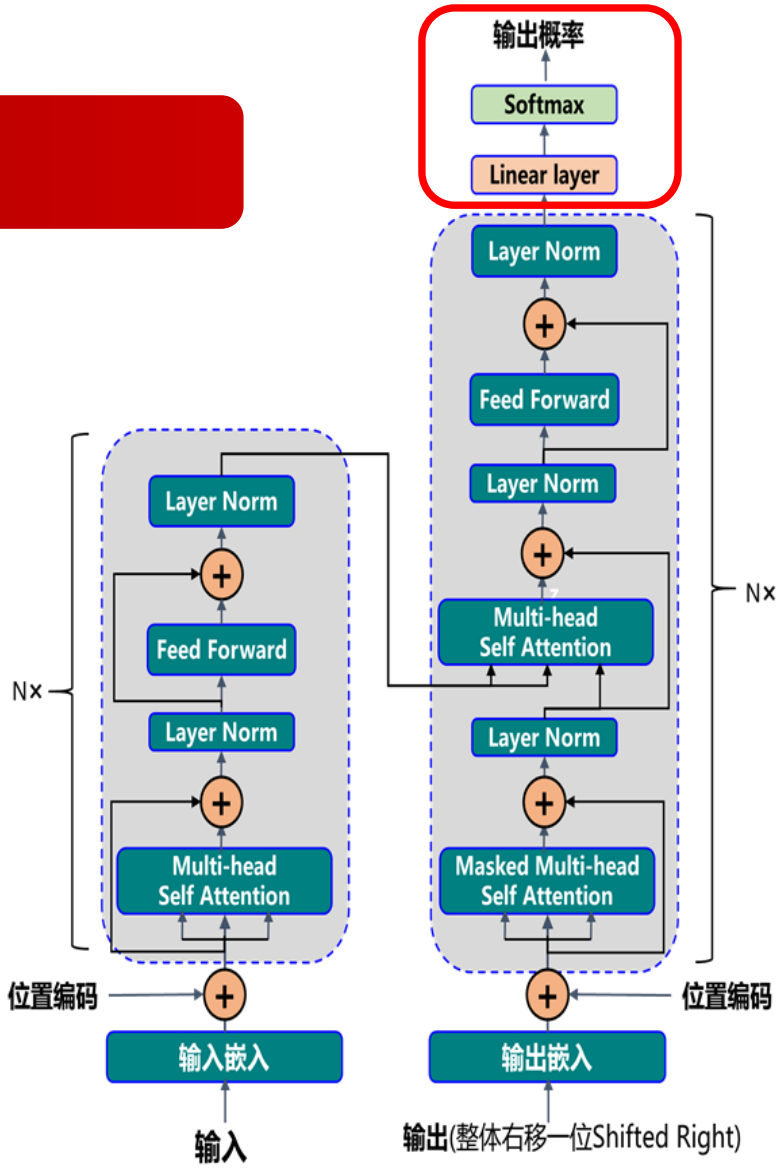


机器翻译模型Transformer

Transformer解码器工作流程

最终的线性变换和Softmax层





单选题 1分

设置

68

下列关于Transformer模型的描述正确的是

A Transformer模型的编码器和解码器的内部结构都是相同的

B Transformer模型只有一个编码器

C Transformer模型除了机器翻译以外，还可以应用在很多其它任务类型

D Transformer模型只有其编码器用到了自注意力机制

提交

多选题 1分

设置

69

下列关于Transformer模型的描述正确的有

A 其在预训练模型BERT和GPT中都获得了较好的应用

B 其训练过程和RNN一样，存在较强的时间步依赖，无法并行训练

C 是一种带有自注意力机制的编码器-解码器（seq2seq）神经网络

D 其中的自注意力机制可以采用多头（Multi-head）的方式

提交

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体

建模序列数据的神经网络

本章内容简介

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- **递归神经网络及其变体**



递归神经网络及其变体

(Recursive Neural Networks and Its Variants)

刘远超
哈尔滨工业大学
计算机学部

递归神经网络及其变体

如何判断一段文本的情感倾向?

以“not very good”为例:

- 深度学习方法:
  - 词义如何表示:每个词表示为一个低维向量

维度	1	2	3	4	5	6	7	8	9	10
not:	-0.022975	0.087888	-0.24248	-0.074691	0.02824	0.22998	-4.5327	0.5373	-0.12518	-0.66138
very:	0.24487	-0.15216	-0.3001	-0.22925	0.071235	-0.37077	-4.2901	0.068465	-0.31345	-0.7891
good:	-0.069254	0.37668	-0.16958	-0.27482	0.25667	-0.20293	-4.1122	0.02595	-0.27085	-0.87003

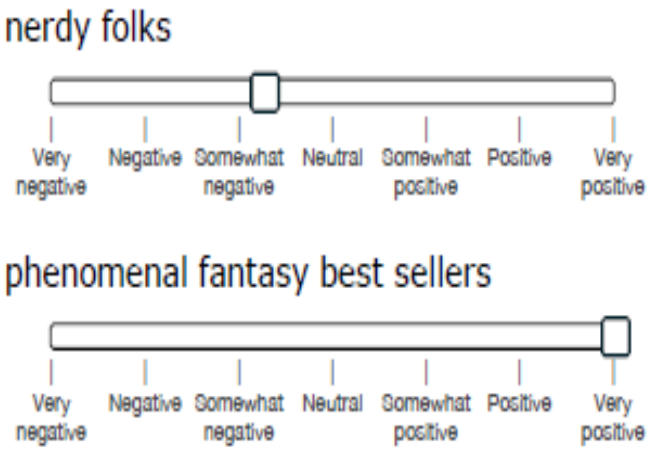
- 问题的关键:语义的组合和分类
- Socher 等人采用情感树库和神经网络模型进行处理:
  - 单个语句的两类情感分类精度从80% 提高到 85.4%
  - 对于短语级别的情感预测精度达到了从71%提高到80.7%。

Socher et al.. Semi-Supervised Recursive Autoencoders for Predicting Sentiment Distributions, EMNLP 2011

递归神经网络及其变体

情感树库语料

- 情感树库（**Stanford Sentiment Treebank**）中的数据来源于Pang and Lee(2005)发布的电影评论（rottentomatoes.com）语料。
- 标注过程：用Stanford Parser 进行句法分析，然后在此基础上进行人工标注。图中的滑块有25个不同的值，其初始值设为neutral。



- 语料规模：对11855个句子中的215,154个短语（phrases）进行了标注。

递归神经网络及其变体

数据描述（续）

5类：0-4

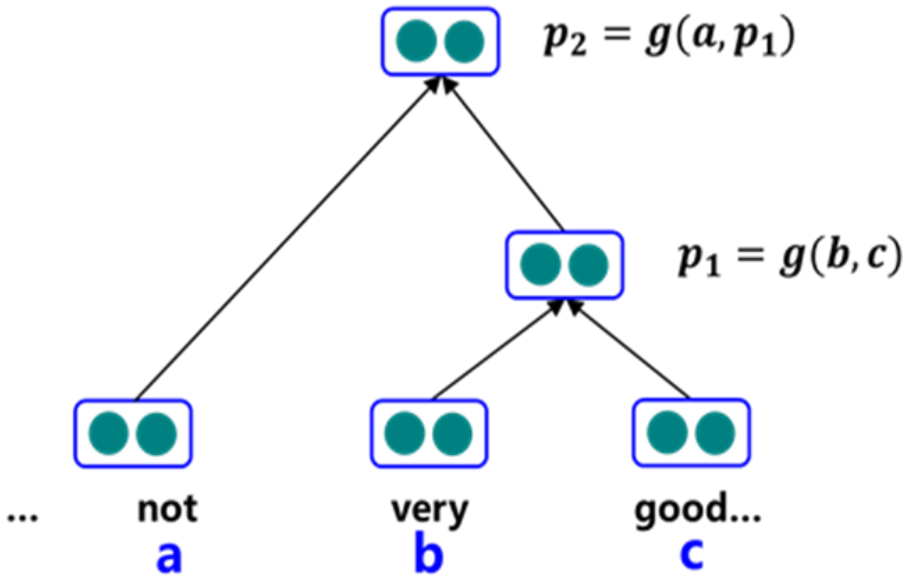
train - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

```
(3 (2 (2 The) (2 Rock)) (4 (3 (2 is) (4 (2 destined) (2 (2 (2 (2 (2 to) (2 (2 be) (2 (2 the) (2 (2 21st) (2 (2 (2 C
(2 (2 Bryan) (2 Adams))) (2 (2 contributes) (2 (2 (2 a) (2 slew)) (2 (2 of) (2 songs))))) (2 (2 --) (2 (2 (2 (2 a)
the) (2 other)) (2 '')) (2 and)) (2 ``)) (2 (2 the) (2 self))))))) (3 (2 ,) (3 (2 '') (3 (2 Derrida) (3 (3 (2 is)
4 (4 (4 (3 (3 good) (2 action)) (2 ,)) (3 (3 good) (2 acting))) (2 ,)) (3 (3 good) (2 dialogue))) (2 ,)) (4 (3 good
2 ,)) (2 and)) (3 (2 host) (3 (2 to) (3 (2 some) (4 (4 (3 truly) (4 excellent)) (2 sequences))))))) (2 .))))))(3 (2
ded)))))) (2 .)))(4 (2 (3 Absorbing) (2 character)) (2 (2 (2 study) (2 (2 by) (2 (2 André) (2 Turpin)))) (2 .)))(3
estival)))) (2 (2 (2 has) (1 (2 (2 become) (2 (2 so) (1 buzz-obsessed))) (2 (2 that) (2 (2 (2 (3 fans) (2 and)) (2
(2 part) (2 (2 of) (2 (2 the) (2 movie)))))) (2 ,)) (2 often)) (3 (3 (3 catapulting) (2 (2 the) (2 artist))) (2 (2
2 its) (0 vulgar))) (2 and)) (1 mean))) (2 ,)) (2 but)) (3 (2 I) (3 (3 liked) (2 it)))) (2 .))(3 (2 (2 What) (1 (2
utter) (3 cuteness))) (2 (2 of) (2 (2 (2 Stuart) (2 and)) (2 Margolo)))))) (2 .)))(3 (1 (2 Their) (2 (2 computer-an
2 (2 (2 (2 (2 Silver) (2 's)) (2 parrot)) (2 (2 has) (3 (2 been) (3 (2 replaced) (3 (2 with) (2 (2 (2 Morph) (2 ,))
(2 (2 the) (2 (2 Playboy) (2 era)))))))))(2 (2 (2 If) (2 (2 (2 (2 Mr.) (2 (2 Zhang) (2 's))) (2 (2 subject) (2 mat
(4 (4 (2 is) (4 (3 (2 a) (3 (4 great) (2 deal))) (3 (2 of) (4 fun)))) (2 .))))))(3 (2 ``) (1 (2 (2 Cremaster) (2 3)
their) (2 story)) (1 (2 is) (2 predictable))))) (2 (2 ,) (3 (2 you) (2 (2 'll) (2 (2 want) (2 (2 things) (2 (2 to)
(2 (2 (2 (2 Analyze) (2 That)) (2 ,)) (2 ')) (1 (2 (2 (2 promised) (2 (2 (2 (1 -LRB-) (2 or)) (2 threatened)) (3 -R
```

递归神经网络及其变体

标准RNN (Socher et al., 2011)

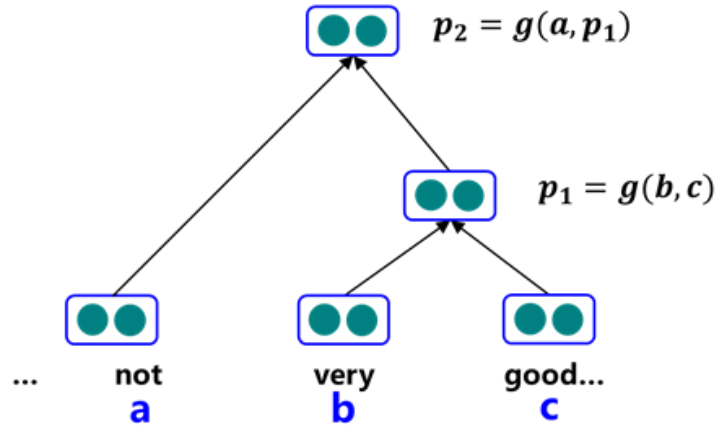


- 每个词初始化表示为一个d维的向量。由一个随机均匀分布(uniform distribution) $U(-r; r)$, $r = 0.0001$随机采样生成
- 所有的词向量被存储在一个词嵌入矩阵$L \in R^{d*|V|}$ 中。其中$|V|$是词汇表的大小
- 父节点的向量如何获得？利用组合函数g。

Socher et al.. Semi-Supervised Recursive Autoencoders for Predicting Sentiment Distributions, EMNLP 2011

递归神经网络及其变体

标准RNN（续）



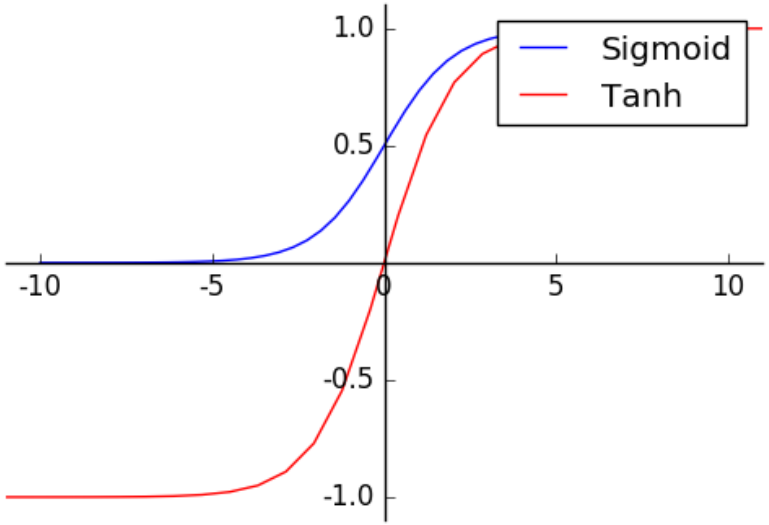
- 父向量的计算方法：

以$p1$为例，$p1$节点对应的向量的计算方法为

$$p_1 = f(W\begin{bmatrix} b \\ c \end{bmatrix})$$

其中，$W \in R^{d \times 2d}$，

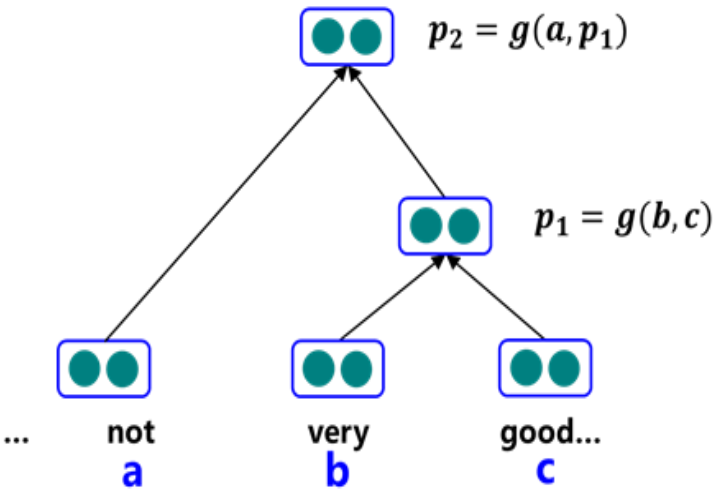
$f = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ 。



递归神经网络及其变体

标准RNN（续）

●情感分类概率分布的计算：



■ 假设节点p1的向量为a，将其传给softmax 分类器，从而计算情感分类概率分布y^a：

$$y^a = softmax(W_s * a)$$

$$softmax_i = \frac{exp(x_i)}{\sum_{j=1}^{C} exp(x_j)}$$

其中，$W_s \in R^{5*d}$，$a \in R^{d*1}$，则$W_s * a \in R^{5*1}$。

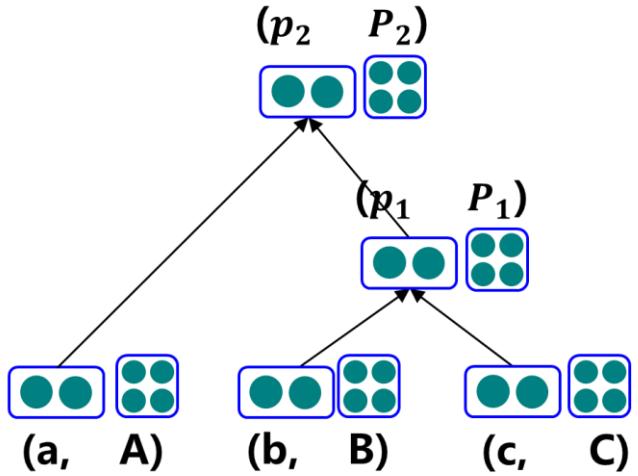
●不同模型的区别在于如何采用自底向上的方法计算隐含向量！

递归神经网络及其变体

MV-RNN

- MV-RNN(Socher et al., 2012)的基本思想是将每个词或者父节点表示为一个向量和一个矩阵。

- 每个词的矩阵被初始化为一个 $d \times d$ 的单位矩阵identity matrix，然后再加上少量的高斯噪音。



- 父节点的向量和矩阵的计算方法分别为

$$\boldsymbol{p_1 = f(W\begin{bmatrix} Cb \\ Bc \end{bmatrix})}$$，其中，$W \in R^{d \times 2d}$，结果p_1是$d \times 1$的向量。

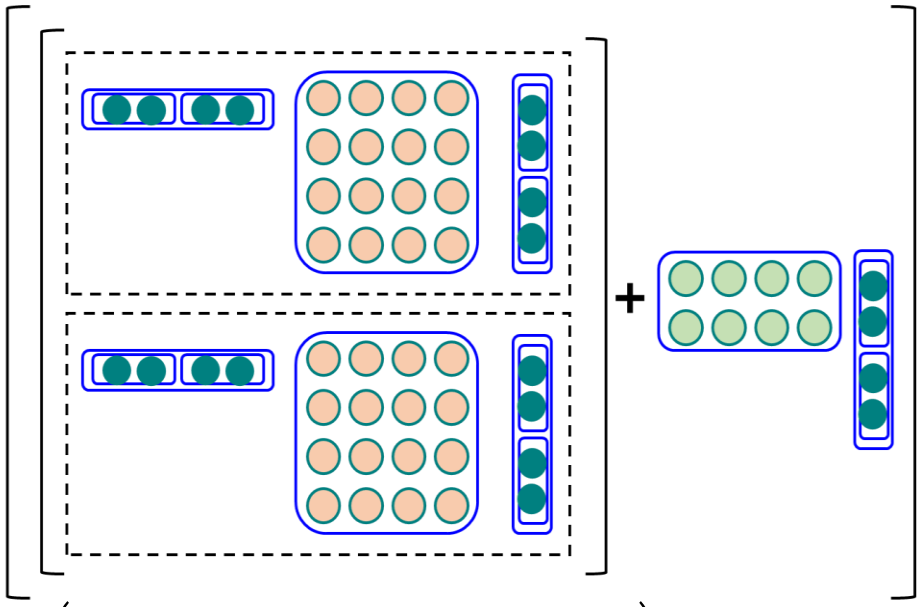
$$\boldsymbol{P_1 = f(W_M\begin{bmatrix} B \\ C \end{bmatrix})}$$，其中，$W_M \in R^{d \times 2d}$，结果P_1是$d \times d$的矩阵。

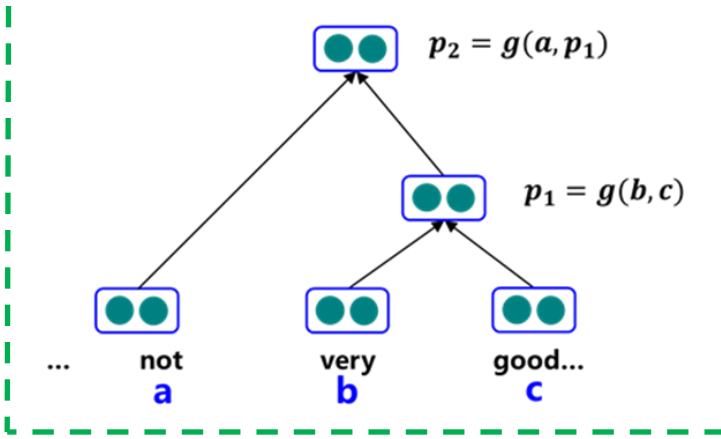
Socher R, Huval B, Manning C D, et al. Semantic compositionality through recursive matrix-vector spaces[C]// Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning. 2012:1201-1211.

递归神经网络及其变体

RNTN（Recursive Neural Tensor Network）

$$p_1 = f\left(\begin{pmatrix} b \\ c \end{pmatrix}^T V^{[1:2]} \begin{pmatrix} b \\ c \end{pmatrix} + W \begin{pmatrix} b \\ c \end{pmatrix}\right)$$





- RNTN 引入了张量层 (tenso layer)，包含d个slice。
- $V^{[1:d]} \in R^{2d \times 2d \times d}$
- $W \in R^{d \times 2d}$

思考：

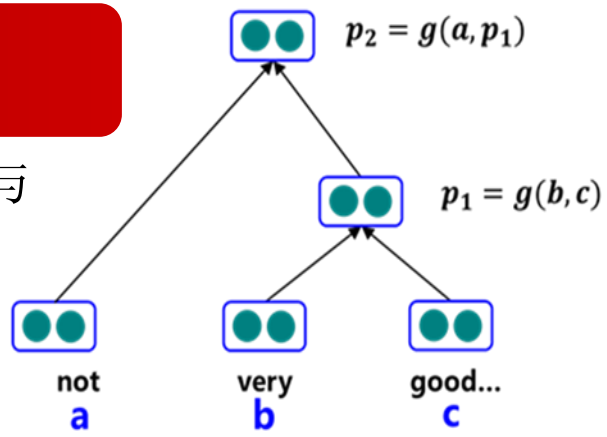
1）该结构有什么优点？和标准RNN的关系？

2）图中的两个红色矩阵是否相同？

3）红色矩阵为什么是2d*2d维的，且要有d个这样的矩阵？

递归神经网络及其变体

RNTN的交叉熵损失函数



- 计算在节点 i 上的预测情感类分布$y^i \in R^{C\times 1}$ 与真实情感类分布$t^i \in R^{C\times 1}$ 之间的交叉熵损失：

$$E(\theta) = -\sum_i \sum_j t_j^i log y_j^i + \lambda ||\theta||^2$$

■节点 i 的预测情感分类概率分布向量 y^i：每个节点利用基于其向量的$softmax$分类器（如前所述）。

例如 $\boldsymbol{y^i}$ 为：{0.1, 0.1, 0.1, 0.1, 0.6}

■节点 i 的真实情感类分布向量 t^i：采取0-1 编码的模式。即如果有5个类，则其长度为5,只有其中一个元素取值为1，其它为零。

例如 $\boldsymbol{t^i}$ 为：{0 , 0, 0, 0, 1}

- $E(\theta)$是关于参数 $\theta = (V, W, W_s, L)$ 的函数
- 调整参数，以使交叉熵损失最小：$\theta_j := \theta_j - \alpha \cdot \frac{\partial E}{\partial \theta_j}$ 。

建模序列数据的神经网络

本章小结

- 循环神经网络
- 长短期记忆网络
- 长短期记忆网络的变体
- 双向循环神经网络
- 注意力机制
- 机器翻译模型Transformer
- 递归神经网络及其变体