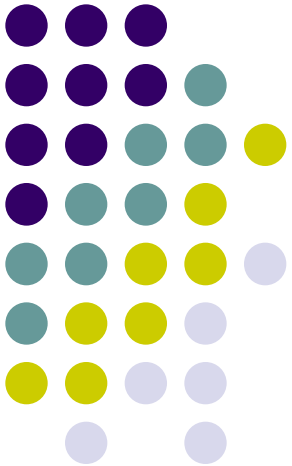


卷积神经网络

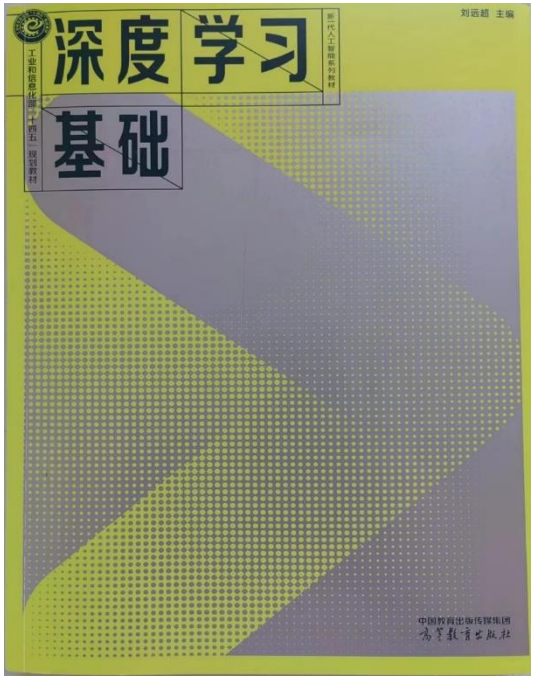
哈尔滨工业大学计算学部

刘远超



卷积神经网络

本章在《深度学习基础》教材中的位置





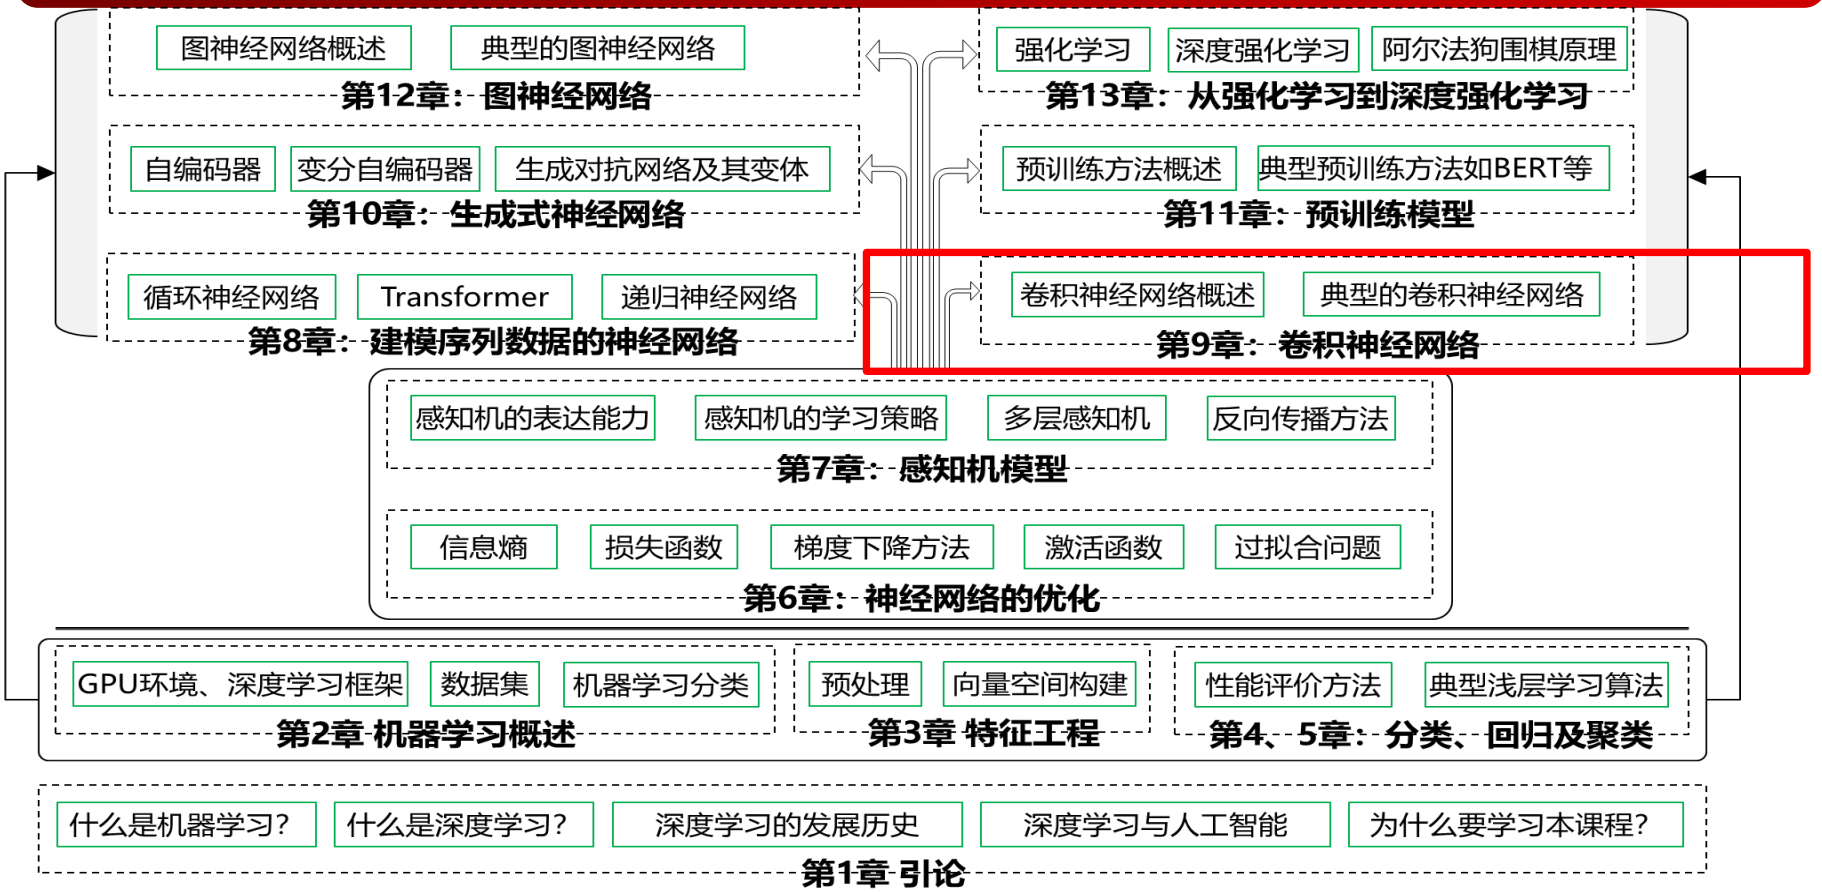


主编：<u>刘远超</u>；出版社：<u>高等教育出版社</u>；出版时间：<u>2023年09月20日</u>。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

建模序列数据的神经网络

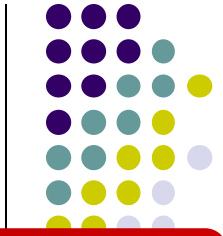
本章内容在《深度学习基础》教材知识体系中的位置



主编：刘远超 出版社:高等教育出版社；出版时间:2023年09月。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

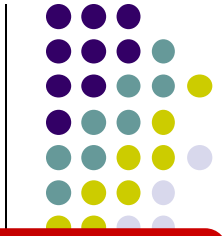
卷积神经网络



本章内容简介

- 卷积神经网络概述
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类

卷积神经网络

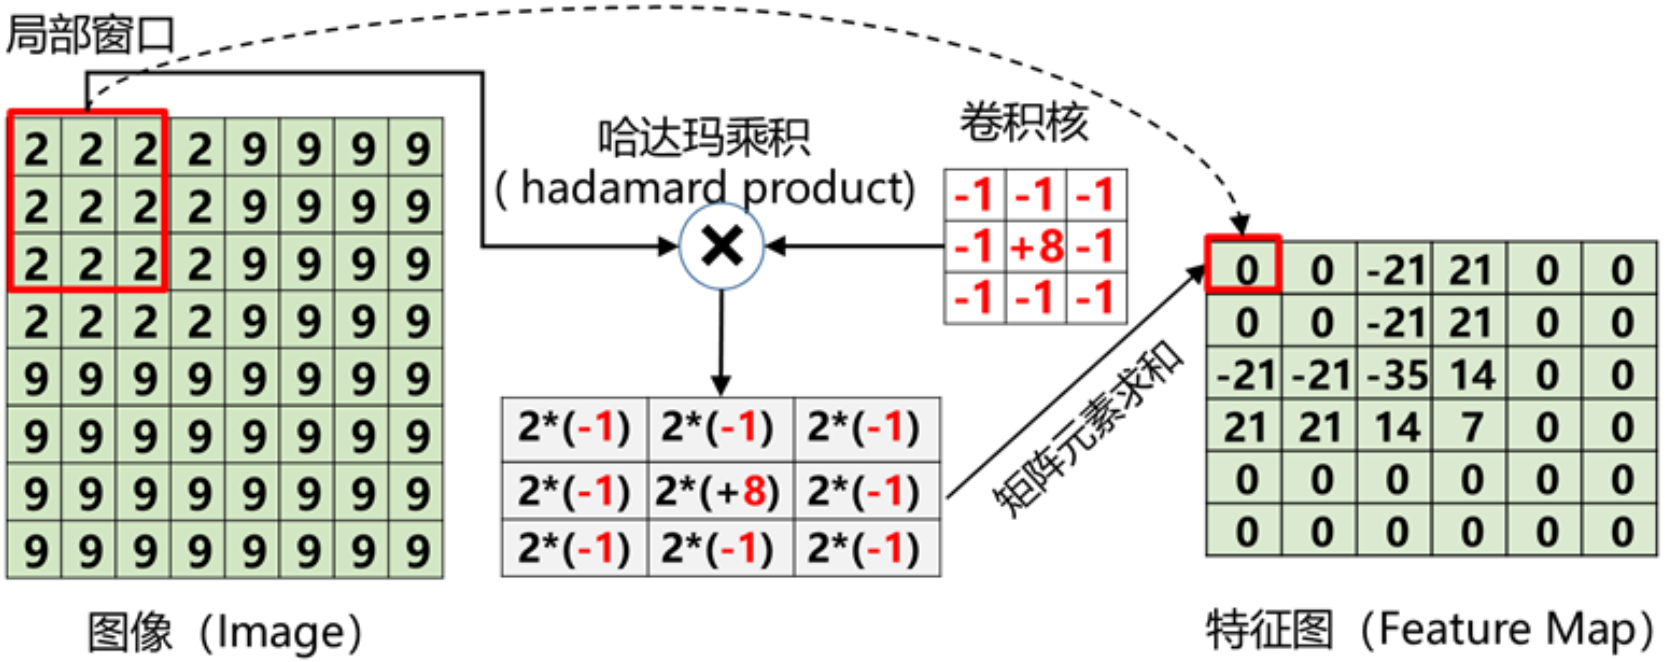


本章内容简介

- **卷积神经网络概述**
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类

卷积神经网络概述

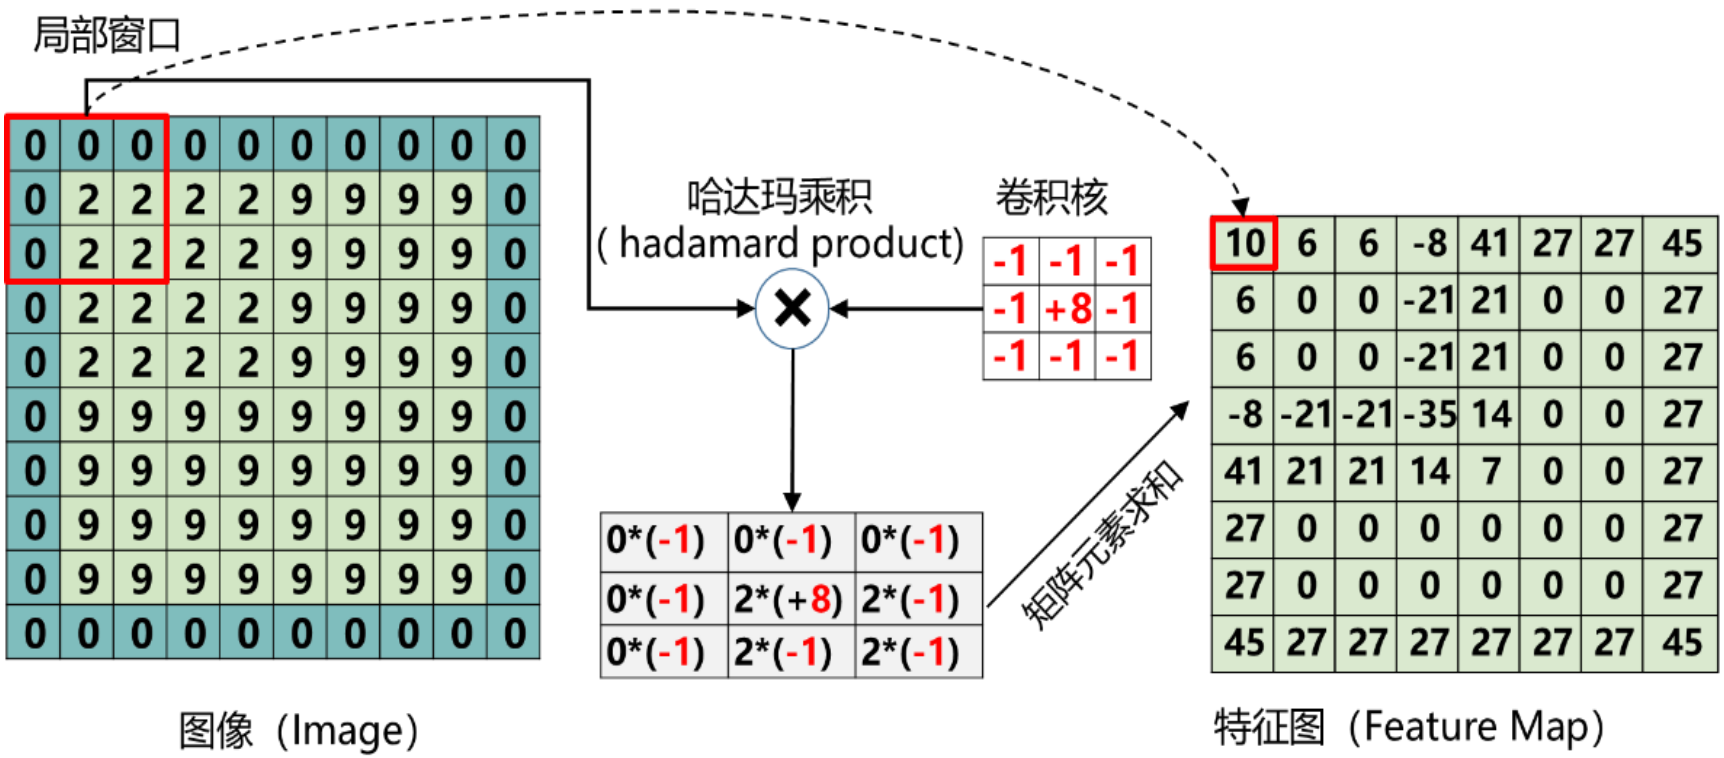
什么是卷积?



- 可以把卷积想象成作用于输入图像矩阵的一个滑动窗口函数，即卷积核、滤波器或是特征检测器。对给定的输入图像，输出特征图中每一个像素实际上是输入图像中局部区域中像素的加权平均，其权值由一个函数定义（即卷积核）。
- **卷积运算还有一个步长的问题。步长是卷积运算的一个超参数，即卷积核每次平移的像素个数。**

卷积神经网络概述

宽卷积（填充0的卷积）



0	0	0	0	0	0	0	0	0	0
0	2	2	2	2	9	9	9	9	0
0	2	2	2	2	9	9	9	9	0
0	2	2	2	2	9	9	9	9	0
0	2	2	2	2	9	9	9	9	0
0	9	9	9	9	9	9	9	9	0
0	9	9	9	9	9	9	9	9	0
0	9	9	9	9	9	9	9	9	0
0	9	9	9	9	9	9	9	9	0
0	0	0	0	0	0	0	0	0	0

10	6	6	-8	41	27	27	45
6	0	0	-21	21	0	0	27
6	0	0	-21	21	0	0	27
-8	-21	-21	-35	14	0	0	27
41	21	21	14	7	0	0	27
27	0	0	0	0	0	0	27
27	0	0	0	0	0	0	27
45	27	27	27	27	27	27	45

卷积神经网络概述

卷积处理图像的一个例子



输入图像

$$\begin{bmatrix} -1 & -1 & -1 \\ -1 & +8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

卷积核



得到的特征图

卷积神经网络概述

卷积处理图像的一个例子

其它典型卷积核及图像处理效果示例



输入图像

尖锐化处理的卷积核

0	-1	0
-1	5	-1
0	-1	0



边缘检测卷积核（一）

0	1	0
1	-4	1
0	1	0



模糊化处理的卷积核

1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9



边缘检测卷积核（二）

1	0	-1
0	0	0
-1	0	1



卷积神经网络概述

什么是卷积神经网络?

- 卷积神经网络（Convolutional Neural Networks，简称CNN）是一类**包含卷积计算且具有深度结构**的前馈神经网络，是深度学习的代表算法之一。

- 对卷积神经网络的研究始于二十世纪80至90年代，**LeNet-5**是较早出现的卷积神经网络，后来又出现了**AlexNet**、**VGGNet**、**GooLeNet**、**ResNet**等各种类型的卷积神经网络。

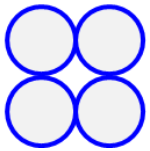
- 卷积神经网络最先在**图像分类**上获得了成功，后来又在**自然语言处理**等领域中获得了较好的应用。

卷积神经网络具有如下特点：

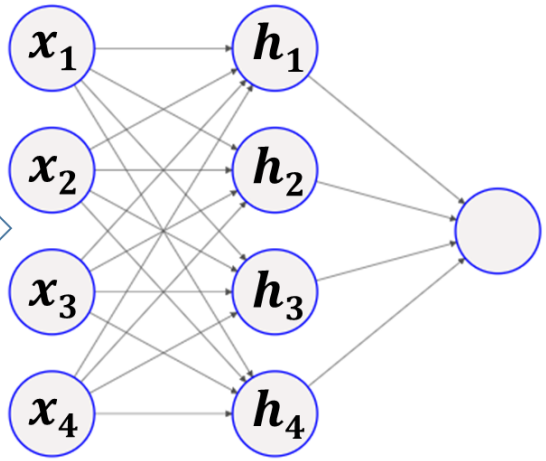
特点一：局部连接和局部卷积

以只有一个隐藏层的简单全连接网络为例：

假设图像只有4个像素



如用隐藏层有4个节点的全连接



由于每条边都对应一个参数，则参数W矩阵形状为为4×4

$$h_1 = f(W_{11}x_1 + W_{12}x_2 + W_{13}x_3 + W_{14}x_4)$$

$$h_2 = f(W_{21}x_1 + W_{22}x_2 + W_{23}x_3 + W_{24}x_4)$$

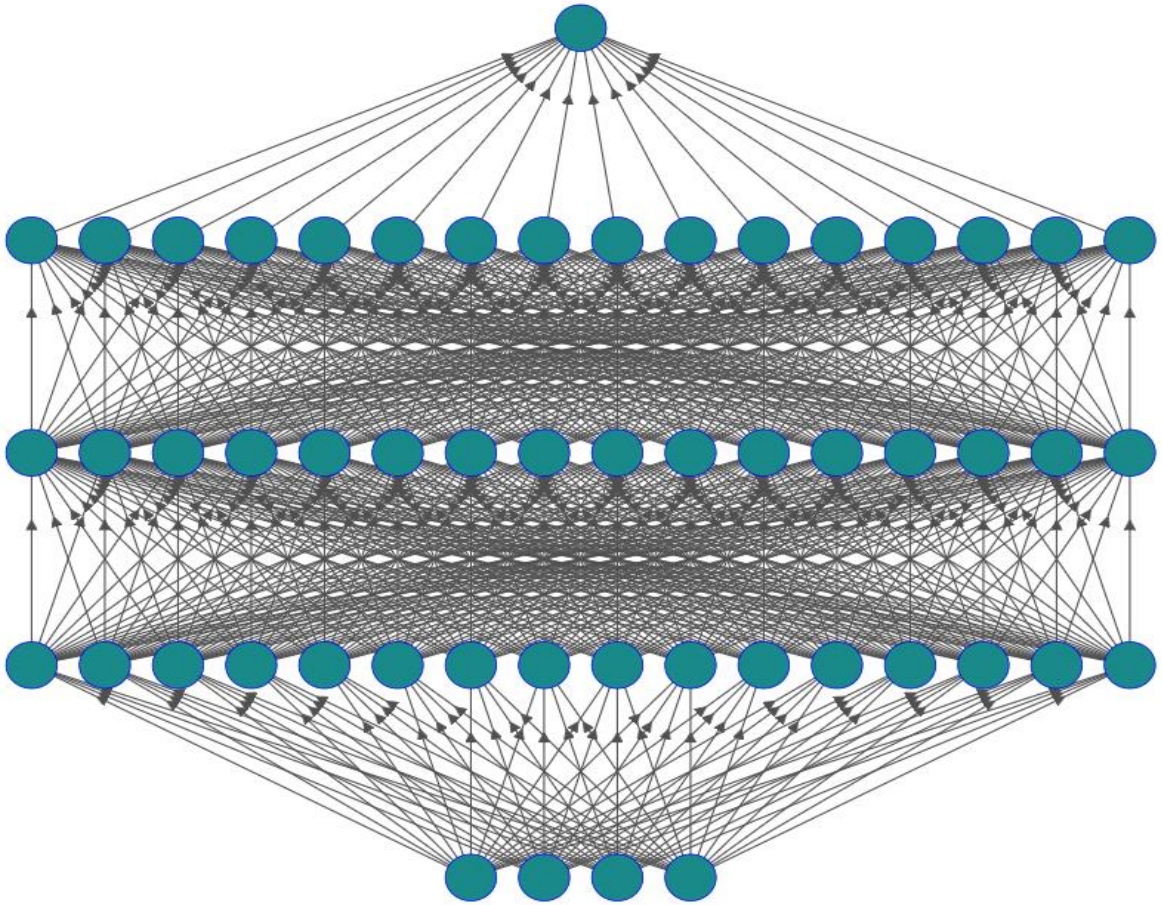
$$h_3 = f(W_{31}x_1 + W_{32}x_2 + W_{33}x_3 + W_{34}x_4)$$

$$h_4 = f(W_{41}x_1 + W_{42}x_2 + W_{43}x_3 + W_{44}x_4)$$

卷积神经网络具有如下特点：

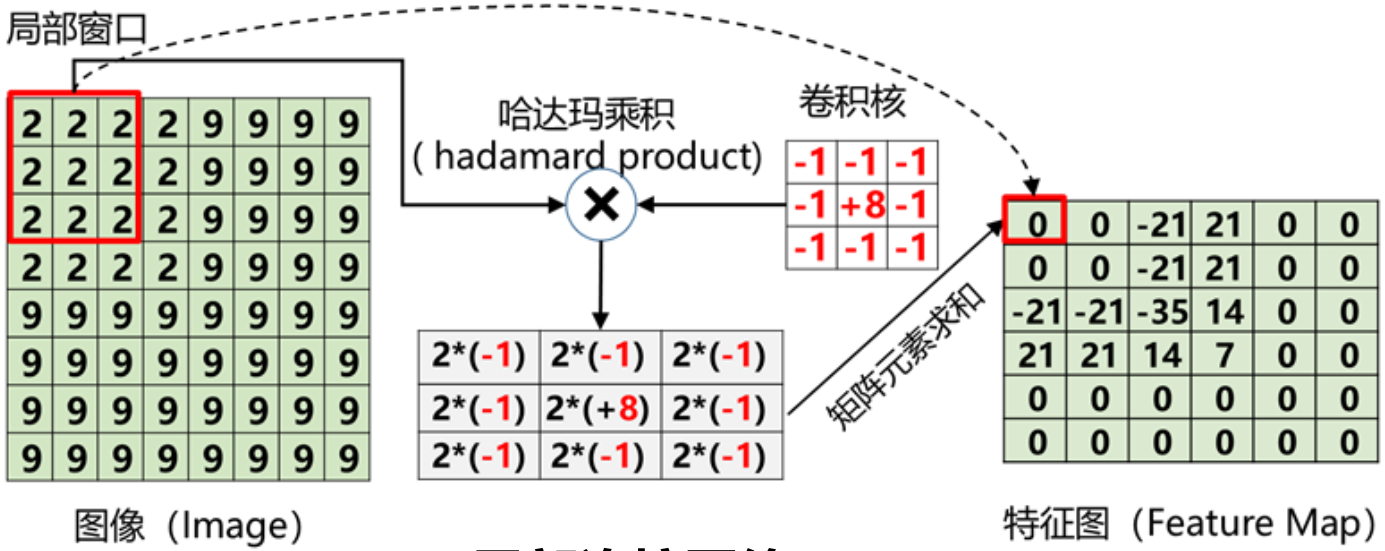
特点一：局部连接和局部卷积

而对于多层全连接网络（每个边对应一个参数）：



卷积神经网络概述

特点一：局部连接和局部卷积

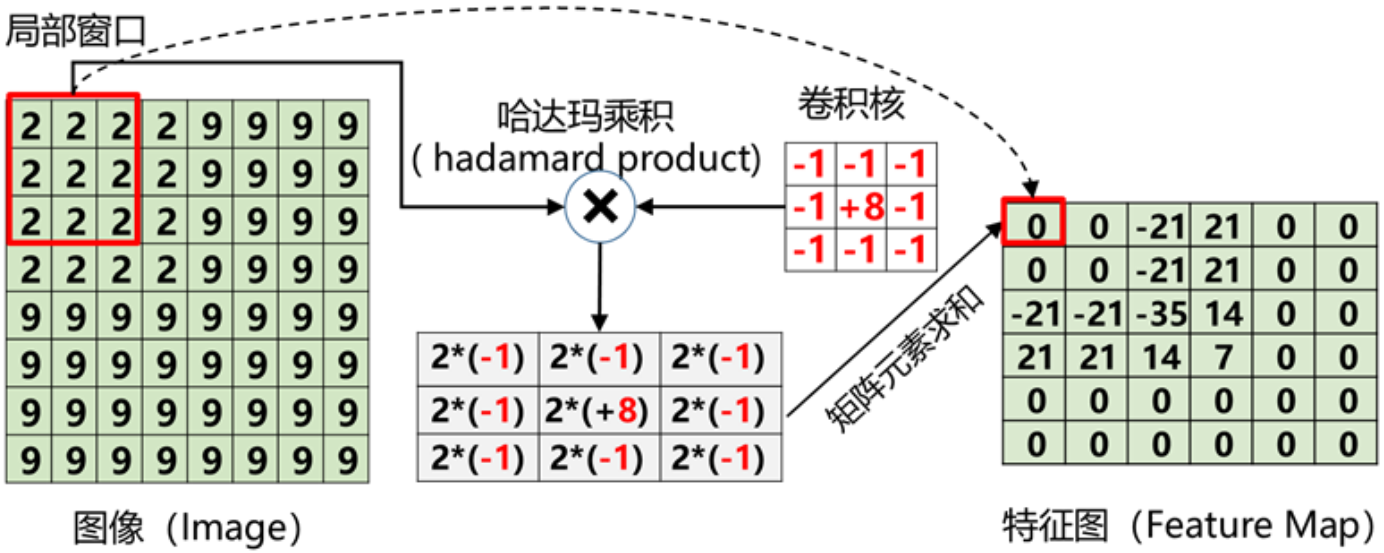


局部连接网络

- 因此，在卷积神经网络中采取的是局部感知的方式（如图所示），即对于生成的特征图中的每个元素，**只需要和输入图像中的局部区域中的部分像素有连接**，因而连接的参数数目得以大幅压缩。
- 除了效率因素外，局部连接的物理意义和思想依据在于**其受启发于生物学中的视觉系统结构**。也可以这样理解，对于图像而言，一般是局部的像素联系较为紧密，而距离较远的像素相关性则相对较弱。

卷积神经网络概述

特点二：参数共享

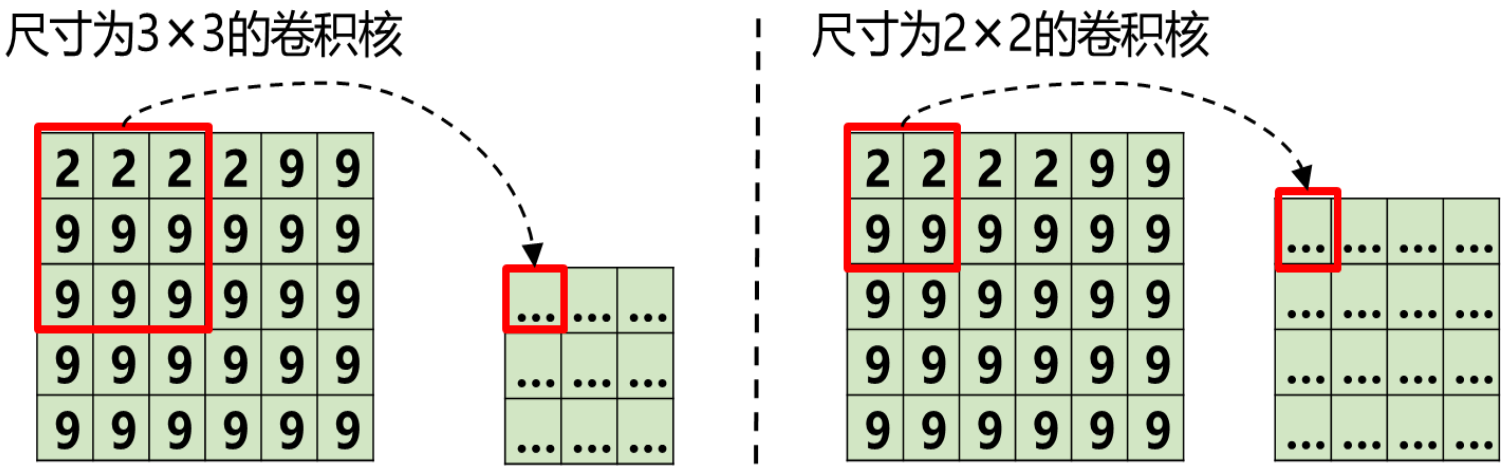


- 以图示局部连接图为例，此时卷积的尺寸是3x3的，则输出的特征图中每个像素都对应3x3=9条边，即9个参数。所谓参数共享是指，在计算获得特征图其它像素时，也仍然使用这些参数，而不必再使用新的更多参数。

- 如何理解参数共享的依据呢？可以将这些参数（卷积操作的参数）看成是提取特征的方式，该方式与位置无关。更为重要的是，共享参数这一机制大大减少了参数的数量，从而有助于提高卷积计算的效率。

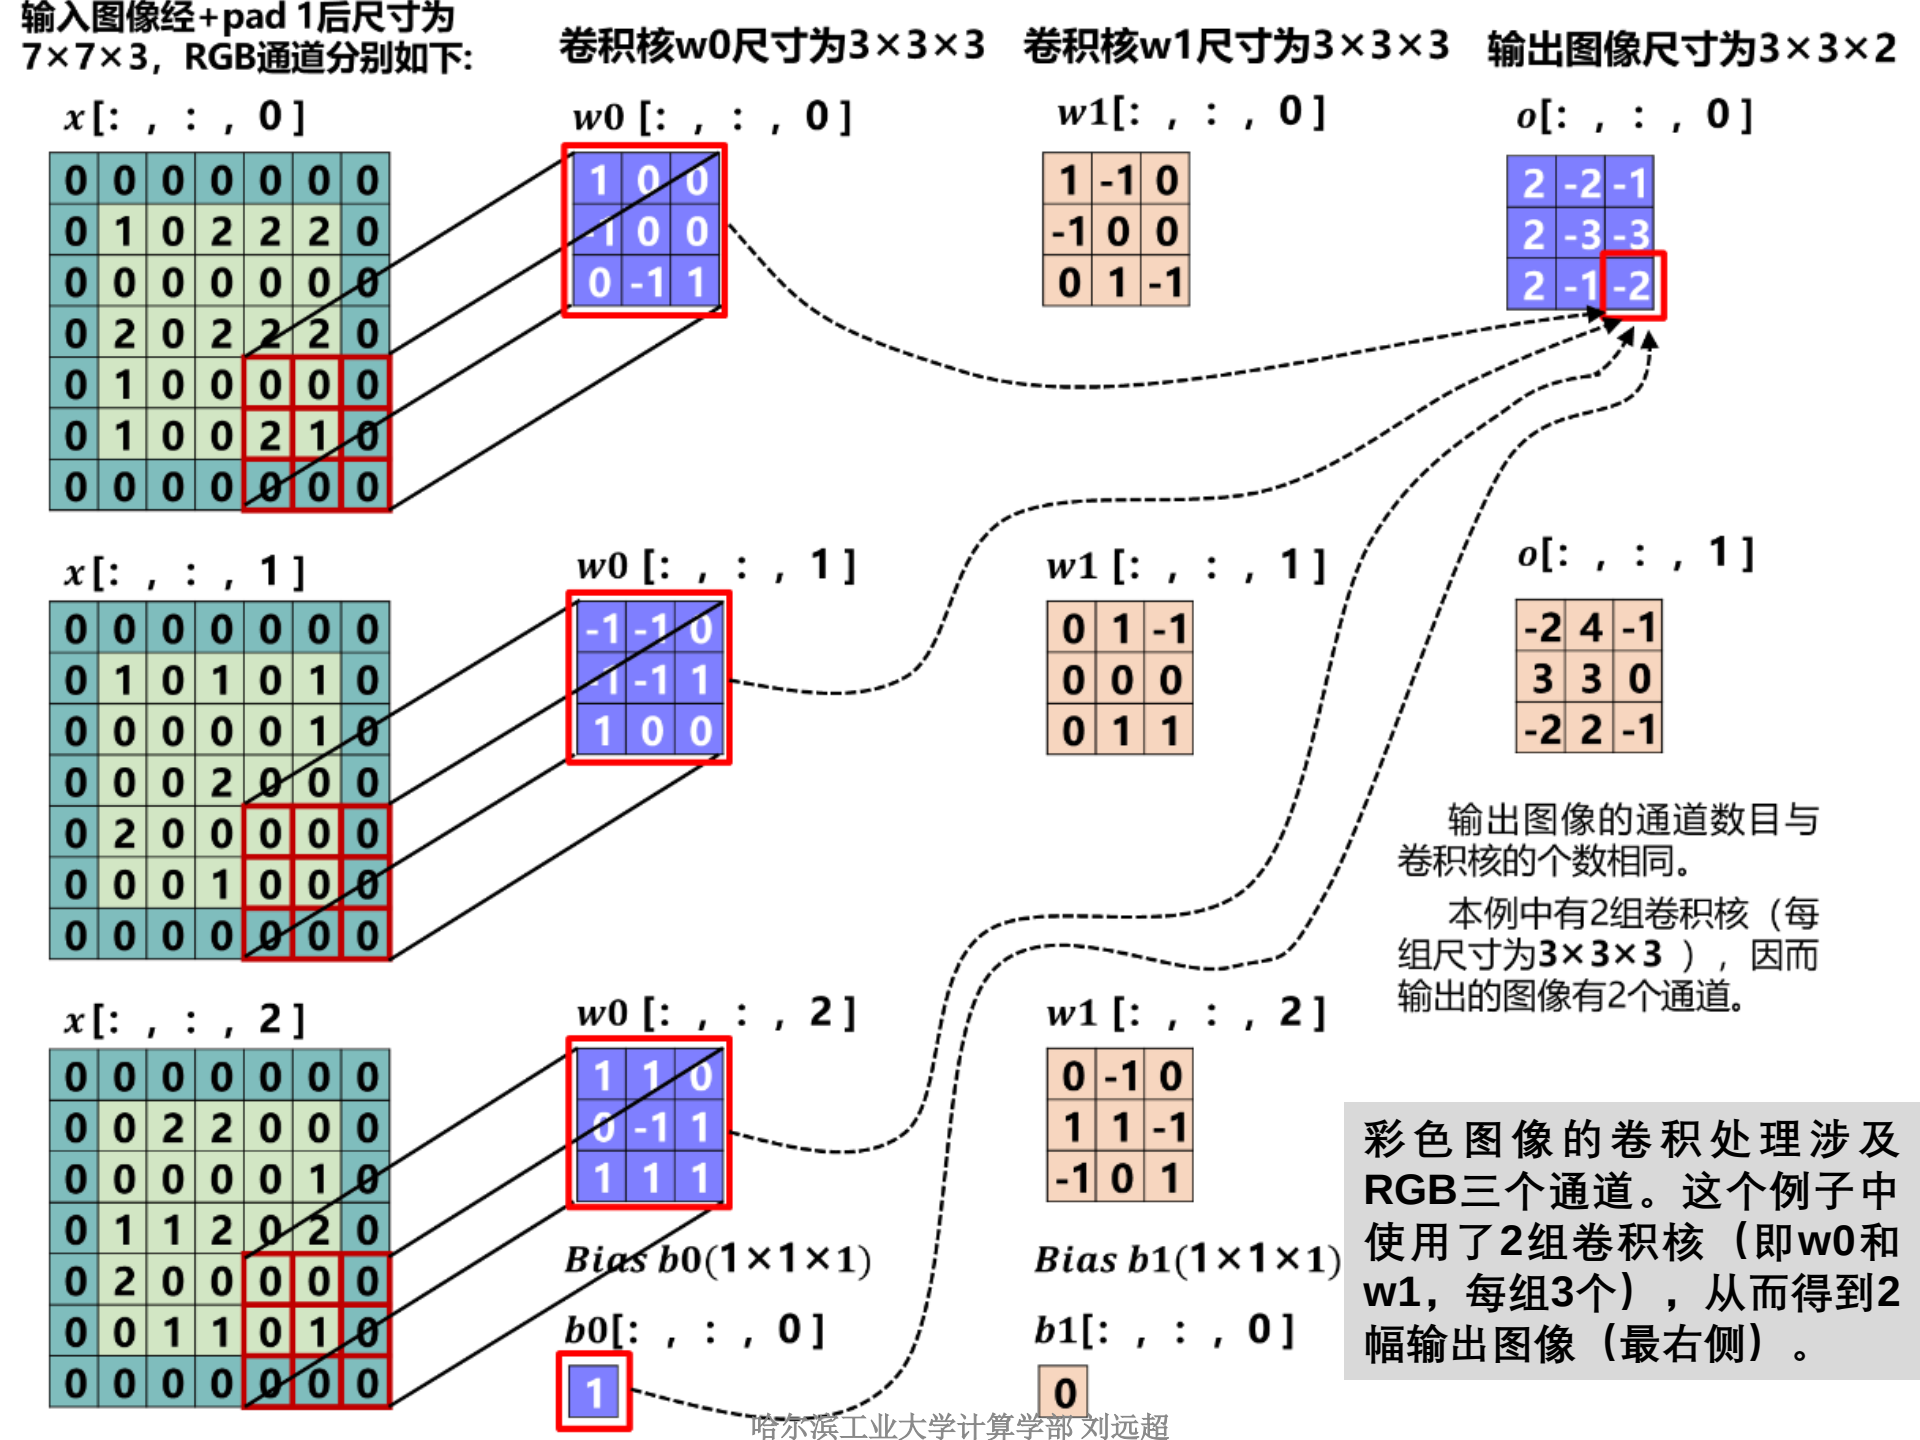
卷积神经网络概述

特点三：多卷积核



- 为了充分提取特征，对于同一幅图像，卷积神经网络一般使用多个卷积核。
- 这些卷积核的尺寸可能不同，或者不同卷积核的尺寸虽然相同但参数取值不同。每个卷积核都会对输入图像进行卷积处理，生成另一幅图像。
- 对于同一输入图像，不同卷积核生成的不同图像可以理解为是该输入图像的不同通道。

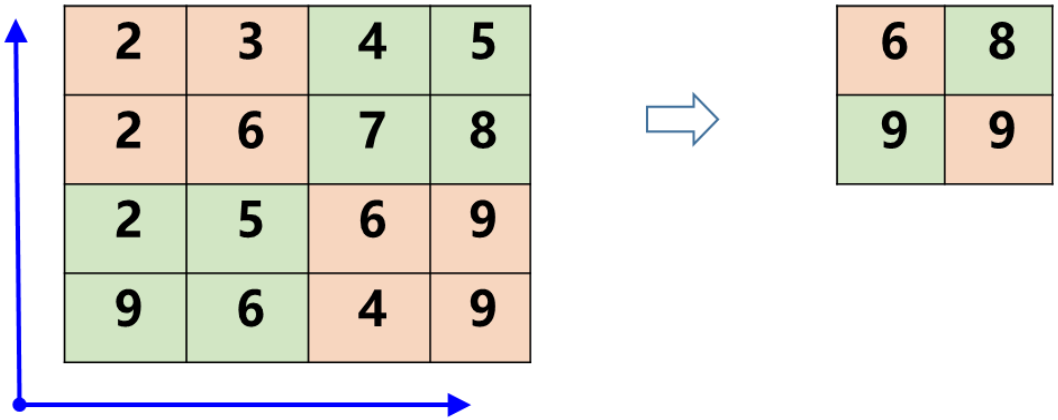
以上例子中没有考虑彩色图像的通道问题。实际上，彩色图像一般有RGB三个通道（channel），针对这三个通道一般要采用不同的卷积核来处理。


输入图像经+pad 1后尺寸为7×7×3，RGB通道分别如下:
卷积核w0尺寸为3×3×3
卷积核w1尺寸为3×3×3
输出图像尺寸为3×3×2
x[:, :, 0]
w0[:, :, 0]
w1[:, :, 0]
o[:, :, 0]
x[:, :, 1]
w0[:, :, 1]
w1[:, :, 1]
o[:, :, 1]
输出图像的通道数目与卷积核的个数相同。
本例中有2组卷积核（每组尺寸为3×3×3），因而输出的图像有2个通道。
x[:, :, 2]
w0[:, :, 2]
w1[:, :, 2]
Bias b0(1×1×1)
b0[:, :, 0]
Bias b1(1×1×1)
b1[:, :, 0]
彩色图像的卷积处理涉及RGB三个通道。这个例子中使用了2组卷积核（即w0和w1，每组3个），从而得到2幅输出图像（最右侧）。
哈尔滨工业大学计算学部 刘远超

卷积神经网络概述

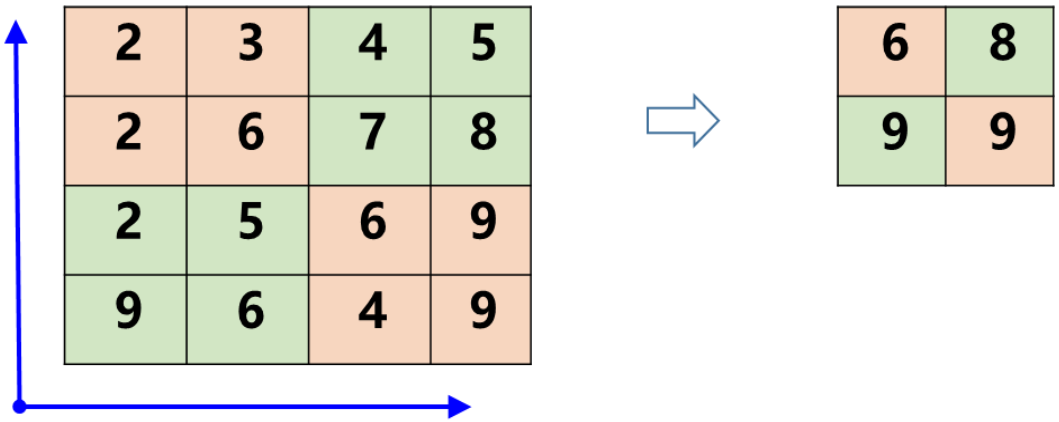
特点四：池化处理

- 池化处理也叫作降采样处理，相应的层则叫池化层或者降采样层。池化处理是对不同位置的特征进行聚合统计，其具体操作通常是取对应位置的最大值、平均值等，分别称作最大池化、平均池化等。



卷积神经网络概述

特点四：池化处理

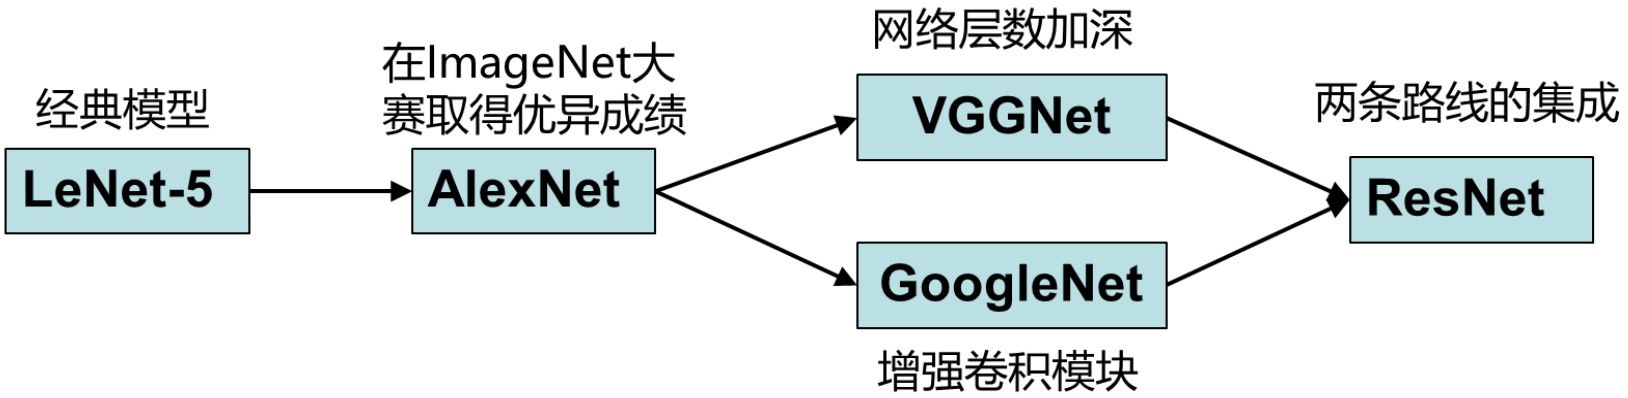


池化处理有如下作用：

- 首先是降维。经过池化处理，特征数目得以压缩，计算效率也会提高；
- 其次是降低模型的复杂度。能够在一定程度上控制过拟合，提高分类器的泛化能力；
- 在图像识别领域，池化还能提供平移和旋转不变性。若对某个区域做了池化，即使图像平移/旋转几个像素，得到的输出值也基本一样，因为每次最大值（或者最小值、平均值）运算得到的结果总是一样的。

卷积神经网络概述

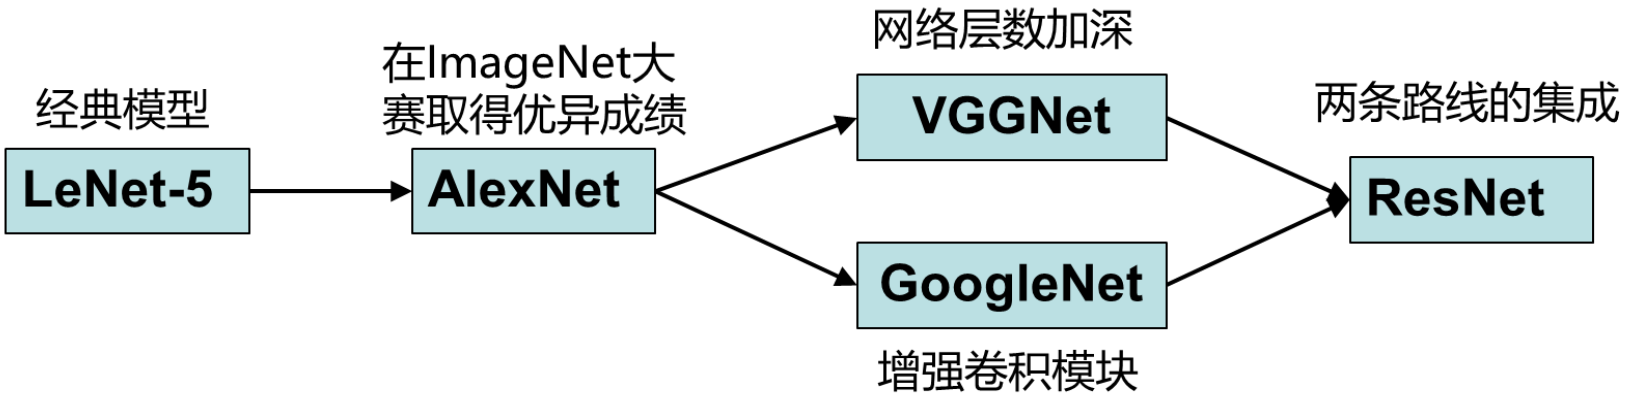
卷积神经网络的常见模型



- **LeNet-5**由LeCun等人提出于1998年提出的一种比较经典的轻量级的卷积神经网络，在手写数字识别和英文字母识别等应用上取得了较好的效果。
- 卷积神经网络真正开始引起广泛关注是由于2012年提出的**AlexNet**，该模型在大规模的图像数据集ImageNet（该数据集目前包括2万多类别，上千万幅图像）大赛上的性能大幅领先第二名。AlexNet与LeNet-5相比，在深度上进行了扩展（有 5 个卷积层和 3 个最大池化层），并采用了ReLU激活函数、加入了Dropout 等技巧。

卷积神经网络概述

卷积神经网络的常见模型



- **VGGNet**可以被视为加深版本的AlexNet，但采用了更小的卷积核和池化核，采用了多卷积子层和更多的通道数，因而其参数数量较多。
- **GoogLeNet** 最大的特点就是多次使用了一种基础增强卷积模块，从而在增加网络深度和宽度的同时减少参数。GoogLeNet深度达到了22层，参数却比AlexNet和VGGNet小很多。
- **残差网络（ResNet）**主要贡献是发现了网络层数过多带来的退化现象，并针对性地**提出了一种跳跃连接的解决思路**。因此残差网络的深度首次突破了100层，却仍然在ImageNet和CIFAR-10等图像分类任务上取得了非常好的结果。

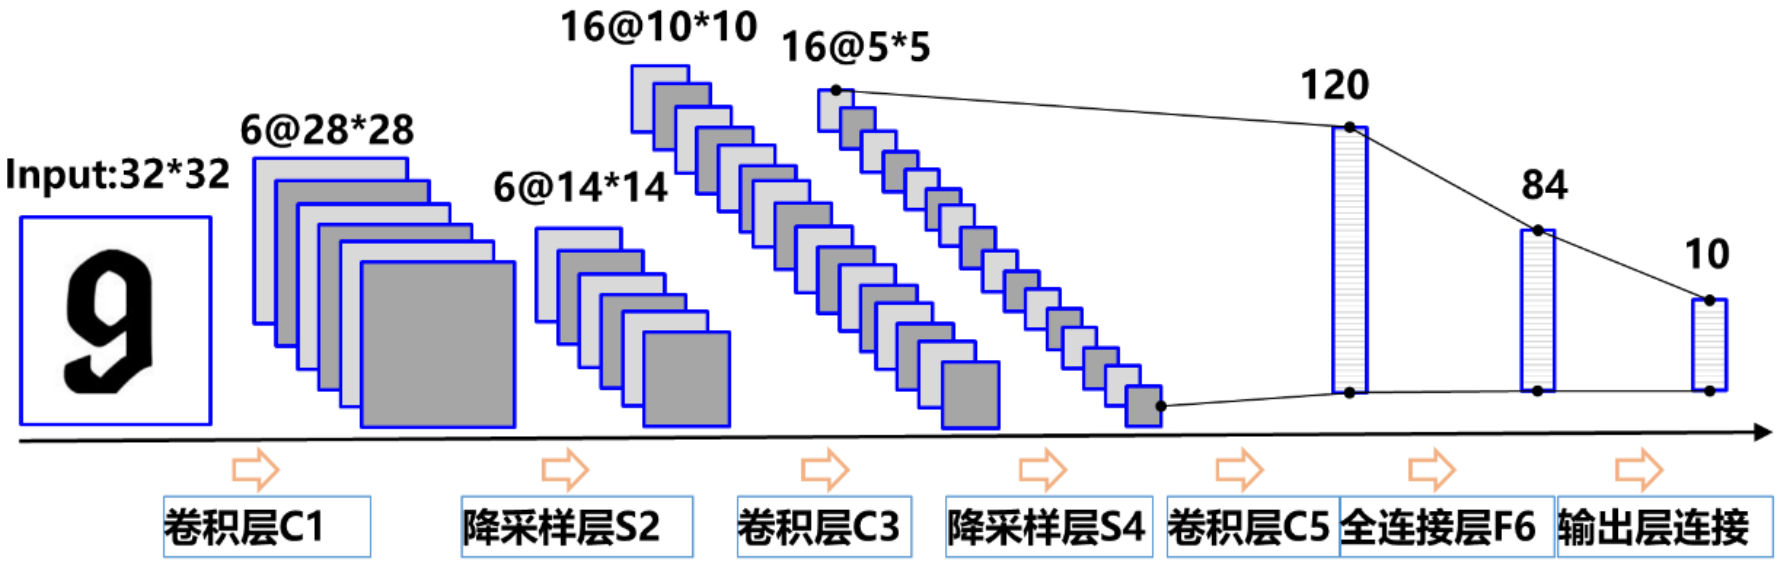
卷积神经网络

本章内容简介

- 卷积神经网络概述
- **LeNet-5**
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类

LeNet-5

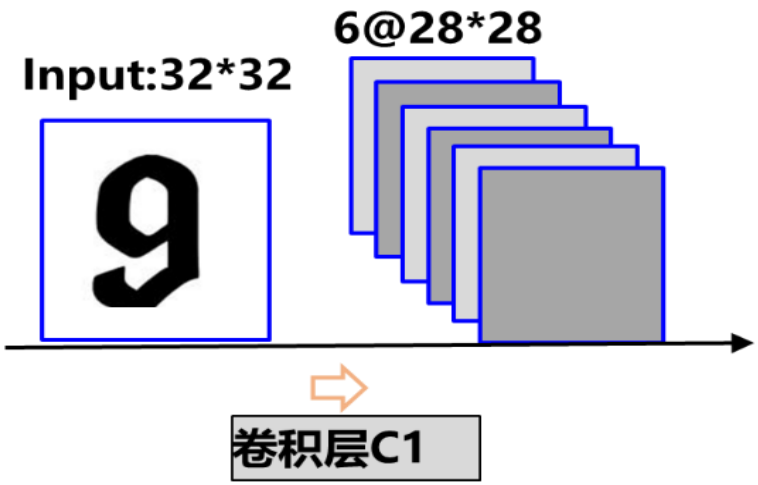
典型的多层卷积神经网络



- 图中是以数字手写体图像的识别问题为例：输入的图像尺寸为32x32像素，经过中间3个卷积层及2个降采样层和后续等处理，可以输出该图像是10个类别（即该图像是数字0-9之间的数字字符）的概率有多大。

LeNet-5

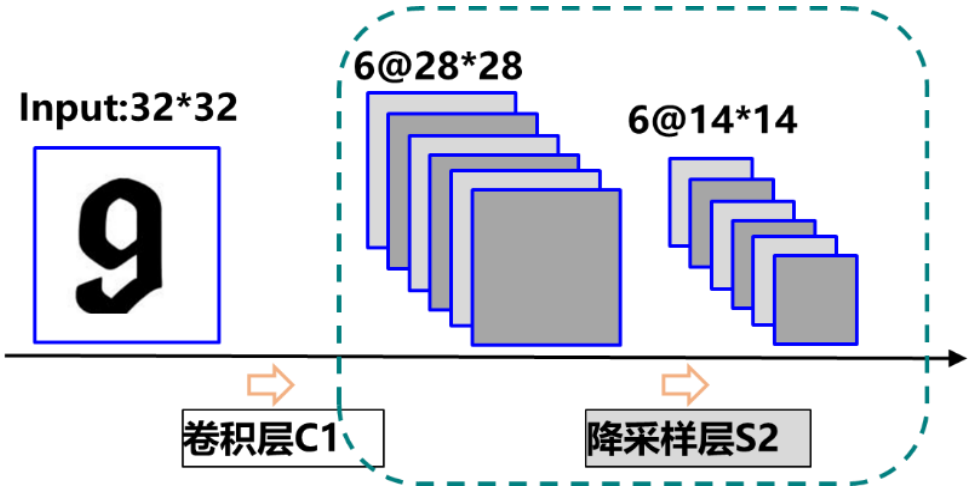
LeNet-5的卷积层C1



- **卷积层C1有6个卷积核，**且每个核的大小为5x5，因而其会输出6个大小为28x28的特征图，对应6种局部特征。
- **每个卷积核有5x5=25个单元参数和一个偏置（bias）参数，**因此每个卷积核的参数数目为(5x5+1)=26。由于总共有6个卷积核，所以该层的参数的总数为26x6=156。
- **卷积层C1中总的连接数目是多少呢？**共有(28x28)x156=122，304个连接，这是因为生成的每个特征图的28x28个像素中的任何一个的生成过程都要使用一次该特征图所对应的卷积核参数（因此要乘以26x6，即156）。

LeNet-5

LeNet-5的降采样层S2（虚线框内）

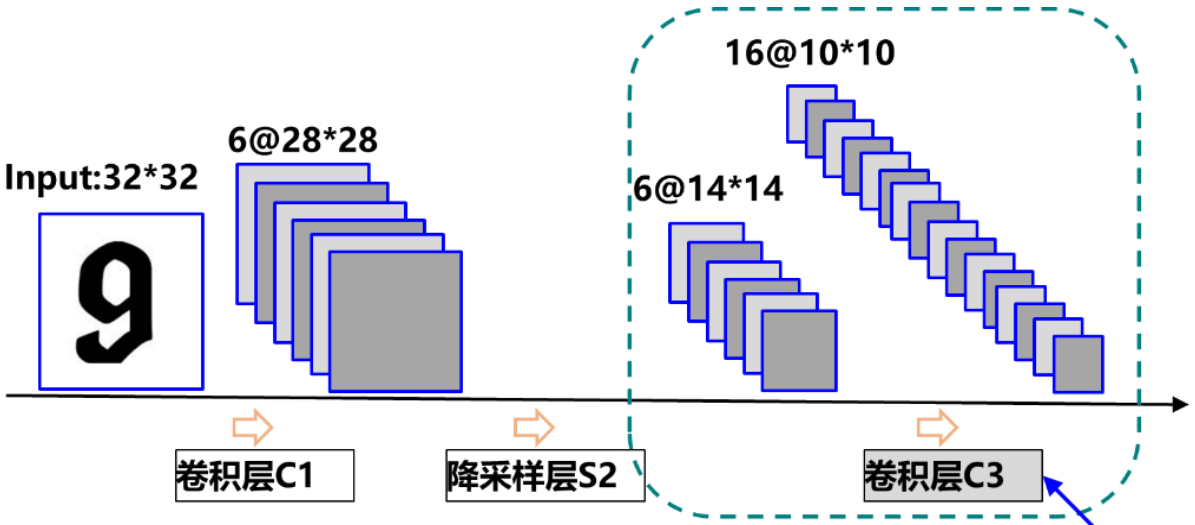


- 降采样层S2的输出仍然是6个特征图，然而其尺寸却有了降低。S2层有6个14x14像素的特征图，其每个像素单元与上一层的 2x2 像素的领域连接（即滑动窗口为2x2）。**所以S2层的尺寸是C1层的1/4**。

- 降采样层通常有两种模式：**最大池（Max-Pooling）或者平均池（Mean-Pooling）**。最大池是指特征图中每个元素来自上一层对应局部区域的最大值，而平均池则是指特征图中每个元素是上一层对应局部区域的平均值。通过使用降采样层，有助于降低网络训练参数及克服模型过拟合。

LeNet-5

LeNet-5的卷积层C3（虚线框内）



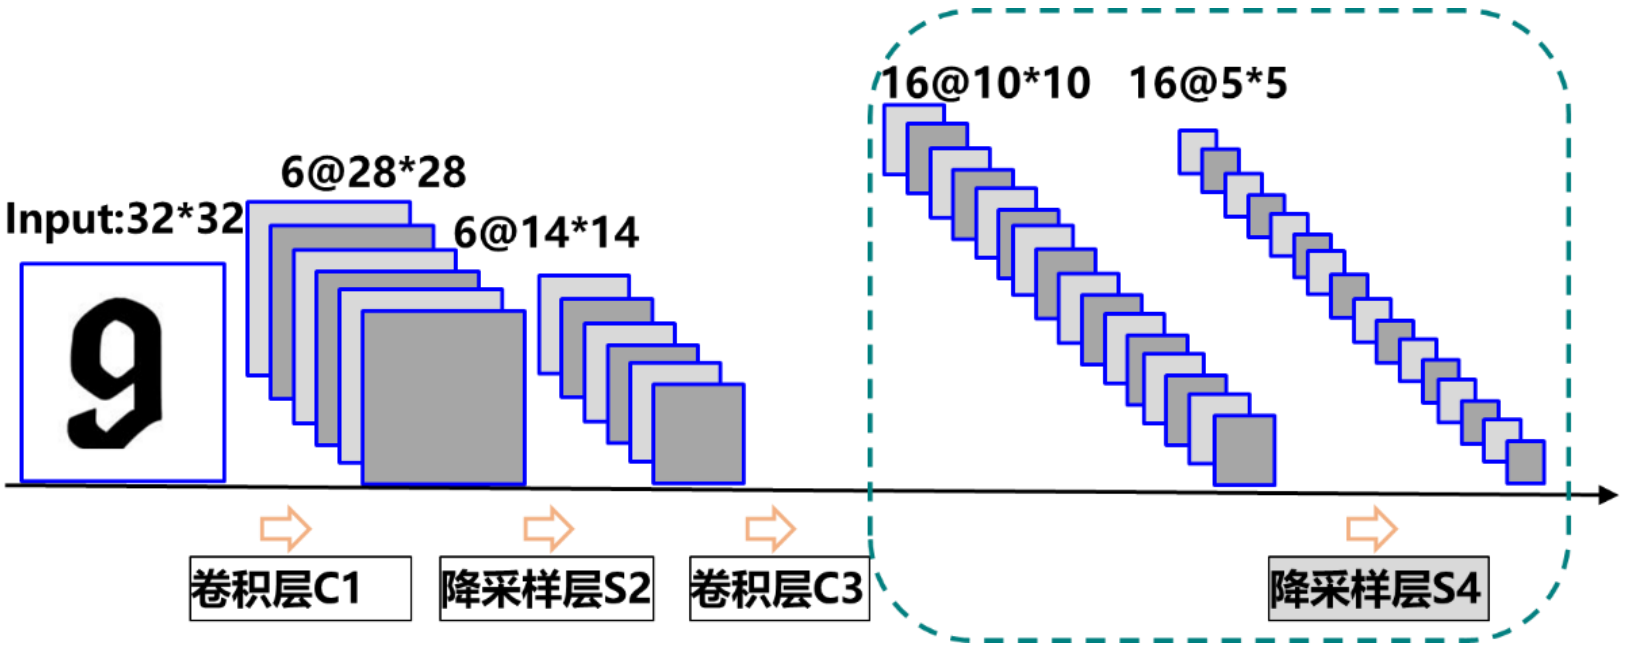
	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
0	X				X	X	X			X	X	X	X		X	X
1	X	X				X	X	X			X	X	X	X		X
2	X	X	X				X	X	X			X		X	X	X
3		X	X	X			X	X	X	X			X		X	X
4			X	X	X			X	X	X	X		X	X		X
5				X	X	X			X	X	X	X		X	X	X

C3卷积层输出的每个特征图**只**与上一层S2中**部分**特征图相连接（连接关系如此**映射表**所示）。

- 注意到C3的结果中，每个特征图与上一层S2中**部分特征图相连接**。其映射关系见图下方这个表格。

LeNet-5

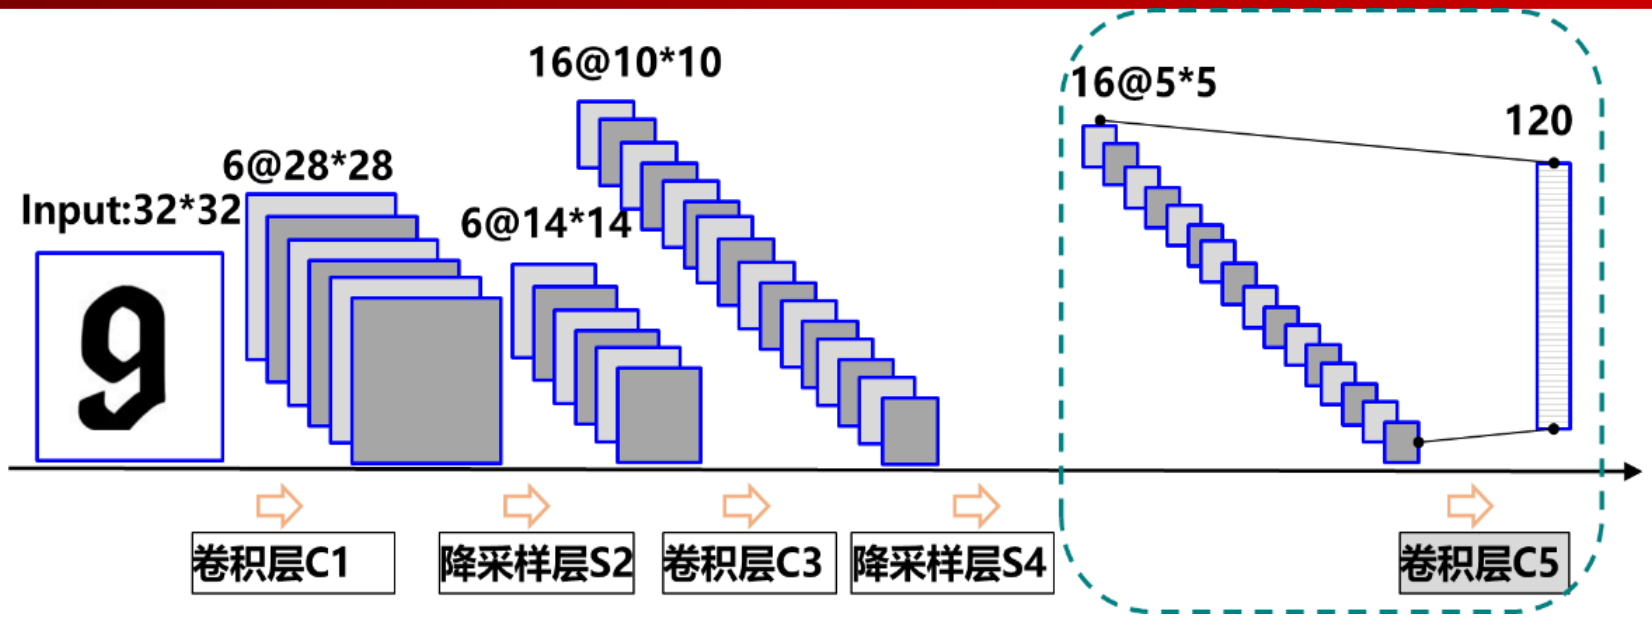
LeNet-5的降采样层S4（虚线框内）



- S4层得到16个5x5的特征图，其每个单元与上一层的 2x2 个领域连接（滑动窗口为2x2）。所以S4层的尺寸是上一层C3层的输出结果的1/4。

LeNet-5

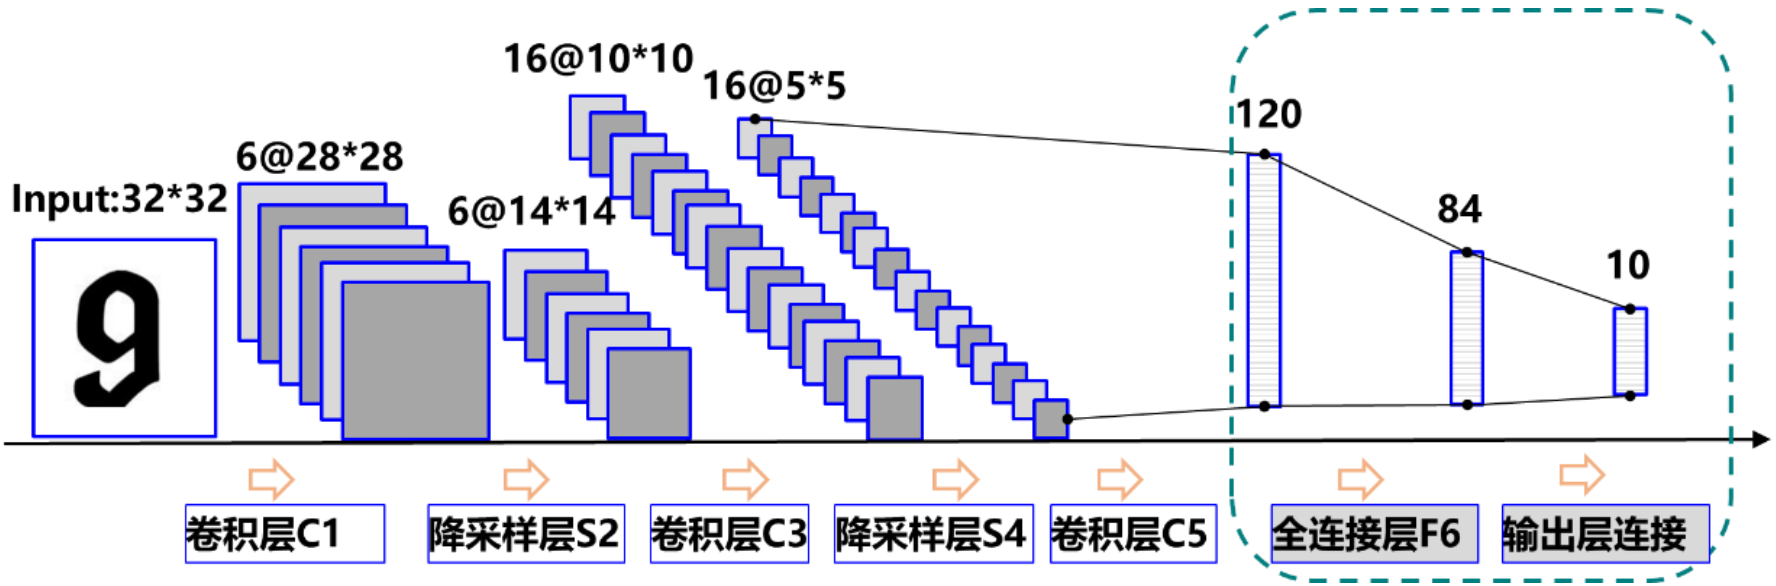
LeNet-5的卷积层C5（虚线框内）



- 卷积层C5有120个卷积核，卷积核大小恰好为5×5，和输入的特征图的整体尺寸相同。因此生成120个特征图，每个特征图的大小为1×1。每个特征图都与上一层S4的所有特征图连接。C5层有120x(5x5x16+1) = 48120个连接，这里的16为上一层的特征图个数。

LeNet-5

LeNet-5的全连接层F6和输出层（虚线框内）



- LeNet-5的下一个层是全连接层，如图所示。其类似于多层感知机神经网络中的一个层，共有84个神经元，或者也可以被理解为像素。
- 这84个神经元与上一层C5层的120个神经元进行全连接，所以需要训练的参数的数量是(120+1)x84=10164。

LeNet-5

LeNet-5的输出层

- LeNet-5的输出层由欧式径向基函数单元构成。每个输出RBF单元计算输入向量和参数向量之间的欧式距离：

$$y_i = \sum_{j=1}^{84} (x_j - w_{ij})^2$$

其中，y_i表示当前待识别的手写数字字符经过前面全连接层F6处理后的特征向量x与第i个字符参数w_i之间的欧式距离。输入图像经过之前的全连接层F6处理，得到的共有84个像素。因此x有84个元素，用下标j来遍历。



LeNet-5使用RBF识别ASCII字符集的初始参数

单选题 1分

设置

30

假设输入的图像为100*100像素（RGB）的图像， 且使用了卷积层进行处理，其包括100个过滤器，每个的尺寸为5*5，则这个隐藏层需要多少参数（包括偏置参数）？

A **2500**

B **2600**

C **7500**

D **7600**

提交

单选题 1分

设置

31

由于池化层没有需要求解的参数，因此其对反向传播中梯度计算没有影响，这个描述正确与否?

A **正确**

B **错误**

提交

多选题 1分

设置

32

卷积神经网络的一个特点是“参数共享”。下面关于“参数共享”的哪种说法是正确的?

A 如果参数较多，则容易导致过拟合。而减少参数有助于避免过拟合

B 参数共享的优势是通过一个任务上学习到的参数可以直接应用到另外一个任务上

C 可以允许一个特征检测器在整个输入图像的不同位置使用，即可以把参数看成是卷积提取特征的方式，该方式与位置无关。

D 参数越多，才能避免过拟合，减少参数容易导致过拟合

提交

单选题 1分

设置

33

下列不属于卷积神经网络中的超参数的是

A 步长

B 核大小

C 神经网络层数

D 权重系数

提交

卷积神经网络

本章内容简介

- 卷积神经网络概述
- LeNet-5
- **AlexNet**
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类

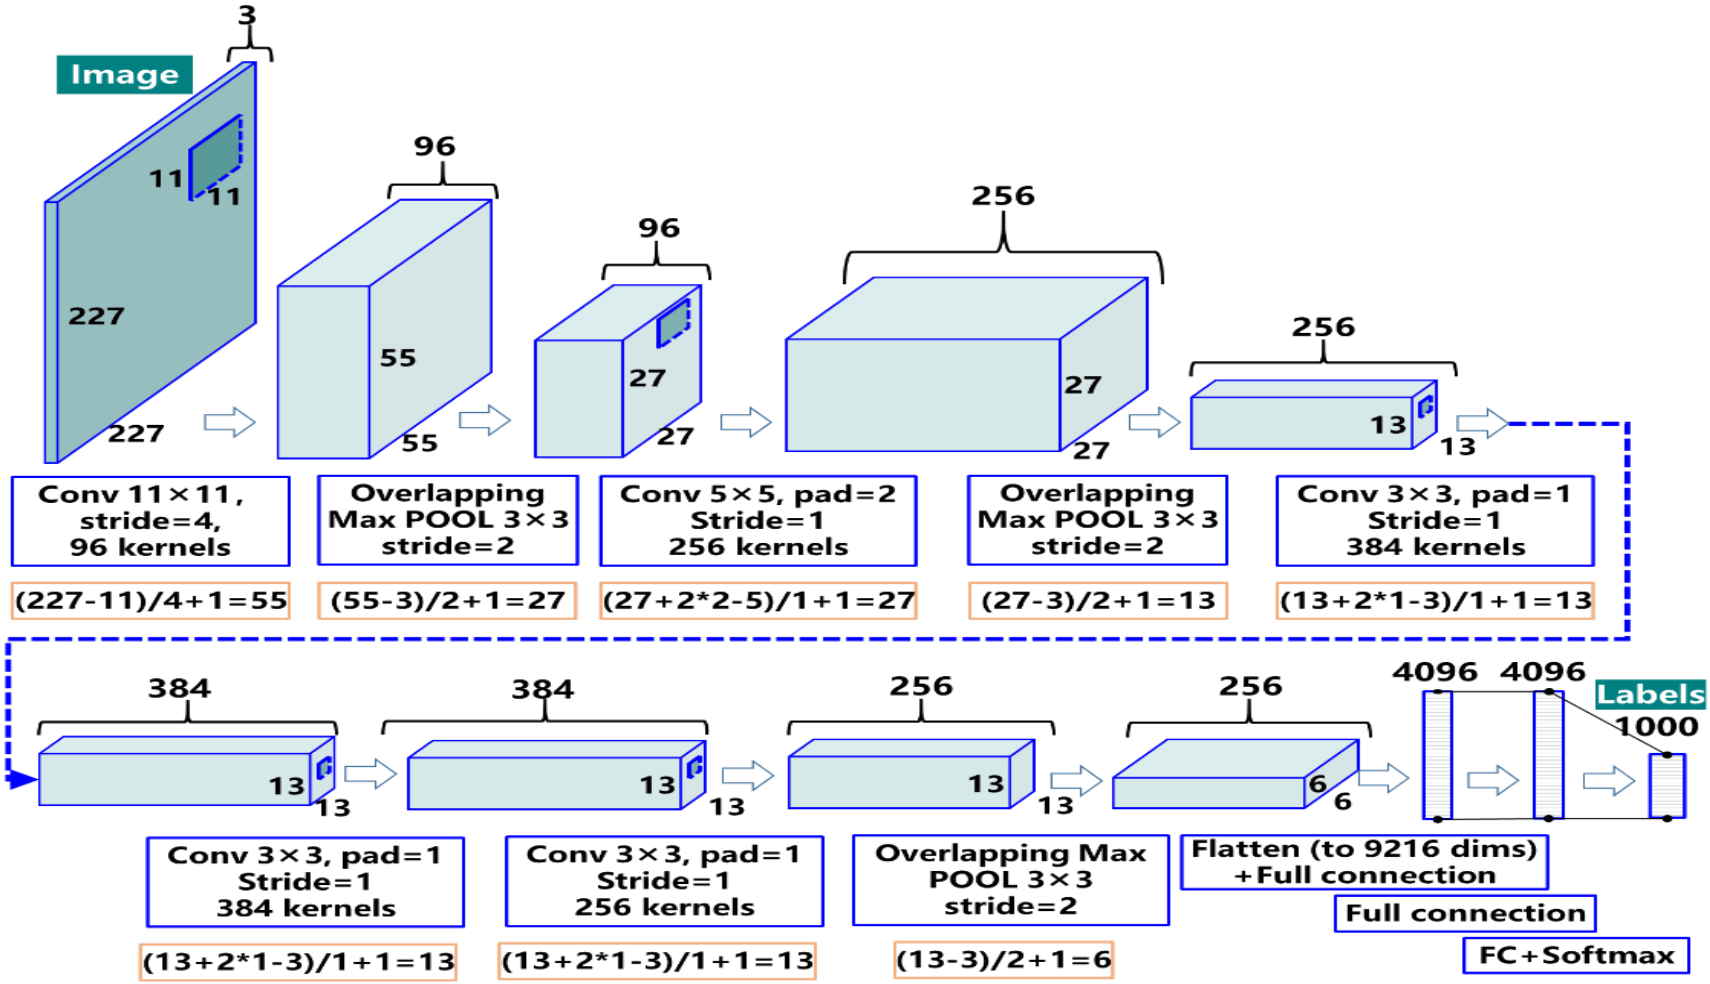
AlexNet

AlexNet概述

- LeNet在数字手写体图像识别分类问题上取得了较好的成绩，但是受限于当时计算机的性能，并没有引起很多的关注。
- 直到2012年，Alex等人提出的AlexNet网络（以作者的名字命名）在ImageNet ILSVRC大赛上以远超第二名的成绩获得冠军，卷积神经网络乃至深度学习才真正引起了广泛的重视。
- ImageNet是一个大规模的图像数据集，其规模自从2009年问世以来仍然在不断的扩充。AlexNet在2012年比赛时对ImageNet中1000个不同的类别120万张高分辨率图像进行了分类，因此处理的数据集规模远大于MNIST。
- 目前深度学习模型已经成为每年的ImageNet LSVRC挑战赛的主要技术手段。

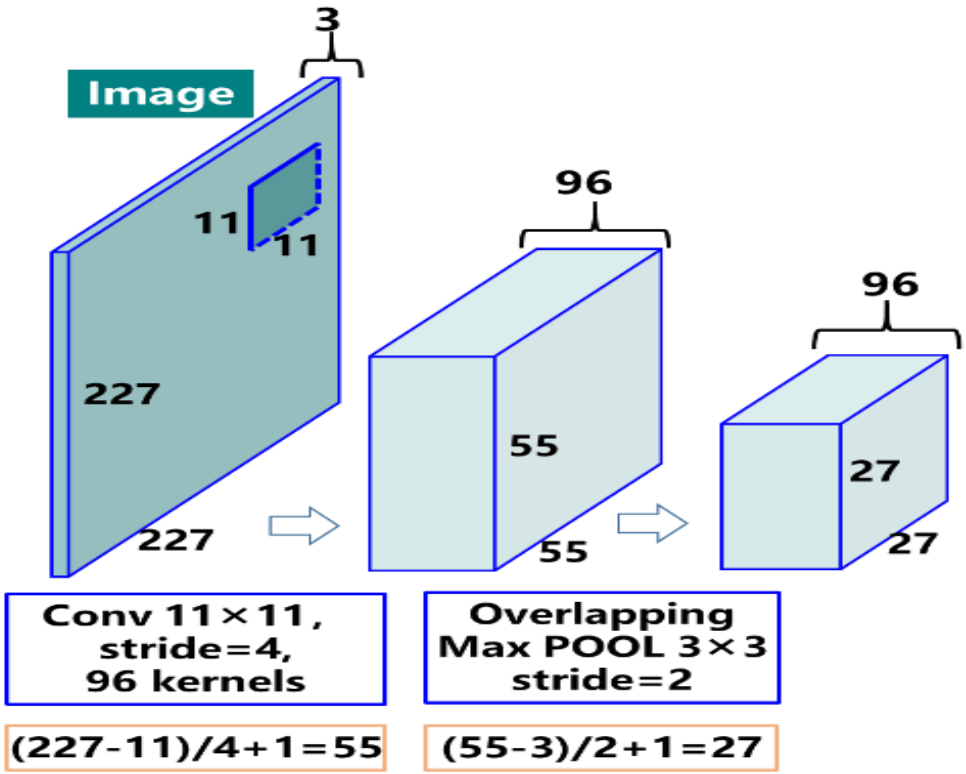
AlexNet

AlexNet的结构



AlexNet

卷积层Conv1

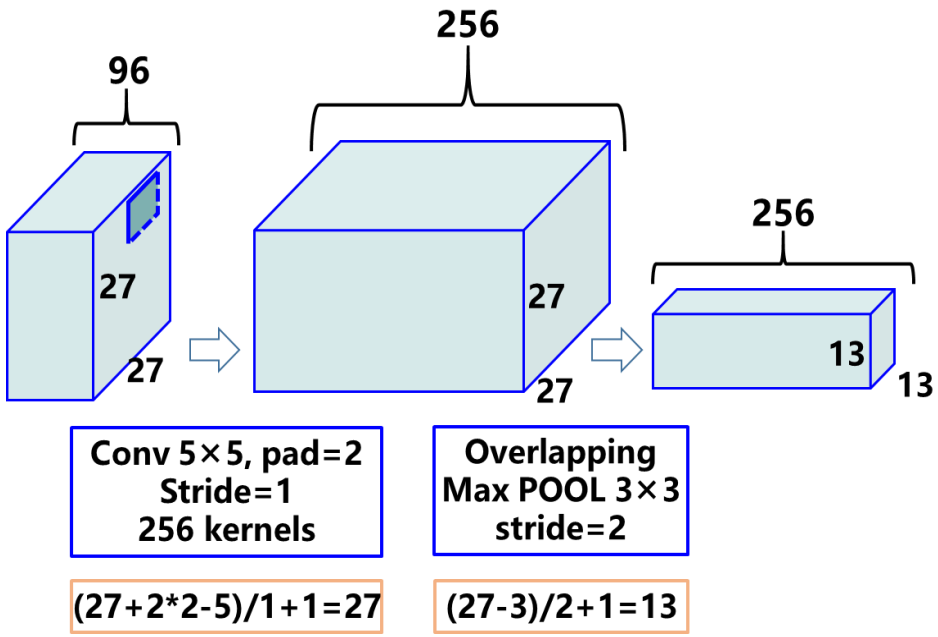


卷积层Conv1的处理过程为：

- **卷积处理。**使用大小为$11 \times 11 \times 3$的卷积核进行特征提取，即卷积核深度与通道的数量相同（都为3），如图中左侧虚线框所示。卷积核的移动步长为4，且由于使用了**96个卷积核**，所以输出特征图形状为$55 \times 55 \times 96$；
- **Relu+LRN处理。**卷积处理后，使用Relu激励函数并经过局部响应归一化处理，以使输出特征图每个元素的取值在合理范围之内，Relu+LRN处理后的特征图形状不变；
- **降采样处理。**如前所述，AlexNet使用重叠的最大池进行降采样。池化核的大小为3×3 ，步长为2，因此降采样之后的特征图形状变为$27 \times 27 \times 96$。这是因为降采样后得到的通道数不变仍为96，而$(55-3)/2+1=27$。

AlexNet

卷积层Conv2



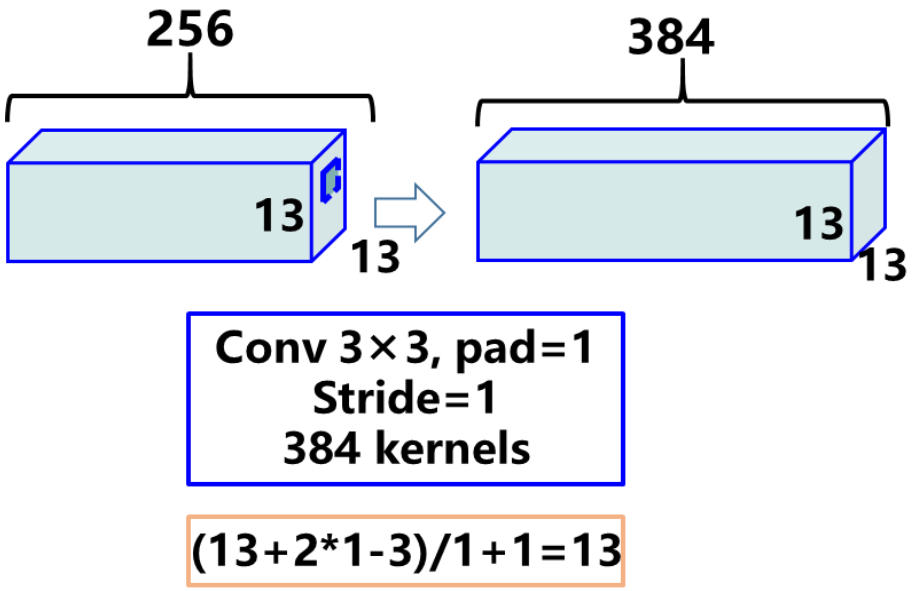
卷积层Conv2的输入特征图形状为：$27 \times 27 \times 96$。其处理过程为：

1. **卷积处理。**使用256个大小为5×5的卷积核对上一步得到的96个特征图进一步卷积处理。这里每个卷积核所处理的是输入的96个特征图中的某几个特征图，将其相应的区域乘以相应的核权重然后加上偏置。卷积时的填充长度为2，移动步长为1。由于使用的卷积核有256个，因此得到256个27×27大小的特征图，即$(27 + 2 \times 2 - 5)/1 + 1 = 27$；
2. **Relu+LRN处理。**该卷积层处理后特征图的形状不变；
3. **降采样处理。**池化核的大小为3×3，步长为2。降采样之后得到的特征图为$13 \times 13 \times 256$。

因此，卷积层Conv2的输出特征图的形状：$13 \times 13 \times 256$。

AlexNet

卷积层Conv3



卷积层Conv3输入特征图的形状为：$13 \times 13 \times 256$。如图所示，其处理过程为：

1. **卷积处理**。使用384个3×3大小的卷积核对上一步得到的256个特征图进一步卷积处理。每个卷积核所处理的是输入的256个特征图中的某几个特征图，将其相应的区域乘以相应的核权重然后加上偏置。卷积时的填充长度为1，移动步长为1。从而得到384个13×13大小的特征图；

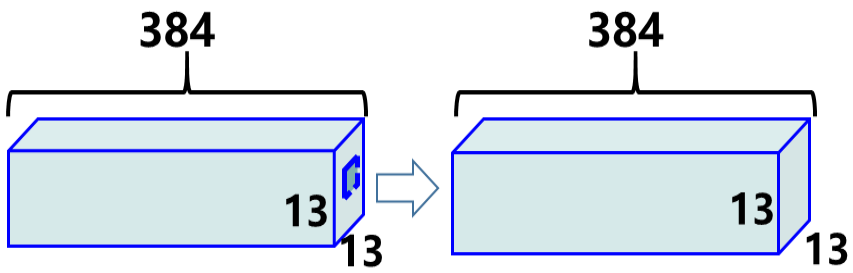
2. **Relu+LRN处理**。该卷积层处理后特征图的形状不变；

3. **卷积层Conv3没有进行降采样处理**。

因此，卷积层Conv3输出特征图的形状为$13 \times 13 \times 384$。

AlexNet

卷积层Conv4　　卷积层Conv4输入特征图的形状为：$13 \times 13 \times 384$



其处理过程为：

1. **卷积处理。**使用384个3×3大小的卷积核对上一步得到的384个特征图进行卷积处理，其中每个卷积核处理384个特征图中的某几个，将其相应的区域乘以相应的核权重并加上偏置。卷积时的填充长度为1，移动步长为1。从而得到384个13×13大小的特征图；

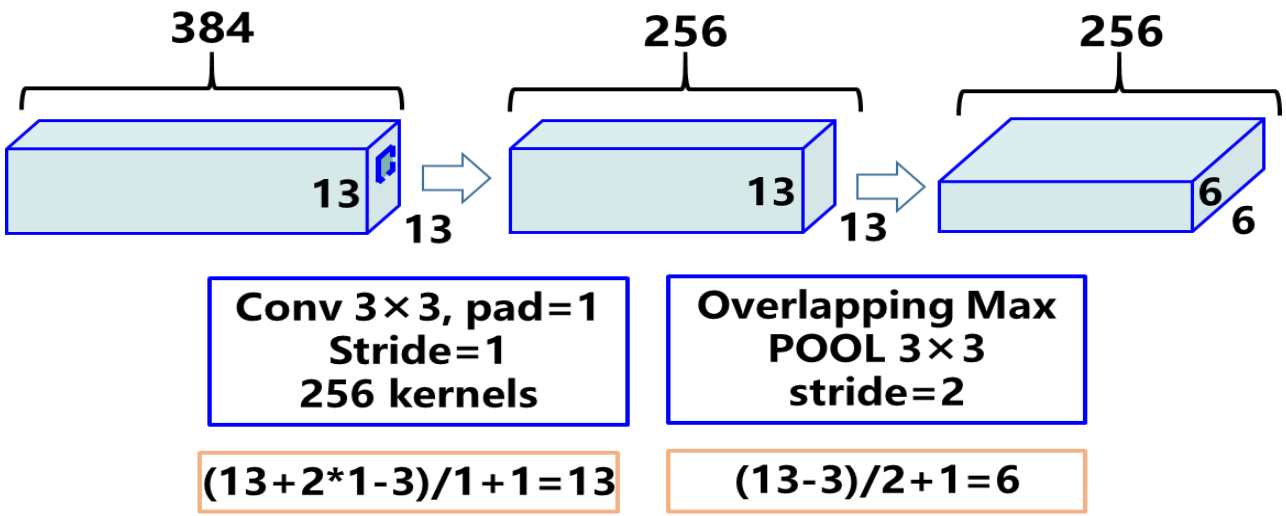
2. **Relu+LRN。**该卷积层处理后特征图的形状不变；

3. **卷积层Conv4没有进行降采样处理。**

因此，卷积层Conv4输出特征图的形状为$13 \times 13 \times 384$，即与输入特征图的形状相同。

AlexNet

卷积层Conv5　　卷积层Conv5的输入特征图形状为$13 \times 13 \times 384$



1. **卷积。**使用256个3×3大小的卷积核对上一步得到的384个特征图进一步卷积处理，其中每个卷积核处理输入的384个特征图中的某几个特征图，将其相应的区域乘以相应的核权重然后加上偏置。卷积的填充长度为1，移动步长为1，因此从而得到256个13×13大小的特征图；

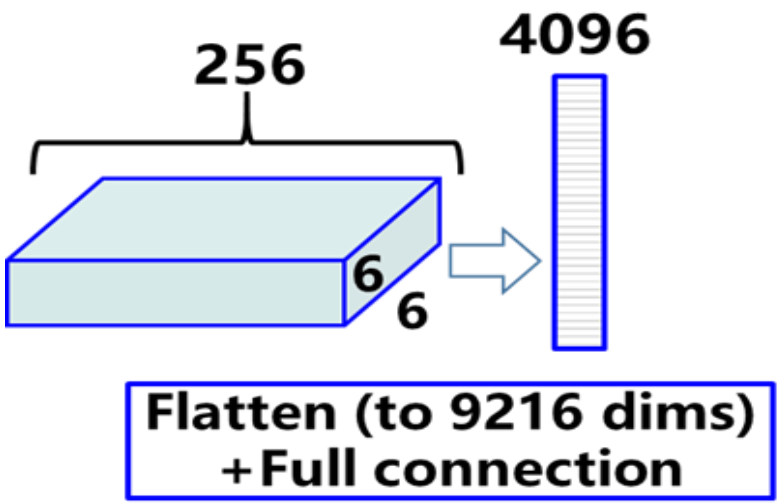
2. **Relu+LRN。**该卷积层处理后特征图的形状不变；

3. **降采样处理。**池化核的大小为3×3，步长为2。降采样之后得到256个6×6的特征图。

因此，卷积层Conv5的输出特征图形状为$6 \times 6 \times 256$。

AlexNet

全连接层FC6



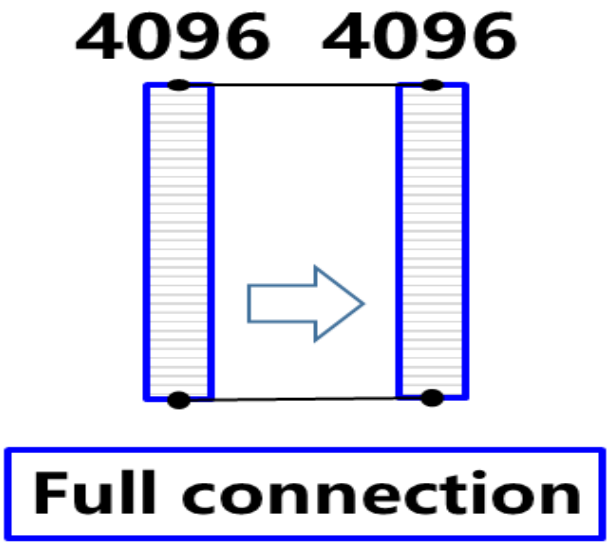
全连接层FC6的输入特征图形状为$6 \times 6 \times 256$。如图所示，其处理过程为：

1. 卷积处理。使用4096个6×6大小的卷积核对上一步得到的256个特征图进一步卷积处理，其中每个卷积核处理的是输入的256个特征图中的某几个特征图，将其相应的区域乘以相应的核权重然后加上偏置。该过程使用了丢弃法（dropout）技巧。由于卷积核大小与输入特征图的大小相同，因此最终得到长度为4096的一维数组；
2. Relu+LRN。该层处理后特征图的形状不变；

因此，全连接层fc6输出特征图的形状为4096×1。

AlexNet

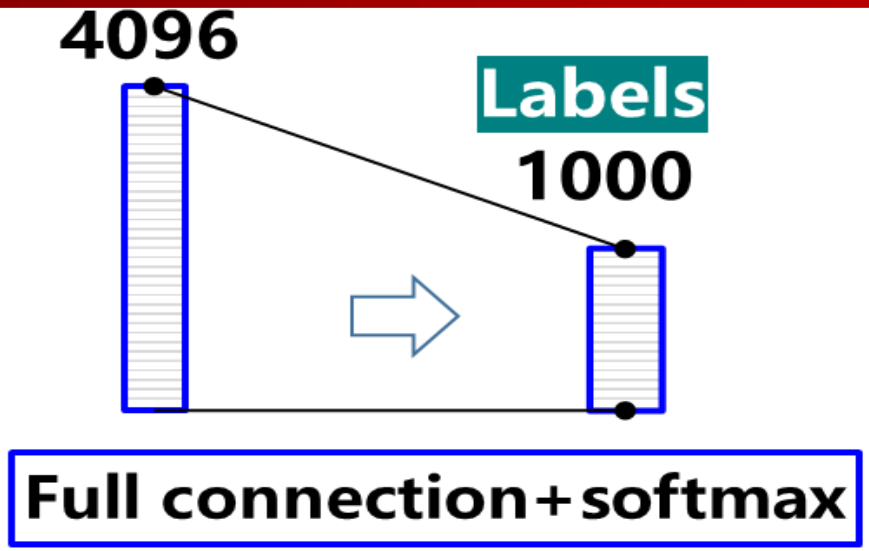
全连接层FC7



- 全连接层FC7的输入和输出的特征图的形状相同。在这个全连接层中也进行了dropout处理。

AlexNet

全连接层FC8



AlexNet的全连接层FC8输入特征图的形状为4096×1。如图所示，其处理过程为：

1. **全连接处理：**从4096个神经元映射为1000个神经元；

2. **softmax处理：**得到1000个float型数值；

可见，全连接层fc8输出特征图的形状为1000×1，其含义为当前输入的原始图像分别属于1000个类的概率。

AlexNet

AlexNet的特点

综上可见，AlexNet网络结构虽然在整体上与LeNet类似，但在细节上有很多不同点：

1. 卷积层数较多。AlexNet有5个卷积层，LeNet有3个卷积层。
2. 激活函数不同。原始LeNet-5中在池化后使用的是sigmoid激活函数，而AlexNet则改为ReLU激活函数。计算较为简单，也有助于缓解梯度消失或梯度爆炸问题，从而加快训练速度。
3. AlexNet对ReLU的值域进行了局部响应归一化（Local Response Normalization，简称LRN）处理。即对局部神经元的活动建立竞争机制，抑制反馈较小的神经元，以增强模型的泛化能力。
4. AlexNet使用重叠最大池处理机制。AlexNet使用最大池化处理，以避免平均池容易导致的模糊化。重叠池化是指池化步长比池化核的尺寸小，从而使池化的输出特征图之间有重叠，目的是使特征更丰富，减少信息丢失。

AlexNet

AlexNet的特点（续）

5. AlexNet通过丢弃法（dropout）来控制全连接层的模型复杂度。所谓丢弃法是指模型在训练时随机忽略一部分神经元（但在测试阶段不忽略），以避免模型过拟合。AlexNet的最后几个全连接层使用了Dropout，而LeNet-5没有使用丢弃法。

6. AlexNet进行了图像增强处理。图像增强是指对图像进行翻转、裁剪和颜色调整等处理，使图像特征发生变化，由于图像的分类标签并未改变，因而可以模拟各种样本。图像增强有利于扩大训练数据集，以缓解过拟合现象提升模型的泛化能力。此外，AlexNet的另外一种数据增强方法是对图像数据进行主成分（PCA）处理，并对主成分施加一个标准差为0.1的高斯扰动，增加一些噪声，从而达到扩充训练样本的目的。

7. AlexNet使用CUDA加速训练。由于神经网络训练需要大量的矩阵运算，AlexNet使用了两块GTX 580 GPU并行进行训练。将AlexNet分布在两个GPU上，在每个GPU的显存（3GB）中储存一半的神经元参数。同时，AlexNet中GPU之间的通信只在网络的某些层进行，以控制通信开销。

AlexNet

ReLU函数的后处理：局部响应归一化

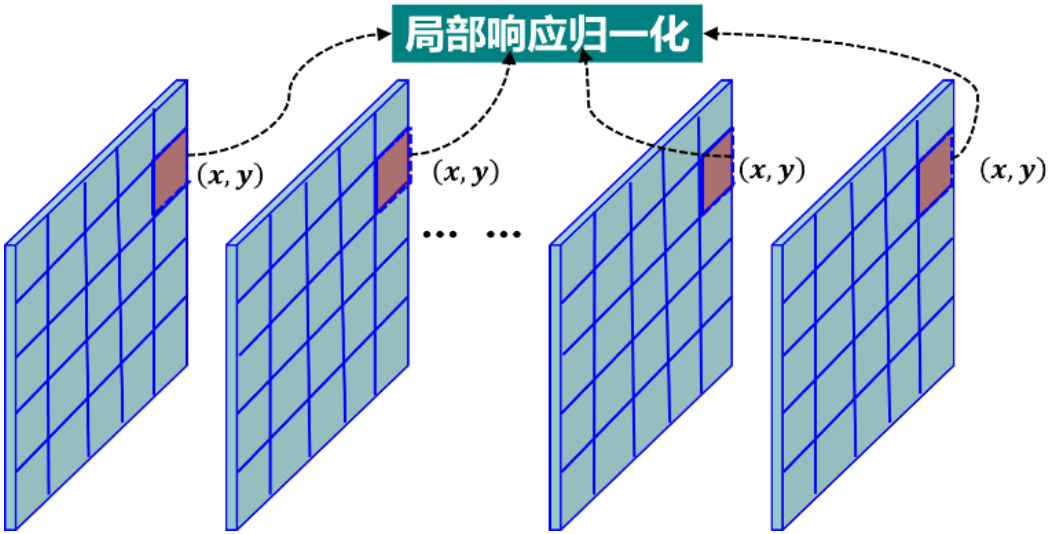
- **局部响应归一化的原因。**尽管ReLU激活函数具有一定优势，但与传统的激活函数tanh和sigmoid相比，ReLU的值域没有确定的区间，所以AlexNet对ReLU得到的结果进行了规范化处理。
- **局部响应归一化的计算过程。**局部响应归一化是指利用局部相邻核的信息来做规范化处理。假设$a_{x,y}^{i}$为使用第 i 个卷积核经过卷积及$ReLU$函数激活处理在(x,y)位置上的输出值，则在此基础上进行局部响应规范化得到的结果$b_{x,y}^{i}$的计算方法为：

$$b_{x,y}^{i}=\frac{a_{x,y}^{i}}{\left(k+\alpha\sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)}(a_{x,y}^{j})^{2}\right)^{\beta}}$$

其中的求和是在与第 i 个卷积核相邻的n个卷积核生成的特征图上相同空间位置(x,y)进行。其中，N是该层中的卷积核总数。常数k、n、β是超参数，可以通过验证集确定其具体取值。

AlexNet

局部响应归一化举例



$$b_{x,y}^{i}=\frac{a_{x,y}^{i}}{\left(k+\alpha\sum_{j=\max(0,i-n/2)}^{\min(N-1,i+n/2)}(a_{x,y}^{j})^{2}\right)^{\beta}}$$

- 为便于理解，图中给出了一个例子。假设其中每一个网格状图形分别表示由不同卷积核卷积生成的特征图，且已经使用了ReLU激活函数处理。假设其中某特征图 i 的某像素位置为(x,y)其取值为$a_{x,y}^{i}$，则所谓局部归一化就是利用其它相邻特征图（用j遍历）的同一位置，即(x,y)的像素值$a_{x,y}^{j}$对其进行局部归一化，从而得到$b_{x,y}^{i}$。

卷积神经网络

本章内容简介

- 卷积神经网络概述
- LeNet-5
- AlexNet
- **VGGNet卷积神经网络**
- 残差神经网络
- 利用卷积神经网络进行文本分类

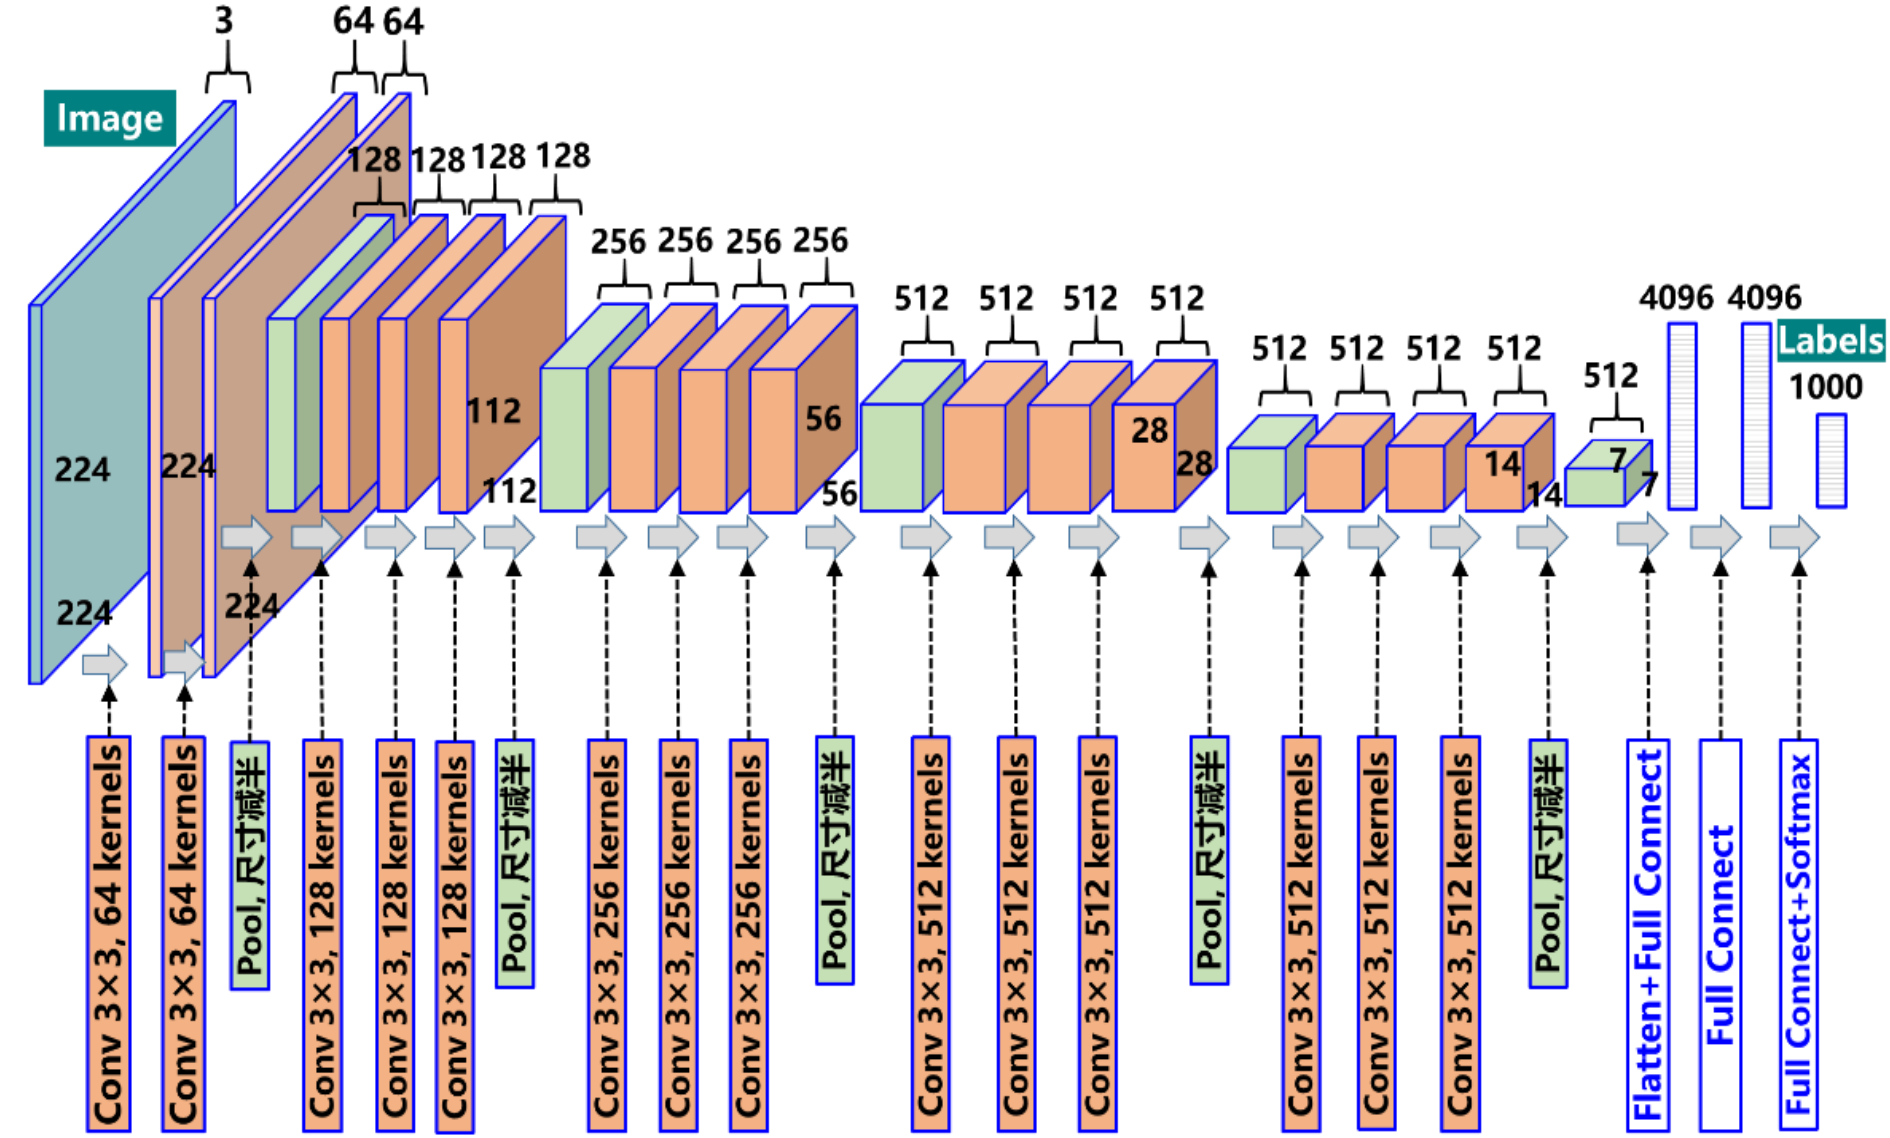
VGGNet卷积神经网络

VGGNet概述

- **VGGNet** 是2014年由牛津大学计算机Visual Geometry Group（视觉几何组）和Google DeepMind公司的研究人员研发的深层卷积神经网络。其获得了ImageNet ILSVRC（ImageNet Large Scale Visual Recognition Challenge）比赛的第二名（第一名是GoogLeNet）。

- **VGGNet共有四个版本**：VGG11、VGG13、VGG16、VGG19，这些版本计算原理类似，主要区别在于网络层次深度等的配置不同。

VGGNet的结构（以VGG16为例，图中显示的数字是处理后的结果）



VGGNet卷积神经网络

VGGNet的结构

图9.29以其中的VGG16为例显示了VGGNet的框架结构。其对输入图像（$224 \times 224 \times 3$）的逐层处理过程为：

1) **两次卷积+ReLU。两次卷积都使用了64个3×3的卷积核，且输出特征图的尺寸都为$224 \times 224 \times 64$（即高和宽不变，但通道数变为64）；而后进行最大化池化处理：池化核的尺寸为2×2，其效果为图像尺寸减半，因此输出特征图的尺寸变为$112 \times 112 \times 64$；**
2) **两次卷积+ReLU。两次卷积都使用128个3×3的卷积核，输出特征图的尺寸变为$112 \times 112 \times 128$；而后最大化池化处理：池化核的尺寸为$2 \times 2$，其效果为图像尺寸减半，因此输出特征图的尺寸变为$56 \times 56 \times 128$；**
3) **三次卷积+ReLU。三次卷积都使用256个3×3的卷积核作，输出特征图的尺寸变为$56 \times 56 \times 256$；而后最大化池化处理，尺寸再次减半变为$28 \times 28 \times 256$；**
4) **三次卷积+ReLU。三次卷积都使用512个3×3的卷积核，输出特征图的尺寸变为$28 \times 28 \times 512$；而后最大化池化处理，尺寸再次减半变为$14 \times 14 \times 512$；**
5) **三次卷积+ReLU。三次卷积都使用512个3×3的卷积核，尺寸变为$14 \times 14 \times 512$；而后最大化池化处理，尺寸再次减半变为$7 \times 7 \times 512$；**
6) **三次全连接+ReLU。前两层的输出特征图尺寸为$1 \times 1 \times 4096$，最后一层的输出特征图尺寸为$1 \times 1 \times 1000$；**
7) **Softmax层。得到输入图像在1000个类别上的预测概率。**

VGGNet卷积神经网络

VGGNet的特点

通过上述介绍可见，VGGNet可以被视为加深版本的AlexNet，也是由卷积层、全连接层两大部分构成。其具有如下特点：

1）小卷积核和多卷积子层。AlexNet的卷积核尺寸为7×7，而VGGNet的卷积核则为小尺寸即3×3，并通过增加卷积子层数来达到同样的性能。这种设置相当于进行了更多的非线性映射，以增加网络的拟合能力。3个3×3卷积的堆叠获取到的感受野相当于一个7×7的卷积，但参数数量得以减少（例如7×7的参数为49个，而3个3×3的参数为27）。

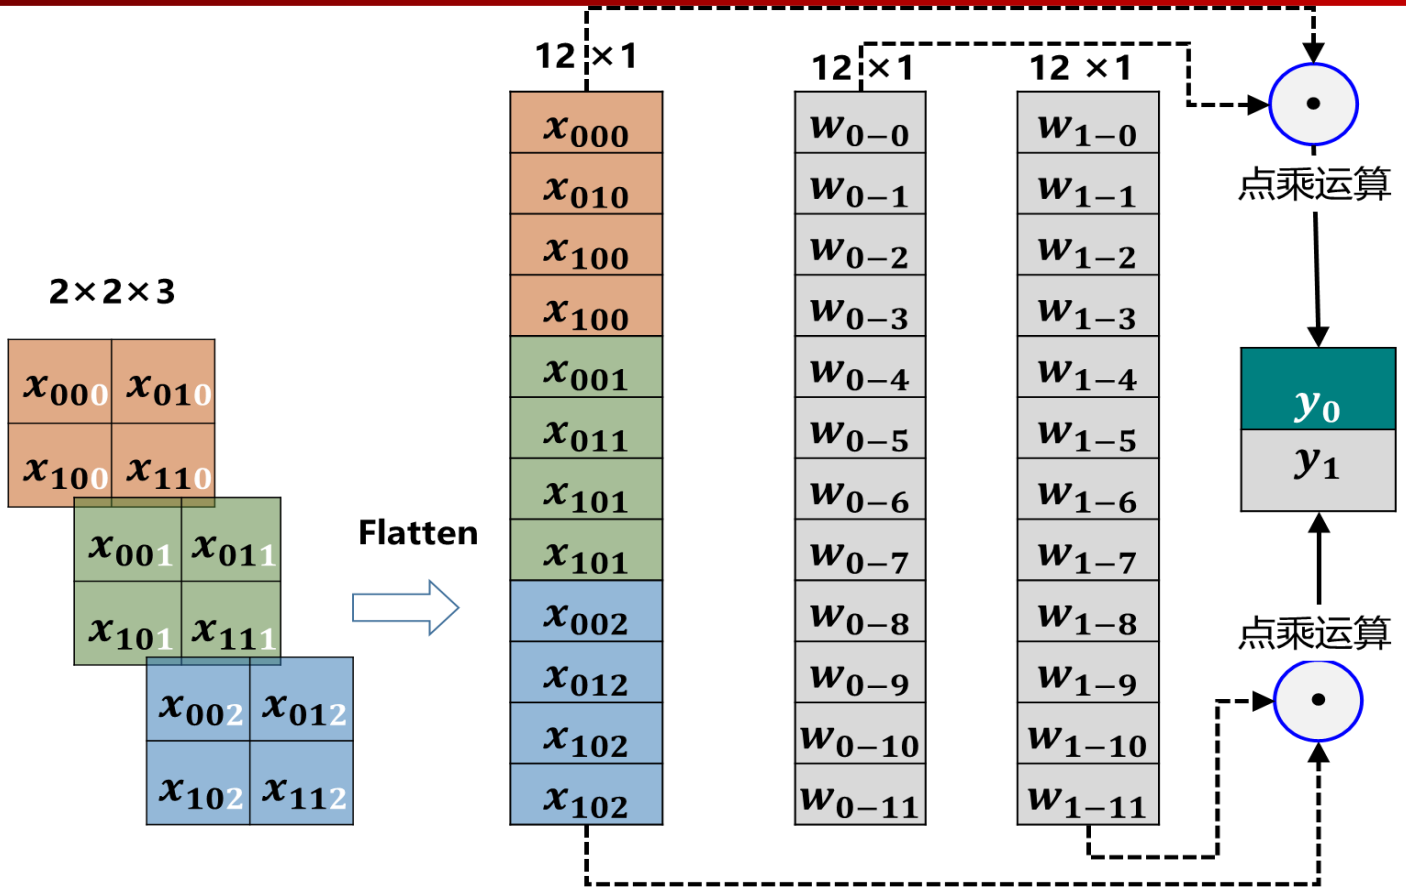
2）小池化核。相比AlexNet的3x3池化核，VGGNet采用2x2的池化核。

3）通道数多。VGGNet第一层的通道数为64，后面每层通道数都成倍增加并最多达到了512个通道。通道数的增加，可以理解为通过更多的不同方式提取特征。

4）全连接层转为卷积层（测试阶段）。VGGNet在测试阶段将模型的最后三个全连接层（如图9.29所示）转换为三个卷积层进行处理。这样做可以使得在测试阶段输入的图像尺寸与训练阶段不同。例如VGGNet在训练阶段的默认输入图像为宽和高为224×224的图像。而测试阶段则可以输入其它尺寸的图像。

VGGNet卷积神经网络

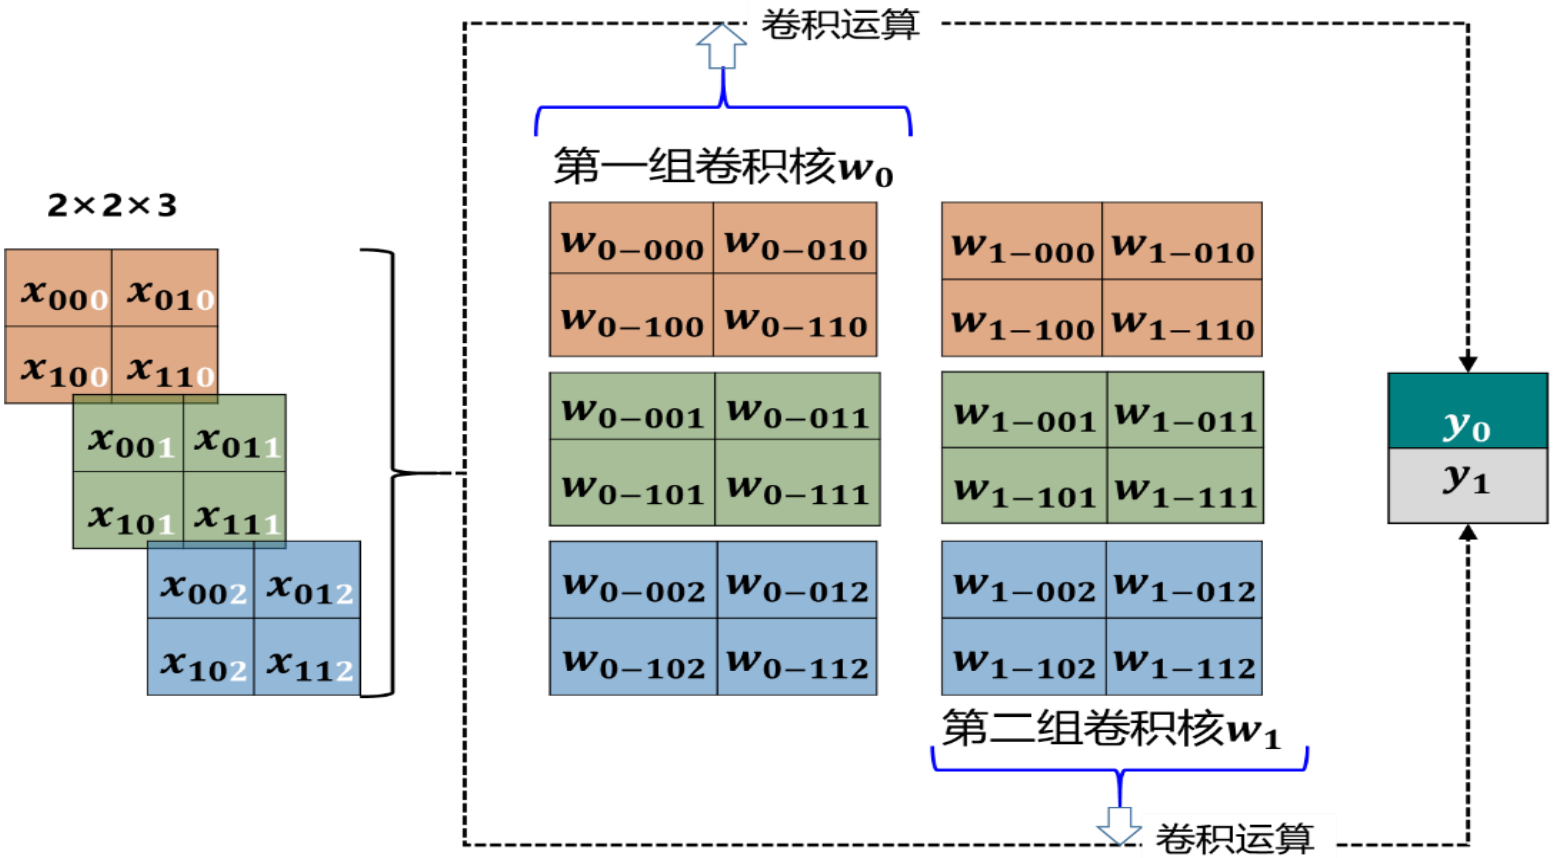
为什么在测试阶段，通过将全连接层转为卷积，可以对不同尺寸的图像进行分类?



如果最后几层采用全连接时的情况

VGGNet卷积神经网络

为什么在测试阶段，通过将全连接层转为卷积，可以对不同尺寸的图像进行分类?



最后几层将全连接层转为卷积层的情况

卷积神经网络

本章内容简介

- 卷积神经网络概述
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类

卷积神经网络

本章内容简介

- 卷积神经网络概述
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- **残差神经网络**
- 利用卷积神经网络进行文本分类

残差神经网络

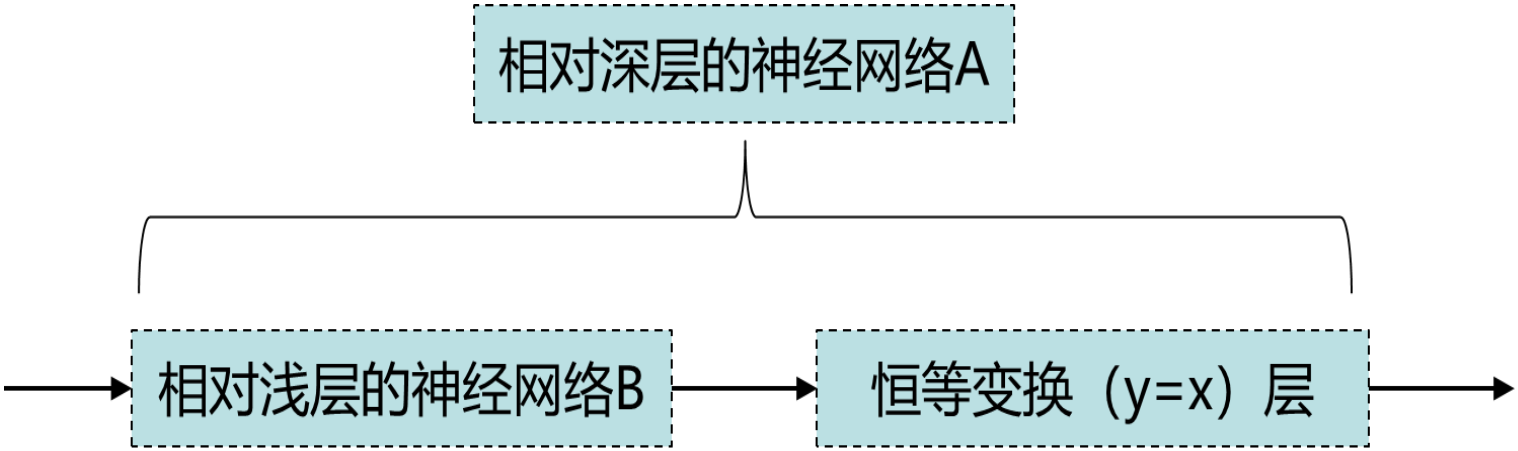
残差神经网络概述

- 残差网络（ResNet）由微软的4位学者提出，其主要贡献是发现了神经网络层数过多带来的副作用即**退化现象（Degradation），**并针对性地提出了一种跳跃连接或称快捷连接（Shortcut connection）的解决思路。因此可以通过增加网络深度的办法来提高模型的预测准确率。
- 因此残差网络的深度首次突破了100层，却仍然在ImageNet和CIFAR-10等图像分类任务上取得了非常好的结果。残差网络在2015年ImageNet ILSVRC图像分类和物体识别比赛中获得了冠军。

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun: Deep Residual Learning for Image Recognition. CVPR 2016: 770-778

残差神经网络

神经网络层数越多，其线性表达能力似乎就越强：



恒等映射来加深网络层数的示意图

一个恒等映射的例子似乎也可以表明深层的网络（假设为A）至少也可以取得和浅层网络（假设为B）相同的预测能力。————即可以将深层网络A的前几层及其参数设置为与浅层网络B完全相同，而将网络A剩下的其余层都变为恒等映射层（即每层的输出等于该层的输入），因此，理论上深层网络A的预测能力应该大于或者等于相对浅层的网络B，但不会降低。

残差神经网络

然而，在实践中网络层加深可能会带来两大问题：

■ 问题一：梯度消失或与梯度爆炸问题

简单地增加深度可能会导致梯度消失或梯度爆炸。二者产生的根本原因都是在反向传播训练过程中，低隐层（接近输入层）上的梯度是来自后面高隐层（接近输出层）上梯度的乘积。当存在过多的层时，多次连乘可能会出现梯度越来越小或者逐步放大，并分别导致梯度消失或梯度爆炸。对于该问题的解决方法包括批量标准化（Batch Normalization）处理等。

■ 问题二：退化问题

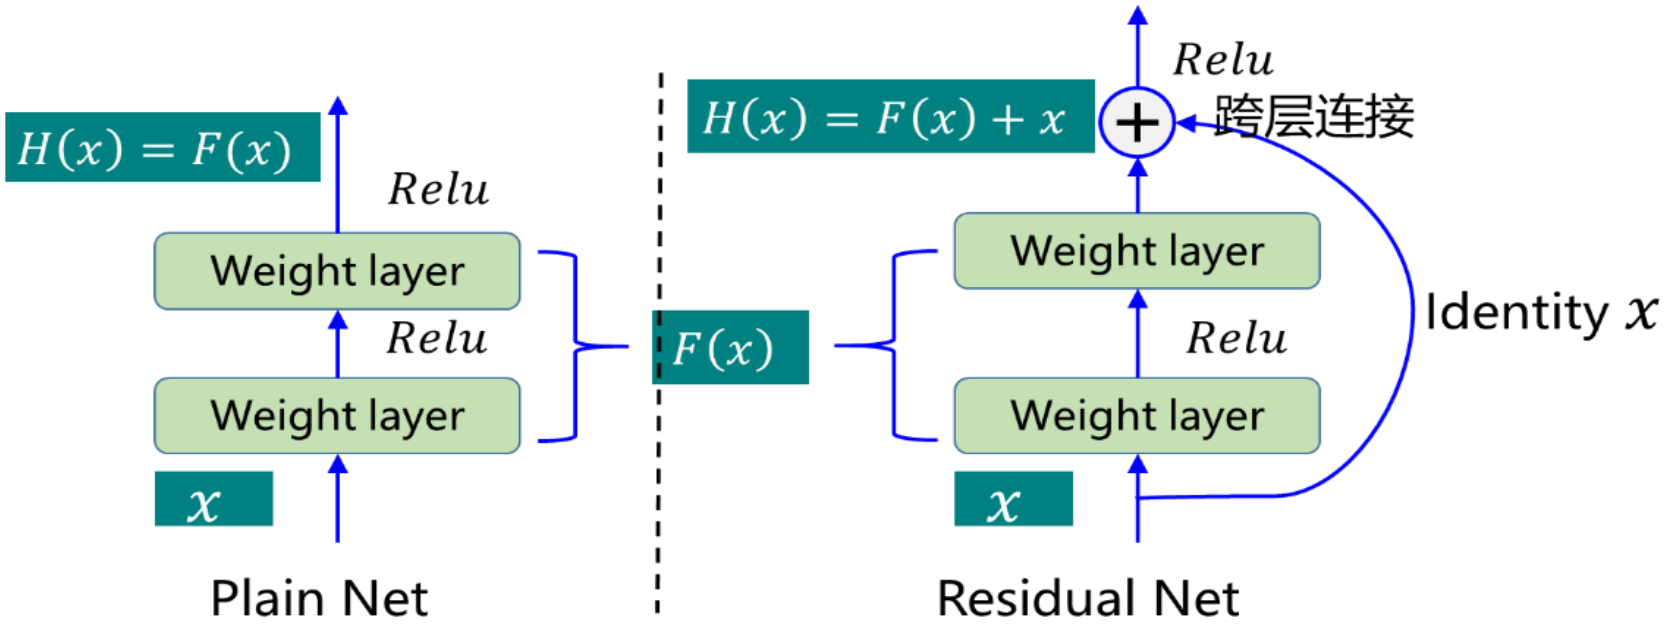
什么是退化？ 简单地增加深度可能还会导致退化（Degradation）。在ImageNet和CIFAR-10图像分类任务上的研究发现，随着网络层的加深，**模型在训练集上的准确率开始的趋势是不断提高，并在达到峰值（准确率饱和）后开始大幅度降低，即网络的加深反而导致预测能力降低，与人们的印象相背离。这一现象被称之为网络退化。**退化的原因不能归结为模型过拟合，因为过拟合是指在训练集上表现更好而在测试集上效果较差。

退化的原因及解决办法。 结合之前的恒等映射的例子，对退化现象原因的一个解释是，**现有的多层非线性神经网络结构难以拟合恒等映射函数（即y=x）。基于上述考虑，残差网络在神经网络中增加了快捷连接分支，以在线性转换和非线性转换之间寻求平衡。**

残差神经网络

残差网络的结构特点

既然现有的神经网络不容易拟合恒等映射，一种替代思路就是构造直接的恒等映射，这也是残差网络的基本思想。



卷积神经网络

本章内容简介

- 卷积神经网络概述
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- **利用卷积神经网络进行文本分类**

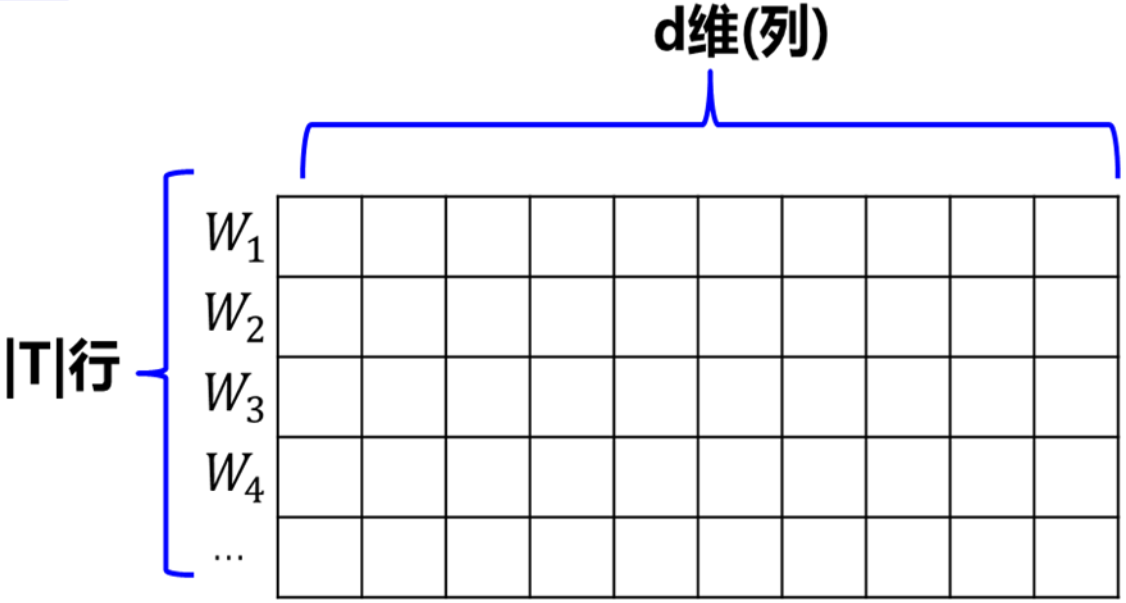
利用卷积神经网络进行文本分类

如何对无结构的文本信息进行卷积处理呢?

问题： 对于文本T=(W_1，W_2,W_3,W_4,…)。T可以为短语、句子或篇章等。

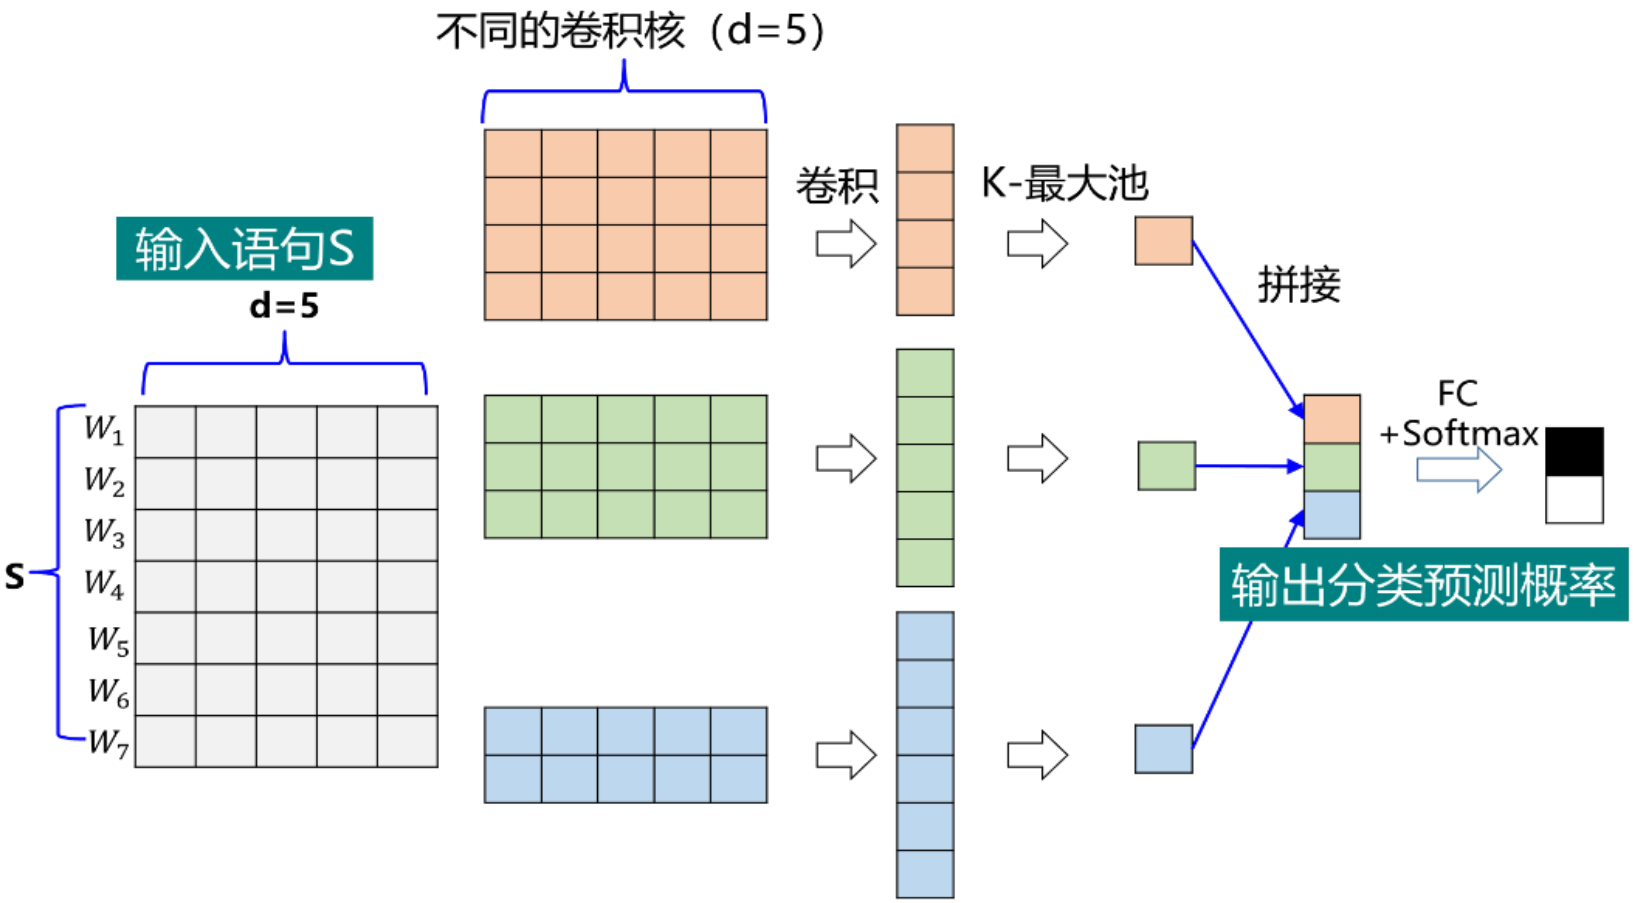
如何借鉴图像卷积神经网络的思想用于文本分类研究?

思路： 假设文本T长度为|T|，则文本也可以转化为矩阵形式：



利用卷积神经网络进行文本分类

文本矩阵如何进行卷积分类?



本章小结

- 卷积神经网络概述
- LeNet-5
- AlexNet
- VGGNet卷积神经网络
- 残差神经网络
- 利用卷积神经网络进行文本分类