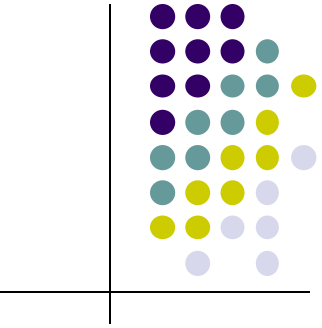
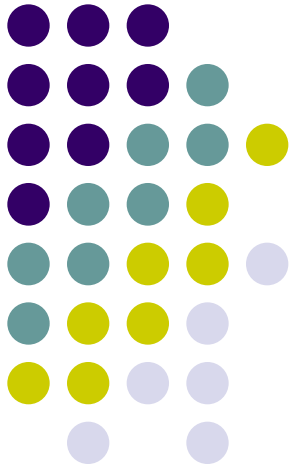


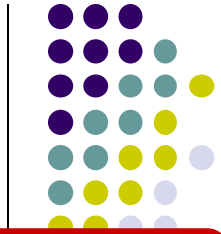
图神经网络

哈尔滨工业大学计算学部

刘远超



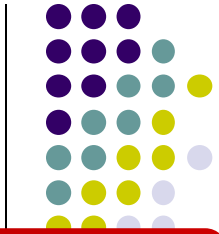
图神经网络



本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

图神经网络



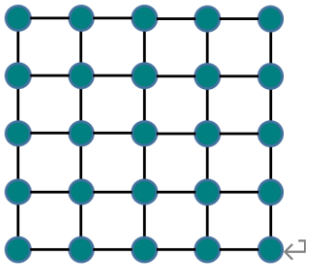
本章内容简介

- **什么是图神经网络**
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

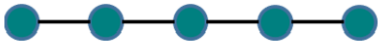
什么是图神经网络?

图神经网络主要用于非欧几里得结构的图类型数据

- 之前章节中介绍的卷积神经网络、循环神经网络等模型所处理的数据，如图像、音频、文本等类型的数据主要为欧几里得结构。
  - **所谓欧几里德结构数据，是指其可以被看作欧氏空间中的点。**例如，图像可以被看作二维空间上的网格数据，语音信号可以被看作是一维空间数据，文本如果采用向量空间模型表示可以被看作是更高维度空间上的数据。

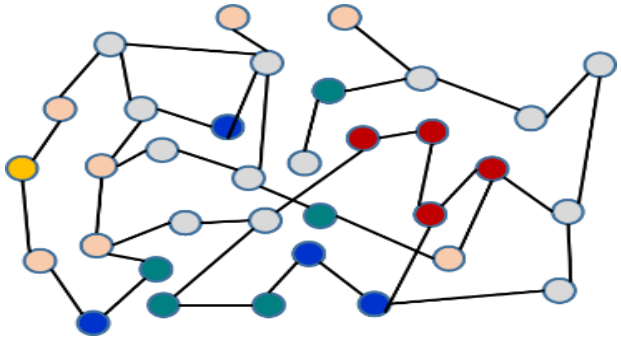


图像类型数据（矩阵）



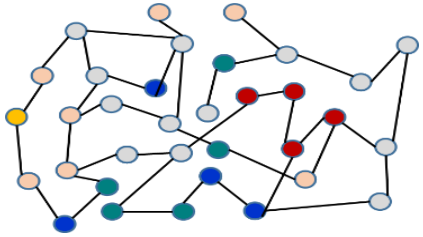
文本类型数据（序列）

- **现实世界中还有很多非欧几里得结构类型数据，例如图数据。**
  - **很多应用场景需要被抽象为图结构来研究，**如**社交网络、用户与商品的关系、交通网络、知识图谱**等。这些图数据通常难以直接用欧氏空间表达。



什么是图神经网络?

图神经网络研究的关键：图嵌入技术



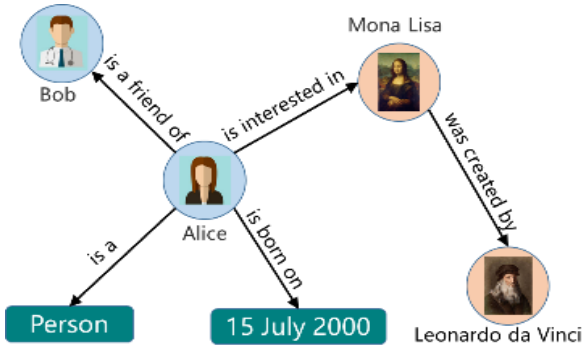
- （卷积神经网络、循环神经网络等模型在自然语言处理领域中其关键是如何获得词、句子或者文档的**嵌入式向量表示**；在计算机视觉领域其关键是对图像通过逐级变换获得其嵌入式向量表示）
- **而在图神经网络中，其核心和关键就是要得到节点或者边的嵌入式低维向量表示**[Cui, 2018]。因此**图神经网络需要综合利用节点之间的连接和邻域信息，基于神经网络的训练方法经过多次变换，得到图中节点或者连接的低维稠密嵌入向量表示**，并使得在原图中相似的节点在低维嵌入表示空间中也接近。
- GNN **的核心思想是消息传递。**它会通过迭代的方式，让每个节点聚合其邻居节点的信息，从而学习到节点的表示（Embedding）。
- 得到的节点或者连接的嵌入表示向量可以被用于进行下游其它任务，**如节点或连接的分类、回归、聚类、链接预测、可视化或重构原始图**等任务[Luxburg，2007] [Wu, 2019]。

什么是图神经网络?

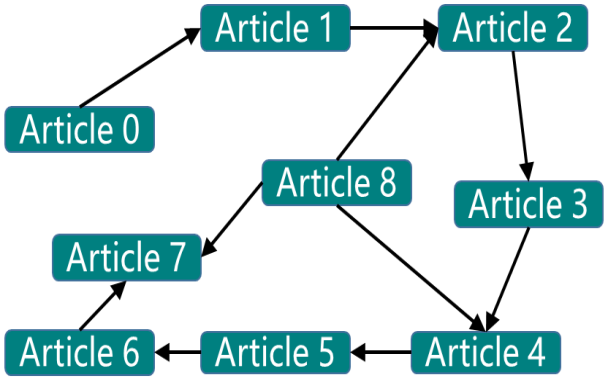
图神经网络的应用领域及常用数据集



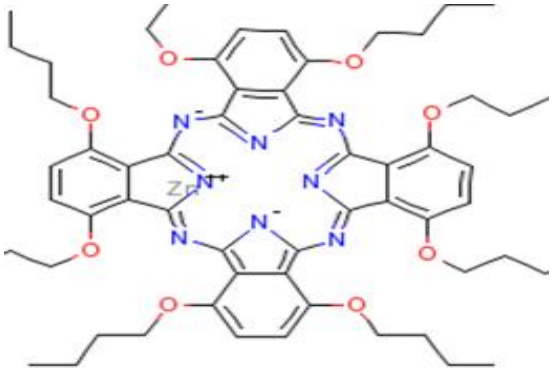
社交网络



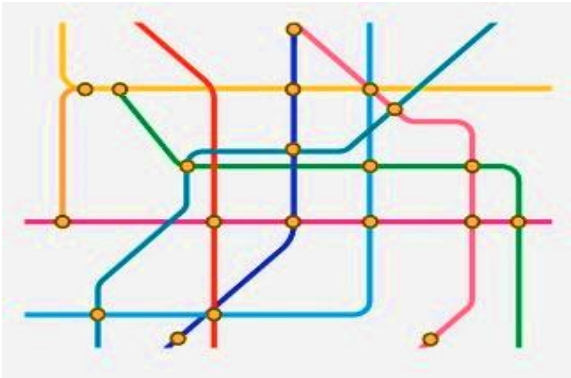
知识图谱



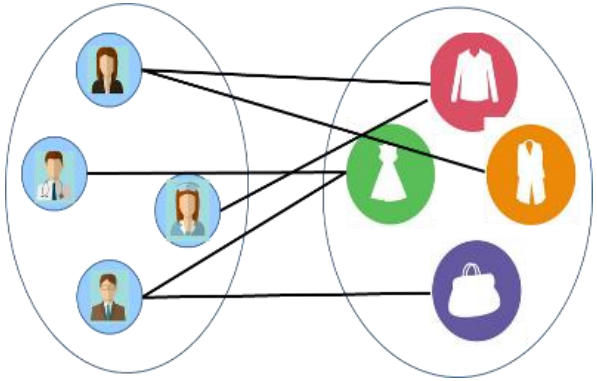
论文引用网络



化学分子



交通网络



电商网络

图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT
  - GraphSAGE

图神经网络

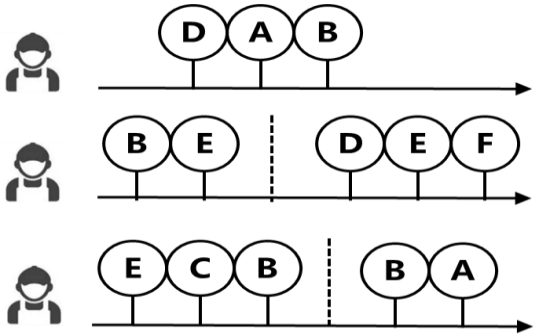
本章内容简介

- 什么是图神经网络
- **典型的图神经网络模型**
  - **DeepWalk模型（深度优先）**
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

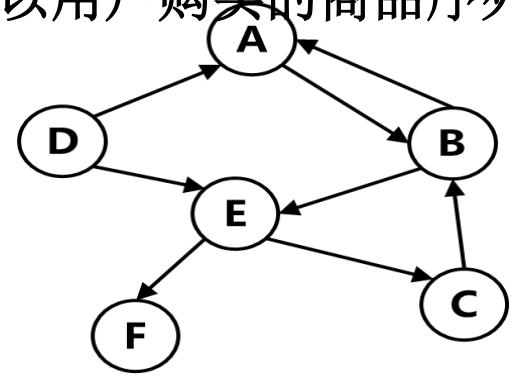
DeepWalk模型

铺垫性知识介绍：随机游走（Random Walk） 是 DeepWalk 中用来从图里生成节点序列的一种采样方法。是**从一个起点节点出发，每一步都随机选择一个相邻节点走过去，重复若干步，得到一条节点序列。**

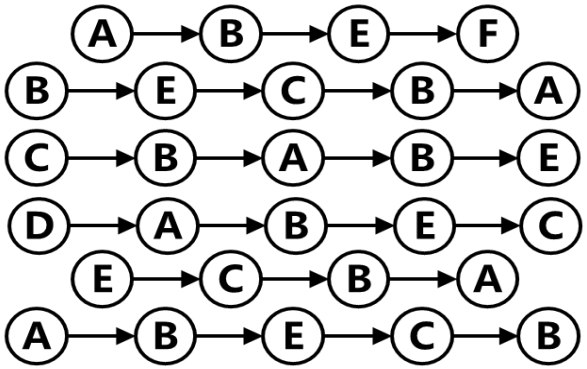
DeepWalk的图嵌入计算主要分4步（以用户购买的商品序列数据为例**）：**



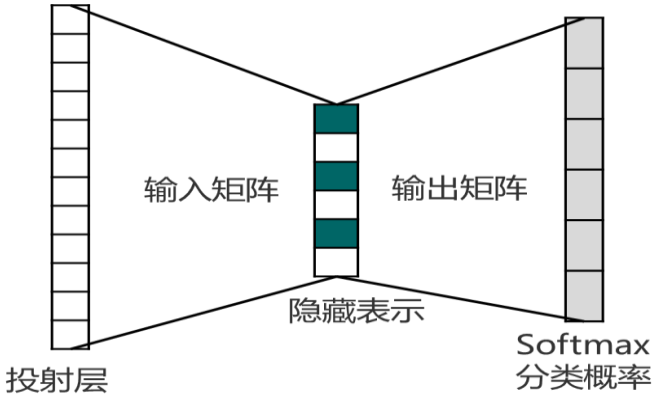
（a）用户的购买行为序列



（b）根据图（a）构建的商品图



（c）基于图（b）的随机游走



（d）基于图（c）得到节点嵌入向量

典型的图神经网络模型

DeepWalk模型

算法 12. 1: DeepWalk 算法

Input: 图$G(V,E)$; 窗口尺寸 w; 嵌入向量尺寸 d; 每个节点的游走次数 γ; 游走长度 t

Output: 节点表征矩阵 $\Phi \in \mathbb{R}^{|V| \times d}$

初始化：从 $\mathcal{U}^{|V| \times d}$ 中采样得到 Φ

从 V 构造一个二叉树 T

for $i \leftarrow 1$ **to** γ **do**

  $\mathcal{O} = Shuffle(V)$

  for each $v_i \in \mathcal{O}$ **do**

    $\mathcal{W}_{v_i} = RandomWalk(G, v_i, t)$

    $SkipGram(\Phi, \mathcal{W}_{v_i}, w)$

  end

end

输入

- **图** $G(V,E)$：节点集合 V，边集合 E。
- **窗口尺寸** w：Skip-gram 的上下文窗口大小，类似 Word2vec 里看前后几个词。
- **嵌入向量尺寸** d：每个节点最终学成的向量维度。
- **每个节点的游走次数** γ：每个节点作为起点，要随机游走多少次。
- **游走长度** t：每次随机游走走多少步。

输出

- **节点表征矩阵** $\Phi \in \mathbb{R}^{|V| \times d}$：每一行对应一个节点的 d 维向量。

典型的图神经网络模型

DeepWalk模型

算法 12. 1: DeepWalk 算法

Input: 图$G(V,E)$; 窗口尺寸 w; 嵌入向量尺寸 d; 每个节点的游走次数 γ; 游走长度 t

Output: 节点表征矩阵 $\Phi \in \mathbb{R}^{|V| \times d}$

初始化：从 $\mathcal{U}^{|V| \times d}$ 中采样得到 Φ

从 V 构造一个二叉树 T

for $i \leftarrow 1$ **to** γ **do**

  $\mathcal{O} = Shuffle(V)$

  for each $v_i \in \mathcal{O}$ **do**

    $\mathcal{W}_{v_i} = RandomWalk(G, v_i, t)$

    $SkipGram(\Phi, \mathcal{W}_{v_i}, w)$

  end

end

先随机初始化所有节点的向量矩阵Φ。U 表示均匀分布。这一步和 Word2vec 初始化词向量类似，后面会通过训练不断更新。

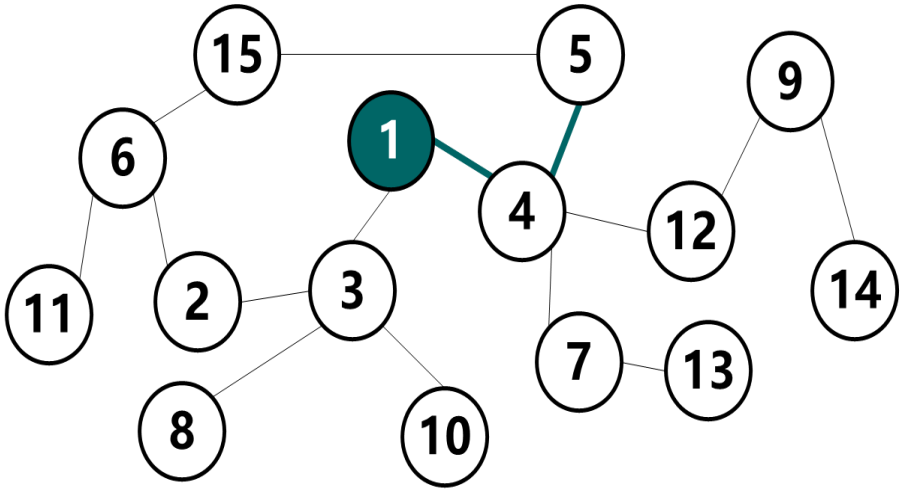
从V 构造一个二叉树T，为 Skip-gram 的层次 Softmax 做准备。当节点很多时，直接计算 Softmax 很慢，所以用霍夫曼来加速训练。

把节点集合 V随机打乱，得到顺序 $\mathcal{O}$。

以避免固定顺序带来的偏差，让训练更随机、更均衡。

典型的图神经网络模型

DeepWalk模型的随机游走



随机游走是一种基于深度优先搜索（Depth First Search，DFS）从图中提取序列的技术。

其基本原理为，给定图中的访问起始节点，从其若干邻居中随机选择节点作为下一个访问节点。并重复这一过程，直到访问的节点序列长度达到预设的长度。

使用随机游走提取访问序列的优势在于：

1）并行化。随机游走发生在网络的局部区域，因而可以同时以图中不同节点为起点进行随机游走以获得采样序列，效率较高；

2）适应性。由于游走的局部性，对于较大的图，即使网络中个别点或边发生变化，也只会影响到个别随机游走序列，因而不一定需要对整个图重新进行随机游走处理

典型的图神经网络模型

学到的节点嵌入有何用途?

DeepWalk 学到的节点嵌入，把图中的每个节点映射成低维、稠密向量。包含了节点在图中的拓扑结构信息和潜在的语义关联。可以作为特征输入到各种下游的机器学习任务中：

- **节点分类**。例如，在社交网络中预测用户的兴趣标签，或者在引用网络中预测论文的主题分类。
- **链接预测。** 推断两个节点之间是否应该存在边。在社交网络的好友推荐、知识图谱补全（推断实体间缺失的关系）等场景中非常有用。
- **节点聚类与社区发现。** 将节点嵌入输入到 K-Means 等聚类算法中，可以把图中连接紧密的节点聚在一起，从而发现潜在的社区或群体。在社交网络中，这有助于识别兴趣相投的用户群，用于精准营销或网络内容审核。
- **可视化。** 节点的嵌入向量通常会被降维到二维或三维空间进行可视化展示。在理想的图中，同一社区或类别的节点，其对应的向量在空间中会靠得更近，直观地观察图的结构。
- **增强推荐系统。** 在电商或内容平台中，通过分析相似用户或相似物品的向量，推荐系统可以更准确地推荐新内容（如视频、文章或产品）。

图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - **LINE模型（宽度优先）**
  - 图卷积神经网络GCN
  - 图注意力网络GAT

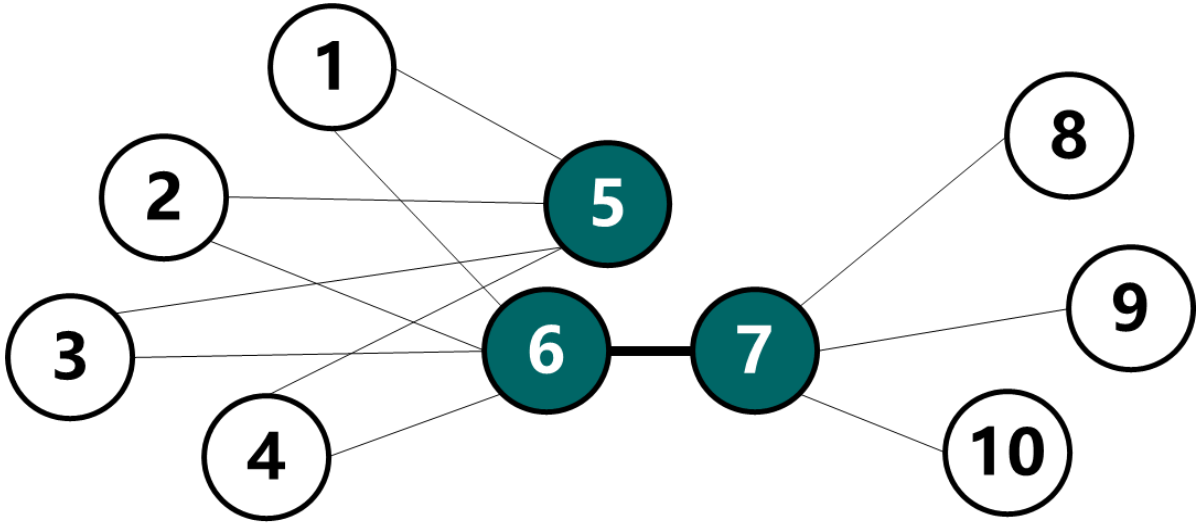
典型的图神经网络模型

LINE模型

- **LINE**（Large-scale Information Network）模型[Tang, 2015]与DeepWalk类似，也是一种**基于邻域相似假设获取图嵌入向量表示**的方法。但区别在于其使用**宽度优先搜索**（Breadth First Search，简称BFS）而不是深度优先搜索来构造邻域。*即策略为：先访问所有直接邻居，再访问邻居的邻居，一层一层往外扩。*
- **LINE的基本思想是，在图中距离较小（或相似度较高）的点，在新的低维嵌入空间中也应尽可能接近**。并基于这种思想来学习得到网络中节点的低维向量表示。
- LINE模型分别对一阶相似度和二阶相似度进行了优化，下面主要介绍一阶相似度及其优化。

典型的图神经网络模型

LINE模型



- 对于每一条边的两个节点(u, v)，**边的权重w_{uv} 即为两个节点之间的一阶相似度（first-order proximity）**。例如图中：
  - 节点6和7之间存在直连边且该边的权重较大，因此二者间的一阶相似度较高；
  - 而节点5和6之间不存在直连边，则二者间的一阶相似度为0。

LINE模型

一阶相似度的优化

边的权重 w_{ij} 如何计算?

情况一 · 加权图：w_{ij} 直接给定

原始数据本身就是带权图，wij 由数据直接给出，无需额外计算：

- 用户—商品的购买次数
- 两个网页之间的超链接数量
- 两个用户之间的通话时长
- 两个节点之间的交通流量

情况二 · 无权图：$w_{ij} = 1$

若图只记录"连不连边"，则每条边权重视为常数 1，归一化分母即边数 |E|，经验概率退化为边频率。

经验分布定义：

$$\hat{p}^1(v_i, v_j) = \frac{w_{ij}}{W}, \qquad W = \sum_{(i,j)\in E} w_{ij}$$

简单举例：三条边的小图

边	边权 w_{ij}
A – B	5
A – C	3
B – C	1

$$W = 5 + 3 + 1 = 9$$

于是经验概率为：

$$\hat{p}^1(A, B) = \frac{5}{9}$$

$$\hat{p}^1(A, C) = \frac{3}{9}$$

$$\hat{p}^1(B, C) = \frac{1}{9}$$

?

LINE模型

一阶相似度的优化

一阶相似度的优化是指设法使通过低维嵌入向量计算得到的联合概率分布与经验分布尽可能接近。对于每个无向边(v_i, v_j)：

1）**定义v_i, v_j在空间$V \times V$上的经验概率$\hat{p}_1(v_i, v_j)$为$\hat{p}_1 = \frac{w_{ij}}{W}$**，其中$W = \sum_{(i,j)\in E} w_{ij}$。**经验概率利用边的权值计算得到。**

2）**定义v_i, v_j在空间$V \times V$上的联合概率为$p_1(v_i, v_j) = \frac{1}{1+\exp(-\vec{u}_i^T \cdot \vec{u}_j)}$**，其中$\vec{u}_i$表示节点$v_i$的低维向量表示。**联合概率通过利用节点的嵌入向量计算得到。**

因此，一阶相似度的优化目标是优化经验概率$\hat{p}_1(v_i, v_j)$分布和联合概率$p_1(v_i, v_j)$的分布之间的差异。通常需要优化如下交叉熵函数：

$$O_1 = -\sum_{(i,j)\in E} \hat{p}_1(v_i, v_j) \, log p_1(v_i, v_j) \qquad (12.1)$$

通过找到可以最小化上述函数的$\{\vec{u}_i\}$，$i = 1, \ldots, |V|$，则可以获得图中每个节点的低维嵌入向量表示$\vec{u}_i$。

图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

图神经网络

本章内容简介

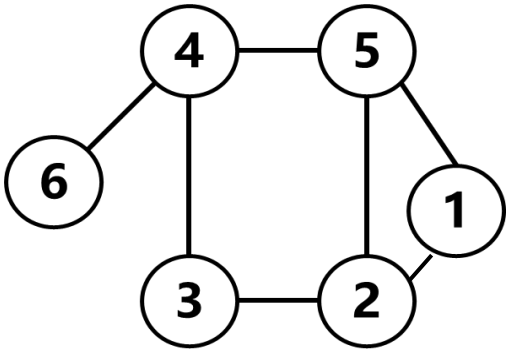
- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - **图卷积神经网络GCN**
  - 图注意力网络GAT

典型的图神经网络模型

图卷积神经网络

与图卷积神经网络相关的图论知识

假设图为$G = (V, E)$，其中V为图中节点的集合，E为边的集合，节点的个数为N，则图中三个重要的属性矩阵可以描述如下：



(a) 图G

$$\begin{Bmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{Bmatrix}$$

(b) 邻接矩阵A

$$\begin{Bmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{Bmatrix}$$

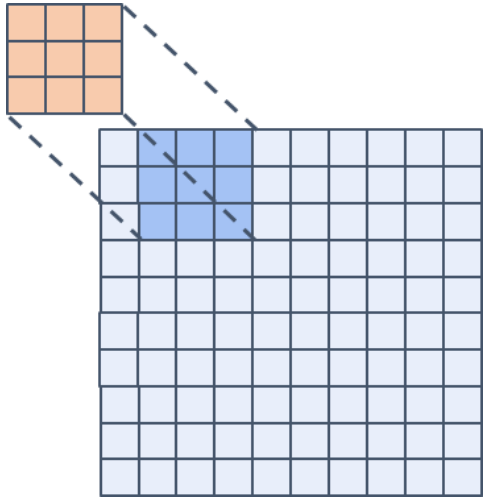
(c) 度矩阵D

- **邻接矩阵A**：$A \in R^{N \times N}$，把N 个节点排成行和列，矩阵中的元素表示节点 i 和节点j之间有没有边、或者边的权重是多少。
- **度矩阵D**：$D \in R^{N \times N}$，表示**图中与每个节点相连的边的个数**。其是一个对角矩阵，即只有对角线上不为零，其它位置元素都是0。
- **特征矩阵X**：$X \in R^{N \times d}$**表示图中所有节点的特征，即N个节点，每个节点的特征个数为d。**

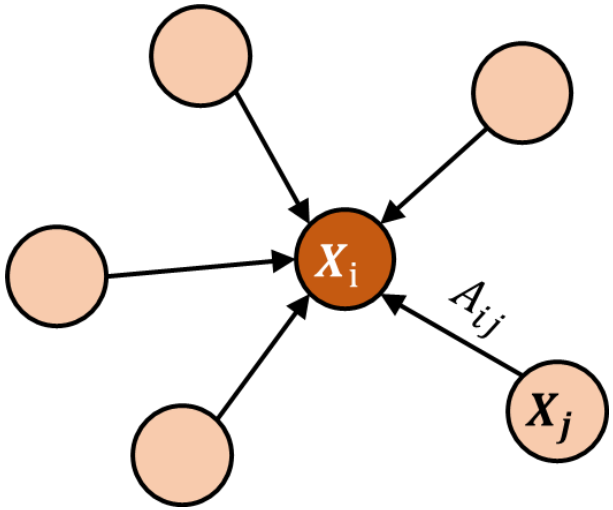
典型的图神经网络模型

图卷积神经网络

如何在图类型数据中借鉴传统卷积神经网络的思想？



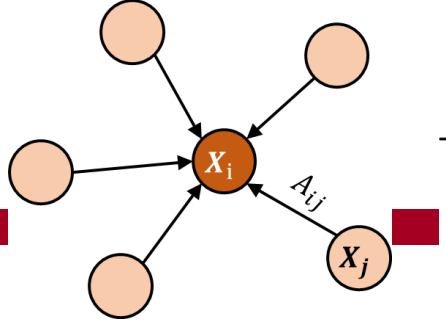
（a）图像数据的卷积处理



（b）图类型数据的卷积处理

- 由于图像样本具有天然的矩阵结构，可以用卷积核来提取特征。
- 但是对于图类型的样本数据，其形状是不规则的，如何借鉴传统的卷积神经网络的思想，并将其应用在图神经网络中呢？

图卷积神经网络



$$\begin{bmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

(b) 邻接矩阵$\boldsymbol{A}$

（一）局部卷积

- 传统卷积神经网络的卷积计算实际上一种加权求和计算。而对于**图卷积神经网络，加权求和计算也可以通过在每个节点的一定邻域内实现**。如图所示，对于节点X_i，其局部邻域就是其邻接节点，同样可以采用加权求和的方法来获取当前节点的嵌入表示，这也可以称为聚合（aggregate）计算，即

$$agg(X_i) = \sum_{j \in neighbor(i)} A_{ij} X_j \qquad (12.11)$$

  - $agg(X_i)$：表示节点 i 经过聚合操作后得到的新特征表示（嵌入表示）。
  - $neighbor(i)$：表示与节点 i **直接相连**的所有邻居节点的集合。
  - X_j：表示邻居节点 j 的特征向量。
  - A_{ij}：表示邻接矩阵（Adjacency Matrix）中的元素，代表节点 i 和节点 j 之间的连接权重。如果两点相连，A_{ij} 通常大于0（无权图中为1）；如果不相连，则为0。
  - $\sum$：求和符号，表示把所有符合条件的邻居节点的特征加权后加起来。

  一句话总结： 节点 i 的新特征，等于它所有邻居特征 X_j 乘以对应边的权重 A_{ij} 后的总和。

- 由于图中与节点 i 没有直接连接节点 j 所对应的邻接矩阵权重 A_{ij} 为0，因此（12.11）又可以改写为：

$$\boldsymbol{agg(X_i) = \sum_{j \in N} A_{ij} X_j} \qquad (12.12)$$

  即扩展输入为图中所有节点。

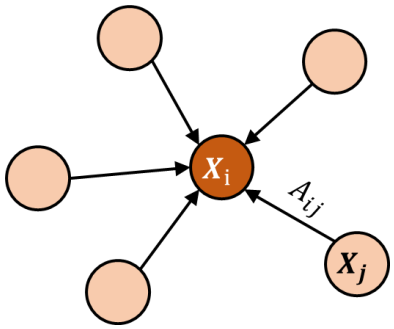
- 以上是对图中特定节点X_i的聚合计算，**推广到图中所有节点**，则有：

$$agg(X) = AX \qquad (12.13)$$

典型的图神经网络模型

图卷积神经网络

如何在图类型数据中借鉴传统卷积神经网络的思想?



图类型数据的卷积处理

$$\begin{bmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{bmatrix}$$

(b) 邻接矩阵A

$$agg(X_i) = \sum_{j \in N} A_{ij} X_j \qquad (12.12)$$

$$agg(X) = AX \qquad (12.13)$$

(一) 局部卷积

公式（12.12）中的邻接矩阵A的对角线上元素为0，因而其只考虑了节点的邻域加权求和，**为了包含节点自身的特征信息，有**

$$agg(X_i) = \sum_{j \in N} A_{ij} X_j + X_i \qquad (12.14)$$

相应地，公式（12.13）变为

$$agg(X) = AX + X = (A + I)X \qquad (12.15)$$

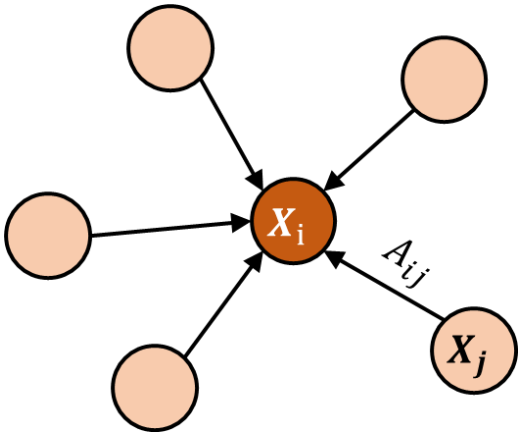
其中，I为单位矩阵，其对角线上元素为1，其它元素为0。令$\widetilde{A} = A + I$，则有

$$agg(X) = \widetilde{A}X \qquad (12.16)$$

典型的图神经网络模型

图卷积神经网络

如何在图类型数据中借鉴传统卷积神经网络的思想？



图类型数据的卷积处理

$$agg(X) = \tilde{A}X \qquad (12.16)$$

（二）归一化

- 标准卷积神经网络中，每个卷积核所覆盖的局部区域其连接数量是固定的，即为卷积核的大小。
- **而在图中每个节点的直连邻域节点个数则是动态的，因而每个节点的度也不同。图卷积神经网络中，进行了归一化处理**。比较常用的是几何平均归一化，因此（12.16）变为

$$agg(X) = \tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}X = \tilde{D}^{-\frac{1}{2}}(A+I)\tilde{D}^{-\frac{1}{2}}X \qquad (12.17)$$

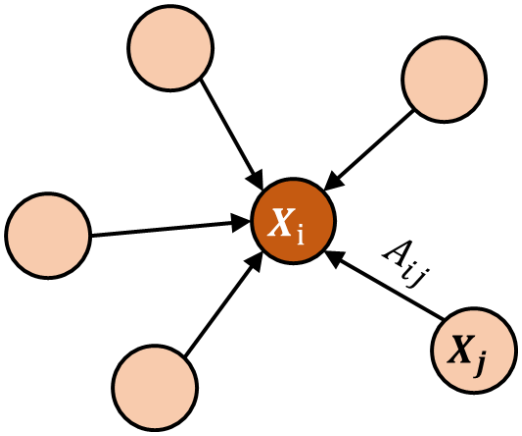
其中，$\tilde{D}$**是**$\tilde{A}$**的度矩阵**，即$\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$。

由于 $\tilde{D}_{ii}$ 在矩阵A的基础上得到，因此在给定矩阵 A 之后，公式中的相乘项$\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}$可以预先计算。

典型的图神经网络模型

图卷积神经网络

如何在图类型数据中借鉴传统卷积神经网络的思想？



图类型数据的卷积处理

（三）计算下一层特征

即在聚合处理的基础上**乘以权重矩阵参数，并通过非线性激活函数处理**：

$$H^{(1)} = \boldsymbol{\sigma}\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}XW^{(0)}\right) \tag{12.18}$$

其中，

- $H^{(1)}$与输入层X相邻的第一个隐藏层特征，
- $W^{(0)}$是该层的可通过训练更新的权重矩阵，
- $\sigma(\cdot)$是非线性激活函数，例如可以采用$ReLU$函数。

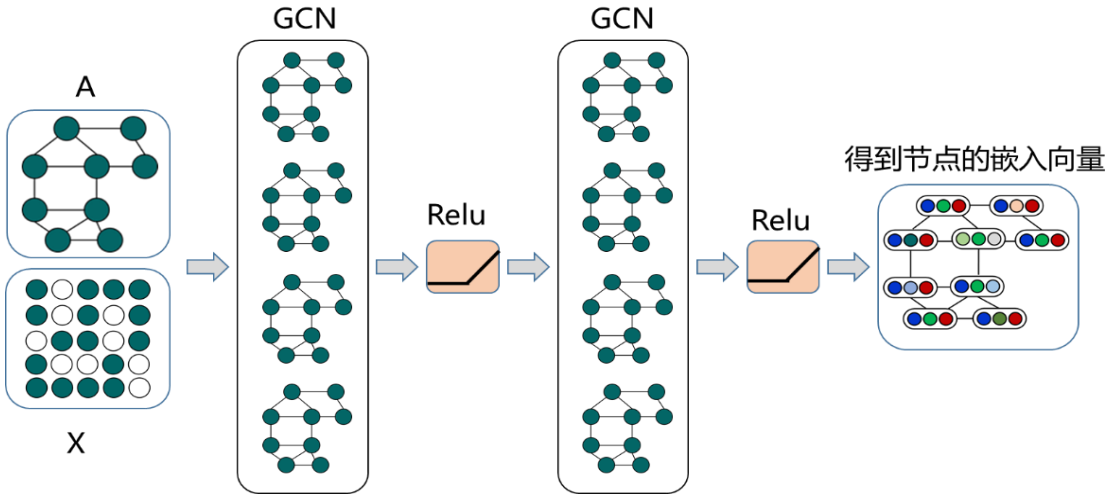
以上介绍了在图卷积神经网络中，如何从输入的随机初始化的图特征矩阵X经过若干步骤得**到第1个隐藏层特征矩阵** $\boldsymbol{H^{(1)}}$。

实际上在图卷积神经网络中，后续其它隐藏层的特征计算方法与之类似→

典型的图神经网络模型

图卷积神经网络

层与层之间的正向传播变换过程



- 之前介绍的步骤可以推广为图卷积神经网络中**层与层之间的正向传播变换过程**。假设输入图G的定义如前所述，且图中所有节点在第 l 层的特征为$H^{(l)} \in \mathbb{R}^{N\times d}$，则第 $l+1$ 层的特征为$H^{(l+1)}$的计算方法为：

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}\right)$$

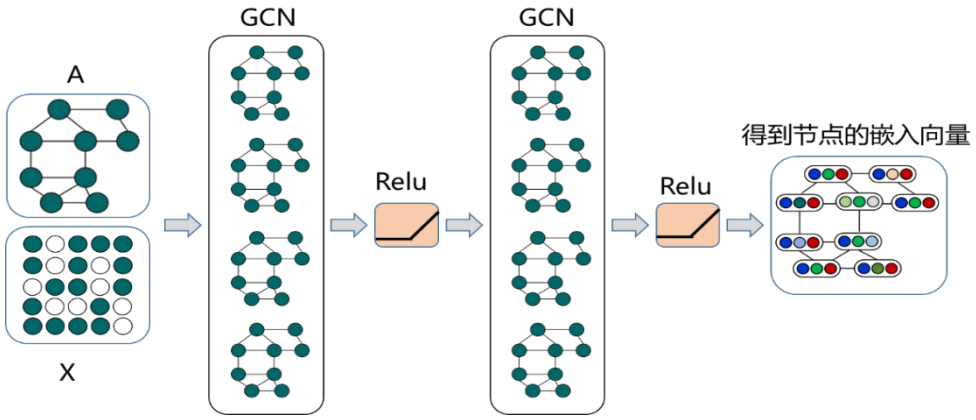
其中，

- $H^{(l)} \in \mathbb{R}^{N\times d}$表示前一层即第 l 层的特征。$H^{(0)} = X$，即为输入层X。
- $\tilde{A} = A + I$，I是单位矩阵。
- $W^{(l)}$是特定于第 l 层的可通过训练更新的权重矩阵，是图卷积神经网络训练阶段学习的重要参数；
- $\sigma(\cdot)$是非线性的激活函数，例如可以采用$ReLU$函数。

典型的图神经网络模型

图卷积神经网络

层与层之间的正向传播变换过程



- 原始 GCN 的实验设定是**直推式的**，即训练阶段与测试阶段中的样本数据都基于同样的图结构。
- 在图卷积神经网络的训练阶段，输入训练集中若干个图经训练学习得到各层参数（主要为各层的参数矩阵$W^{(l)}$）的取值。**每个节点的隐藏向量通过图结构得以融合其它相邻节点的特征。**相邻节点相当于感受野，随着层次的变深其感受野越来越大，从而节点特征也将融合更广范围节点的信息。

- **基于最后一个隐藏层的特征后可以得到节点的预测值**，因而可以对所有带标签的节点计算交叉熵损失函数，并通过反向传播进行参数优化；
- 在测试阶段，可以利用学习得到的各层参数取值计算得到测试集中图中每个节点的最终隐藏向量，并进而用于对节点的分类或者回归结果进行预测。

图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT

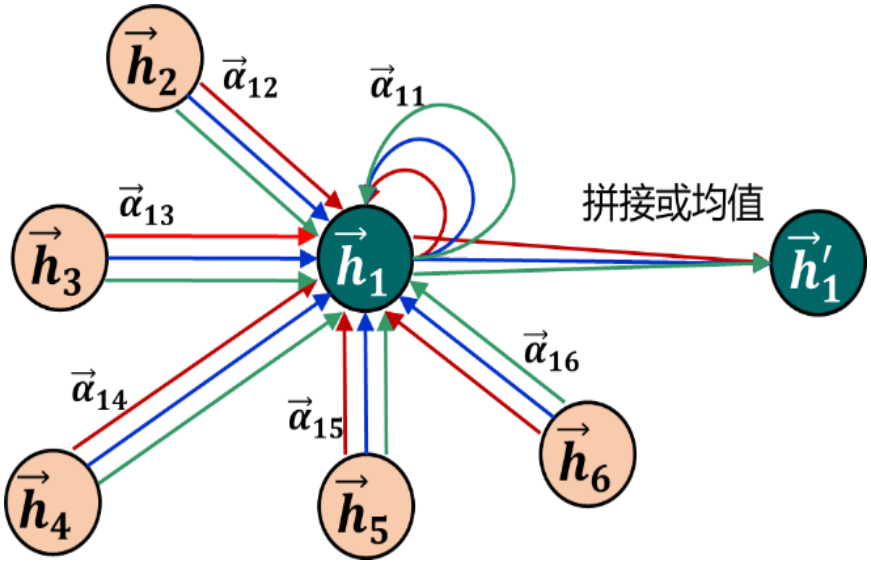
图神经网络

本章内容简介

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - **图注意力网络GAT**

典型的图神经网络模型

图注意力网络GAT

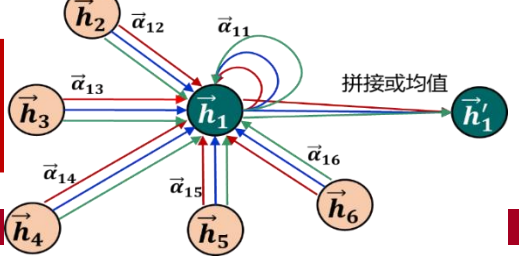


每个节点的图注意力机制计算原理

- **经典图卷积神经网络GCN**结合邻域点特征的方式较为依赖图结构，因而训练得到的模型**难以在其它图结构上进行泛化**。
- **图注意力网络（Graph Attention Networks，简称GAT）**[Veličković, 2018]与图卷积神经网络相比，更**擅长处理归纳（inductive）任务**中的动态图，即测试阶段的图结构可以和训练阶段的图有所不同。

- GAT训练阶段可以只在子图（subgraph）上进行，测试阶段对未知标签的节点进行预测。另外，图注意力网络对不同的邻域节点可以赋予不同权重，即其使用注意力机制对一阶邻域节点的特征进行加权求和，**虽然邻域节点信息来自图结构，但其嵌入特征对图结构有一定独立性，因而对其它图结构样本数据上的泛化能力相对较好**。

图注意力网络GAT



因此，与其它注意力机制类似，图注意力网络的每个注意力层的计算也包括两步：

（一） 计算注意力系数（attention coefficient）

即需要**计算当前节点 i 的每个一阶邻居节点（$j \in N_i$）的低维嵌入向量对节点 i 的重要程度：**

$$e_{ij} = \vec{a}^T \left[W\vec{h}_i || W\vec{h}_j \right], j \in N_i \tag{12.20}$$

$$\alpha_{ij} = softmax(e_{ij}) = \frac{\exp(LeakyReLU(e_{ij}))}{\sum_{k \in N_i} \exp(LeakyReLU(e_{ik}))} \tag{12.21}$$

上述公式中，

① 首先使用权重参数矩阵$W \in \mathbb{R}^{F' \times F}$对节点 i 和 j 的嵌入向量进行线性变换：$\mathbb{R}^F \rightarrow \mathbb{R}^{F'}$；

② 然后将结果进行拼接：$\mathbb{R}^{F'} \rightarrow \mathbb{R}^{2F'}$；

③ 再通过使用权重向量参数为$\vec{a} \in \mathbb{R}^{2F'}$（$T$为转置）的单层前馈神经网络将拼接结果映射为一个实数：$\mathbb{R}^{2F'} \rightarrow \mathbb{R}$；

④ 公式（12.21）表示将注意力系数进行归一化处理。

（二）加权求和（aggregate）

即利用得到的注意力系数α_{ij}，采用线性加权及激活处理的方法将一阶邻域（也包括当前节点自身）内节点的嵌入向量融合，从而得到当前节点 i 在下一层中的新特征h'_i：

$$\vec{h}'_i = \sigma\left(\sum_{j \in N_i} \alpha_{ij} W \vec{h}'_j \right) \tag{12.22}$$

其中，$\sigma(\cdot)$是激活函数。

本章小结

- 什么是图神经网络
- 典型的图神经网络模型
  - DeepWalk模型（深度优先）
  - LINE模型（宽度优先）
  - 图卷积神经网络GCN
  - 图注意力网络GAT