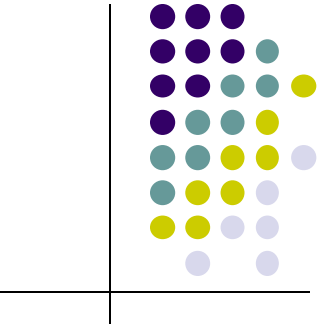
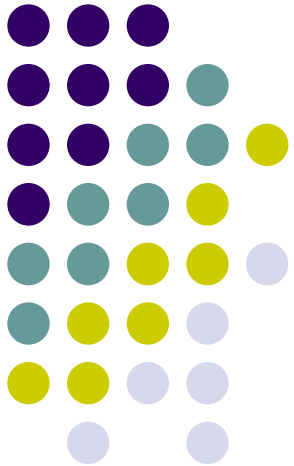


生成式神经网络

寻常一样窗前月，才有梅花便不同。——宋·杜耒

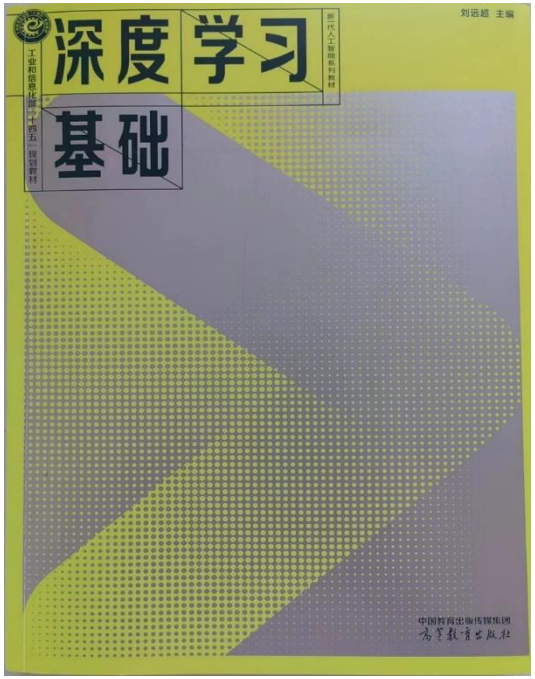
哈尔滨工业大学计算学部

刘远超



生成式神经网络

本章在《深度学习基础》教材中的位置





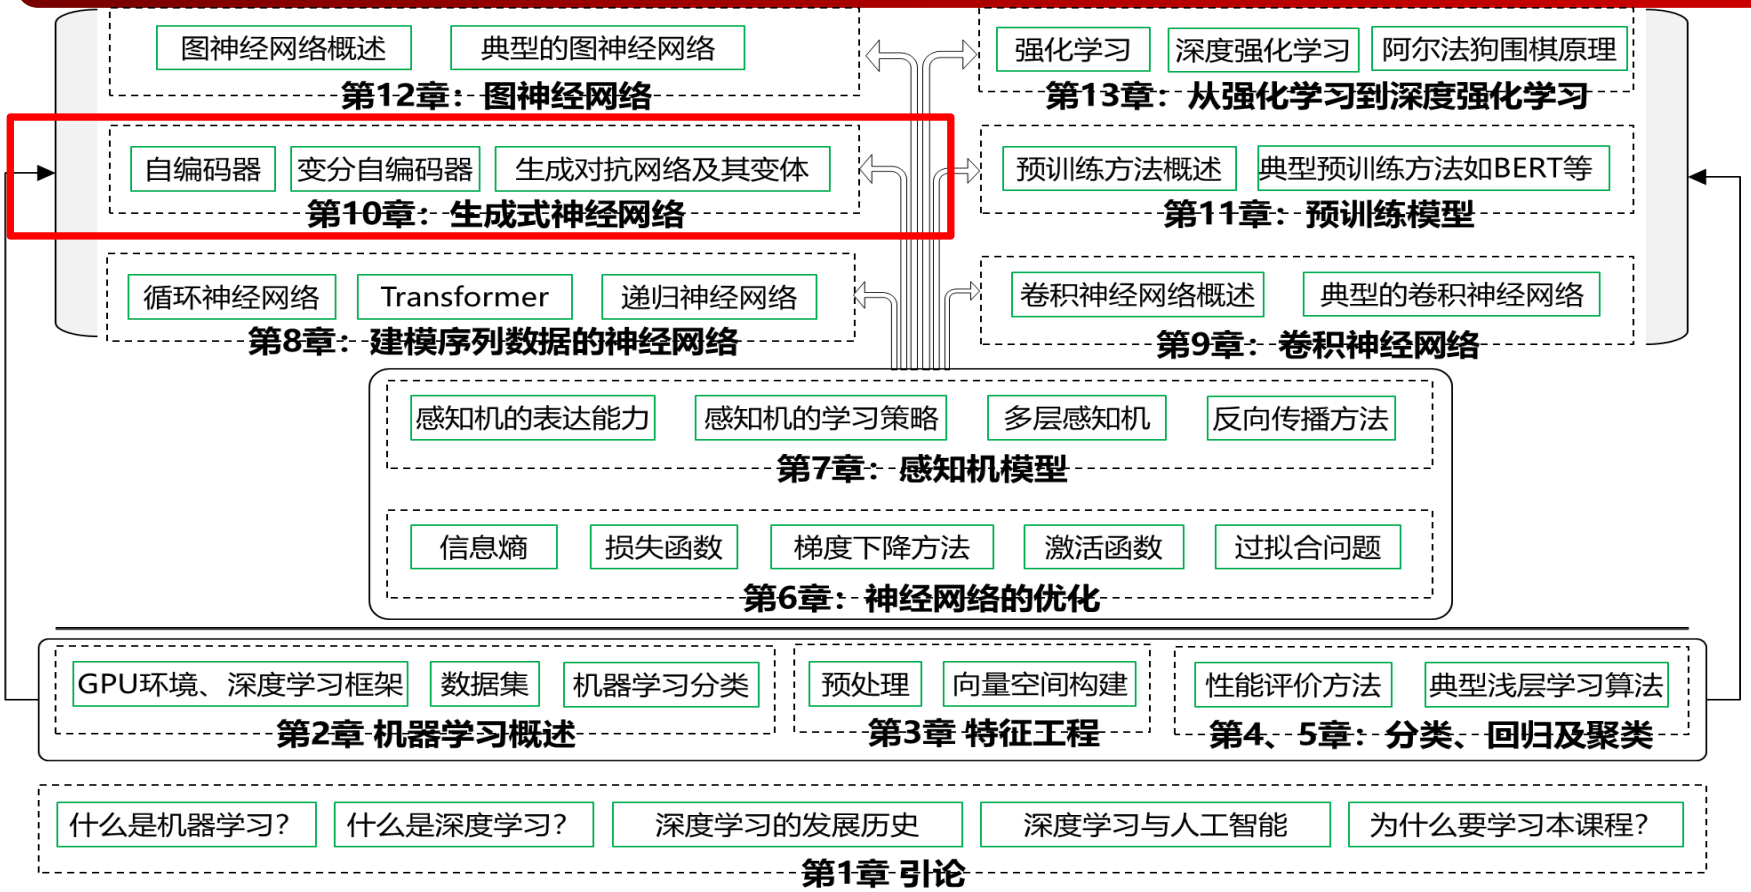


主编：<u>刘远超</u>；出版社：<u>高等教育出版社</u>；出版时间：<u>2023年09月20日</u>。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

生成式神经网络

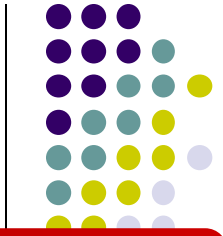
本章内容在《深度学习基础》教材知识体系中的位置



主编：刘远超 出版社:高等教育出版社；出版时间:2023年09月。

该教材先后入选：1）工信部十四五规划教材；2）国家新一代人工智能战略咨询委员会推出的新一代人工智能系列教材；3）智能基座精品教材

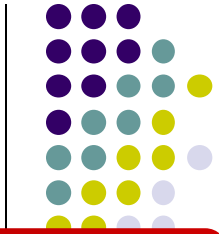
生成式神经网络



本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN

生成式神经网络

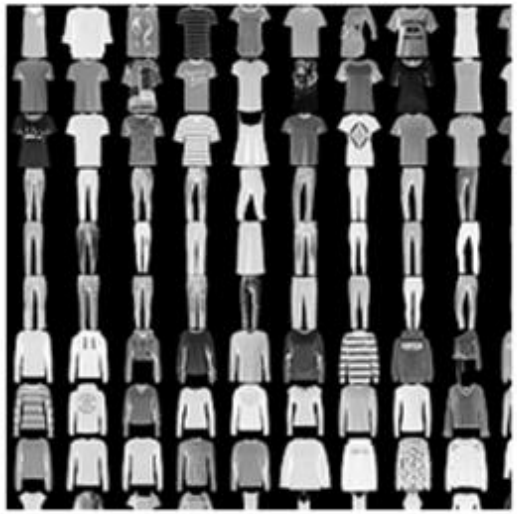


本章内容简介

- **生成式神经网络概述**
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN

生成式神经网络概述

不是学习输入样本与标签之间的映射关系，而是学习特征分布



(a) 训练集中的样本~$\boldsymbol{p_{data}(x)}$



(b) 生成的样本~$p_{model}(x)$

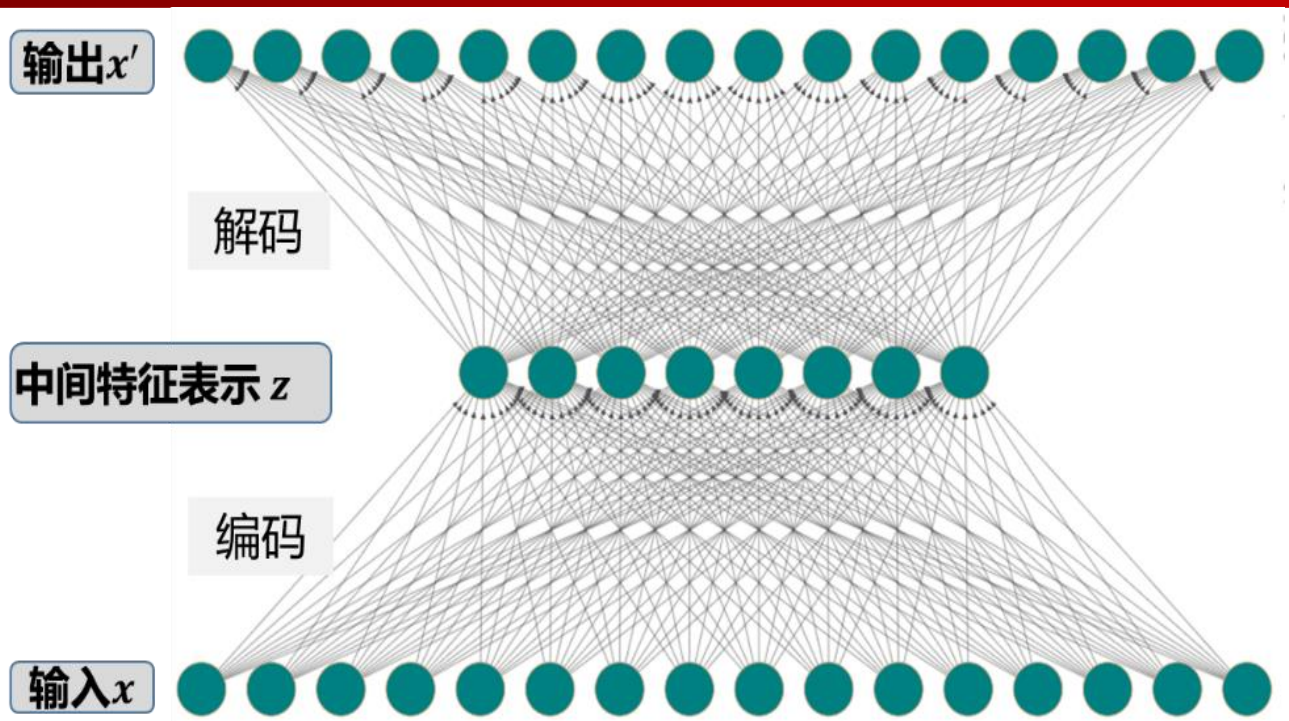
生成式神经网络可以分为两个主要步骤：

- **训练：** 假设x表示样本，模型从训练集中学习得到的样本数据分布为$p_{model}(x)$，以尽可能接近训练数据中的真实分布$p_{data}(x)$；
- **生成：** 从$p_{model}(x)$中通过采样生成新的样本。

- 生成式神经网络模型的训练阶段：学习样本中的数据分布
- 常见的生成式神经网络模型包括两大类，即变分自编码器（VAE）和生成式对抗网络（GAN）。

自编码器(Auto encoder)

什么是自编码器?



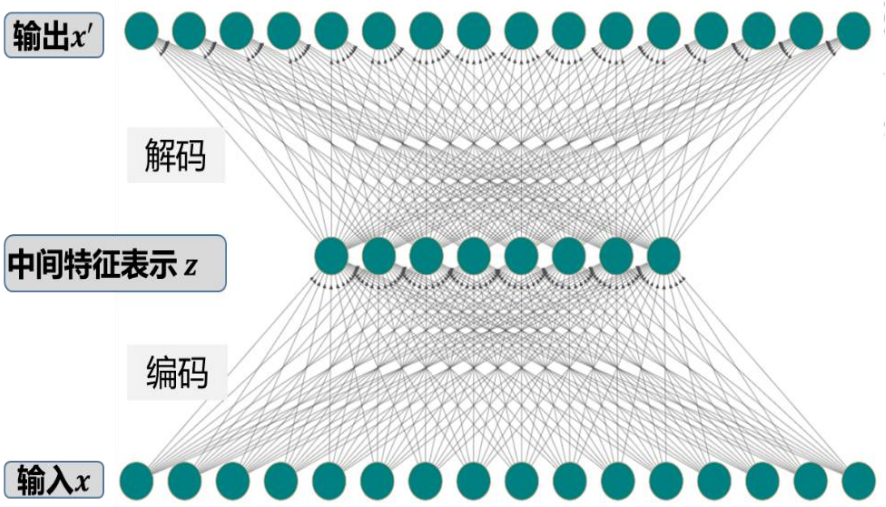
自编码器通常分为两个步骤:

1) **编码器**(coder) ϕ: $x \to z$。即将输入样本x转换为压缩的隐含特征表示z。

2) **解码器**(decoder) ψ: $z \to x'$。即将隐含的特征表示z重构为样本x'，x'的维度和x的维度相同，以使x'尽量与原始输入样本x相同。

自编码器(Auto encoder)

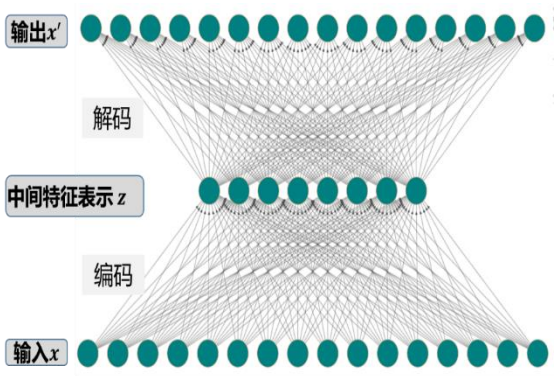
自编码器有哪些用途?



- **首先，自编码器有助于去除数据噪声**。
- 其次，**自编码器提取的特征可以在其它有监督学习中进一步使用**。可以在未标注样本数据上利用自编码器学习到新特征，并送入到其它有监督学习模型中做进一步学习调整。
- 另外，**自编码器可以达到对数据的降维效果**。中间隐藏向量表示z的维度通常小于输入样本x的维度，因此可以起到降维的效果并便于可视化。

自编码器的编码解码过程及目标函数

自编码器的编码解码过程



下面以只有一个隐藏层的自编码器为例介绍一下自编码器的计算过程。

（一）编码阶段：编码器接受输入x，并将其映射为z。例如如果采用单层感知机，则其计算公式为：

$$z = \sigma(Wx + b)$$

其中，z为隐藏向量，σ为激活函数如sigmoid或Relu函数，W为权重矩阵，b为偏置向量。

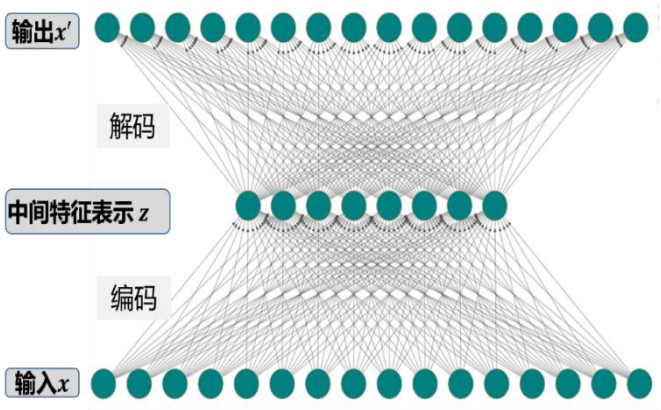
（二）解码阶段：解码器将z映射为与x形状相同的重构x'。例如如果解码器也采用单层感知机，则其计算公式为

$$x' = \sigma'(W'z + b')$$

参数σ'、W'、b'一般和编码器中的σ、W、b的取值不同。

自编码器的编码解码过程及目标函数

自编码器的目标函数



- 自编码器训练的**目标主要是减少重构误差**，因此一般而言，参数取值的优化目标是使在训练样本集合X中所有样本的误差平方和最小：

$$\boldsymbol{\phi, \psi} = \underset{\boldsymbol{\phi,\psi}}{\boldsymbol{arg\,min}} \, \boldsymbol{||X - (\psi \circ \phi)X||^2}$$

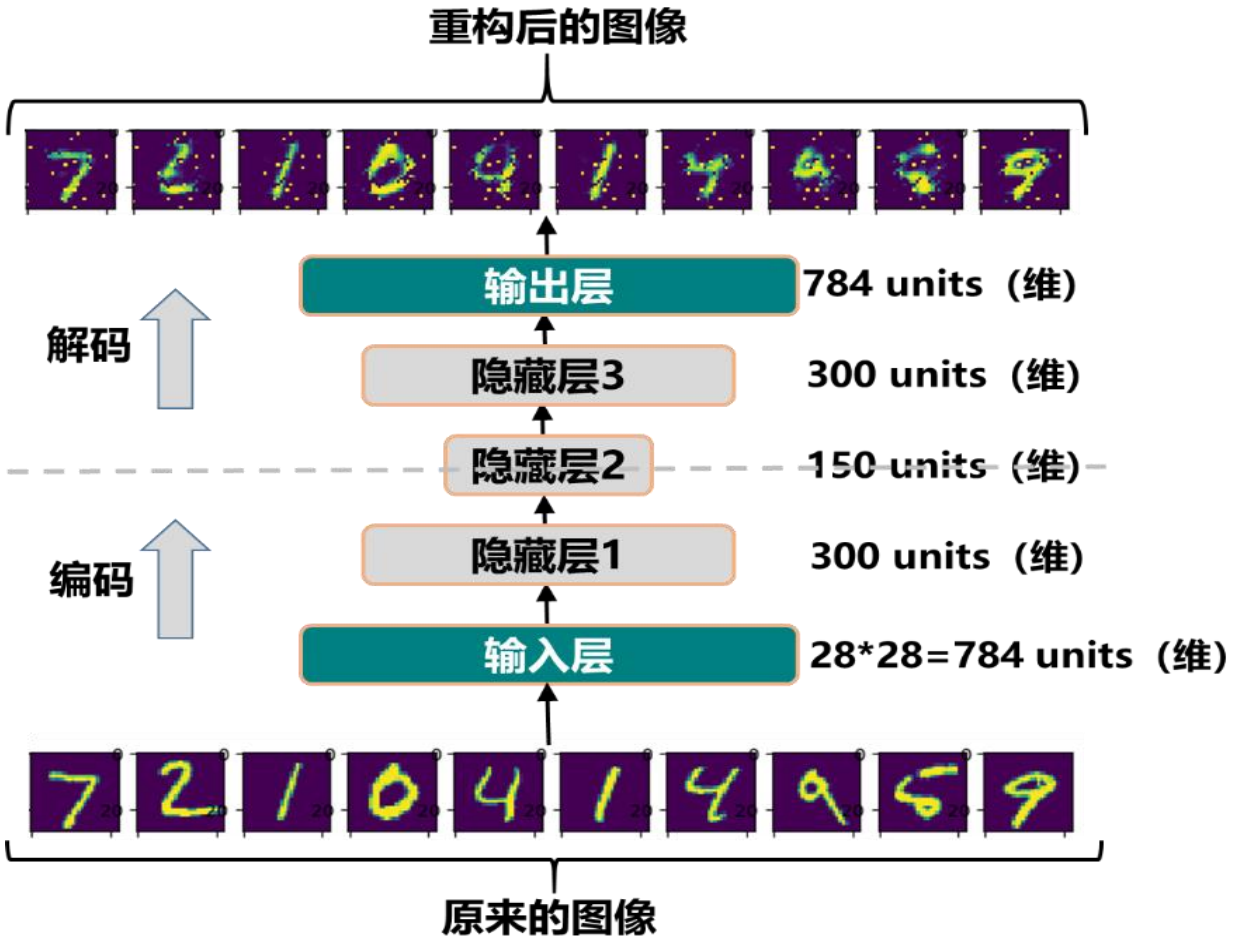
- 例如，对于刚才介绍的采用单层感知机作为编码器和解码器的例子，其损失函数可以具体表示为：

$$\boldsymbol{\mathcal{L}(X, X') = ||X - X'||^2}$$

$$\boldsymbol{= ||X - \sigma'\left(W'(\sigma(WX + b)) + b'\right)||^2}$$

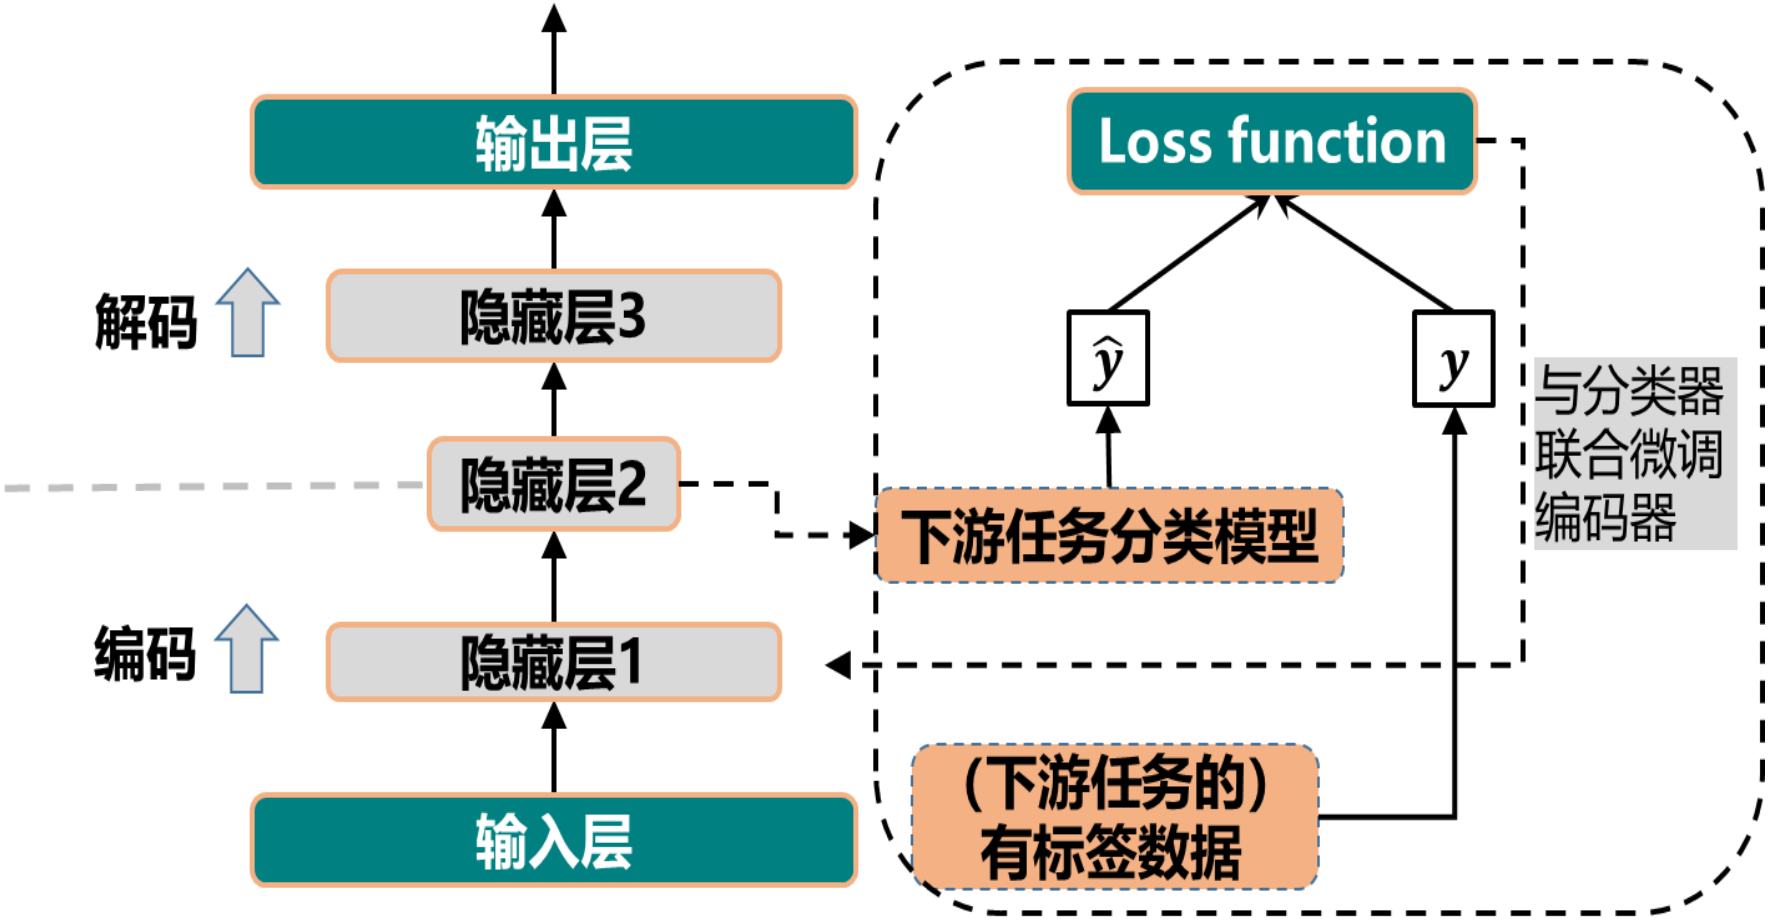
堆栈自编码器

本质上是增加了更多中间特征层的编码器



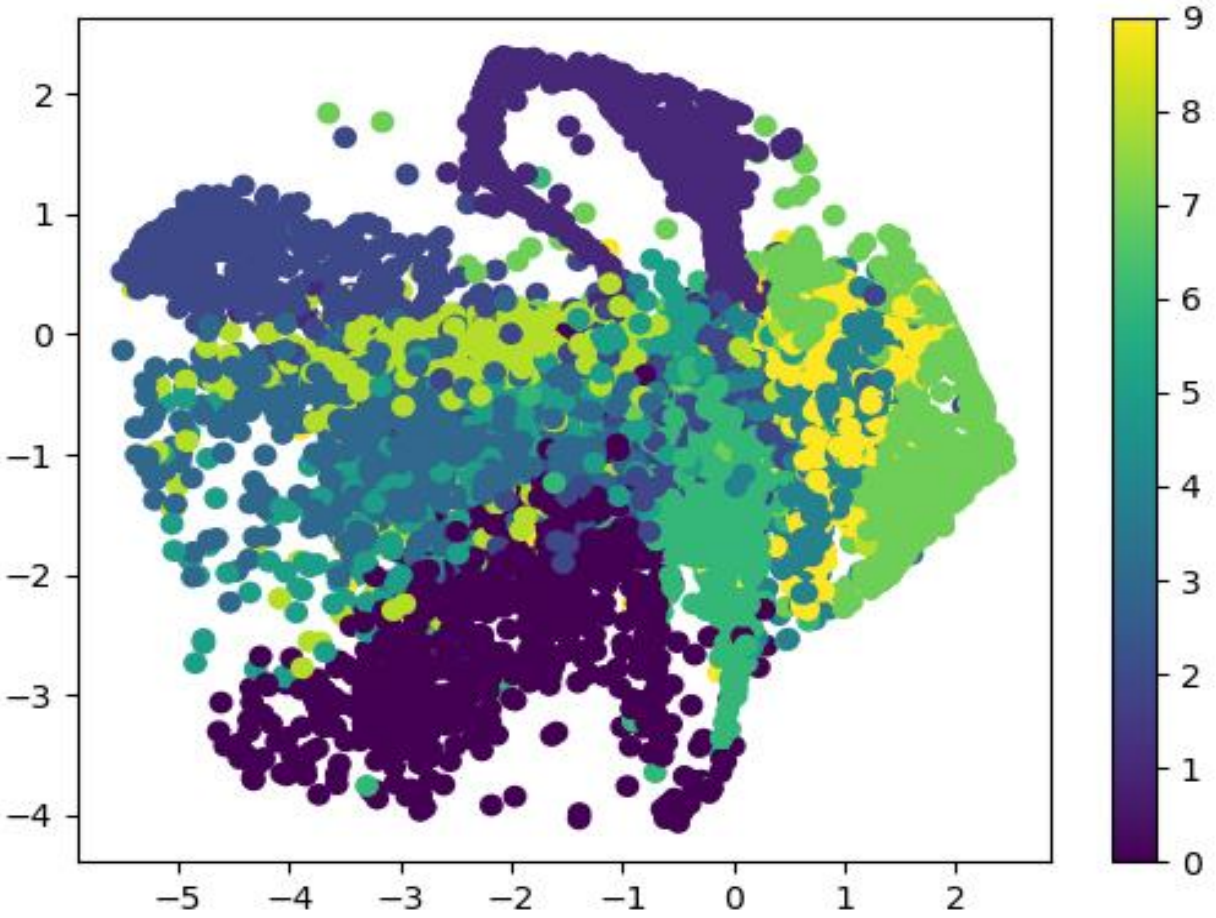
用自编码器得到新特征

自编码器提取的特征可以在有监督学习中进一步使用



基于自编码器的图像聚类可视化

压缩到二维时会怎么样?



MNIST数据的二维平面聚类

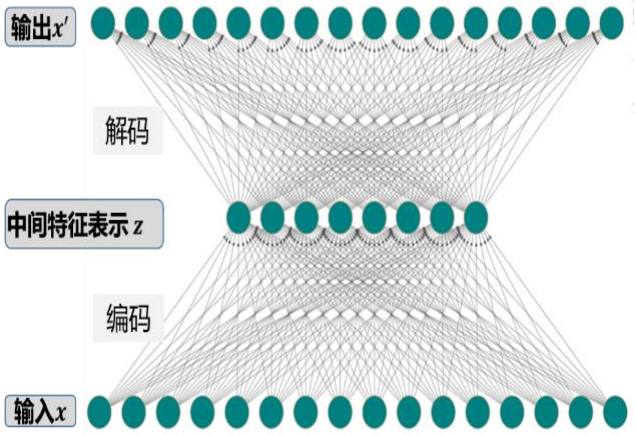
生成式神经网络

本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- **变分自编码器**
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN

变分自编码器

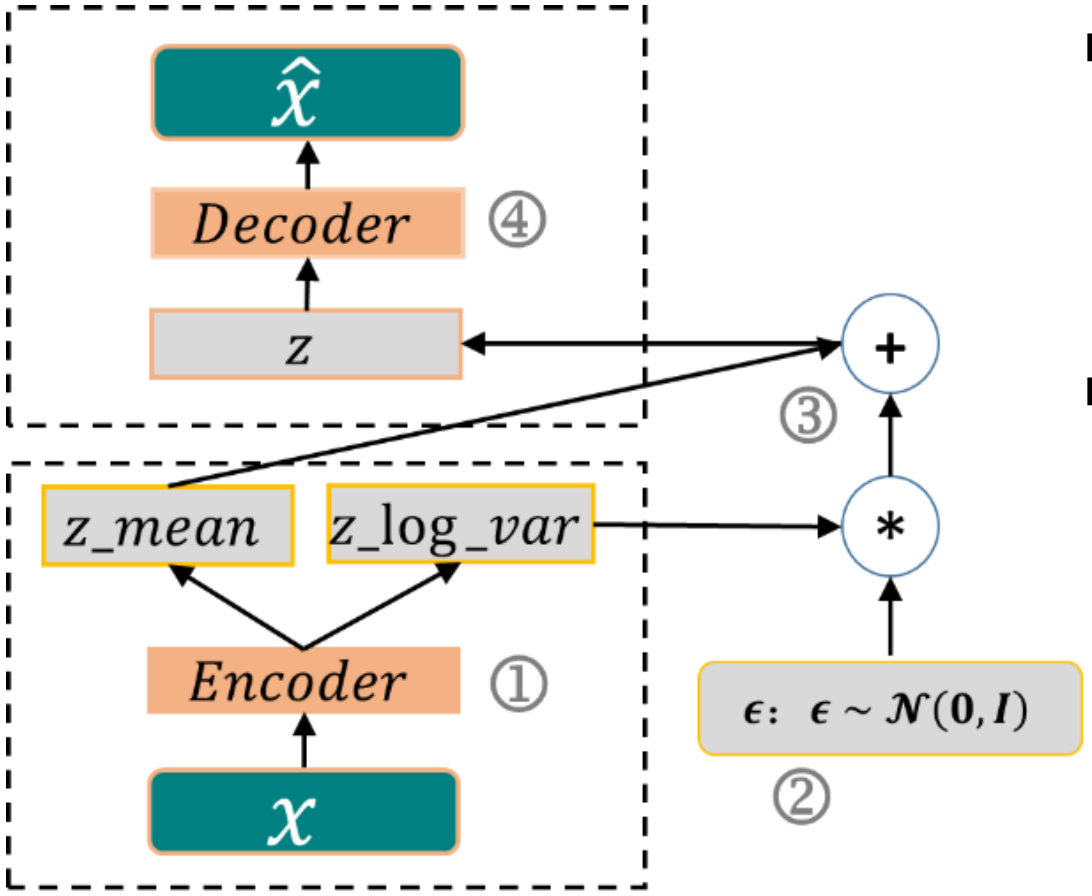
什么是变分自编码器?



- 注意自编码器中，解码器利用潜在变量z（其实质是一个低维度的向量）就可以得到一幅图像。
- 如果这个z不是通过原始图像编码得到，而是设法学习到输入图像集中的分布规律并从中随机采样获得，是否仍然可以生成某个比较合理的图像呢?
- 可以打个比方，比如画家可以设计出在真实世界中不存在的动画片人物形象且得到观众认同，是因为画家见过大量的真实形象并在脑海中有各种特征的分布。这实际就是变分自编码器最初的设想。

变分自编码器

变分自编码器的原理示意图



- 在变分自编码器中，采用的是一种重采样的技巧，即利用标准正态分布来完成采样过程：$z = \mu + \varepsilon \times \sigma$，从而得到解码器的输入向量z。
- 该公式在反向传播时可以对均值、方差求偏导。这里的ε是从正态分布$\mathcal{N}(0,1)$中采样得到的随机数向量。

主观题 10分

设置

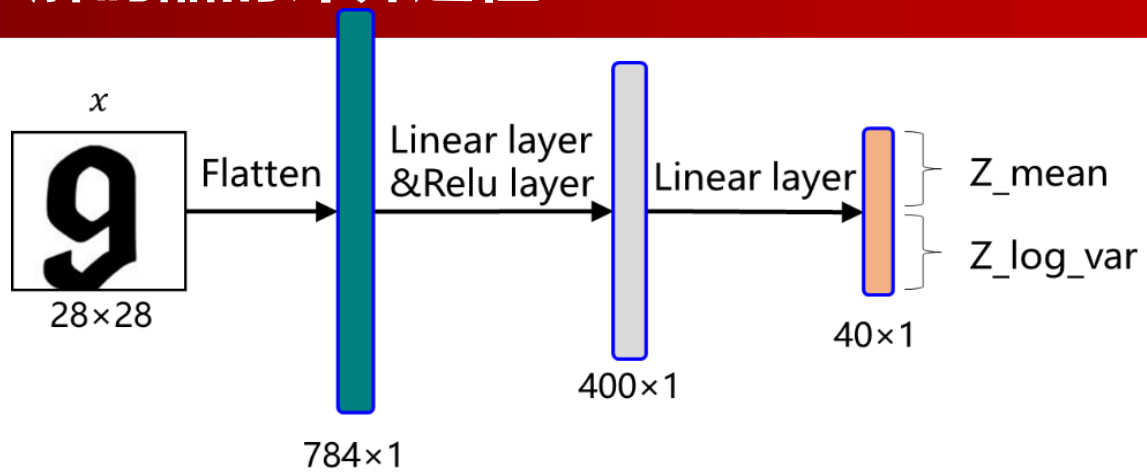
17

请复述一下变分自编码器的基本原理，（以图像生成为例）其为什么可以生成看似真实的图像？其随机性如何保证？

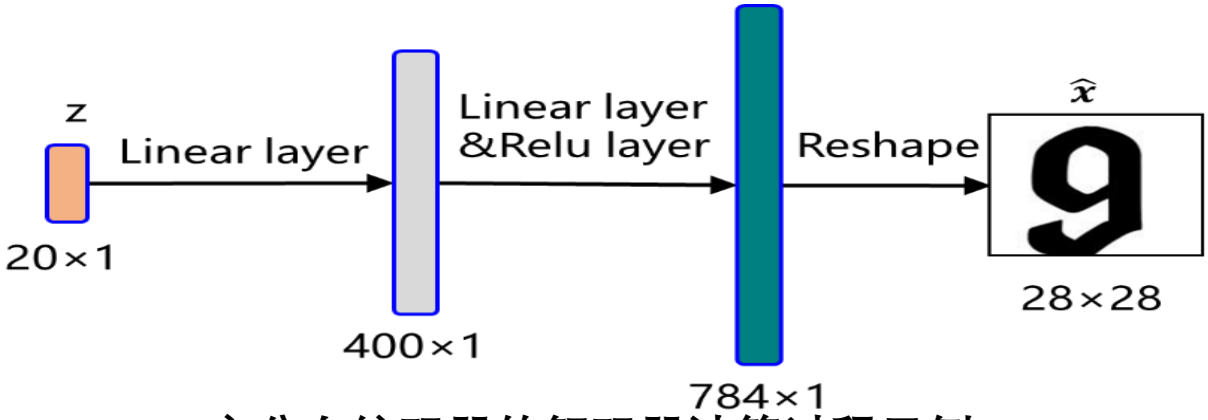
作答

变分自编码器

编码器和解码器的计算过程



变分自编码器将输入的MNIST图像利用编码器得到z的分布的示例

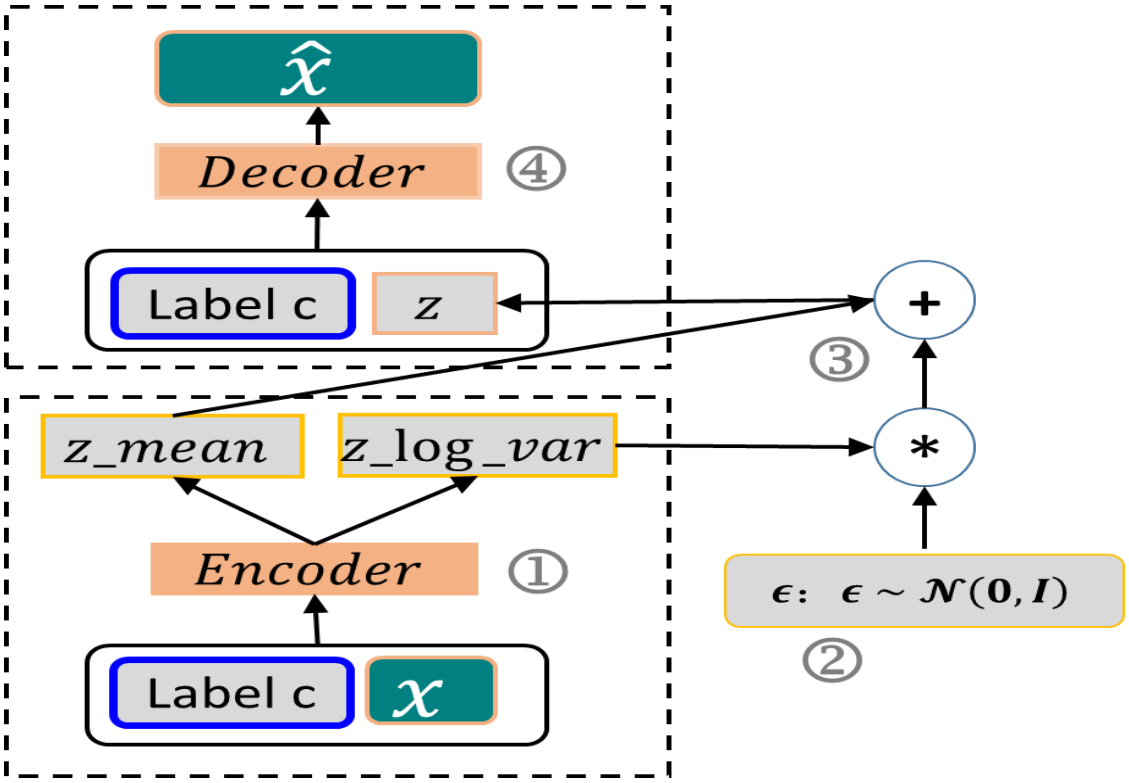


变分自编码器的解码器计算过程示例

条件变分自编码器

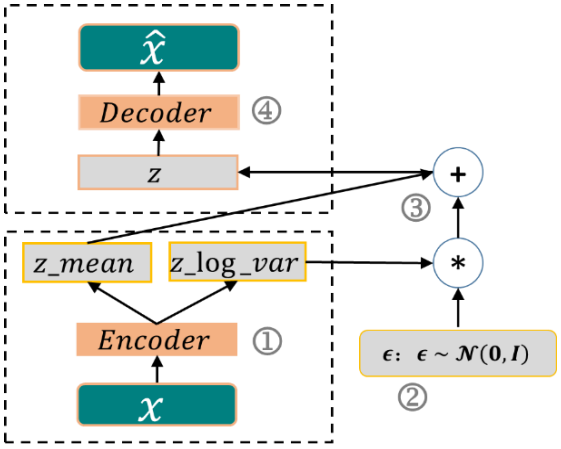
在生成时可以通过指定其标签来生成指定类别的样本

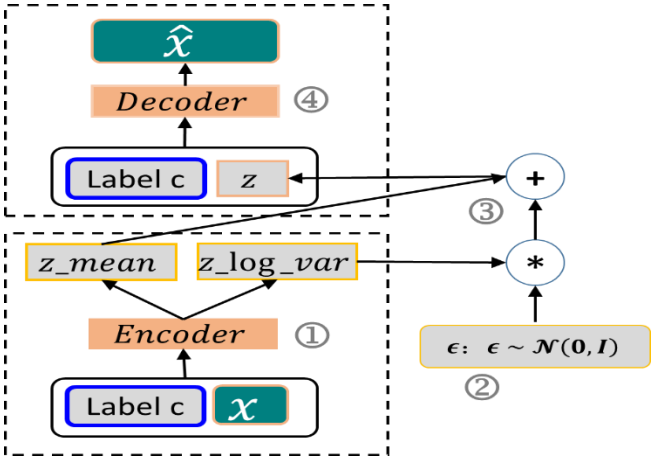
- 条件变分自编码器是指在生成时可以通过指定其标签来生成指定类别的样本，例如指定生成数字9（Label c=“9”）的手写体图像。



使用变分自编码器/条件变分自编码器生成新样本

生成数据只需要解码器



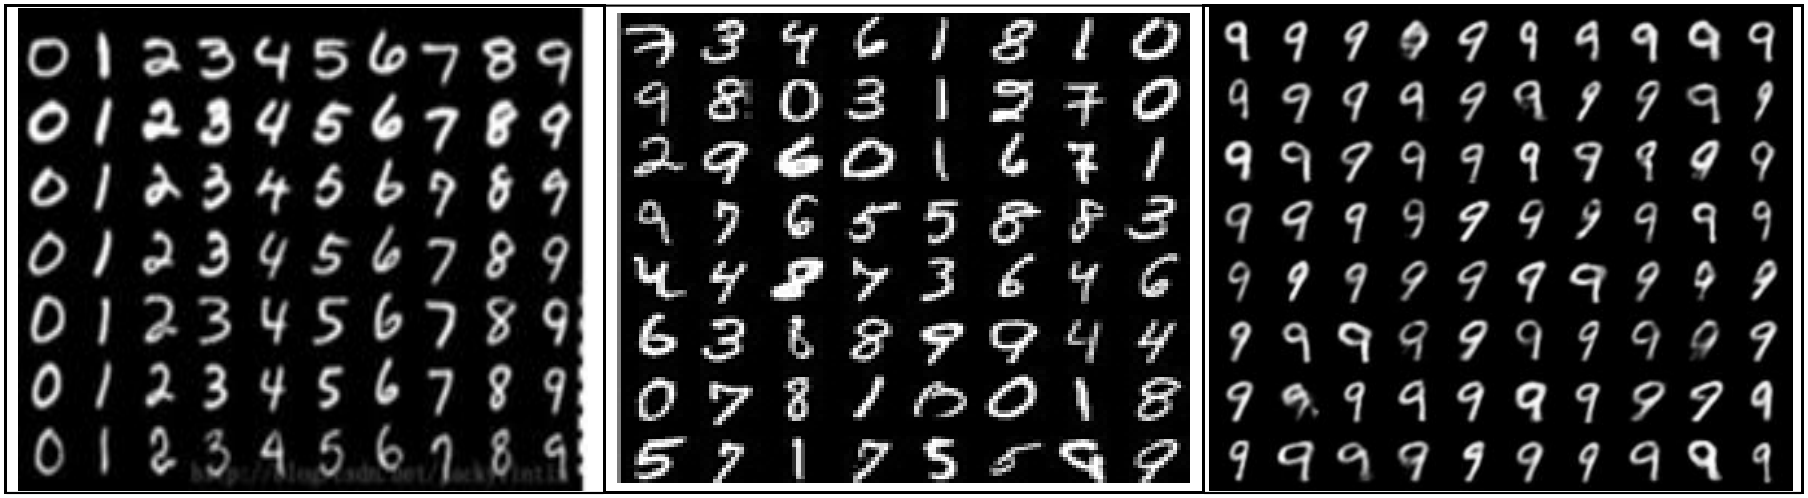


- **变分自编码器中样本的生成**。训练完毕变分自编码器得到神经网络中参数的优化取值θ^*, ϕ^*以后，生成数据只需要解码器就可以了。生成阶段解码器的输入z可以从设定好的先验标准正态分布$\mathcal{N}(\vec{0}, \vec{1})$ 中采样，利用解码器网络得到生成的图像$\hat{x}$ 。

- **条件变分自编码器中样本的生成**。训练完毕条件变分自编码器之后，在生成数据阶段，与变分自编码器类似，也是先从正态分布采样，此时需要再拼接上希望得到的数字图像类别标签的嵌入，然后送入解码器，以生成该标签所对应的图像。

变分自编码器生成的图像举例

MNIST数据集



- 左侧是来自MNIST数据集的原始手写体数字图像；
- 中间是变分自编码器生成的若干手写体数字图像；
- 右侧是使用条件变分自编码器生成的某个类别（9）的若干手写体数字图像。

多选题 1分

设置

22

下列关于自动编码器auto encoder的描述正确的有

A 自动编码器常用于做生成模型

B 自动编码器不需要任何训练数据，完全是自动编码

C 自动编码器可以用于数据的降维处理

D 自动编码器学习到的新特征可以送入有监督学习模型中，所以自动编码器可以起到特征提取器的作用

提交

多选题 1分

设置

23

下列关于自动编码器auto encoder的描述正确的有

A 自动编码器不需要解码器

B 自动编码器既有编码器，也有解码器

C 如果使用自动编码器提取特征，并与有监督学习模型使用，则在其训练过程中不需要解码器

D 自动编码器的编码器和解码器可以使用感知机模型

提交

多选题 1分

设置

24

下列关于变分自动编码器的说法中正确的有

A 变分自编码器（Variational Autoencoders，VAE）通常假设潜在变量 z 服从某种先验分布（如高斯分布）

B 模型训练完毕后，可以从这种先验分布中采样得到潜在变量 z。并在解码器中通过 z 得到 新的样本x'

C VAE在自编码器基础上加入了随机因子，这样就可以从该模型中采样得到新的数据

D 以上都不对

提交

多选题 1分

设置

25

下列关于使用变分自动编码器进行新的样本生成，描述正确的有

A 变分自编码器在生成数据阶段只需要解码器

B 变分自编码器在生成数据阶段只需要编码器

C 变分自编码器在生成数据阶段需用用到采样技术

D 变分自编码器既然是无监督模型，因此不需要进行训练

提交

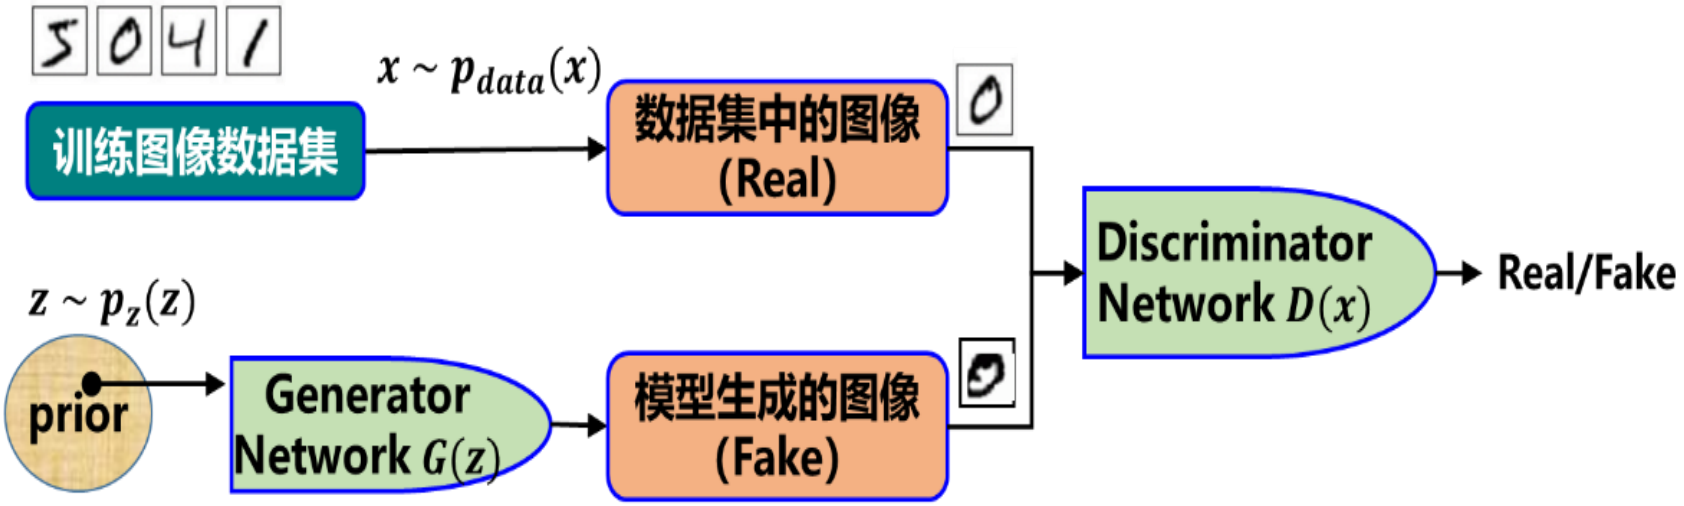
生成式神经网络

本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- **生成对抗网络**
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN

生成对抗网络

生成对抗网络（Generative Adversarial Networks）的基本原理



GAN有两个重要构成部件，即生成网络（Generator Network）和判别网络（Discriminator Network）。

- 生成网络（生成器）可以采用多层感知机、卷积网络、变分自编码器等来生成样本。其通常从均匀分布或高斯分布中获取随机噪声，进而生成样本，例如图像或者文本等。
- 判别网络（判别器）的训练集中包括来自原始数据集中的图像（真实图像，标签设为1）以及来自生成器生成的图像（作为虚假图像，标签设为0），从而构成一个训练集，用于其学习甄别。判别网络也可以采用任何具有分类或者回归能力的神经网络，如多层感知机、卷积神经网络等。

生成对抗网络的目标函数

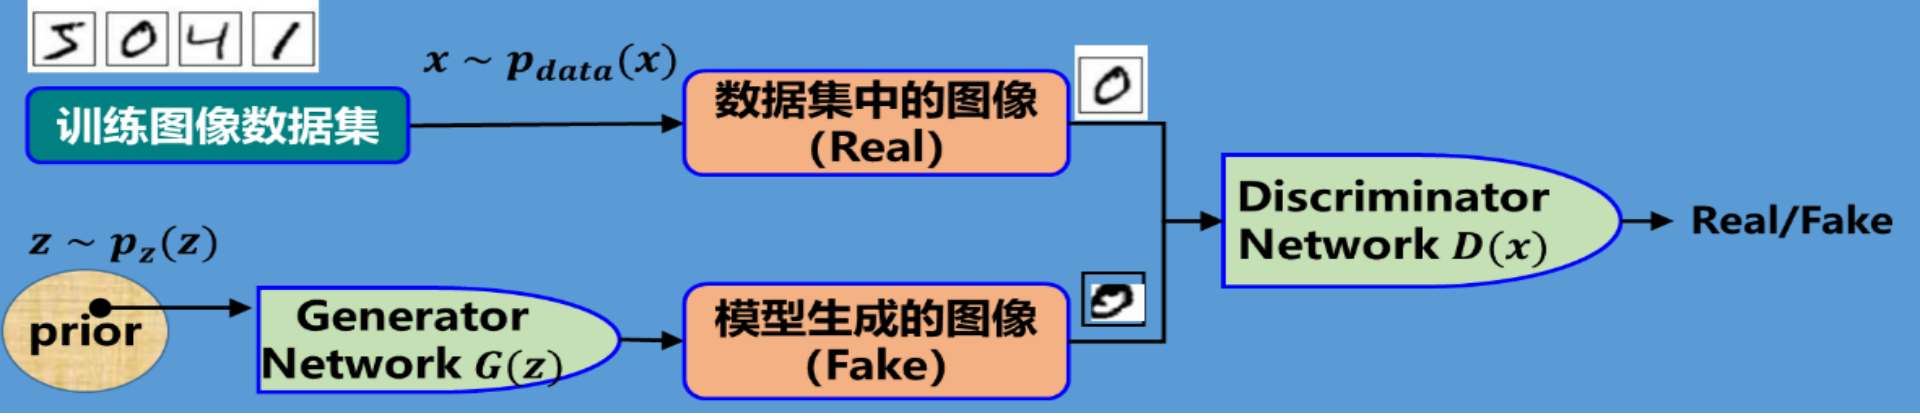
生成对抗网络的目标函数的总体表达式

生成对抗网络的目标函数的总体表达式如下：

$$\min_G \max_D V(D,G) = E_{x\sim p_{data}(x)}[logD(x)] + E_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

表达式实际上包括两个含义：

- 当优化判别器D时，需要使得等号右侧的表达式取值最大化；
- 而当优化生成器G时，需要使得等号右侧的表达式取值最小化。



(一) 判别器D的优化

- **当对判别器D进行优化时，为了得到一个很好的判别模型，需要使得$V(D,G)$的取值最大化，即**

$$\max_D V(D,G) = E_{x\sim p_{data}(x)}[logD(x)] + E_{z\sim p_z(z)}[log(1-D(G(z)))]$$

  - 等号右边第一项的下标$x\sim p_{data}(x)$表示输入的图像样本x来自真实数据集，**$D(x)$表示判别器判断样本x为真的概率**。
  - 等号右边第二项的下标$z\sim p_z(z)$表示z是从某个随机概率分布$p_z(z)$中的采样值，用于生成样本$G(z)$。

生成对抗网络的目标函数

(二) 生成器G的优化

生成对抗网络的目标函数的总体表达式：

$$\min_G \max_D V(D,G) = E_{x\sim p_{data}(x)}[logD(x)] + E_{z\sim p_z(z)}[\log(1-D(G(z)))]$$

- 相比于判别模型，生成模型的目标函数不太容易定义，因为人们对于生成结果的期望，难以从数学上准确描述。所以在生成对抗网络中，**将生成模型的目标函数和评价送给判别模型处理。**
- 由于只需要评价生成的样本，不需要真实样本，所以只需要优化公式损失函数的第二部分，即生成器G的优化目标是

$$\min_G V(D,G) = E_{z\sim p_z(z)}[log(1-D(G(z)))]$$

这里等号右边各项的含义与之前类似。

生成对抗网络的训练算法

生成器和判别器在交替学习的过程中分别提升性能

Input: 训练迭代次数 T; 判别次数 K; 小批量数据的样本数目 m

Output: output result

for $t \leftarrow 1$ **to** T **do**

  //固定生成器 G 的参数，更新判别器 D 的参数；

  for $k \leftarrow 1$ **to** K **do**

    从噪声先验 $p_g(z)$ 中采样由 m 个样本构造的小批量数据 $\{z^{(1)}, ..., z^{(m)}\}$;

    从 $p_{data}(x)$ 中采样由 m 个样本构造的小批量数据 $\{x^{(1)}, ..., x^{(m)}\}$;

    使用随机梯度上升来更新判别器的参数：

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} [logD(x^{(i)}) + log(1 - D(G(z^{(i)})))] \qquad \text{//公式 (10.17)}$$

  end

  //固定判别器 D 的参数；更新生成器 G 的参数；从噪声先验 $p_g(z)$ 中采样由 m 个样本构造的小批量数据 $\{z^{(1)}, ..., z^{(m)}\}$;

  使用随机梯度下降来更新生成器的参数：

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^{m} [log(1 - D(G(z^{(i)})))] \qquad \text{//公式 (10.18)}$$

end

主观题 10分

设置

32

简述一下生成对抗网络的基本原理，以及其为什么可以共享同一个目标函数?

作答

生成对抗网络生成的部分数字手写体结果

MNIST数据集







生成式神经网络

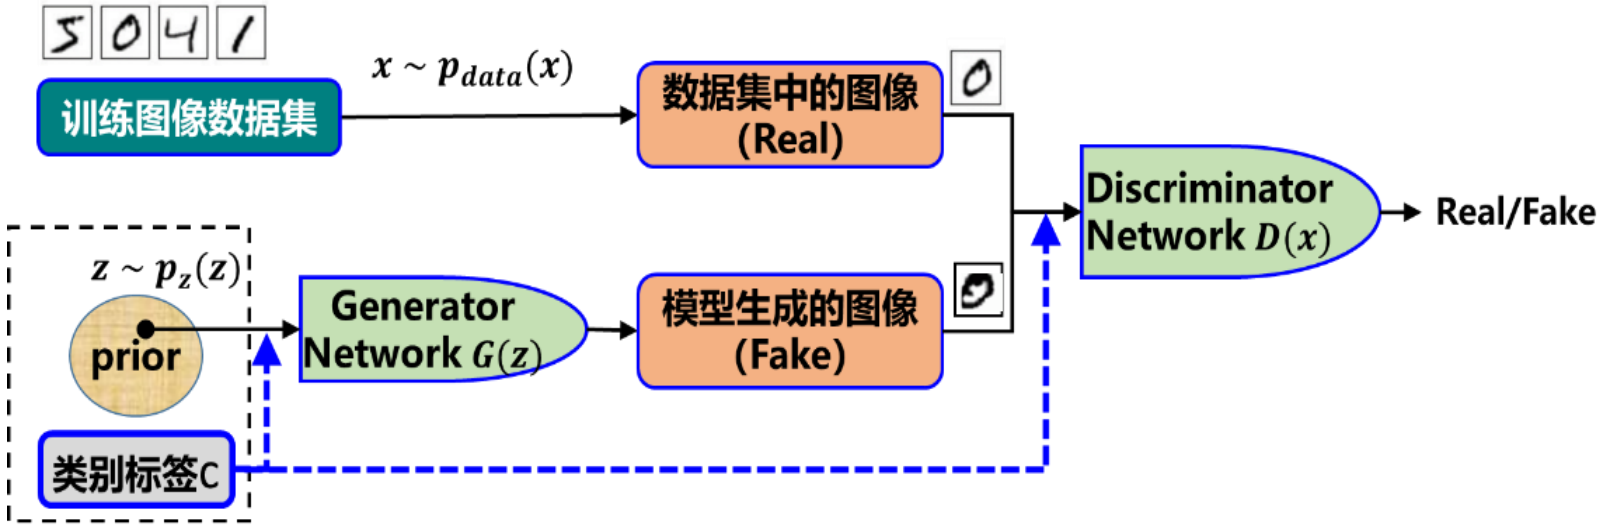
本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- **条件生成对抗网络**
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN

条件生成对抗网络

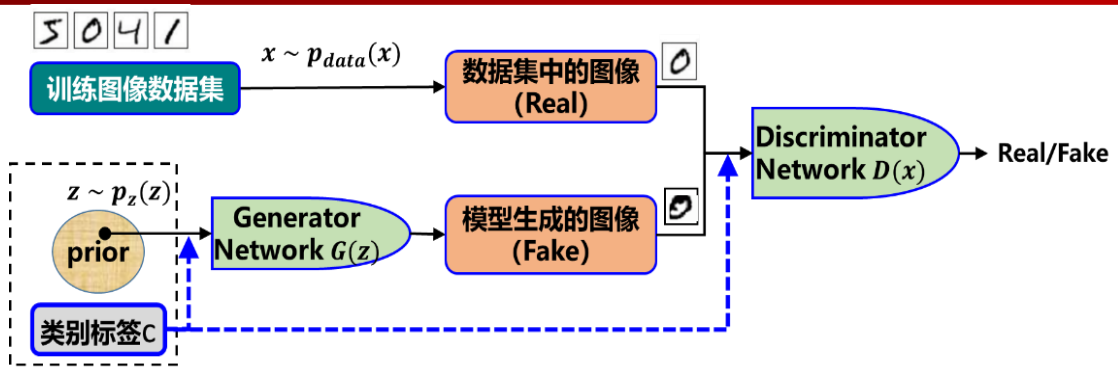
在生成模型G和判别模型D中都加入条件约束c

- 条件生成对抗网络是在生成模型G和判别模型D中都加入条件约束c来指导样本的生成。加入的约束条件可以是任何补充的信息，如类别标签等。从而使得模型在生成新样本的同时还可以控制生成样本的类型。



条件生成对抗网络

加入的控制类别c以嵌入向量的形式与z或者x拼接在一起



- 由于为生成器G、判别器D都额外加入了一个约束条件c（希望生成的标签），因此，其条件生成对抗网络的目标函数的总体表达式如下：

$$\min_G \max_D V(D,G) = E_{x\sim p_{data}(x)}[logD(x|c)] + E_{z\sim p_z(z)}[\log(1-D(G(z|c)))]$$

- 以MNIST数据集为例，在CGAN中，生成器G和判别器D的输入输出是：
  - 生成器G的输入为噪声z和某个数字标签c（为0~9中的任意一个数字），输出为与c相对应的图像$G(z|c)$。
  - 判别器D的输入为一幅图像x（可能是生成的或者是真实的），以及一个数字标签c，输出该图像在该设定标签条件下的真实概率$D(x|c)$。
- CGAN训练完成后，**向G输入某个数字标签和噪声**，可生成与该标签相对应的图像。

哈尔滨工业大学计算学部周志超

生成式神经网络

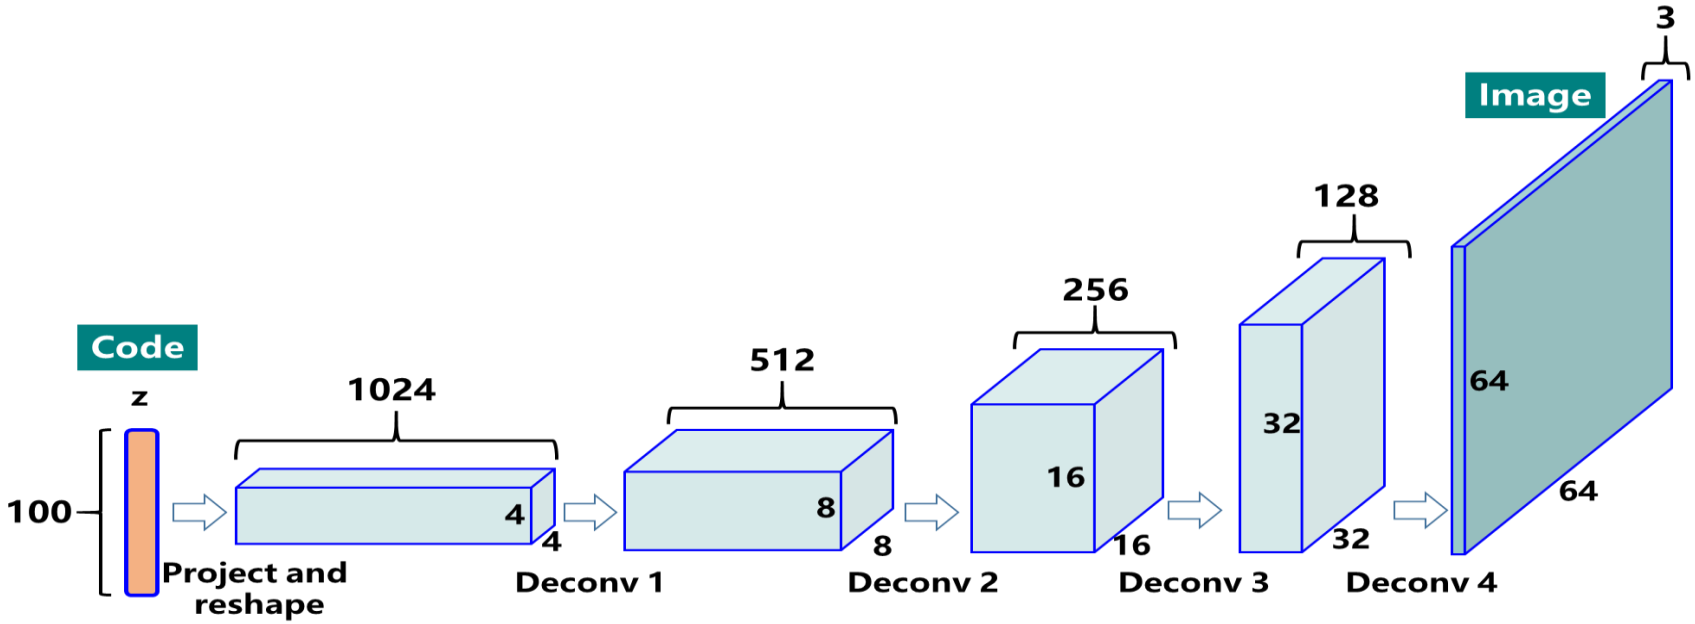
本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- **深度卷积生成对抗网络DCGAN**
- pix2pix
- CycleGAN

深度卷积生成对抗网络DCGAN

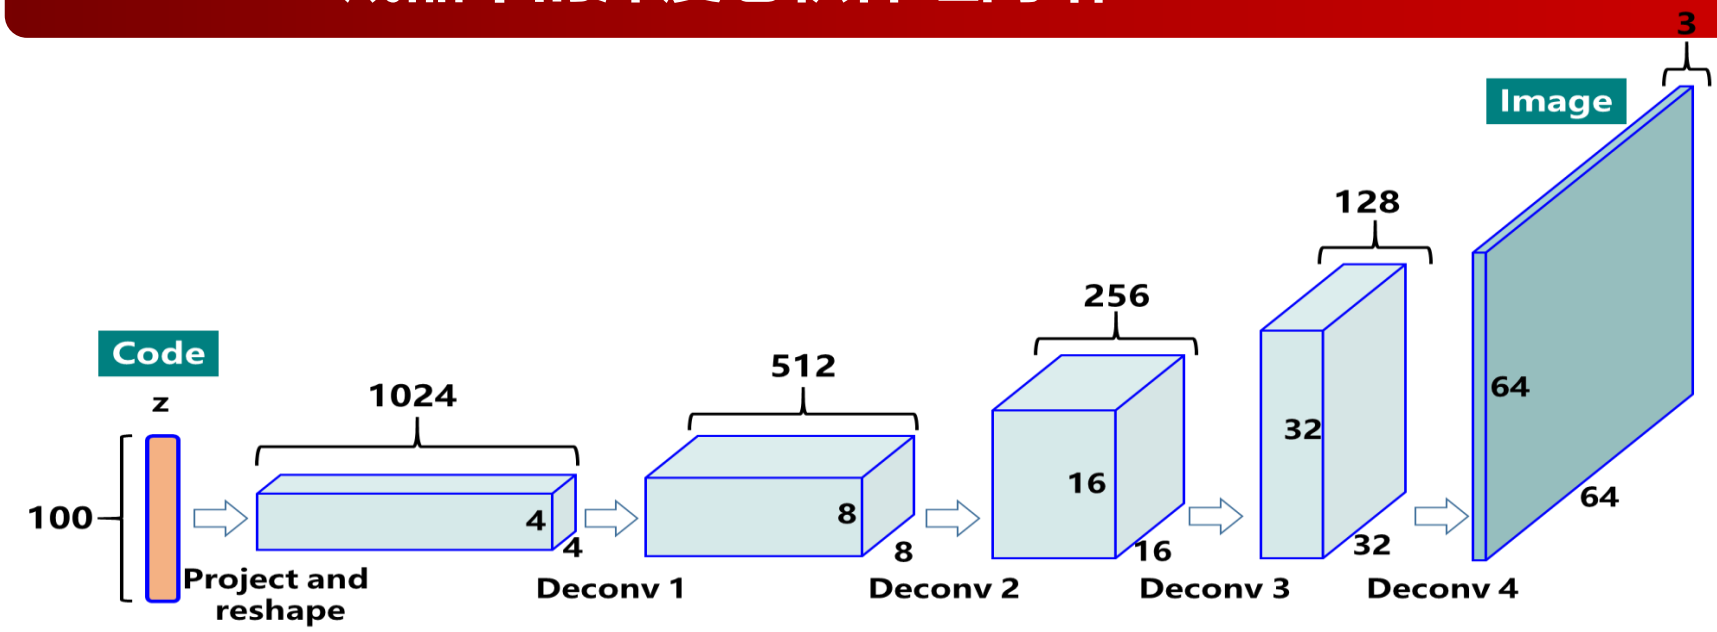
DCGAN生成器中的深度卷积神经网络

- 深度卷积生成对抗网络（Deep Convolutional GAN，简称DCGAN）是原始GAN（Vanilla GAN）的改进版。DCGAN 的训练方法与原始GAN 类似。
- 主要区别是相比于原始 GAN中使用的多层感知机，DCGAN 的判别器和生成器都使用了卷积神经网络，以提升图像处理能力。但这种改变不是简单的替换，而是对卷积神经网络的结构做了若干改变，以进一步提高生成样本的质量和收敛速度。



深度卷积生成对抗网络DCGAN

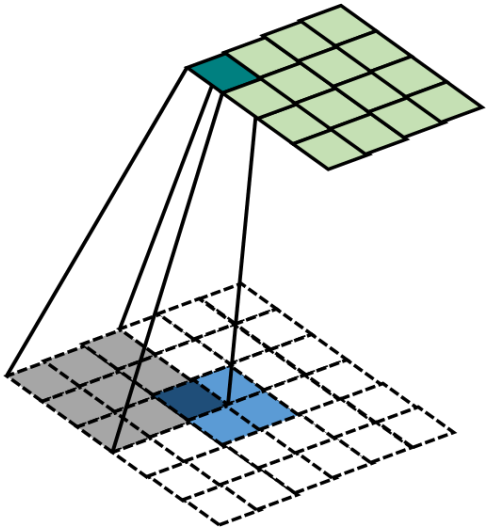
DCGAN生成器中的深度卷积神经网络



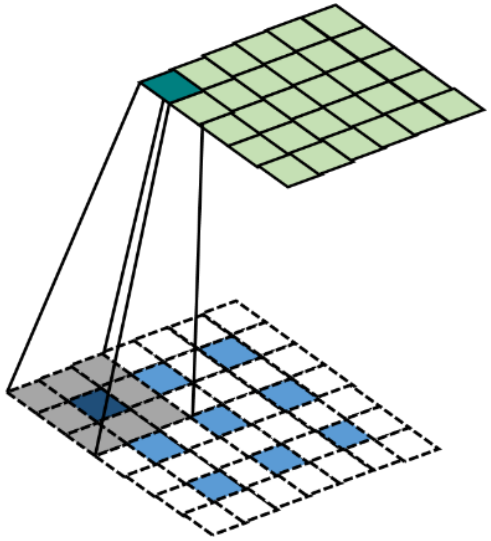
- DCGAN生成器的输入是一个随机采样得到的100维的噪声向量z，中间经过4层微步幅度卷积层（fractionally strided convolution）的处理，且每通过一个层通道数减半，长宽扩大一倍，最终输出一个64*64*3大小的图像。

深度卷积生成对抗网络DCGAN

微步幅度卷积与反卷积的区别



（a）反卷积

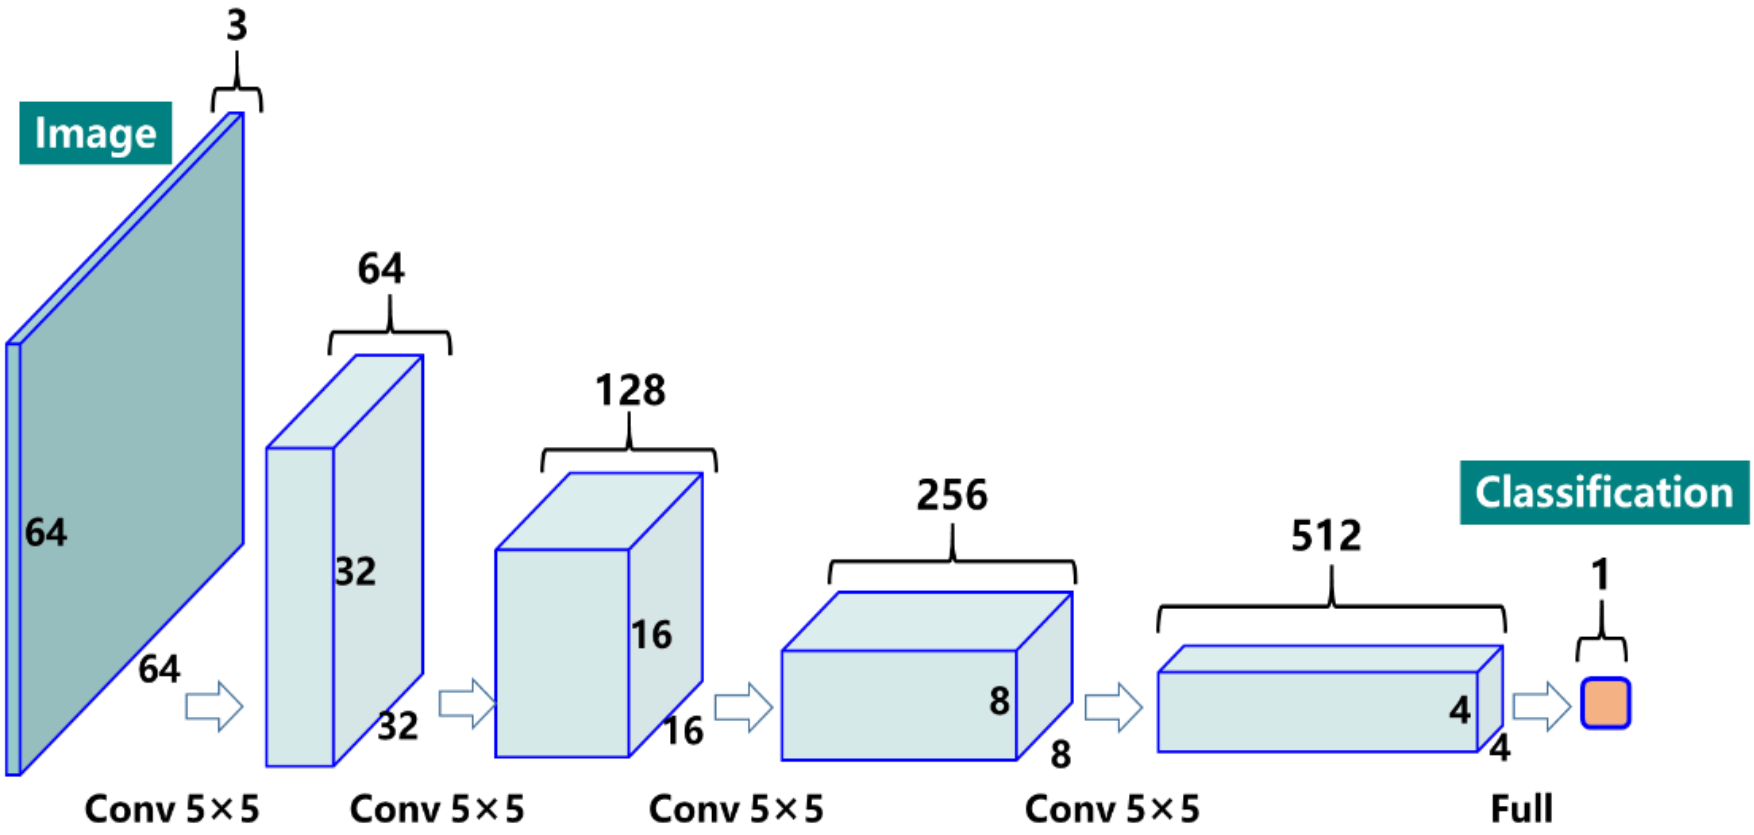


（b）微步幅度卷积

- 微步幅度卷积处理与标准的反卷积（Deconvolution）处理类似，都是将图像特征图变大，但区别在于padding 的方式不同。

深度卷积生成对抗网络DCGAN

DCGAN的判别器结构与标准的卷积神经网络类似



生成式神经网络

本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- **pix2pix**
- CycleGAN

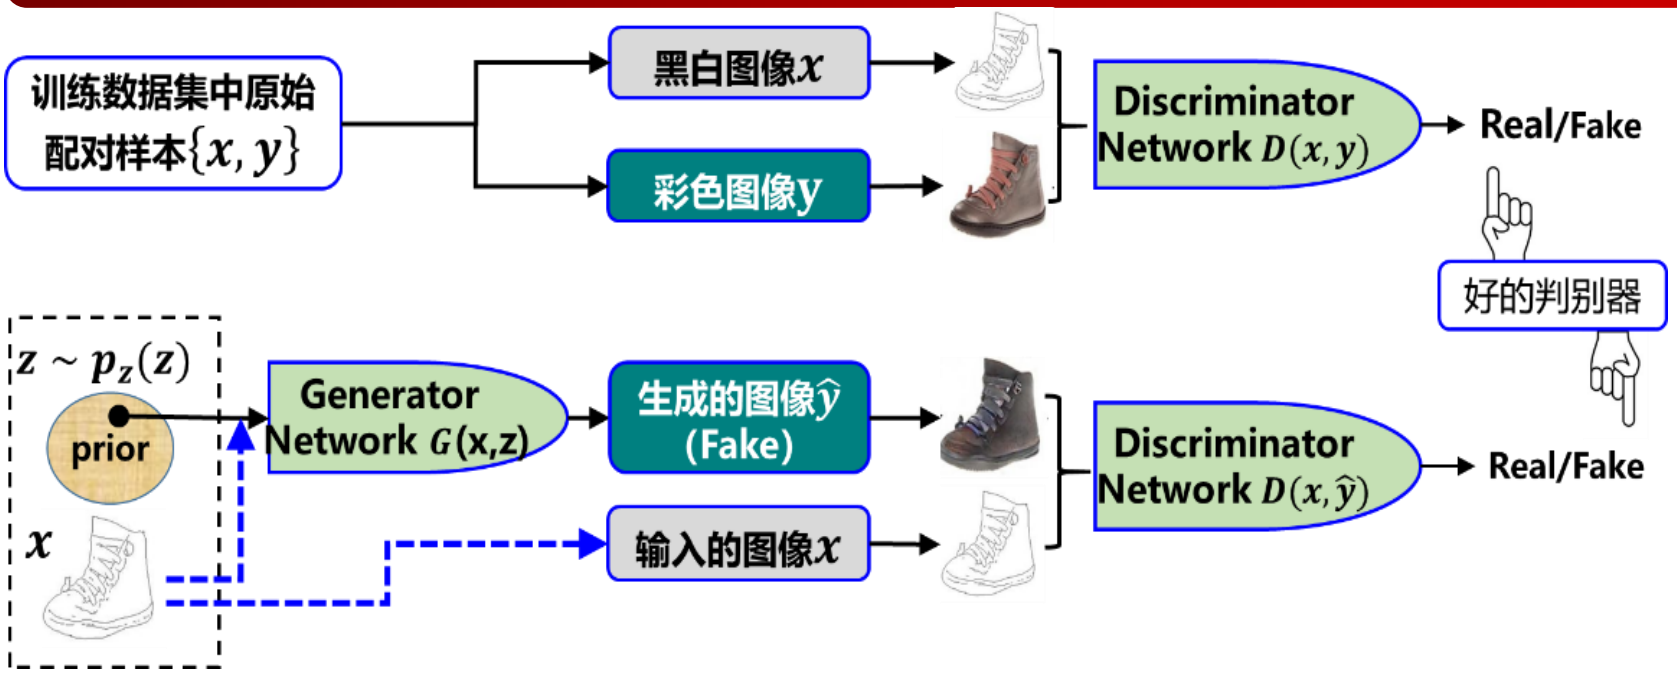
pix2pix

pix2pix是基于生成对抗网络的图像到图像的有监督转换模型

- 之前介绍的模型主要是利用输入的随机采样噪声来生成图像的过程。但除此之外，**输入还可以包括图像、文本等**，即可以进行图像到图像的转换、文本到图像的转换等。
- 此外，图像修复、图像超分辨率处理等应用也可以利用生成对抗网络来实现。
- pix2pix就是一种基于生成对抗网络的图像到图像的有监督转换模型

pix2pix

pix2pix的图像转换过程



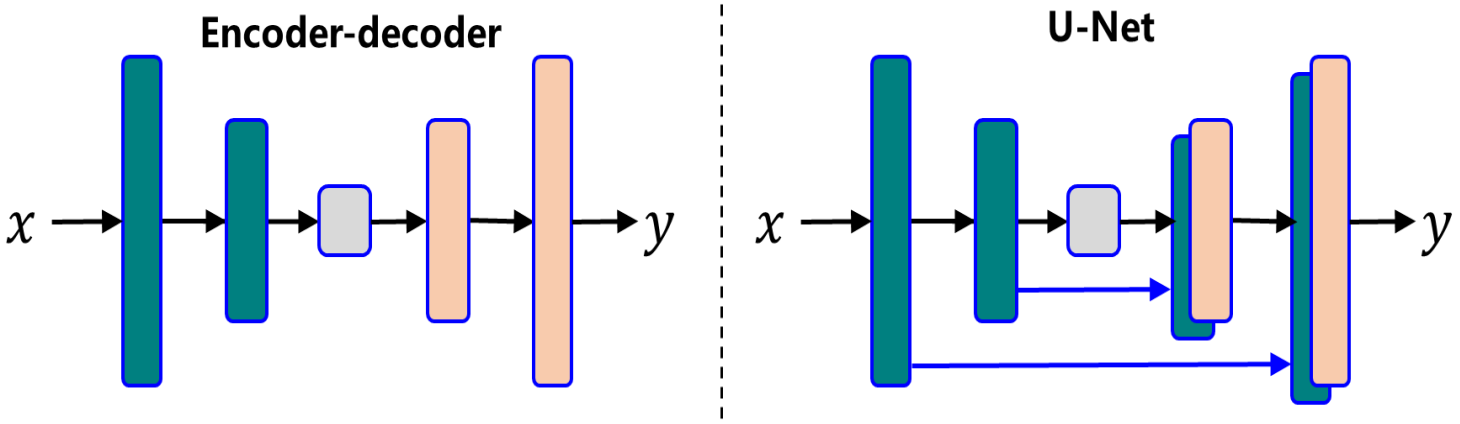
pix2pix的图像转换过程示意图（以黑白图像上色为例）

- pix2pix的判别器D与之前学习的其它GAN的判别器不同的是，其是对两个图像之间关系的判断，因此需要成对图像的输入。

pix2pix

(一) pix2pix的生成器G

- pix2pix的生成器本质上是一种条件生成对抗网络。pix2pix认为对于图像上色这种应用，其输入和输出关联性较强，因此应该将输入特征进行共享，所以在生成器中使用了U-Net结构而不是之前GAN中模型中常见的编码器-解码器生成器结构。



pix2pix

（二）pix2pix的判别器D

- 对于判别器部分，pix2pix的特点是使用了PatchGAN的方法，即其判别器不是对图像整体进行真伪判断，而是将图像分为若干个像素块（patch），并对每个像素块分别输出预测概率，因而其更关注提升生成图像的细节。
- 具体地，PatchGAN判别器采用全卷积的形式：图像经过多个卷积层处理后，最后不是接全连接层或激活函数，而是再次使用卷积将结果映射为一个N*N的矩阵，其中每个数值为对输入图像的某个像素块的真伪概率。

pix2pix

（三）pix2pix的优化目标

- pix2pix的整体优化目标为：

$$G^* = \arg\min_G \max_D \mathcal{L}_{cGAN}(G, D) + \lambda \mathcal{L}_{L1}(G)$$

即pix2pix的优化目标需要考虑两个因素：

- **一是**与传统cGAN优化目标类似的优化函数（等号右边第一项）
- **二是**采用L1距离来约束生成图像$G(x, z)$和真实图像y之间的差异（等号右边第二项），即在优化目标函数中加入重构损失来应对低频成分：

$$\mathcal{L}_{L1}(G) = \mathbb{E}_{x,y,z}[||y - G(x, z)||_1]$$

- 总体上，pix2pix利用生成对抗网络为图像转换问题提供了一种通用框架。**但其缺点是训练过程需要大量的成对图片**，例如图10.18中的线条上色工作需要大量的线条图和与之对应的上色图作为训练集。

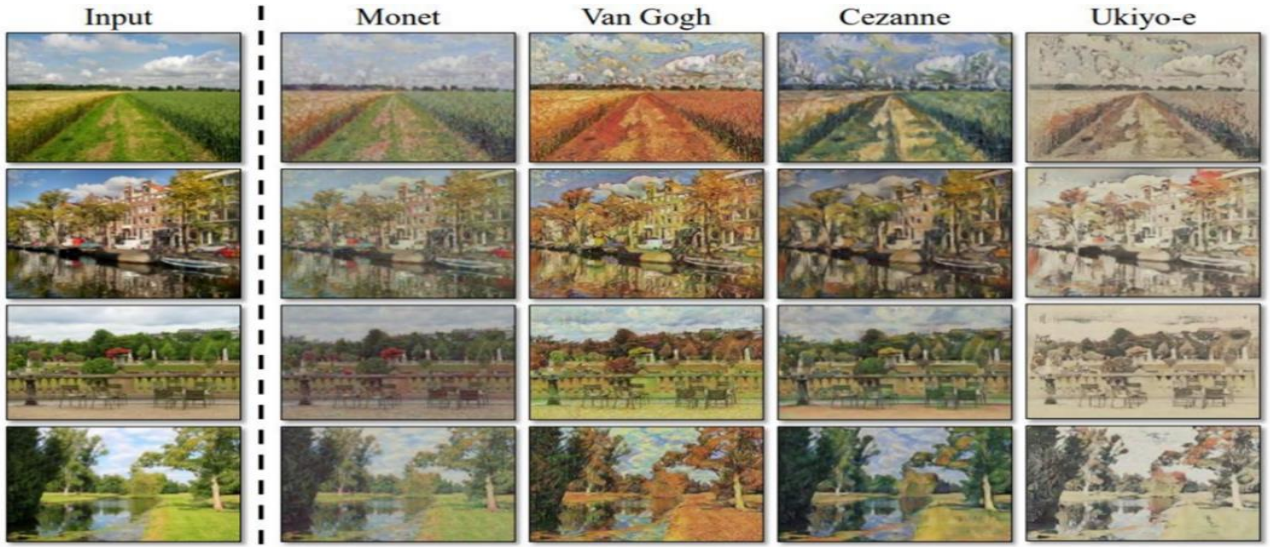
生成式神经网络

本章内容简介

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- **CycleGAN**

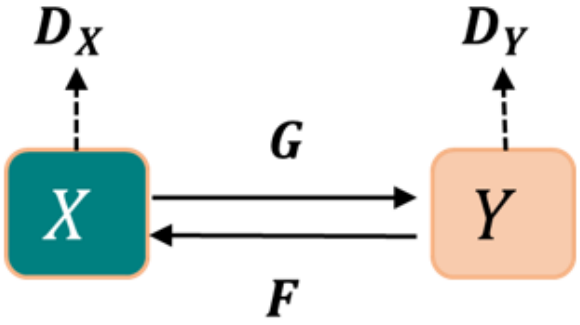
CycleGAN

CycleGAN实现图像风格迁移



- 与pix2pix类似，CycleGAN也是一种基于生成对抗网络的图像转换模型。
- 不同点：
  - CycleGAN主要应用点在于对输入图像进行**风格迁移处理**，例如一种常见标志性应用是将输入的图像赋予莫奈、梵高等名家的绘画风格。
  - **CycleGAN不需要建立一对一的源域-目标域成对映射样本作为训练数据**（而pix2pix需要使用在两个域中成对（paired）的图像进行训练）。

CycleGAN中的双“生成器+判别器”机制



整体原理图

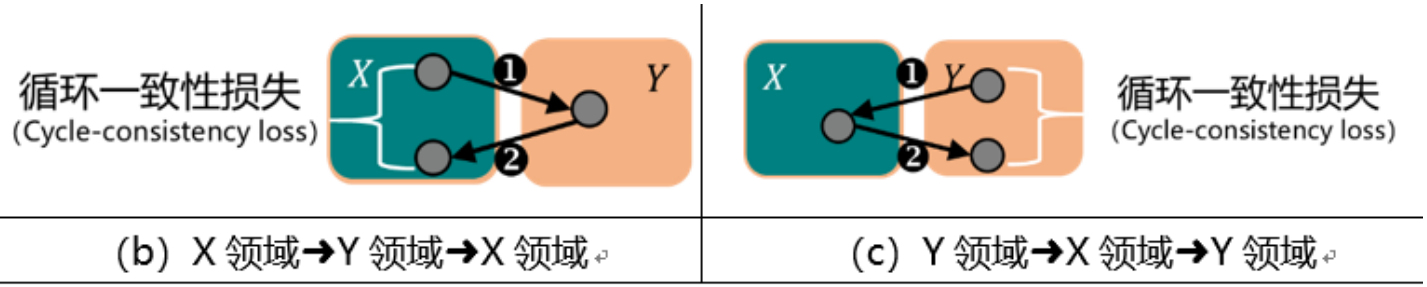
具体可以分解为



- 因此，以上构成了两对“生成器+判别器”，各自的损失函数如下：
  - $\mathcal{L}_{GAN}(G, D_Y, X, Y) = \mathbb{E}_{y \sim p_{data}(y)}[logD_Y(y)] + \mathbb{E}_{x \sim p_{data}(x)}[\log(1 - D_Y(G(x))]$
  - $\mathcal{L}_{GAN}(F, D_X, Y, X) = \mathbb{E}_{x \sim p_{data}(x)}[logD_X(x)] + \mathbb{E}_{y \sim p_{data}(y)}[\log(1 - D_X(F(y))]$

CycleGAN

CycleGAN还考虑了循环一致性损失



- 除了以上两对生成对抗损失外，CycleGAN中还考虑了循环一致性损失（Cycle Consistency Loss）：

$$\mathcal{L}_{cyc}(G,F)=\mathbb{E}_{x\sim p_{data}(x)}[||F(G(x))-x||_1]+\mathbb{E}_{y\sim p_{data}(y)}[||G(F(y))-y||_1]$$

综上，CycleGAN的整体损失函数为上述三个公式的和，即

$$\mathcal{L}(G,F,D_X,D_Y)=\mathcal{L}_{GAN}(G,D_Y,X,Y)+\mathcal{L}_{GAN}(F,D_X,Y,X)+\lambda\mathcal{L}_{cyc}(G,F)$$

其中，λ为权重因子，是超参数。

生成式神经网络

本章小结

- 生成式神经网络概述
- 自编码器(Auto encoder)
- 变分自编码器
- 生成对抗网络
- 条件生成对抗网络
- 深度卷积生成对抗网络DCGAN
- pix2pix
- CycleGAN